SUP'COM
Ecole Supérieure des Communications de Tunis

Rapport de stage d'ingénieur

Reconnaissance faciale par deep learning

Réalisé par :
Omri Dhouha

Encadré par :
Ajili Moez

Entreprise d'accueil :
MV Services FR Limited

MY VOICE
BIOMETRIC AUTHENTICATION

Année universitaire 2018-2019

Table des matières

Notations et Abréviations 8

Remerciements 9

Introduction générale 10

1 État de l'art 13

1.1 Introduction 14

1.2 La biométrie faciale 14

1.2.1 Définition de la biométrie 14

1.2.2 Comment choisir un trait biométrique ? 18

1.2.3 La reconnaissance faciale 19

1.2.4 L'identification faciale 19

1.2.5 La vérification faciale 19

1.2.6 Étapes de la reconnaissance faciale 20

1.3 Les réseaux de neurones 20

1.3.1 Qu'est-ce qu'un réseau de neurone ? 20

1.3.2 Concepts de base 23

1.3.3 Réseau de neurones artificiel 24

1.3.4 Le réseau de neurones convolutifs 25

1.3.5 Les Perceptrons Multicouches 28

1.3.6 Le Réseau de neurones récurrent 29

1.3.7 Long Short-Term Memory 30

1.4 Les méthodes de la reconnaissance faciale par deep learning 31

1.4.1 LBPH . . . 31
1.4.2 KNN . . . 32
1.4.3 VGGFace Network . . . 32
1.4.4 DeepFace . . . 33
1.4.5 DeepID . . . 34
1.4.6 FaceNet . . . 34
1.4.7 GaussianFace . . . 34
1.5 Conclusion . . . 35

2 Méthodologie, corpus et outils 36
2.1 Introduction . . . 37
2.2 Les corpus de données utilisés pour la reconnaissance faciale . . . 37
2.2.1 VGGFace . . . 37
2.2.2 MegaFace . . . 38
2.2.3 VGGFace2 . . . 38
2.2.4 WIDER FACE . . . 38
2.2.5 LFW . . . 39
2.3 Outils utilisés . . . 39
2.3.1 Python . . . 39
2.3.2 Apprentissage profond(deep learning) . . . 40
2.3.3 OpenCV . . . 40
2.3.4 Dlib . . . 40
2.3.5 Face recognition . . . 41
2.3.6 Imutils . . . 41
2.3.7 TensorFlow . . . 41
2.3.8 Mtcnn . . . 41
2.4 Méthodologie et solution proposée . . . 41
2.4.1 Méthodologie utilisée . . . 41
2.4.2 Solution proposée . . . 44

2.5 Conclusion 45

3 Contributions 46

3.1 Introduction 46

3.2 Évaluer un système de reconnaissance faciale existant 47

3.3 Évaluer le réseau de neurone entraîné à partir de zéro 47

3.4 Réaliser un système de reconnaissance faciale 48

3.4.1 Détection de visage 48

3.4.2 Extraction des paramètres 49

3.4.3 Résultat de l'identification et la vérification 50

3.4.4 Discussion des résultats 53

3.5 Conclusion 54

Conclusion générale 55

Table des figures

1.1 Exemple de traits biométriques pouvant être utilisés pour authentifier un individu [7] 16
1.2 Scores de compatibilité pour différentes technologies biométriques dans un système MRTD"Machine Readable Travel Documents" . 16
1.3 Biométrie faciale[4] 17
1.4 Chaîne de traitement générique pour la reconnaissance faciale . . 20
1.5 Architecture d'un réseau de neurone composé de 2 couches 21
1.6 Les différents fonctions d'activations 22
1.7 Le processus d'entraînement d'un réseau de neurones 23
1.8 Fonctionnement du réseau de neurones 25
1.9 Schéma de parcours de la fenêtre de filtrage sur une image 26
1.10 Architecture de CNN 27
1.11 représentation d'un MLP 29
1.12 Représentation compacte des RNN 30
1.13 Une cellule Long Short-Term Memory (LSTM) 31
1.14 Fonctionnement de KNN 32

2.1 Triplet loss 42
2.2 Architecture de pyramidbox 43
2.3 Architecture de pyramidbox anchor 44
2.4 Le corpus de données utilisé 45

3.1 Taux de précision pour chaque état, facile, moyenne et difficile . . 48
3.2 Détection d'un seule visage dans l'image 49
3.3 Détection de 4 visages dans l'image 49
3.4 Le contenu du fichier encodings2.pickle 50
3.5 Exemple de 128-d embeddings 50
3.6 Identification de la personne détecté 50
3.7 Identification d'un groupe de personne 51
3.8 Identification d'un seul visage dans une image 51
3.9 Identification de deux visages dans une image 51
3.10 La vérification de visage d'une même personne 52
3.11 La vérification de visage de deux personnes différents 52
3.12 Reconnaissance de visage détecté par web cam 53
3.13 Reconnaissance de visage détecté par web cam 53

Liste des tableaux

1.1 Taux de précision de chaque architecture de CNN 27

2.1 Statistiques des ensembles de données des visages publiques récents. Les trois entrées de la colonne images par sujet sont les minimum / moyenne / maximum 39

3.1 Résultat de l'évaluation 47

3.2 Taux de précision 47

3.3 Temps nécessaire pour la détection et l'identification 53

Notations et Abréviations

Abréviations	Significations
IA	Intelligence Artificielle
CNN	Convolutional Neural Network
RNN	Recurrent Neural Network
LSTM	Long Short-Terme Memory
TDNN	time delay neural network
LBPH	Local Binary Patterns Histograms
KNN	KNearest Neighbour
RNA	réseaux de neurones artificiels
RELU	unité linéaire de réactivation
st.	stride convolutive
pad	rembourrage "padding"
VGG	Visual Geometry Group
LFW	Labeled Faces in the Wild
HMM	Modèle de Markov caché
MLP	Multilayer perceptron
YTF	Youtube Face
IJB-A	L'IARPA Janus Benchmark-A
IJB-B	L'IARPA Janus Benchmark-B
OpenCV	Open Source Computer Vision Library
Mtcnn	(Multi-task Cascaded Convolutional Neural Networks
EER	le taux d'erreur

Remerciements

Je tiens tout d'abord à remercier tous les membres de la société de m'avoir accueilli dans ses locaux.

Mes remerciements s'adressent plus particulièrement à mon encadrant, Moez Ajili le vice-président de la société, c'est lui qui m'a aidé de postuler dans cette entreprise. Bien évidemment je le remercie aussi pour son encouragement, toujours il me dit "t'inquiète pas". Il a toujours fait son maximum pour être disponible, a été à l'écoute de mes remarques, mes questions et a toujours assuré le bon déroulement de mon stage. Ainsi, je le remercie également en fait il m'a aidé lors de la rédaction de ce rapport et il m'a donnée des remarques pertinentes pour bien le rédiger.

Enfin, je remercie également ma famille, mes amis et tous mes collègues de l'école supérieure des communications de Tunis (SUP'COM), qui m'ont encouragé tout au long de ce stage.

Introduction générale

Actuellement la nécessité de maintenir la sécurité de l'information ou de la propriété physique devient de plus en plus important et de plus en plus difficile. De temps en temps nous entendons parler de crimes de fraude de carte de crédit, de cambriolage informatique commis par des pirates informatiques ou d'atteintes à la sécurité dans une entreprise ou un immeuble gouvernemental. En 1998, des cyber-escrocs sophistiqués causé plus de 100 millions de dollars de pertes. Dans la plupart de ces crimes, les criminels ont profité plus précisément des systèmes de contrôle d'accès conventionnels : les systèmes ne permettent pas l'accès par "qui nous sommes", mais par "ce que nous avons", telles que cartes d'identité, clés, mots de passe, code PIN ou le nom.
Aucun de ces moyens n'est vraiment nous définir mais ils sont simplement des moyens de nous authentifier. C'est à dire que nos données personnelles peuvent être accéder à tout moment. Pour éviter ces problèmes, de nouvelles solutions technologiques sont progressivement mises en oeuvre. Parmi ces technologies, la biométrie s'est rapidement distinguée comme la plus pertinente pour identifier et authentifier les personnes de manière fiable et rapide soit en utilisant le visage, la voix, etc...

Depuis son invention dans les années 70, la reconnaissance faciale a énormément progressé. En effet, pendant longtemps la reconnaissance faciale fonctionnait bien avec des visages statiques. Désormais avec l'intelligence artificielle, les caméras reconnaissent maintenant des individus en mouvement, en train de marcher ou au volant de leur véhicule. Dans le même ordre d'idée, grâce aux avancées technologiques des algorithmes et de l'intelligence artificielle, les systèmes de reconnaissance faciale obtiennent de bien meilleurs résultats. Bien évidemment, l'identité des personnes peut donc être utilisée comme une clé pour les solutions de sécurité dans de nombreuses organisations. De nos jours, le système de reconnaissance de visage est de plus en plus utilisé dans le monde entier pour offrir une technologie

de sécurité extrêmement sûre et fiable. Des milliers d'entreprises et d'organisations gouvernementales gagnent en importance et en attention, uniquement en raison de son haut niveau de sécurité et de fiabilité.

Pour le cerveau humain, le processus de la reconnaissance de visages est une tâche visuelle de haut niveau. Bien que les êtres humains puissent détecter et identifier des visages dans une scène sans beaucoup de peine, construire un système automatique qui accomplit de telles tâches représente un sérieux défi. Ce défi est d'autant plus grand lorsque les conditions d'acquisition des images sont très variables. Il existe deux types de variations associées aux images de visages qui sont inter et intra sujet. La variation inter-sujet est limitée à cause de la ressemblance physique entre les individus. Par contre la variation intra-sujet est plus vaste. Elle peut être attribuée à plusieurs facteurs tels que, les variations d'éclairage, la variation de pose est considérée comme un problème majeur pour les systèmes de reconnaissance faciale. Un autre facteur qui affecte l'apparence du visage est l'expression faciale et finalement, la présence des composants structurels telle que la barbe, la moustache, ou bien les lunettes peut modifier énormément les caractéristiques faciales. Tous ces facteurs rendent la tâche de reconnaissance de visage très difficile et peut entraîner une mauvaise classification des images d'entrée.

Dans ce travail nous avons focalisé essentiellement sur :

— L'évaluation d'un système de reconnaissance faciale existant.

— L'entraînement d'un réseau de neurones.

— La réalisation d'un système qui fait l'identification et la vérification faciale.

Ce rapport traite la reconnaissance faciale par deep learning. Nous avons le divisé en trois chapitre.

Pour le premier chapitre, nous avons effectué un état de l'art dans lequel nous avons parlé de la biométrie faciale. Dans laquelle nous avons mentionné la no-

tion de celle-ci. Ainsi, nous avons focalisé sur les notions de la reconnaissance, l'identification et la vérification faciale et en mettant un coup d'oeil sur les étapes de la reconnaissance faciale. Bien évidemment, nous avons évoqué les principaux réseaux de neurones, entre autre, les réseaux de neurones artificiel, les réseaux de neurones convolutifs, le réseau récurent et le long short-term-memory. De surcroît, nous avons parlé des méthodes de la reconnaissance faciale par deep learning tels que LBPH, KNN, DeepFace, ...

Dans le deuxième chapitre, nous avons parlé des différents ensembles de données existantes et la différence entre ces ensembles. Bien évidemment, nous avons évoqué les différents outils utilisé pour la reconnaissance faciale. Finalement, nous avons évoqué la méthodologie utilisée et nous avons également décrit notre solution en expliquant l'ensemble de données utilisé et l'architecture de réseau de neurone.

Concernant le dernier chapitre, nous avons évalué dans ce dernier un système de reconnaissance faciale existant qui utilise l'ensemble de données "LFW" et en affichant les résultats de cette évaluation.

Ainsi, nous avons évalué un système de reconnaissance faciale existant. Enfin, nous avons parlé de la détection faciale ,l'extraction de paramètres et en mettant un coup d'oeil sur les résultats obtenus de l'identification et la vérification faciale soit dans une image ou dans le web cam.

Finalement, nous avons achevé par une conclusion sur le travail effectué.

Chapitre 1

État de l'art

Sommaire

1.1 Introduction 14

1.2 La biométrie faciale 14

1.2.1 Définition de la biométrie 14

1.2.2 Comment choisir un trait biométrique ? 18

1.2.3 La reconnaissance faciale 19

1.2.4 L'identification faciale 19

1.2.5 La vérification faciale 19

1.2.6 Étapes de la reconnaissance faciale 20

1.3 Les réseaux de neurones 20

1.3.1 Qu'est-ce qu'un réseau de neurone ? 20

1.3.2 Concepts de base 23

1.3.3 Réseau de neurones artificiel 24

1.3.4 Le réseau de neurones convolutifs 25

1.3.5 Les Perceptrons Multicouches 28

1.3.6 Le Réseau de neurones récurrent 29

1.3.7 Long Short-Term Memory 30

1.4 Les méthodes de la reconnaissance faciale par deep learning . . 31

1.4.1 LBPH 31
1.4.2 KNN 32
1.4.3 VGGFace Network 32
1.4.4 DeepFace 33
1.4.5 DeepID 34
1.4.6 FaceNet 34
1.4.7 GaussianFace 34
1.5 Conclusion 35

1.1 Introduction

Dans ce chapitre, nous avons commencé de parler de méthodes biométriques pour établir l'identité d'un individu. De surcroît, nous avons défini la reconnaissance faciale. Bien évidemment, nous avons évoqué les notions de l'identification et la vérification faciale. Dans le même ordre d'idée, nous avons cité les étapes de la reconnaissance faciale.

1.2 La biométrie faciale

1.2.1 Définition de la biométrie

En pratique, il est possible de vérifier une identité individuelle par trois méthodes différentes : une chose qu'il sait, comme un mot de passe ou un code PIN, quelque chose qu'il possède, comme une clé ou un badge, ou quelque chose qu'il est, caractéristiques biométriques. L'utilisation de méthodes biométriques pour établir l'identité d'un individu présente deux avantages principaux par rapport aux autres :

— Simple et sécurisé car il n'est pas nécessaire de se souvenir du mot de passe ni d'être peur de le perdre.

— Fiable puisqu'il repose sur des caractéristiques liées à l'individu lui-même.

Le terme biométrie est composé de deux mots -Bio (mot grec pour la vie) et métriques (Des mesures). La biométrie est "l'analyse de données biologiques à l'aide de méthodes mathématiques et statistiques". Selon (Jain et al, 2007) [5], la biométrie est la science qui permet d'établir l'identité d'un individu en fonction de ses attributs physiques ou comportementaux. En bref, elle est liée à mesurer intrinsèquement les caractéristiques corporelles de l'individu à des fins de déduction d'identité. Les propriétés biométriques d'une personne sont supposées ne pas changer. Il y a un fort lien entre une personne et ses traits biométriques car les traits biométriques sont inhérents à un individu. Les chercheurs ont distingué les attributs physiques et comportementaux :

— Attributs physiques tels que les empreintes digitales, la couleur de l'iris, la géométrie de la main, etc.

— Attributs comportementaux tels que la voix, l'écriture manuscrite, la signature, la démarche ou la manière de taper les touches du clavier de l'ordinateur, etc.

La figure 1.1 présente un exemple de traits biométriques pouvant être utilisés pour authentifier un individu.

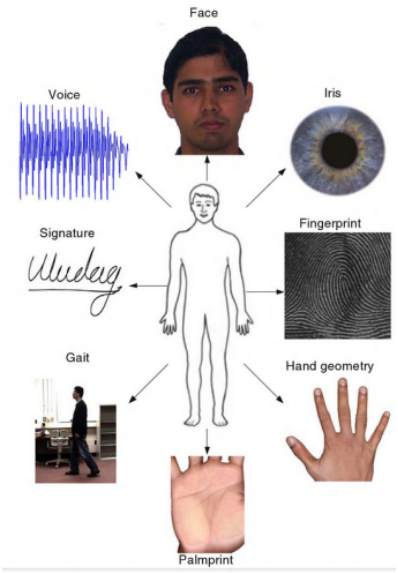


Figure 1.1 – Exemple de traits biométriques pouvant être utilisés pour authentifier un individu [7]

Puisque ces caractéristiques sont relativement personnalisées elles sont utilisées donc pour accroître la sécurité des systèmes.

Les formes de technologies biométriques [4] les plus connus sont le mapping des empreintes digitales, la reconnaissance faciale et la reconnaissance vocale.

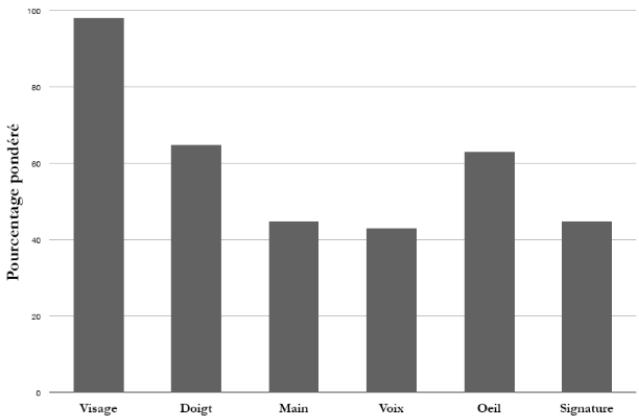


Figure 1.2 – Scores de compatibilité pour différentes technologies biométriques dans un système MRTD"Machine Readable Travel Documents"
"Technolgies biométriques"

La biométrie ne s'arrête pas aux mesures réalisées sur des données physiologiques, mais s'appuie d'ores et déjà sur des données comportementales. Les données physiologiques sont celles liées à la morphologie tels que : les empreintes digitales, forme du visage, de la main ou du doigt, oeil (iris et rétine) ou à la biologie tels que : ADN, sang, salive. Quant aux données comportementales, la biométrie parvient à analyser la dynamique des signatures (vitesse de déplacement du stylo, accélérations, pression exercée), la frappe sur le clavier d'un ordinateur, la démarche. Cependant, la biométrie ne parvient pas encore à garantir le même degré de fiabilité dans la mesure de ces diverses données. L'identification d'une personne à partir de ses données physiologiques même si celles-ci changent au cours de l'existence reste à ce jour plus performante que celle qui est liée à ses attitudes. Il est nécessaire aussi d'ajouter que la biométrie faciale est fortement utilisée dans divers domaines. Les exemples les plus frappant sont ceux des passeports électroniques sont dotés d'une puce qui contient une photographie numérique du visage, des empreintes digitales, et sont équipés d'une technologie qui empêche la puce d'être lue par des lecteurs non autorisés. Aussi, la technologie de la reconnaissance faciale sur l'IPhone X d'Apple qui permet l'identification du propriétaire de l'appareil par une image en 3D de son visage, même si l'on ajoute une paire de lunettes ou si l'on change de coupe de cheveux. La probabilité de se tromper d'identité est d'une sur un million, selon Apple.



Figure 1.3 – Biométrie faciale[4]

Grâce à la biométrie faciale, la reconnaissance faciale remplace les mots de passe et les codes, ainsi elle simplifie le déverrouillage des terminaux, l'accès aux services

et les modes de paiement sont devenus plus sécurisés.

1.2.2 Comment choisir un trait biométrique ?

Toute caractéristique physique et / ou comportementale d'un individu peut être utilisée comme une caractéristique biométrique pour autant qu'elle réponde à certaines exigences (Maltoni et al, 2009 [9] ; Marzotti et Nardini, 2006 [11] ; Jain et al., 2004 [6]) ont identifié sept facteurs qui déterminent l'adéquation d'une caractéristique biométrique :

1. Universalité : chaque personne devrait avoir une caractéristique biométrique.

2. Unicité (le caractère distinctif est souvent utilisé pour éviter le terme "unicité") : chaque être humain est unique en termes de caractéristiques, ce qui le rend différent de tous les autres.

3. Permanence : les caractéristiques biométriques ne changent pas dans le temps.

4. Possibilité de collecte : la caractéristique biométrique peut être mesurée de manière quantitative.

Dans les applications réelles, trois facteurs supplémentaires doivent également être pris en compte, comme :

5. La performance, qui fait référence à la précision et à la rapidité de reconnaissance réalisables, à la ressource nécessaire pour obtenir la précision et la rapidité de reconnaissance souhaitées.

6. Acceptabilité, dans quelle mesure chaque personne acceptera une technologie biométrique particulière.

7. Le contournement indique à quel point on peut facilement tromper le système.

Il est difficile de trouver une caractéristique biométrique qui réponde effectivement à toutes ces exigences et puisse donc s'adapter à toutes les applications biométriques. Chaque trait biométrique a ses forces et ses faiblesses. La pertinence d'une caractéristique biométrique spécifique pour une application est établie en fonction de la nature et des exigences du application, et les propriétés de la caractéristique

biométrique.

1.2.3 La reconnaissance faciale

La reconnaissance faciale est une tâche qui consiste à détecter, à identifier et à vérifier l'identité d'une personne sur la base d'une photographie de son visage.
Remarque : avant de faire la reconnaissance faciale, il est nécessaire de faire la détection faciale.
La différence entre la détection et la reconnaissance faciale réside dans le fait que, dans la détection, nous devons simplement déterminer s'il y a un visage dans l'image, mais pour la reconnaissance nous voulons déterminer le propriétaire de visage.
Bien évidemment, il y a une différence entre l'identification et la vérification faciale.

1.2.4 L'identification faciale

Identifier un visage est l'acte de répondre à la question "qui est cette personne ?"[15]. C'est à dire on met en entrée une image et la sortie va être l'identité de visage détecté dans l'image.

1.2.5 La vérification faciale

La vérification des visages est la tâche de répondre à la question "est-ce que c'est la personne ?"[15], Cela signifie que lorsque nous comparons deux images, nous trouvons finalement si ces deux images appartiennent à la même personne ou non.

1.2.6 Étapes de la reconnaissance faciale

Malgré la variété des traits biométriques, ils partagent tous la même chaîne de traitement biométrique. Dans notre cas nous avons utilisé le visage. Généralement, elle se compose de 4 phases, comme indiquer dans la figure 1.4 : détection du visage, normalisation du visage, extraction de caractéristiques, la comparaison des caractéristiques détectés avec les caractéristiques d'un profil existant (Drygajlo, 2012 [3]) et finalement l'obtention de l'identité de la personne.

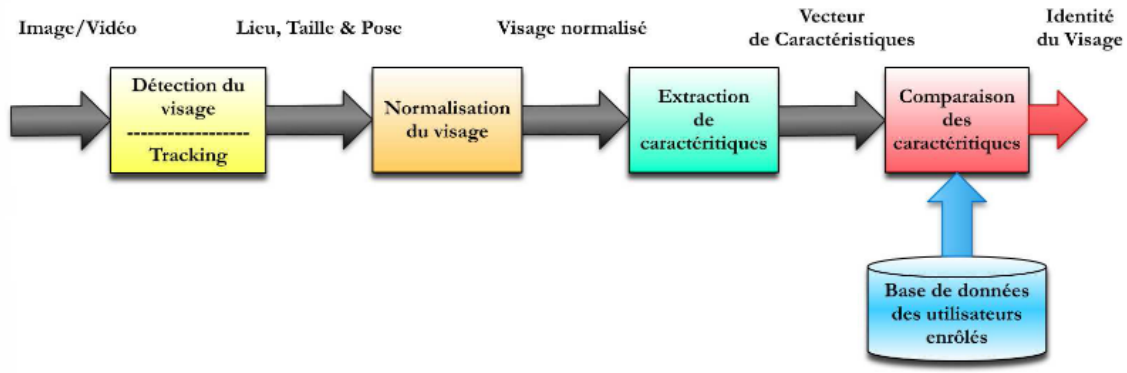


Figure 1.4 – Chaîne de traitement générique pour la reconnaissance faciale "Reconnaissance faciale"

Bien évidemment, les meilleures solutions pour faire la biomtérie faciale appliquent les réseaux de neurones qui sont considérés maintenant l'état de l'art.

1.3 Les réseaux de neurones

1.3.1 Qu'est-ce qu'un réseau de neurone ?

Un réseau de neurones est une fonction mathématique qui associe une entrée donnée à une sortie souhaitée [2]. Il est généralement constitué de :

— Une couche d'entrée, x
— Un nombre arbitraire de couches cachées

— Une couche de sortie $\hat{y}$

— Un ensemble de poids et de biais entre chaque couche, nommé respectivement w et b.

— Un choix de fonction d'activation pour chaque couche caché, nommé σ.

Vous voyez ici l'architecture d'un réseau de neurone composé de deux couches. Remarque : la couche d'entrée est généralement exclue lors du comptage de nombre de couches d'un réseau de neurones.

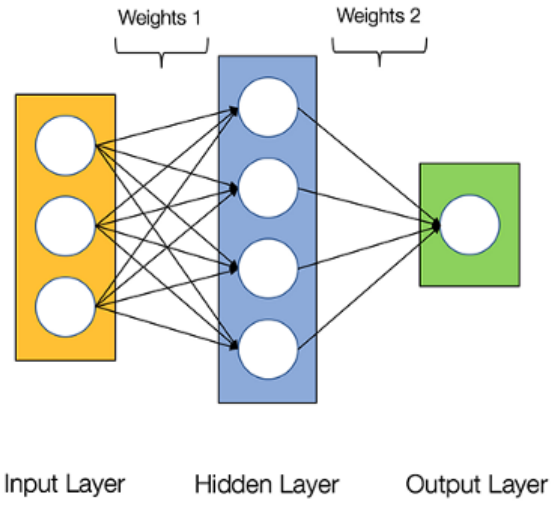


Figure 1.5 – Architecture d'un réseau de neurone composé de 2 couches "Réseau de neurone artificiel"

Concernant la fonction d'activation utilisé, plusieurs possibilités existent pour spécifier la nature de cette fonction. Les fonctions mathématiques les plus souvent utilisées sont :

— La fonction sigmoïde

— La fonction de seuil

— La fonction linéaire par parties

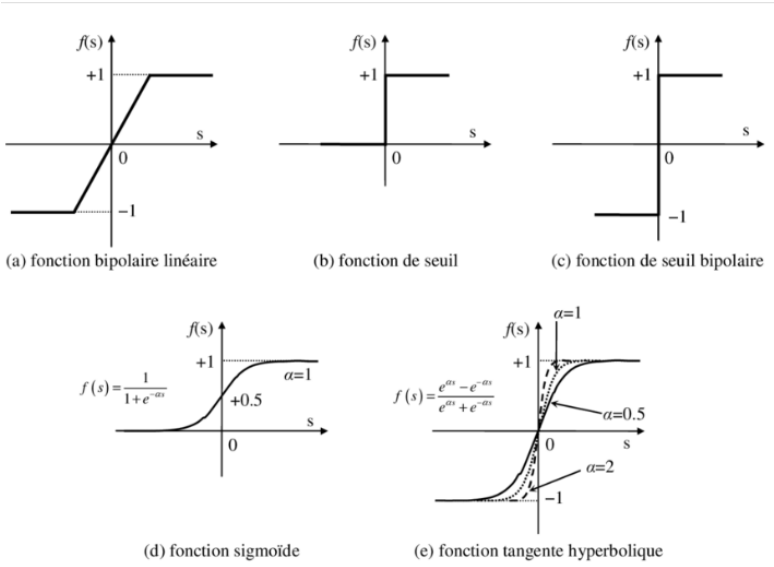


Figure 1.6 – Les différents fonctions d'activations
"Fonction d'activation"

Dans un réseau de neurone à 2 couches, la sortie $\hat{y}$ s'écrit comme suit :

$$\hat{y} = \sigma(w_2\sigma(w_1x + b1)) + b2$$

La sortie $\hat{y}$ dépend des paramètres w_i et b_i avec $i = 1, 2$
Le processus de chaque itération d'entraînement d'un réseau de neurone consiste essentiellement de 2 étapes :

— calcul de la sortie prévue , appelée feedforward.
Le but de l'entraînement est la faite de trouver w et b qui minimisent la fonction de perte noté Loss est égale à :
$Loss(y, \hat{y}) = \sum_{i=1}^{N}(y - \hat{y})^2$

— Mise à jour des poids et des biais, connue sous le nom de backpropagation.
Après la mesure de l'erreur de prédiction qui est la fonction de perte Loss, on doit donc trouver un moyen de propager l'erreur en arrière et de mettre

à jour les poids et les biais.

Afin de connaître le montant approprié pour ajuster les poids et les biais, nous avons besoin de connaître la dérivée de la fonction de perte.

$$\frac{dLoss(y,\hat{y})}{dw} = \frac{dLoss(y,\hat{y})}{d\hat{y}} \times \frac{d\hat{y}}{dz} \times \frac{dz}{dw} = 2(y-\hat{y}) \times z(z-1) \times x$$

avec $z = wx + b$

Voici une image descriptive du processus.

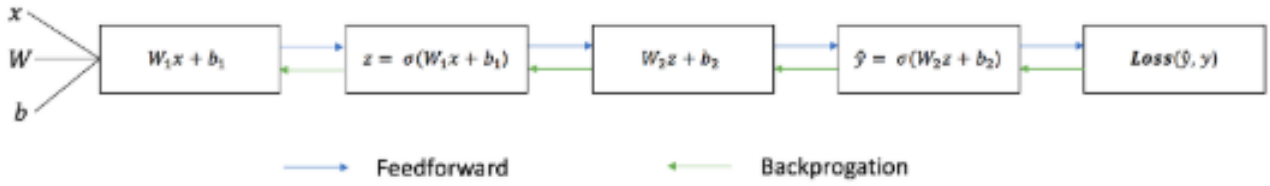


Figure 1.7 – Le processus d'entraînement d'un réseau de neurones "Entraînement"

1.3.2 Concepts de base

L'architecture des réseaux de neurones artificiels regroupe un ensemble d'unités élémentaires appelées "neurones formels". Ces neurones sont connectés entre eux pour former un graphe orienté. En analogie avec les réseaux biologiques de neurones, les connexions entre les noeuds du graphe symbolisent les synapses. Ces connexions sont pondérées par des poids ajustés durant la phase d'apprentissage par le moyen d'un algorithme dédié. Ce type d'algorithme adapte les poids afin de minimiser la différence entre la sortie du réseau (l'hypothèse) et la sortie attendue. Le comportement des neurones du système nerveux a été repris pour la création du concept mathématique de "neurones formels". Ces neurones reçoivent les informations produites par d'autres noeuds à travers les connexions d'entrée. Chaque neurone j effectue en premier temps une somme pondérée des N valeurs en entrée. Les poids affectés aux entrées d'un neurone sont stockés dans une matrice w, où

la valeur w_{ij} représente le poids de la connexion d'entrée a_i du neurone j. À cette somme est ajouté la valeur de b_j qui représente la sortie d'un neurone "biais". Cette grandeur totale représente le potentiel post-synaptique biaisé p_j formulé comme suit :

$$p_j = b_j + \sum_{i=1}^{N} w_{ij} a_i$$

Enfin, une fonction d'activation f transforme ce potentiel biaisé pour obtenir la valeur d'activation du neurone qui pourra ensuite être transmise à d'autres neurones.

Parmi les fonctions d'activation communément utilisées, nous pouvons citer la fonction sigmoïde qui fournit une sortie comprise entre 0 et 1 :

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

L'avantage de cette fonction est que sa dérivée, une composante indispensable aux algorithmes d'apprentissage, peut être obtenue facilement :

$$\frac{d\sigma(x)}{dx} = \sigma(x) \cdot (1 - \sigma(x))$$

1.3.3 Réseau de neurones artificiel

Les réseaux de neurones artificiels, nés il y a environ une cinquantaine d'années [10], sont toujours en cours de développement. Ces réseaux de neurones artificiels(RNA) sont issus de la combinaison entre la neurobiologie comme idée de base, la physique comme champs d'application et les mathématiques avec l'informatique en tant que moyens de réalisation. C'est un système dont la conception est à lorigine schématiquement inspirée du fonctionnement des neurones biologiques.

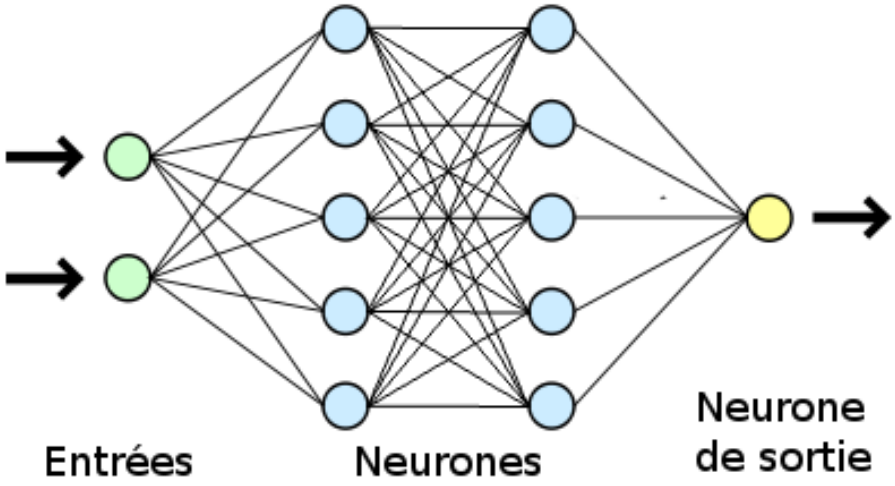


Figure 1.8 – Fonctionnement du réseau de neurones
"Réseau de neurone artificiel"

Comme il est schématisé sur la figure 1.8, un réseau de neurones est en général composé d'une succession de couches dont chacune prend ses entrées sur les sorties de la précédente. Chaque couche (i) est composée de N_i neurones, prenant leurs entrées sur les N_{i-1} neurones de la couche précédente. À chaque synapse est associé un poids synaptique, de sorte que les N_{i-1} sont multipliés par ce poids, puis additionnés par les neurones de niveau i, ce qui est équivalent à multiplier le vecteur d'entrée par une matrice de transformation. Mettre l'une derrière l'autre, les différentes couches d'un réseau de neurones reviendraient à mettre en cascade plusieurs matrices de transformation et pourrait se ramener à une seule matrice, produit des autres.

1.3.4 Le réseau de neurones convolutifs

C'est quoi la convolution ?

La question le plus frappant dans ce cas est, c'est quoi la convolution ?
La convolution agit comme un filtrage. D'abord on définit une taille de fenêtre

qui va se balader à travers toute l'image (rappelez-vous qu'une image peut être vue comme étant un tableau). Au tout début de la convolution, la fenêtre sera positionnée tout en haut à gauche de l'image puis elle va se décaler d'un certain nombre de cases (c'est ce que l'on appelle le pas) vers la droite et lorsqu'elle arrivera au bout de l'image, elle se décalera d'un pas vers le bas ainsi de-suite jusqu'à ce que le filtre est parcourue la totalité de l'image. Vous voyez ici le schéma de parcours de la fenêtre de filtrage.

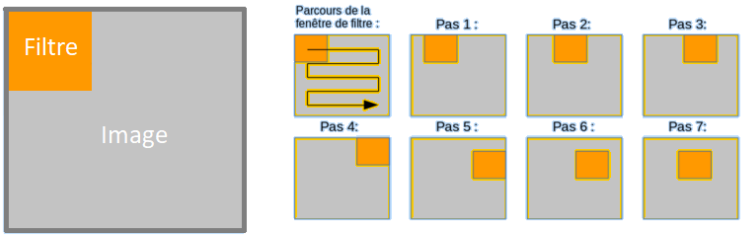


Figure 1.9 – Schéma de parcours de la fenêtre de filtrage sur une image "Filtrage"

Architecture de CNN

CNN (réseau de neurone convolutifs) est un type de réseau de neurone le plus utilisé pour le traitement de données. Il s'agit d'un réseau profond composé des couches suivantes :

- La couche convolutif : permet d'extraire les caractéristiques d'image.
- La couche de mise en commun(pooling) : permet d'effectuer une opération de sous-échantillonnage et de réduire la taille d'une entrée.
- La couche entièrement connectée : dans laquelle Chaque neurone de la couche précédente est connecté à chaque neurone de la couche suivante.

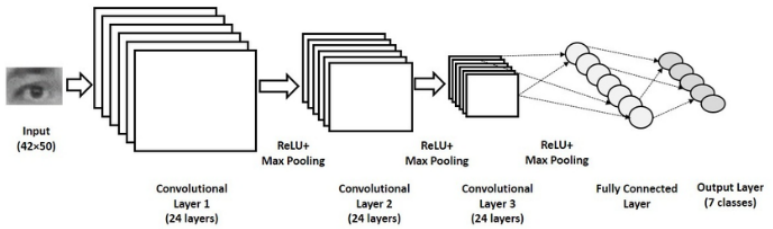


Figure 1.10 – Architecture de CNN
"CNN"

Généralement l'architecture du CNN utilisée dépend de la taille de l'ensemble de données utilisé pour l'entraînement. Plus la taille est faible plus on utilise moins de couches est filtres.

Prenons le cas de l'ensemble de données LFW, dans ce cas il y aura trois différentes architectures de taille différents :

CNN-S(petite), CNN-M(moyen) et CNN-L(grand).

CNN-S et CNN-M ont 3 couches convolutives et deux couches entièrement connectées, tandis que CNN-M a plus de filtres que CNN-S.

Pour CNN-L elle possède 4 couches convolutives et la fonction d'activation utilisée est l'unité linéaire de réactivation (RELU). Dans ce cas le résultat de taux de précision obtenu est résumé dans le tableau suivant :

Modèle	Taux de précision
CNN-S	0.7828(+-)0.0046
CNN-M	0.7882(+-)0.0037
CNN-L	0.7807(+-)0.0035

Table 1.1 – Taux de précision de chaque architecture de CNN

Interprétation :

CNN-M réalise la meilleure performance de reconnaissance faciale de l'ordre de 0.7882.

1.3.5 Les Perceptrons Multicouches

Les réseaux de neurones non bouclés (Feed-Forward Neural Networks) représentent une catégorie de réseaux de neurones artificiels dont les noeuds forment un graphe orienté acyclique dans lequel l'information circule dans un seul sens, c'est-à-dire, de l'entrée vers la sortie.

Les Perceptrons Multicouches, voir figure 1.11, sont des réseaux de neurones non bouclés dont les noeuds sont organisés en trois niveaux ou plus appelés "couches". Les couches voisines sont complètement connectées, c'est-à-dire, les noeuds de chaque couche sont liés à tous les noeuds de la couche inférieure et à tous ceux de la couche supérieure. En revanche, aucune connexion n'existe entre les unités d'une même couche.

Un MLP est constitué de trois types de couche, une couche d'entrée, une ou plusieurs couches cachées, et une couche de sortie.

La phase dapprentissage des MLP consiste à adapter les poids des connexions en fonction des erreurs de prédiction constatées à chaque classification d'une nouvelle instance.

La rétropropagation du gradient (backpropagation) est la méthode la plus utilisée pour l'adaptation des poids. Cet algorithme permet de déterminer le gradient de l'erreur pour chaque neurone du réseau en partant de la dernière couche et en arrivant jusqu'à la première couche cachée.

Dans ce cas l'objectif de la rétropropagation du gradient est d'ajuster les poids des connexions dans le but de minimiser l'erreur quadratique (E) qui représente l'écart entre la sortie attendue (la référence : ref) et la sortie produite par le réseau (hypothèse : hyp) correspondant à un vecteur d'entrée donné. N représente la taille des vecteurs en sortie.

$$E = 1/2 \sum_{i=1}^{N} (ref_i - hyp_i)^2$$

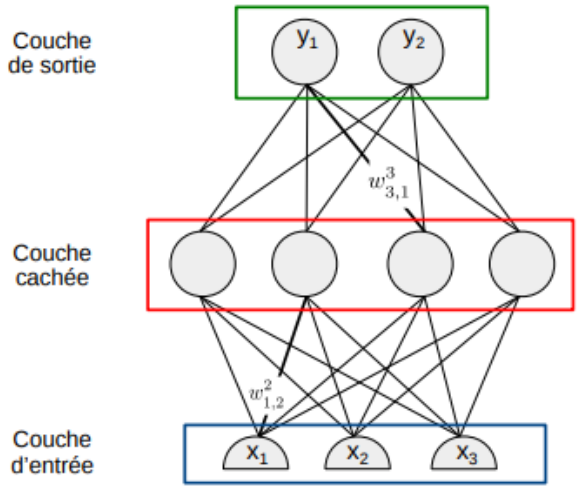


Figure 1.11 – représentation d'un MLP
"MLP"

1.3.6 Le Réseau de neurones récurrent

Contrairement aux MLP, les réseaux de neurones récurrents ou RNN, voir figure 1.12, comportent des cycles au sein du graphe de neurones (Elman, 1990).
La motivation principale derrière ce type d'architecture est de pouvoir manipuler des séquences de vecteurs d'entrée, représentant chacun un événement temporel, et non pas seulement des données isolées n'ayant pas de signification temporelle. En déroulant, par rapport au temps, la modélisation compacte dun RNN, ce type de réseaux peut ainsi être considéré comme une suite temporelle de réseaux MLP reliés entre eux à travers leur couche cachée respectives.
W_{xh} : représente la matrice de poids entre les couches, d'entrée x et caché h.
W_{hy} : représente la matrice de poids entre les couches, caché h et de sortie y.

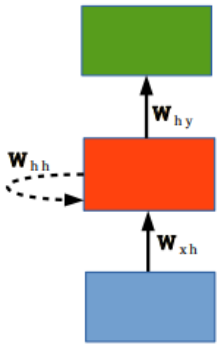


Figure 1.12 – Représentation compacte des RNN
"RNN"

1.3.7 Long Short-Term Memory

Les LSTM sont une catégorie de RNN dont l'architecture et la formulation mathématique générales sont identiques à celle présentée par la figure 1.12.
La particularité des LSTM réside dans la manière selon laquelle l'état caché est géré. Dans le cas des RNN simples, le traitement de la récurrence est assuré par une simple fonction tanh. En ce qui concerne les LSTM, ce traitement est remplacé par une "cellule à mémoire" représenté dans la figure 1.13.
La cellule LSTM est caractérisée par un noeud central, contenant l'état (ou mémoire) interne de la cellule, et un nombre de portes divisées en 3 catégories.
Ces portes permettent de gérer, d'une part, la tenue en mémoire de l'information séquentielle (portes d'entrée et d'oubli) et, d'autre part, le rôle de l'état interne dans la production de chaque sortie (porte de sortie). En fermant la porte d'entrée, par exemple, les nouveaux événements sont moins pris en compte dans l'information de la cellule. La figure 1.13 correspond à une des versions les plus utilisées des LSTM qui est enrichie par les connexions peephole (Gers, 2001). Les peepholes représentent des connexions supplémentaires qui permettent d'informer les différentes portes du contenu de l'état interne avant de décider de l'ouverture ou de la fermeture.

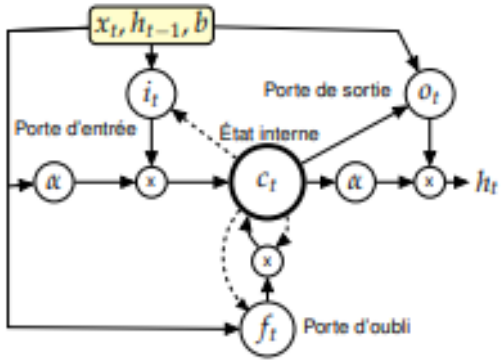


Figure 1.13 – Une cellule Long Short-Term Memory (LSTM)
"LSTM"

1.4 Les méthodes de la reconnaissance faciale par deep learning

De nombreux méthodes sont utilisés pour la reconnaissance faciale entre autres on peut citer :
Local Binary Patterns Histograms (LBPH), KNearest Neighbour (KNN), DeepFace, DeepID et on a plein d'autres.
Ces différentes méthodes se diffèrent principalement par leurs architectures, le taux de précision et le taux d'erreur, ...

1.4.1 LBPH

La procédure consiste à diviser une image faciale dans plusieurs régions où les fonctionnalités LBP sont extraites et concaténées dans une vecteur qui sera utilisé comme un descripteur du visage. L'opérateur attribue une étiquette à chaque pixel d'une image en seuillant un voisinage 3x3 avec la valeur de pixel centrale et en considérant le résultat comme un nombre binaire.

1.4.2 KNN

En intelligence artificielle, la méthode des k plus proches voisins est une Méthode d'apprentissage supervisé.

Pour estimer la sortie associée à une nouvelle entrée x, la méthode des k plus proches voisins consiste à prendre en compte (de façon identique) les k échantillons d'apprentissage dont l'entrée est la plus proche de la nouvelle entrée x, selon une distance à définir.

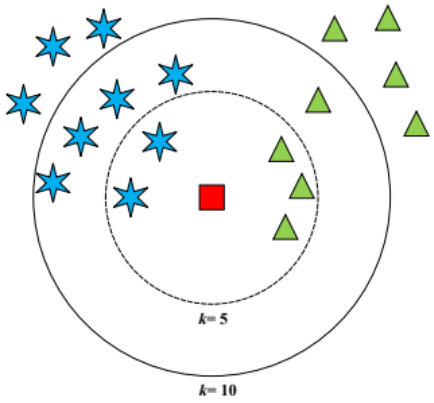


Figure 1.14 – Fonctionnement de KNN
"KNN"

Comme le montre la figure 1.14, le carré rouge représente l'échantillon à classer. Il doit être classé dans l'étoile bleue ou le triangle vert. Pour K=5, il est classé dans le triangle vert, car la probabilité de le classer dans le triangle vert est de 60% qui est plus élevé que celui de le classer en étoile bleue (40%). Alors que pour k=10, le carré rouge est classé en étoile bleue, puisque la probabilité de le classer dans l'étoile bleue est de 60% supérieure à la probabilité de la classer dans le triangle vert (40%).

1.4.3 VGGFace Network

VGG-Face [1] est un réseau de convolution profond proposé pour la reconnaissance faciale en utilisant l'architecture VGGNet [17]. Il est utilisé pour l'entraînement

de 2,6 millions d'images faciales sur 2622 identités recueillies sur le web.
Le réseau comprend 16 couches convolutives, 5 couches de regroupement maximal (max-pooling layer) et 3 couches entièrement connectées.
VGG-Face prend des images de taille 224x224 pixels en entrée et applique la fonction d'activation ReLU à toutes ses couches convolutives. Cette méthode a été évaluée sur l'ensemble de données LFW et atteint une précision de 98,95%.

1.4.4 DeepFace

DeepFace [19] est une méthode utilisé pour l'apprentissage profond de la reconnaissance faciale, qui contient un modèle CNN profond à neuf couches avec deux couches convolutives et plus de 120 millions de paramètres formé sur quatre millions d'images faciales de plus de 4000 identités. Cette méthode, basée sur l'alignement des images sur un modèle 3D et l'utilisation d'un ensemble de CNN, pourrait atteindre des précisions de 97,35% et 91,4% respectivement pour les ensembles de données LFW et YTF. DeepFace est la meilleure solution utilisée. En fait, en 2014, Facebook annonçait le lancement de son programme baptisé DeepFace, capable de déterminer si deux visages photographiés appartiennent à la même personne, avec une précision de 97,25%. Soumis au même test, les humains répondent correctement dans 97,53% des cas, soit à peine 0,28% de mieux que le programme de Facebook.
Facebook a déjà un système de reconnaissance faciale qui est capable de vous proposer des noms d'amis à taguer quand vous téléchargez une photo : il utilise des informations telles que la distance entre les yeux et le nez en les comparant avec des photos de profil et des photos déjà taguées. Mais ces résultats sont beaucoup moins précis que ceux obtenus par DeepFace, qui utilise des techniques d'apprentissage profond.
Le point commun de toutes ces technologies est l'utilisation de deep learning (apprentissage profond) qui s'appuie sur un réseau de neurones artificiels imitant le

fonctionnement du cerveau humain.

1.4.5 DeepID

DeepId [18] est une autre méthode d'apprentissage profond proposé pour la reconnaissance et la vérification de visage avec trois couches de réseau et quatre couches de convolution. Ce schéma apprend d'abord les poids grâce à l'identification du visage et à des extraits en utilisant les dernières sorties de couche masquées et les généralise plus tard pour faire face à la vérification.
DeepID aligne les visages par transformation de similarité basée sur les deux centres de l'oeil et deux coins de la bouche. Ce réseau a été formé sur le Celebrity Faces (CelebFaces) et atteint une précision de 97,45% sur l'ensemble de données LFW.

1.4.6 FaceNet

FaceNet [16] est un CNN profond basé sur GoogleNet et formé sur un ensemble de données avec 100 à 200 millions d'images d'environ huit millions d'identités.
FaceNet a été évalué sur les ensembles de données LFW et YTF et atteindre respectivement les taux de précisions suivants 99,63% et 95,12%.

1.4.7 GaussianFace

Développé dès 2014 par des chercheurs de l'université de Hong Kong affichait des scores d'identification faciale de 98,52% contre 97,53% pour les humains.
En effet, GaussianFace normalise la photo faciale en une image d'une taille fixe (150x150 pixels). Il la transforme, ainsi, en retenant la position des yeux, du nez et des coins de la bouche. Ensuite, l'image est divisée en morceaux (25x25 pixels) et chaque morceau est présenté sous forme de vecteurs. Ceci permet à l'algorithme de rechercher des similitudes entre les images et d'identifier par conséquent la personne souhaitée.

Par ailleurs, l'approche employée dans GaussianFace consiste à utiliser quatre bases de données différentes, contrairement aux approches classiques qui utilisent des échantillons d'images provenant d'une seule base de données pour former et tester un algorithme.
Malgré sa réussite remarquable, cet algorithme pose encore des inconvénients non négligeables, à savoir : la capacité de mémoire requise pour son fonctionnement et le temps nécessaire pour l'exécution du processus.

1.5 Conclusion

Tout au long de ce chapitre, nous avons parlé d'abord de la biométrie. Ainsi, nous avons mentionné les notions de la reconnaissance, identification et vérification faciale. De surcroît, nous avons cité les étapes de la reconnaissance faciale. Finalement, nous avons évoqué les différentes méthodes de la reconnaissance faciale.

Chapitre 2

Méthodologie, corpus et outils

Sommaire

2.1 Introduction 37

2.2 Les corpus de données utilisés pour la reconnaissance faciale . . 37

2.2.1 VGGFace 37

2.2.2 MegaFace 38

2.2.3 VGGFace2 38

2.2.4 WIDER FACE 38

2.2.5 LFW 39

2.3 Outils utilisés 39

2.3.1 Python 39

2.3.2 Apprentissage profond(deep learning) 40

2.3.3 OpenCV 40

2.3.4 Dlib 40

2.3.5 Face recognition 41

2.3.6 Imutils 41

2.3.7 TensorFlow 41

2.3.8 Mtcnn 41

2.4 Méthodologie et solution proposée 41

2.4.1 Méthodologie utilisée 41
2.4.2 Solution proposée 44
2.5 Conclusion 45

2.1 Introduction

Au cours de ce chapitre, nous avons parlé des différents ensembles de données utilisés pour la reconnaissance faciale. En mentionnant la différence entre ces différents ensembles (nombres d'images, ...). Bien évidemment, nous avons cité quelques outils que nous avons utilisé dans notre projet. Finalement, nous avons décrit la méthodologie utilisée et notre solution proposée.

2.2 Les corpus de données utilisés pour la reconnaissance faciale

En général, les ensembles de données récents (voir Table 2.1) ont exploré l'importance de la variation intra et inter classe. Le premier est axé sur la profondeur (plusieurs images dun sujet) et le second sur l'étendue (beaucoup de sujets à images par sujet). Il existe divers ensembles de données utilisés pour la reconnaissance faciale. Ces derniers diffèrent par le nombre de personnes et le nombres d'images pour chaque personne. Parmi ces ensembles on peut citer :

2.2.1 VGGFace

VGGFace [14] publié en 2015 contient 2,6 millions d'images, couvrant 2 622 personnes, ce qui en fait l'un des plus grands ensembles de données disponibles au public. CASIA-WebFace et VGGFace ont été libérés uniquement à des fins de formation

2.2.2 MegaFace

MegaFace [8] a été publié en 2016 pour évaluer les méthodes de reconnaissance du visage. Il contient 4,7 millions d'images de 672, 057 identités. Cependant, une moyenne de 7 images seulement par identité le rendent limité dans sa variation de visage par identité. Afin d'étudier l'effet de la variation de la pose et de l'âge dans la reconnaissance des visages, le défi MegaFace utilise les sous-ensembles de FaceScrub [12] contenant 4000 images à partir de 80 identités et FG-NET [13] contenant 975 images à partir de 82 identités pour évaluation.

2.2.3 VGGFace2

Contient 3,31 millions d'images de 9131 célébrités appartenant à un large éventail d'ethnies, par exemple il comprend plus de visages chinois et indiens que VGGFace (cependant, l'équilibre ethnique est encore limité par la répartition des célébrités et des personnalités publiques), et des professions (par exemple politiciens et athlètes). Les images ont été téléchargées à partir de Google Image Search et ont de grandes variations dans la pose, l'âge, l'éclairage et l'arrière-plan. L'ensemble de données est approximativement équilibré entre les sexes, avec 59,3% d'hommes, variant entre 80 et 843 images pour chaque identité, avec 362,6 images sur moyenne. L'ensemble de données est divisé en deux parties : une pour l'entraînement ayant 8631 classes, et une pour l'évaluation (test) avec 500 classes.

2.2.4 WIDER FACE

Contient 32203 images. Il est actuellement le plus grand ensemble de données de détection de visage, parmi lequel des images sont sélectionnées à partir de l'ensemble de données WIDER disponible au public.

2.2.5 LFW

LFW(Labeled Faces in the Wild) contient 13233 images avec 5749 identités dans laquelle Chaque image a été étiqueté avec le nom de la personne représentée. En dehors de ces ensembles de données publics, Facebook et Google ont de grands ensembles de données internes. Par exemple, Facebook a formé un modèle d'identification de visage utilisant 500 millions d'images de plus de 10 millions de sujets. Le modèle de reconnaissance de visage par Google [16] a été formé à l'aide de 200 millions d'images de 8 millions d'identités.
Vous voyez ici une table récapitulative qui représente les ensembles de données utilisés pour la reconnaissance faciale.

Ensemble de données	sujets	images	images par sujet	étiquetage manuel d'identité	pose	age	année
LFW	5749	13233	1/2.3/530	-	-	-	2007
YTF	1595	3425 videos	-	-	-	-	2011
CelebFaces+	10177	202599	19.9	-	-	-	2014
CASIA-WebFace	10575	494414	2/46.8/804	-	-	-	2014
IJB-A	500	5712images 2085 videos	11.4	-	-	-	2015
IJB-B	1845	11754 images 7011 videos	36.2	-	-	-	2017
VGGFace	2622	2.6 M	1,000/1, 000/1,000	-	-	oui	2015
MegaFace	690572	4.7 M	3/7/2469	-	-	-	2016
MS-Celeb-1M	100000	10 M	100	-	-	-	2016
UMDFaces	8501	367920	43.3	oui	oui	oui	2016
UMDFaces-Videos	3107	22075 videos	-	-	-	-	2017
VGGFace2	9131	3.31 M	80/362.6/843	oui	oui	oui	2018

Table 2.1 – Statistiques des ensembles de données des visages publiques récents. Les trois entrées de la colonne images par sujet sont les minimum / moyenne / maximum

2.3 Outils utilisés

2.3.1 Python

Est le langage de programmation le plus utilisé pour la reconnaissance faciale. Il y a une migration massive vers Python, en effet il est gratuit et d'une grande utilité. Pour cette simple raison, nous avons opté pour Python, qui propose plusieurs bibliothèques dans le domaine de la reconnaissance faciale.

2.3.2 Apprentissage profond(deep learning)

Avec l'apprentissage profond, nous avons entraîné généralement le réseau à accepter une image d'entrée unique et à générer une étiquette pour cette image. Cependant, l'apprentissage métrique profond est différent. Au lieu d'essayer de produire une seule étiquette, nous avons produit plutôt un vecteur d'entités à valeur réelle.

Dans notre cas, le vecteur caractéristique en sortie est 128-d, qui signifie une liste de 128 nombres à valeurs réelles utilisée pour quantifier le visage.

2.3.3 OpenCV

OpenCV (Open Source Computer Vision Library) est une bibliothèque de logiciels open source de vision informatique et d'apprentissage automatique initialement développée par Intel. La bibliothèque contient plus de 2500 algorithmes optimisés, qui incluent un ensemble complet d'algorithmes classiques et avancés de vision par ordinateur et d'apprentissage automatique. Ces algorithmes peuvent être utilisés pour détecter et reconnaître les visages, identifier des objets, classer les actions humaines dans des vidéos, suivre les mouvements de la caméra et suivre des objets en mouvement.

2.3.4 Dlib

Est une bibliothèque qui contient notre implémentation de "l'apprentissage métrique profond (deep metric learning)" qui est utilisé pour construire nos imbrications de visage (face embeddings) utilisées pour le processus de reconnaissance réel.

2.3.5 Face recognition

C'est une bibliothèque utilisée pour rendre la fonctionnalité de Dlib plus facile à utiliser.

2.3.6 Imutils

Une série de fonctions pratiques permettant de simplifier les fonctions de traitement d'image telles que la traduction, la rotation, le redimensionnement et l'affichage d'images Matplotlib.

2.3.7 TensorFlow

TensorFlow est un outil open source d'apprentissage automatique développé par Google.

2.3.8 Mtcnn

MTCNN (Multi-task Cascaded Convolutional Neural Networks) est un algorithme utilisé qui permet de détecter le visage dans une image. Dans notre cas il est utilisé pour aligner l'ensemble de données.

2.4 Méthodologie et solution proposée

2.4.1 Méthodologie utilisée

Pour tester et évaluer un système de reconnaissance faciale existant, la méthode utilisé est une méthode purement axée sur les données qui apprend sa représentation directement à partir des pixels du visage.
Dans ce cas la méthode est FaceNet, qui utilise un réseau de convolution profonde. La partie la plus importante de cette approche réside dans l'apprentissage de bout en bout de l'ensemble du système.

Il utilise la perte de triplet (Triplet loss) qui reflète directement ce qu'il veut réaliser dans la vérification du visage, et la reconnaissance. La perte de triplet est plus appropriée pour la vérification du visage, elle tente d'imposer une marge entre chaque paire de visages d'une personne à tous les autres visages.

Perte de triplet ((triplet loss)

L'incorporation est représentée par $f(x) \in \mathbf{R}^d$. Il incorpore une image x dans un espace euclidien de dimension d.

Dans ce cas le but est d'assurer qu'une image A(anchor) d'une personne spécifique est plus proche de toutes les autres images positives P de la même personne que pour toute autre image négative N d'une autre personne. Cela est présenté par la figure 2.1 dans laquelle on veut que :

$$\left\|f(A) - f(P)\right\|^2 + \alpha < \left\|f(A) - f(N)\right\|^2$$

$$\forall f(A), f(P), f(N) \in T$$

où α est une marge imposée entre les paires positives et négatives. T est l'ensemble de tous les triplets possibles dans l'ensemble d'entraînement et de cardinalité N.

La perte minimisée et le coût nommés respectivement, L et J sont égale à :

$$L(A, P, N) = \left\|f(A) - f(P)\right\|^2 - \left\|f(A) - f(N)\right\|^2 + \alpha$$

$$J = \sum_{i=1}^{N} L(A^{(i)}, P^{(i)}, N^{(i)})$$

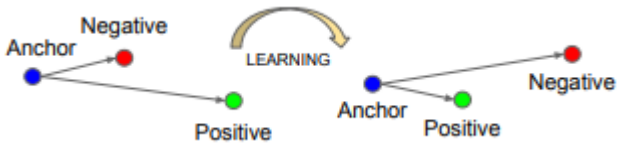


Figure 2.1 – Triplet loss
"Triplet loss"

Pour la phase d'entraînement d'un réseau de neurone à partir de zéro, nous avons entraîné un réseau qui utilise le détecteur de visage "Pyramidbox", nous avons utilisé aussi "Pyramidbox Anchor" qui permet au détecteur de visage d'apprendre

les caractéristiques des parties autour de visage. L'entraînement de ce réseau a déroulé 3 jours.

Le pyramidbox utilise le même squelette étendu VGG16. Il renferme essentiellement :

— Couches de pyramide de bas niveau (Low-level Feature Pyramid Layers) : permet d'améliorer les performances de détecteur du visage.
— Couches de détection (Pyramid Detection Layers) : dans ce cas nous sélectionnons lfpn 2, lfpn 1, lfpn 0, conv fc 7, conv 6 2 et conv 7 2 en tant que couches de détection avec une taille de 16, 32, 64, 128, 256 et 512, respectivement. Ici, lfpn 2, lfpn 1 et lfpn 0 sont les couches de sortie de LFPN.
— Couches de prédiction (Predict Layers) :chaque couche de détection est suivie d'un CPM (Context-sensitive Predict Module) basé sur les couches de convolution conv 3 3, conv 4 3 et conv 5

— PyramidBox loss layers

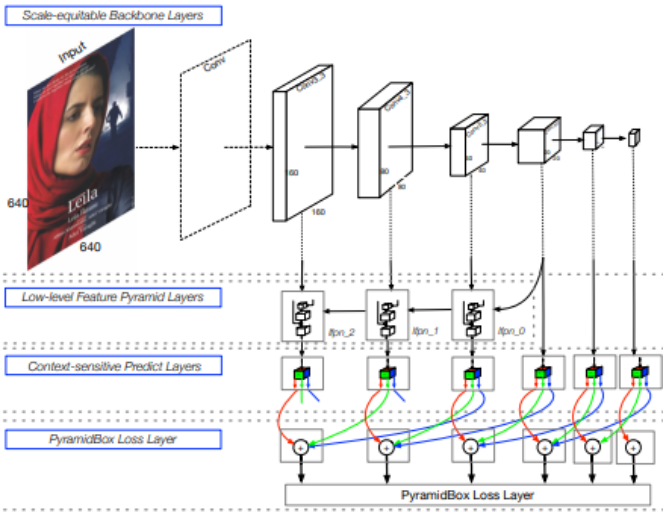


Figure 2.2 – Architecture de pyramidbox "Pyramidbox"

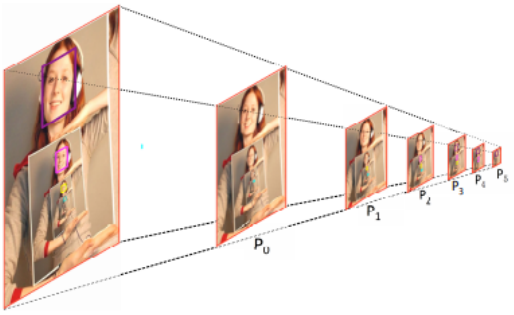


Figure 2.3 – Architecture de pyramidbox anchor

Pour l'entraînement, nous avons utilisé la fonction de perte de pyramidbox qui est représenté comme suit :

$$L(\{p_{k,i}\},\{t_{k,i}\}) = \sum_K \lambda_k L_k(\{p_{k,i}\},\{t_{k,i}\})$$

Avec la k éme fonction de perte de pyramidbox anchor est égale à :

$$L_k(\{p_{k,i}\},\{t_{k,i}\}) = \frac{\lambda}{N_{k,cls}} \sum_{i_k} L_{k,cls}(p_{k,i}, p^*_{k,i} + \frac{1}{N_{k,reg}} \sum_{i_k} p^*_{k,i}\, L_{k,reg}(t_{k,i}, t^*_{k,i})$$

Avec k est l'indice des pyramidbox anchors (k = 0, 1 et 2 représente respectivement la face, la tête et corps), et i est l'indice d'une ancre(anchor) et p_{ki} est la probabilité prévue que l'ancre i soit le k-ième objet (face, tête ou corps).

2.4.2 Solution proposée

Notre solution consiste à détecter les visages dans l'image d'entrée en affichant le nombre et la position des visages. Puis, faire passer la région du visage détectée dans le réseau d'intégration en profondeur fourni par dlib. Ce réseau produit ensuite l'incorporation de visage sur 128-d (c'est la phase d'extraction des paramètres).

Finalement, nous avons fait la phase de l'identification et la vérification faciale.

Architecture de réseau utilisé :

Nous avons utilisé le réseau métrique profonde CNN (CNN deep metric network), car elle est lente mais plus précise. Elle prend une visage d'entrée et calcule la

quantification sur 128-d de visage.

Ce modèle a été entraîné pendant trois jours et a atteint une précision de 99,38% avec l'ensemble de données "Labeled Faces in the Wild". Cela, signifie que, avec deux images de visage, il prédit correctement si les images sont de la même personne 99,38% du temps. Notre architecture de réseau pour la reconnaissance faciale est basée sur ResNet-34 avec 29 couches de convolutions.

Le corpus de données de test utilisé :

Bien évidemment, notre ensemble de données contient 811 images. Nous avons le crée en utilisant image search API pour les personnes connus mais dont 25 images sont manuellement ajoutées, ce sont les 4 dossiers sous les noms de "dhouha, oumayma, ghada et chayma" pour que nous puissions faire un test avec le cam.

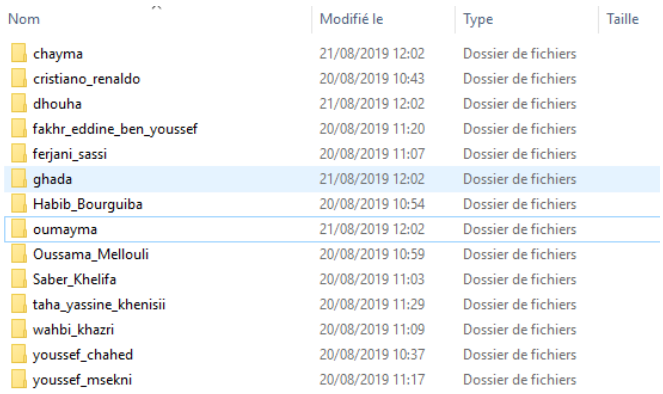


Figure 2.4 – Le corpus de données utilisé

2.5 Conclusion

Dans ce chapitre, nous avons présenté les différents ensembles de données utilisés pour la reconnaissance faciale. Ainsi, nous avons cité les outils utilisés pour l'accomplissement de notre travail. Finalement, nous avons décrire la méthodologie utilisée et parlé de notre solution.

Chapitre 3

Contributions

Sommaire

3.1 Introduction 46

3.2 Évaluer un système de reconnaissance faciale existant 47

3.3 Évaluer le réseau de neurone entraîné à partir de zéro 47

3.4 Réaliser un système de reconnaissance faciale 48

3.4.1 Détection de visage 48

3.4.2 Extraction des paramètres 49

3.4.3 Résultat de l'identification et la vérification 50

3.4.4 Discussion des résultats 53

3.5 Conclusion 54

Conclusion générale 55

3.1 Introduction

Dans ce chapitre nous avons évalué le système de reconnaissance faciale existant. De surcroît, nous avons évalué le réseau de neurone que nous avons entraîné à partir de zéro. Finalement, nous avons affiché le résultat de notre solution, dans laquelle nous avons parlé de la détection de visage, l'extraction de paramètres,

les résultats de l'identification et la vérification faciale et finalement, nous avons discuté ces résultats.

3.2 Évaluer un système de reconnaissance faciale existant

Après la phase de test, nous avons évalué un système de reconnaissance faciale existant, déjà décrit dans la partie"méthodologie et solution proposé" avec l'ensemble de données LFW (déjà décrit dans la section "ensemble de données et outils utilisés").
En plus de taux de précision "Accuracy", nous avons utilisé le taux d'erreur (EER) en tant que métrique dévaluation. Après l'évaluation de ce modèle en utilisant LFW, on a obtenu les résultats dans le tableau"Table 3.1".

Précision	Taux de validation	Taux d'erreur
0.98867+-0.00306	0.92067+-0.2265	0.011

Table 3.1 – Résultat de l'évaluation

3.3 Évaluer le réseau de neurone entraîné à partir de zéro

Après la phase d'entraînement de réseau à partir de zéro décrite dans la partie"méthodologie et solution proposé" nous avons l'évalué en utilisant l'ensemble de données WIDER FACE. Cet ensemble de données est divisé en trois sous-ensembles qui sont : entraînement (40%), validation (10%) et test (50%), où les deux validation et test sont divisés en"facile", "moyen" et"difficile" selon les difficultés de la détection. Nous avons obtenu les résultats suivants :

État	Facile	Moyenne	Difficile
Taux de précision (%)	90,6	88,8	73,4

Table 3.2 – Taux de précision

Vous trouvez ci joint les images explicatives de ce taux de précision.

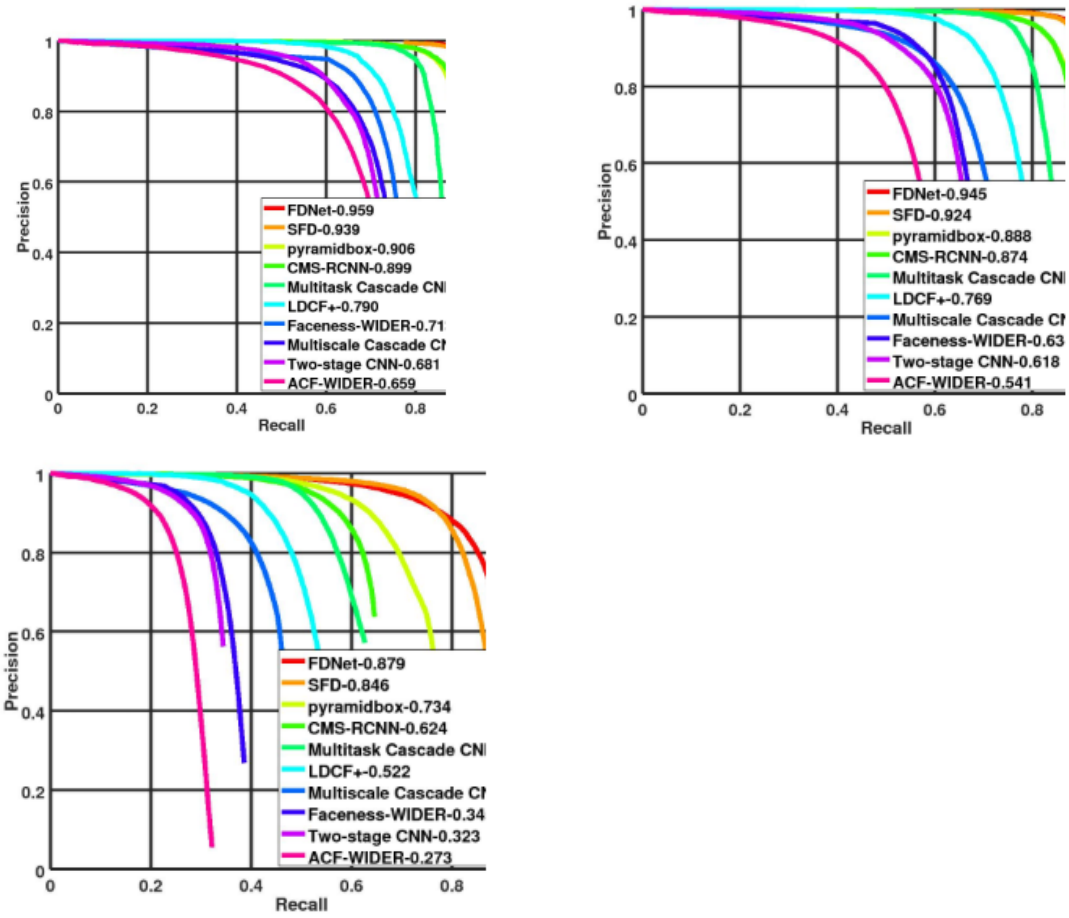
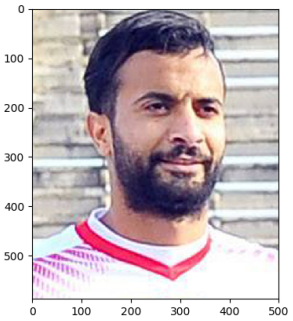


Figure 3.1 – Taux de précision pour chaque état, facile, moyenne et difficile

3.4 Réaliser un système de reconnaissance faciale

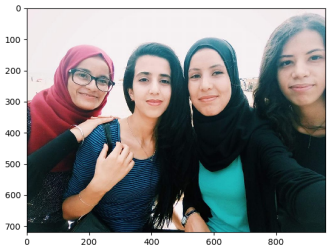
3.4.1 Détection de visage

Détecté un visage c'est la faite d'ajouter une image puis d'afficher la position de visage dans cette dernière. Bien évidemment, nous avons ajouté la tâche qui consiste à afficher le nombre de visage aussi détecté. Voici quelques exemples qui confirme ça.




```
(face recognition) C:\Users\admin\PycharmProjects\face_recognition_in_image+in_video
 j'ai détecté 1 visages dans cette image
Le visage est localisé comme à : top:112 , right :438 , bottom:379,left:171
```

Figure 3.2 – Détection d'un seule visage dans l'image




```
(face recognition) C:\Users\admin\PycharmProjects\face_recognition_in_image+in_video>py
 j'ai détecté 4 visages dans cette image
Le visage est localisé comme à : top:196 , right :468 , bottom:325,left:339
Le visage est localisé comme à : top:167 , right :648 , bottom:322,left:494
Le visage est localisé comme à : top:167 , right :287 , bottom:322,left:132
Le visage est localisé comme à : top:118 , right :960 , bottom:304,left:778
```

Figure 3.3 – Détection de 4 visages dans l'image

3.4.2 Extraction des paramètres

Elle se fait lorsque nous avons détecté le visage dans l'image, puis l'encodé en renvoyant les caractéristiques de celle-ci et que nous l'avons enregistré dans un fichier. Dans notre cas, nous avons le nommé "encodings2.pickle". Avant de pouvoir reconnaître les visages dans les images et les vidéos, nous devons d'abord quantifier les visages de notre ensemble de données afin de créer 128-d embeddings. Ce dernier signifie qu'il prend en entrée une image et renvoie un vecteur incorporé de 128-d représentant la représentation de l'image dans un espace euclidien de dimension 128.

Vous pouvez voir ici un exemple du contenu de notre fichier "encodings2.pickle", il contient les noms des personnes et chaque nom est répété autant de fois que le nombre des images de notre ensemble de données. (Voir figure 2.5). Et vous voyez aussi un exemple de 128-d embeddings d'un visage détecté (voir figure 3.3).


4.06419188e-02, -1.12288103e-01, 4.40947600e-02, 8.17383304e-02])], 'names': ['cristiano_renaldo', 'cristiano_renaldo', 'cristiano_renaldo', 'cristiano_renaldo', 'cristiano_renaldo', 'cristiano_renaldo', 'cristiano_renaldo', 'cristiano_renaldo', 'cristiano_renaldo', 'cristiano_renaldo', 'fakhr_eddine_ben_youssef', 'fakhr_eddine_ben_youssef', 'fakhr_eddine_ben_youssef

Ce dernier se déroulera en comparant les 128-d embeddings de l'image qu'on veut l'utiliser et les 128-d embeddings existant dans le fichier encodings2.pickle.
Vous trouvez ici quelques exemples :

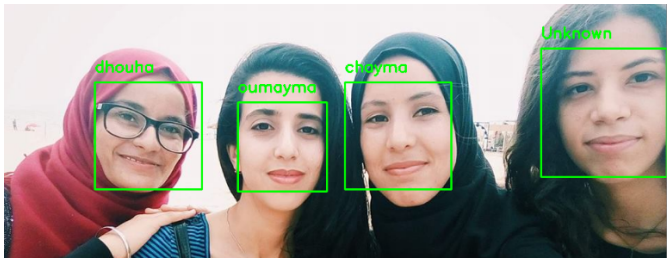


Figure 3.7 – Identification d'un groupe de personne

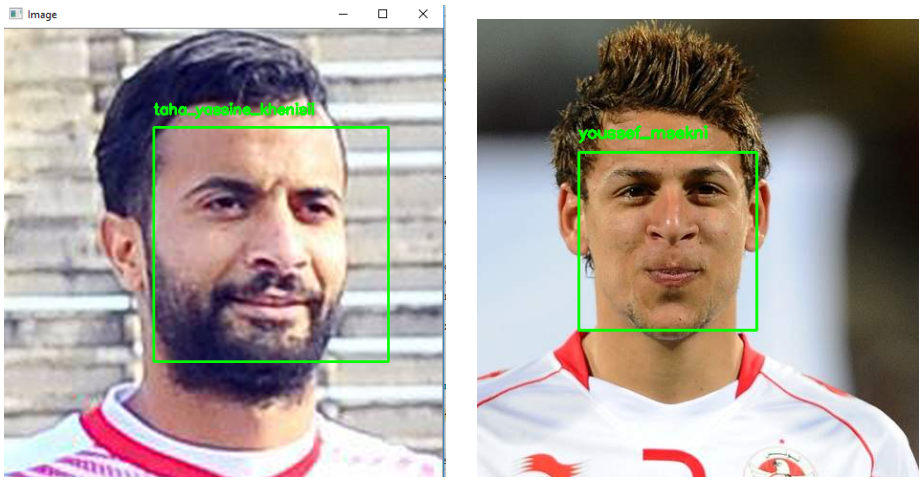


Figure 3.8 – Identification d'un seul visage dans une image

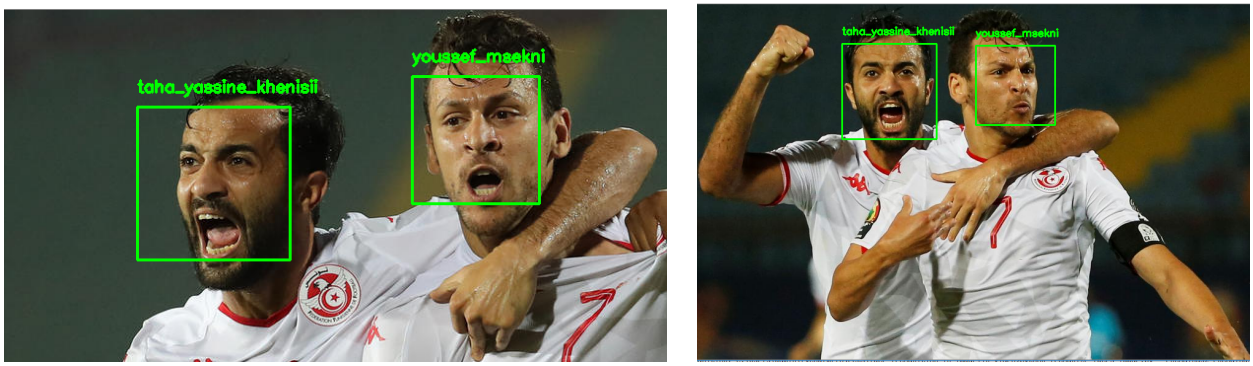


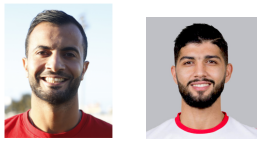
Figure 3.9 – Identification de deux visages dans une image

Nous avons aussi fait la tâche de la vérification faciale dans laquelle en comparant deux images, nous avons trouvé si ces deux images appartiennent à la même personne ou non.
En réalité, les images de la même personne sont proches tandis que les images de personnes différentes sont éloignées. Il est donc possible de déterminer si deux images représentent la même personne en évaluant la distance euclidienne entre les représentations des deux images. Si oui, le résultat est vrai, si non le résultat est faux.



```
(face recognition) C:\Users\admin\PycharmProjects\face_recognition_in_image+in_video>python face_verification.py
[True]
```

Figure 3.10 – La vérification de visage d'une même personne



```
(face recognition) C:\Users\admin\PycharmProjects\face_recognition_in_image+in_video>python face_verification.py
[False]
```

Figure 3.11 – La vérification de visage de deux personnes différents

Dans le même ordre d'idée nous avons aussi appliqué notre programme pour la reconnaissance de visage à partir de web cam. Dans ce cas, de la même façon que l'identification de visage dans une image nous avons affiché le nom de la personne détectée sur le visage. Et enfin nous avons enregistré tous les mouvements de la tête dans un vidéo. Vous trouvez ici un exemple de ma propre visage capter par le cam et identifié en retournant mon nom "dhouha".



Figure 3.12 – Reconnaissance de visage détecté par web cam

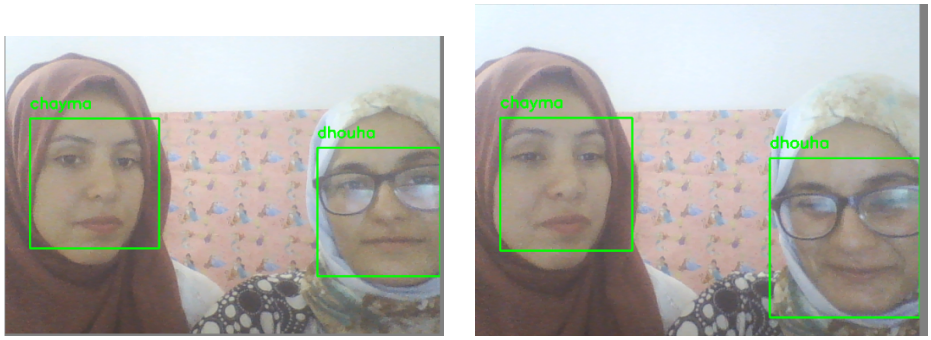


Figure 3.13 – Reconnaissance de visage détecté par web cam

3.4.4 Discussion des résultats

En fait, le processus de détection, d'identification et de vérification ne prend pas beaucoup de temps. Il nécessite juste quelques secondes. Dans notre cas, ce tableau explique bien le temps écoulé pour détecter et identifier les visages de quelques images que nous avons identifié précédemment (figures 3.6, 3.7 et 3.8).

Nombre de visages	1	2	4
Temps de la détection (secondes)	0.46	0.85	0.99
Temps de l'identification(secondes)	2.15	2.41	4.04

Table 3.3 – Temps nécessaire pour la détection et l'identification

On remarque que, le temps de détection est inférieur au temps d'identification. Cela est totalement logique, puisque pendant l'identification il est nécessaire de consulter le fichier "embeddings2.pickle" et on fait la comparaison avec les caractéristiques de l'image détecté. Alors que, pour la détection, on s'intéresse seulement sur la position de visage et nombre de visages détecté dans l'image.

3.5 Conclusion

Durant ce chapitre nous avons parlé de divers choses entre autres, nous avons affiché les résultats de l'évaluation, nous avons parlé aussi de la détection de visage, puis de la notion d'extraction des paramètres. Finalement, nous avons affiché les résultats de l'identification et la vérification faciale dans une image et par web cam.

Conclusion générale

La reconnaissance faciale peut être utilisé comme une clé pour les solutions de sécurité dans de nombreuses organisations. Aujourd'hui, le système de reconnaissance de visage est de plus en plus utilisé dans le monde entier pour fournir une technologie de sécurité extrêmement sûre et fiable.

En outre, ce système offre de nombreux avantages par rapport à d'autres systèmes de sécurité biométrique telles que l'empreinte digitale.

Bien évidemment, la capacité de reconnaître les visages est très importante pour de nombreux aspects de la vie. Cela nous aide non seulement à reconnaître nos proches, mais nous permet également d'identifier des personnes que nous ne connaissons pas afin de pouvoir être plus conscients des dangers possibles.

Le but principal de ce stage était d'évaluer et tester un système de reconnaissance faciale existant, d'entraîner un réseau de neurone de zéro, et de développer un script qui fait l'identification et la vérification faciale.

Pour conclure, ce stage était très bénéfique dans la mesure où il m'a permis de mettre en pratique mes connaissances acquises lors de mon cursus académique et d'améliorer mes connaissances dans le domaine de deep learning.

Bibliographie

[1] Jun-Cheng Chen, Vishal M Patel, and Rama Chellappa. Unconstrained face verification using deep cnn features. In 2016 IEEE winter conference on applications of computer vision (WACV), pages 1–9. IEEE, 2016.

[2] Gérard Dreyfus et al. Les réseaux de neurones. Mécanique industrielle et matériaux, 51, 1998.

[3] Andrzej Drygajlo. Automatic speaker recognition for forensic case assessment and interpretation. In Forensic Speaker Recognition, pages 21–39. Springer, 2012.

[4] Anil Jain, Lin Hong, and Sharath Pankanti. Biometric identification. Communications of the ACM, 43(2) :90–98, 2000.

[5] Anil K Jain, Patrick Flynn, and Arun A Ross. Handbook of biometrics. Springer Science & Business Media, 2007.

[6] Anil K Jain, Arun Ross, Salil Prabhakar, et al. An introduction to biometric recognition. IEEE Transactions on circuits and systems for video technology, 14(1), 2004.

[7] Anil K Jain, Arun A Ross, and Karthik Nandakumar. Introduction to biometrics. Springer Science & Business Media, 2011.

[8] Ira Kemelmacher-Shlizerman, Steven M Seitz, Daniel Miller, and Evan Brossard. The megaface benchmark : 1 million faces for recognition at scale. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 4873–4882, 2016.

[9] Davide Maltoni, Dario Maio, Anil K Jain, and Salil Prabhakar. Handbook of fingerprint recognition. Springer Science & Business Media, 2009.

[10] Lemmouchi Mansoura. Identification des visages humains par réseaux de neurones. PhD thesis, 2013.

[11] Manuela Marzotti and Cristina Nardini. Biometric authentication using voice. TDDC03 Projects, 2006.

[12] Hong-Wei Ng and Stefan Winkler. A data-driven approach to cleaning large face datasets. In 2014 IEEE International Conference on Image Processing (ICIP), pages 343–347. IEEE, 2014.

[13] Gabriel Panis and Andreas Lanitis. An overview of research activities in facial age estimation using the fg-net aging database. In European Conference on Computer Vision, pages 737–750. Springer, 2014.

[14] Omkar M Parkhi, Andrea Vedaldi, Andrew Zisserman, et al. Deep face recognition. In bmvc, volume 1, page 6, 2015.

[15] Christine Irene Podilchuk and Xiaoyu Zhang. Face recognition using dct-based feature vectors, September 1 1998. US Patent 5,802,208.

[16] Florian Schroff, Dmitry Kalenichenko, and James Philbin. Facenet : A unified embedding for face recognition and clustering. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 815–823, 2015.

[17] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. arXiv preprint arXiv :1409.1556, 2014.

[18] Yi Sun, Xiaogang Wang, and Xiaoou Tang. Deep learning face representation from predicting 10,000 classes. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 1891–1898, 2014.

[19] Yaniv Taigman, Ming Yang, Marc'Aurelio Ranzato, and Lior Wolf. Deepface : Closing the gap to human-level performance in face verification. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 1701–1708, 2014.