Ecole Supérieure des Communications de Tunis



Rapport de stage d'ingénieur

Prédiction du kilométrage d'une voiture à l'aide du ML pour le Driver Monitoring

Organisme d'accueil :



Auteur :
Yasmine BOUMNIJEL

Encadré par :
Dr. Ferdaous CHAABANE

Année Universitaire : 2018/2019

Signatures

Remerciement

Avant tout développemnet sur expérience professtionnelle, il apparaît opportun de commencer ce rapport de stage par des remerciements, à ceux qui m'ont beaucoup appris au cours de ce stage , et même à ceux ont fait de ce stage un moment profitable. Aussi je remercie Dr. Ferdaous CHAABANE mon encadrante de stage qui m'a accompagné tout au long de cette expérience professionnelle avec beaucoup de patience et pédagogie. Je remercie également M. Walid MAAROUFI pour m'avoir donné l'opportunité de joindre le groupe SAGEMCOM. Enfin, je remercie l'ensemble des employés de SAGEMCOM pour les conseils qu'ils m'ont pu me prodiguer tout au long de ces deux mois.

Résumé

Ce stage s'inscrit dans le cadre de notre cursus académique du cycle d'ingénieur. L'objectif de ce travail est de mettre en pratique la théorie qu'on étudie tout au long de l'année.
Le travail demandé par l'organisme d'accueil SAGEMCOM est de prédire le kilométrage d'une voiture à l'aide de Machine Learning pour le Driver Monitoring ensuite nous devons faire une sorte de rapport sous forme d'un Dashboard pour afficher la prédiction et la comparer avec les kilométrages réalisés précedemment.

Mots clés : Machine Learning , Modèle, kilométrage, Python , Prédiction , Dashboard, Angular

Table des matières

1 Présentation de l'entreprise d'accueil **2**
1.1 Introduction . . . 2
1.2 Description de l'entreprise . . . 2
1.3 Activités de l'entreprise . . . 2
1.4 Organisation de l'entreprise . . . 3
1.5 Conclusion . . . 3

2 Contexte du projet et étude théorique **4**
2.1 Introduction . . . 4
2.2 Contexte et objectifs du projet . . . 4
2.3 Etude théorique . . . 4
2.3.1 Intelligence Artificielle . . . 4
2.3.2 Machine Learning . . . 5
2.3.2.1 Apprentissage supervisé . . . 5
2.3.2.2 Apprentissage non supervisé . . . 5
2.3.3 Relation entre l'intelligence artificielle et le Machine Learning . . . 5
2.4 Etapes du projet . . . 6
2.5 Feature Engineering . . . 7
2.5.1 Imputation . . . 8
2.5.2 Binning . . . 8
2.5.3 Feature Extraction . . . 8
2.5.4 Feature Selection . . . 9
2.6 Métriques d'évaluation . . . 9
2.7 Conclusion . . . 10

3 Implémentation et résultats **11**
3.1 Introduction . . . 11
3.2 Outils utilisés . . . 11
3.2.1 Outils Hardware . . . 11
3.2.2 Outils Software . . . 11
3.2.2.1 Les outils liés aux modèles de ML . . . 11
3.2.2.2 Outils logiciels . . . 13
3.2.2.3 Technologies et Frameworks . . . 13
3.3 Développement des modèles de Machine Learning . . . 14
3.3.1 Dataset . . . 14
3.3.2 Visualisation des données . . . 15
3.4 Features Selection . . . 17
3.5 Modélisation . . . 20
3.6 Evaluation . . . 26
3.7 Déploiement . . . 27
3.8 Conclusion . . . 27

Table des figures

1.1 Logo Sagemcom 2

2.1 Relation entre IA et ML 6
2.2 Etapes de réalisation 7
2.3 La répartition temporelle du travail d'un Data Scientist 7
2.4 Illustration du Binning pour des données numériques 8
2.5 Illustration du Feature Extraction 9
2.6 Illustration du Feature Selection 9

3.1 Logo de Python 12
3.2 Logo de Jupyter 12
3.3 Logo de Visual Studio Code 13
3.4 Logo de Angular 13
3.5 Logo de Flask 13
3.6 Les attributs du dataset de Renault 14
3.7 La taille du dataset de Renault 14
3.8 Vérification des valeurs manquantes 15
3.9 La taille du dataset du net 15
3.10 Nombre de voitures par VIN 16
3.11 La variation de la distance 16
3.12 Informations sur le dataset du Net. 17
3.13 Distribution de la distance dans le dataset du Net. 17
3.14 La matrice de corrélation des attributs du dataset de Renault. 18
3.15 Les attributs retenus du dataset de Renault 18
3.16 Les attributs retenus du dataset du Net 19
3.17 Les attributs retenus par XGBOOST Classifier du dataset de Renault 19
3.18 Les attributs retenus par XGBOOST Classifier du dataset du Net 20
3.19 Le process de Random Forest 21
3.20 La prédiction de XGBOOST Regressor pour le dataset de Renault 22
3.21 La prédiction de Random Forest Regressor pour le dataset de Renault 22
3.22 La prédiction de K Neighbors Regressor pour le dataset de Renault 23
3.23 La prédiction de Support Vector Regressor pour le dataset de Renault 23
3.24 Visualisation de la prédiction de SVR pour le dataset de Renault 23
3.25 La prédiction de KNR pour le dataset du Net 24
3.26 Visualisation de la prédiction de KNR pour le dataset du Net 24
3.27 La prédiction de SVR pour le dataset du Net 24
3.28 La prédiction de RFR pour le dataset du Net 25
3.29 La prédiction de XGBOOST Regressor pour le dataset du Net 25
3.30 La prédiction de ARIMA pour le dataset de Renault 26
3.31 Evaluation des modèles du dataset Renault 26
3.32 Evaluation des modèles du dataset du Net 27
3.33 L'interface de prédiction de la distance 27

Introduction générale

Bien que nous sommes de plus en plus habitués à lire et à relire les chiffres considérables liés aux données que nous générons, nous en sommes surpris à chaque nouvelle étude publiée. En 2018 par exemple, le nombre d'internautes autour du globe a dépassé les 4 milliards de personnes, soit plus de la moitié de l'humanité. Les données générées par l'utilisation des Smartphones et des objets connectés ont amené à estimer que le marché des données à l'échelle mondiale devrait doubler de valeur dans les dix prochaines années, passant de 42 à 103 milliards de dollars. Selon Accenture, 79% des dirigeants sont d'avis que les entreprises négligent le traitement et l'exploitation de leurs données, perdraient leur positionnement concurrentiel et se dirigeraient vers leur perte. Loin d'être une simple tendance, les données prennent de plus en plus d'importance dans de nombreux enjeux stratégiques. Pour faire face à la demande croissante de ressources capables de maîtriser et de tirer profit d'un flot conséquent de données, les métiers de Data Analyst, de Data Scientist et de Data Architect montent au front. Intéressée par le domaine de data, j'ai choisi d'effectuer un stage dans le domaine de data science au sein de SAGEMCOM. Ce rapport vise dans un premier temps à présenter l'entreprise d'accueil, par la suite nous allons passer à une étude théorique dans laquelle on présentera le contexte du projet et les grandes notions du projet. Nous décrirons ensuite l'implémentation et les résultats de ce stage et on finira par conclure.

Chapitre 1

Présentation de l'entreprise d'accueil

1.1 Introduction

Tout au long de ce chapitre, on va présenter l'organisme d'accueil où j'ai effectué mon stage. On va commencer par une description du groupe SAGEMCOM, on parlera par la suite de ses activités et on finira par décrire l'organisation de SAGEMCOM.

1.2 Description de l'entreprise

SAGEMCOM est un leader français dans le domaine des terminaux de communications de grande valeur sur le marché européen. Son siège social est situé à Rueil-Malmaison, une commune française, le centre nerveux du groupe, où se trouve un centre de R&D avec plus de 500 collaborateurs. En 2014, le Groupe SAGEMCOM investit plus de 75 millions d'euros dans sa RD. Avec 4 000 employés répartis dans plus de 50 pays, le groupe a réalisé des ventes de 2,05 milliards d'euros, et plus de 31,5 millions de terminaux sont conçus, fabriqués et livrés chaque année dans le monde entier. SAGEMCOM Software Technologies (SST) est une filiale du groupe SAGEMCOM qui a commencé ses activités en juillet 2005. Sa mission principale est de concevoir, développer et valider des logiciels embarqués qui répondent aux exigences du marché de la communication haut débit. SST rassemble en Tunisie environ 300 ingénieurs de développement et de

validation spécialisés dans le domaine des terminaux de communication à haute valeur ajoutée.



FIGURE 1.1 – Logo Sagemcom

1.3 Activités de l'entreprise

Grâce à sa culture commune fondée sur l'innovation, les progrès technologiques, la valeur ajoutée élevée et le temps nécessaire au marché, SST développe et produit une gamme complète de produits qui répondent aux marchés en forte croissance, en particulier dans trois grands marchés :

Broadband : SAGEMCOM Broadband est l'un des principaux fabricants européens de Set-Top Boxes et de portes résidentielles. Il propose des produits présentant les toutes dernières avancées technologiques, y compris les Set-Top Boxes qui sont compatibles avec tous les écosystèmes de la télévision, des passerelles résidentielles offrant un accès gigabit de bout en bout,

et des Boxes combinant l'accès à large bande et à la télévision dans un seul produit.

Smart City : SAGEMCOM possède plus de 50 ans d'expérience dans la conception et le déploiement de projets d'infrastructures de télécommunications (infrastructures de réseau et gestion de l'information), et plus de 20 ans d'expérience dans la mesure de l'énergie et de la mesure intelligente (eau, gaz et électricité), en déployant des solutions sûres et durables.

Internet des Objets (IOT) : SAGEMCOM propose une offre intégrée de bout en bout adaptée à l'Internet industriel des objets, basée sur la norme ouverte LoRaWAN. Cette offre couvre les modules radiofréquences utilisés pour connecter les éléments, jusqu'à l'ensemble du réseau d'infrastructure permettant à la fois la réception des données transmises par les capteurs, et le contrôle de ces éléments en émettant des commandes du réseau.

1.4 Organisation de l'entreprise

L'organisation de la SST consiste en une orientation opérationnelle, un service des ressources humaines, des services généraux, un service de qualité et les trois pôles suivants :

Pôle d'activités Décodeurs et Télévisions : Ce pôle comprend de nombreuses activités telles que la conception, le développement et la validation de logiciels embarqués STB, et l'intégration de briques de contrôle d'accès sur le décodeur.

Terminaux résidentiels Pôle d'activité : Ce pôle comprend de nombreuses activités telles que la conception, le développement et la validation de logiciels embarqués pour des passerelles résidentielles et professionnelles, offrant des services VoIP et la télévision, utilisant les technologies xDSL et FTTH.

Pôle Énergie et télécommunications : Ce pôle est ouvert récemment, il assure la conception, le développement et la validation de logiciels embarqués de compteurs d'électricité numérique, et il assure aussi l'innovation pour l'internet des objets basée sur la norme ouverte LoRaWAN.

1.5 Conclusion

Ce chapitre a été consacré à décrire l'organisme d'accueil et à comprendre ses activités et son organisation comme une étape d'introduction qui peut aider à mieux comprendre le milieu du travail.

Chapitre 2

Contexte du projet et étude théorique

2.1 Introduction

Dans ce chapitre nous allons expliquer tout d'abord le contexte du projet et les objectifs qui doivent être atteints à la fin ensuite nous allons parler des étapes qui doivent être suivies pour réaliser ce projet.

2.2 Contexte et objectifs du projet

Compte tenu de la diversité de ses produits et de la richesse de son expertise et de ses ressources humaines, l'ambition de SAGEMCOM est d'avoir un haut niveau de performance technique, économique et sociale afin de maintenir un leadership durable dans son domaine dans un environnement concurrentiel. Afin d'améliorer leur compétitivité et de développer leur productivité, SAGEMCOM a commencé à s'attaquer à d'autres domaines liés à la technologie de l'intelligence artificielle, en particulier la surveillance des conducteurs.
La prédiction du kilométrage de la voiture fait partie du grand thème de la surveillance des conducteurs et surtout de ses comportements routiers, d'où l'utilité de notre projet.
L'objectif principal de ce projet est de créer un modèle de Machine Learning qui nous informe sur le comportement des conducteurs vis-à-vis du kilométrage réalisé.

2.3 Etude théorique

Une recherche approfondie, qui utilise divers types de ressources, a permis de définir certaines normes et concepts de base. Par conséquent, cette partie est dédiée à présenter les étapes qui sont liés à la réalisation de notre projet. En fait, nous définissons d'abord quelques termes essentiels pour comprendre le thème du sujet et mettre ce projet dans un cadre clair. Ensuite, nous exposons brièvement les principales bases de ML pour comprendre quels types de modèles sont les plus adaptés aux spécifications du projet.

2.3.1 Intelligence Artificielle

L'intelligence artificielle ou IA est une discipline scientifique dont le but est la recherche de moyens susceptibles de doter les systèmes informatiques de capacités intellectuelles comparables à celles des êtres humains.
Deux écoles se distinguent dans l'approche des objectifs de l'intelligence artificielle :
La première considère que l'IA doit fonctionner sur le même modèle que l'intelligence humaine.
La seconde préconise un modèle idéal, dont la perfection rationnelle serait dissociée des critères et processus de l'intelligence biologique.

2.3.2 Machine Learning

Le machine learning est une méthode d'analyse des données qui automatise la création de modèles analytiques. C'est une branche de l'intelligence artificielle qui repose sur l'idée que les systèmes peuvent apprendre des données, identifier des tendances et prendre des décisions avec un minimum d'intervention humaine.
Le regain d'intérêt pour le machine learning s'explique par des facteurs qui sont également à l'origine de l'incroyable popularité du data mining et de l'analyse bayésienne : multiplication et diversification des données disponibles, puissance de calcul plus importante et moins coûteuse, stockage des données plus économique.
Les deux méthodes de machine learning les plus utilisées sont l'apprentissage supervisé et l'apprentissage non supervisé.

2.3.2.1 Apprentissage supervisé

Les algorithmes d'apprentissage supervisé sont entraînés sur des exemples étiquetés, c'est-à-dire une entrée dont le résultat attendu est connu. L'algorithme d'apprentissage reçoit une série de données en entrée avec les sorties correctes correspondantes, et apprend en comparant la sortie réelle avec les sorties correctes. Il modifie alors le modèle en conséquence.
Cette méthode d'apprentissage est couramment utilisée dans les applications où les données historiques servent à prévoir des événements futurs probables.

2.3.2.2 Apprentissage non supervisé

L'apprentissage non supervisé s'applique aux données sans étiquettes historiques. Dans ce cas, le système ne connaît pas la « bonne réponse ». C'est à l'algorithme de déterminer le modèle présenté. Le but est d'explorer les données et d'en découvrir la structure. L'apprentissage non supervisé fonctionne bien avec les données transactionnelles.

2.3.3 Relation entre l'intelligence artificielle et le Machine Learning

L'intelligence artificielle signifie que les machines peuvent effectuer des tâches de manière "intelligente". Ces machines ne sont pas simplement programmées pour faire un seul mouvement répétitif mais plus que ça , elles peuvent faire plus en s'adaptant à différentes situations.
Le Machine Learning est techniquement une branche de l'intelligence artificiell, mais c'est plus spécifique que le concept global. L'apprentissage automatique est basé sur l'idée que nous pouvons construire des machines pour traiter les données et apprendre par eux-mêmes, sans notre supervision constante.
Les deux concepts semblent très similaires, mais en quoi diffèrent-ils ? Fondamentalement, l'IA est l'intelligence, celle qui dote les machines de leur apparente intelligence, alors que le machine learning consiste en l'application de méthodes de calcul qui la soutiennent. En d'autres termes, l'IA est la science et le machine learning, le logiciel et les algorithmes qui rendent les machines intelligentes.

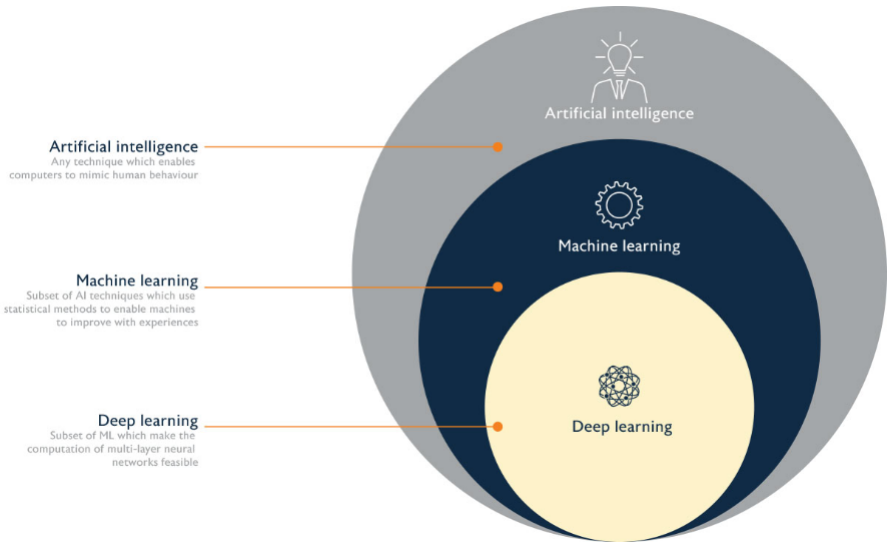


FIGURE 2.1 – Relation entre IA et ML

2.4 Etapes du projet

Pour élaborer un modèle d'apprentissage, il convient de suivre les étapes décrites ci-dessous :

Data Gathering : Choisir les meilleures données qui aident à construire un modèle robuste, l'ensemble de données peut être collecté à partir de diverses sources telles qu'un fichier, une base de données, un capteur et de nombreuses autres sources.

Data pre-processing : C'est l'étape la plus importante qui aide à construire des modèles d'apprentissage machine plus précisément. Le prétraitement des données est un processus de nettoyage des données brutes des données manquantes, des données bruyantes et des données incohérentes, qui peut être utilisé pour former le modèle.

Model researching : L'objectif principal est de former le modèle le plus performant possible en utilisant les données prétraitées. Pour cela, il est nécessaire d'avoir une image claire des données. Il est donc important de :

- Comprendre les données ; le type de données.
- Catégoriser le problème ; les données sont étiquetées ou non et la sortie est un nombre, une classe ou un ensemble de groupes d'entrée.
- Comprendre les contraintes ; la capacité de stockage des données et la prédiction et la vitesse d'apprentissage souhaitées.

Training et Testing : Décomposer le jeu de données en ensembles de formation et de tests pour la validation, construire un modèle et un paramètre de réglage.

Evaluation : Elle aide à trouver le meilleur modèle qui représente les données et à déterminer dans quelle mesure le modèle choisi fonctionnera à l'avenir en utilisant certains critères de qualité qui sont expliqués plus loin en détail.
La figure ci-dessous résume les étapes mentionnées ci-dessus

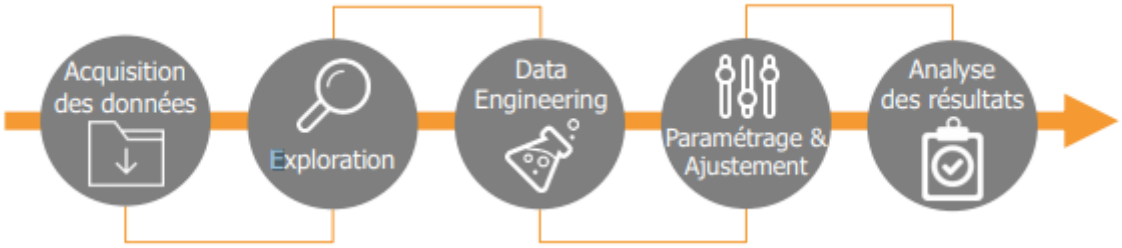


FIGURE 2.2 – Etapes de réalisation

2.5 Feature Engineering

En gros, tous les algorithmes de Machine Learning utilisent des données d'entrée pour créer des sorties. Ces données d'entrée comprennent des fonctions, généralement sous forme de colonnes structurées. Les algorithmes nécessitent des fonctionnalités ayant des caractéristiques spécifiques pour fonctionner correctement. Dans ce cas, la nécessité de l'ingénierie des caractéristiques ,ou Feature Engineering, se fait sentir. Selon une enquête réalisée à Forbes, comme indiqué ci-dessous dans la figure 2.3, les Data Scientists consacrent 80% de leur temps à la préparation des données :

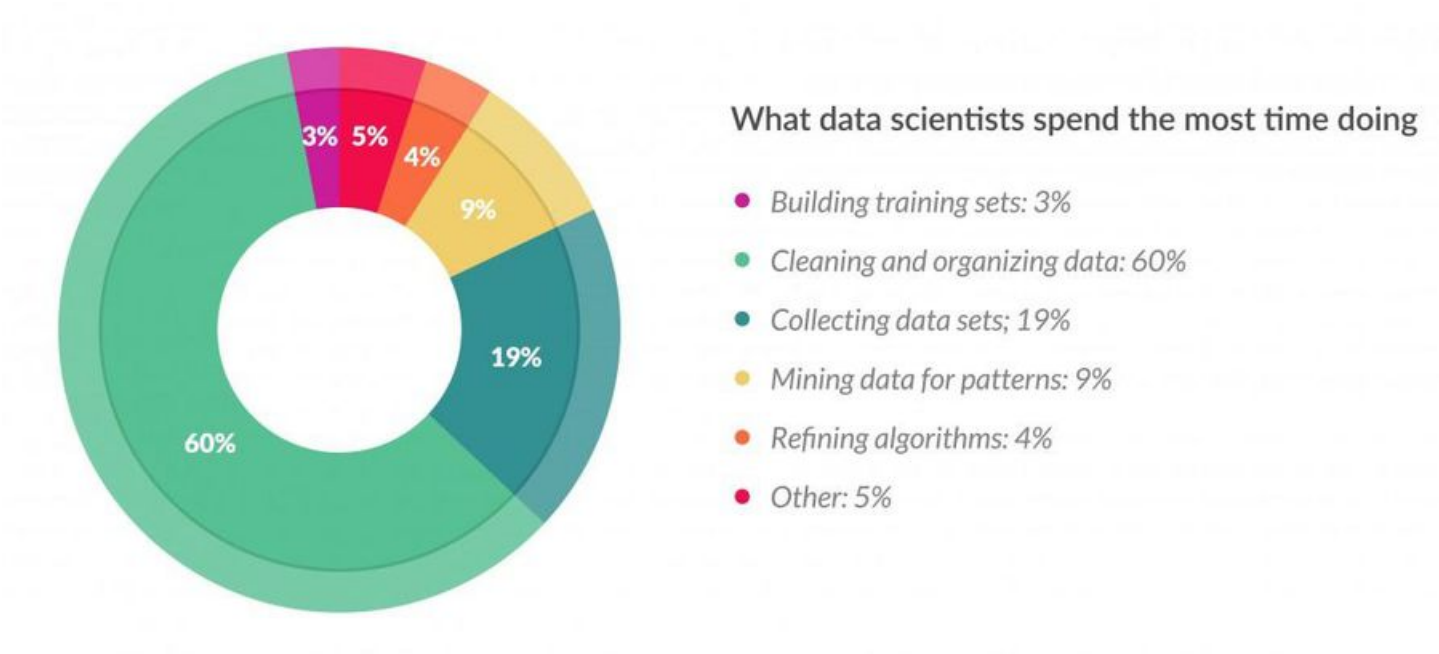


FIGURE 2.3 – La répartition temporelle du travail d'un Data Scientist

Parmi les techniques de Featuring Engineering utilisées, on peut citer :

2.5.1 Imputation

Les valeurs manquantes sont l'un des problèmes les plus courants que vous pouvez rencontrer lorsque vous essayez de préparer vos données pour l'apprentissage automatique. Les valeurs manquantes peuvent être dues à des erreurs humaines, à des interruptions dans le flux de données, à des problèmes de confidentialité, etc. Quelle que soit la raison, les valeurs manquantes affectent les performances des modèles d'apprentissage automatique.
Certaines plateformes de MachineLearning abandonnent automatiquement les lignes qui incluent des valeurs manquantes dans la phase de formation du modèle et cela diminue les performances du modèle en raison de la réduction de la taille de la formation. D'un autre côté, la plupart des algorithmes n'acceptent pas les datasets avec des valeurs manquantes et donnent une erreur.
La solution la plus simple pour les valeurs manquantes est de supprimer les lignes ou la colonne entière.
L'imputation est une option plus préférable que la suppression, car elle préserve la taille des données. Cependant, il y a une sélection importante de ce que nous imputons aux valeurs manquantes.
Une des solutions utilisées comme imputation est de remplacer les valeurs manquantes par la valeur maximale d'occurrence dans une colonne.

2.5.2 Binning

La principale motivation du Binning est de rendre le modèle plus robuste et d'empêcher le Overfitting , cependant, il est coûteux en terme de performance.
La figure 2.4 illustre le concept du binning :

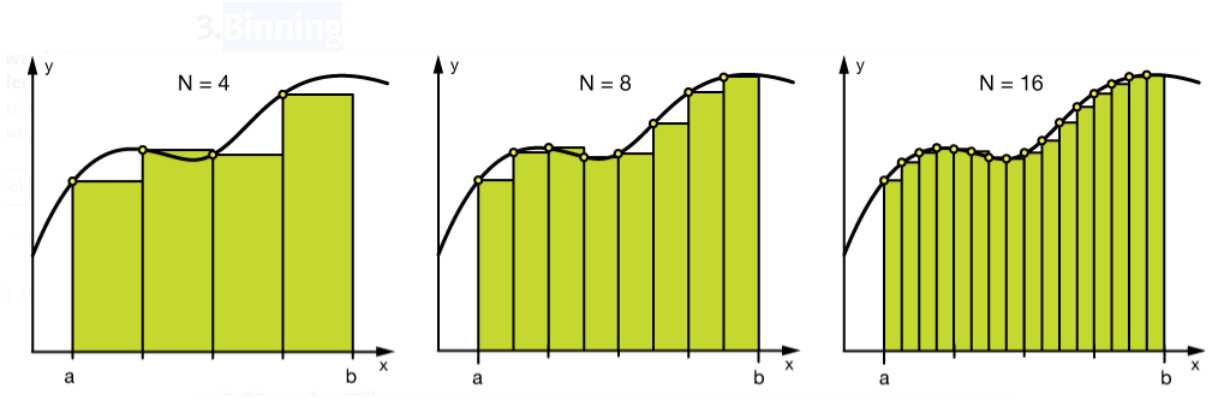


FIGURE 2.4 – Illustration du Binning pour des données numériques

2.5.3 Feature Extraction

il s'agit d'extraire des informations afin de représenter la série chronologique comme un vecteur de traits, comme min, max, medium ou d'autres dérivations mathématiques.
La figure ci-dessous illustre le concept de l'extraction des attributs.

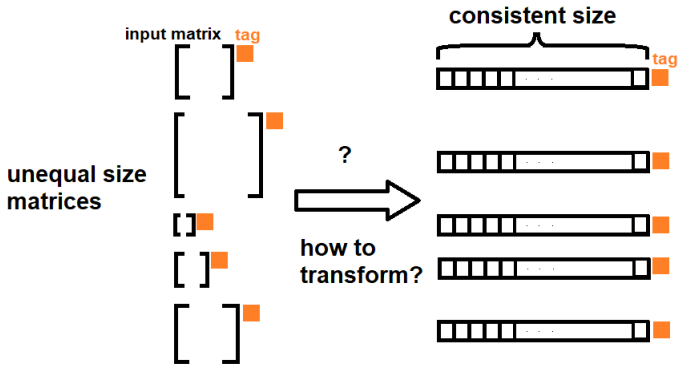


FIGURE 2.5 – Illustration du Feature Extraction

2.5.4 Feature Selection

C'est la sélection automatique des attributs dans nos données (comme les colonnes dans les données tabulaires) qui sont les plus pertinents pour le problème de modélisation prédictive sur lequel nous travaillons.
Feature Selection est le processus de sélection d'un sous-ensemble de fonctions pertinentes à utiliser dans la construction de modèles.
La sélection des attributs est différente de la réduction des dimensions. Les deux méthodes cherchent à réduire le nombre d'attributs dans le dataset, mais une méthode de réduction des dimensions le fait en créant de nouvelles combinaisons d'attributs, alors que les méthodes de sélection des fonctions incluent et excluent les attributs présents dans les données sans les modifier.
La figure ci-dessous est une illustration du la séléction des attributs

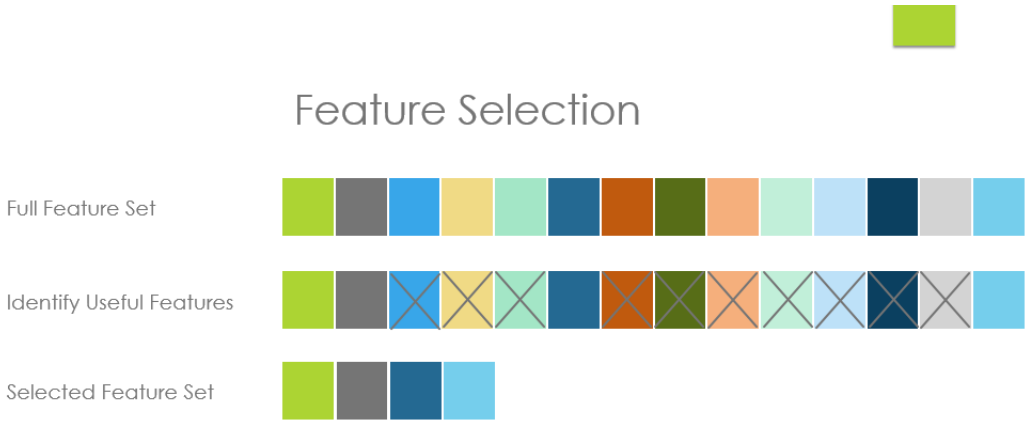


FIGURE 2.6 – Illustration du Feature Selection

2.6 Métriques d'évaluation

L'évaluation des modèles fait partie intégrante du processus de développement des modèles. Il est utile de trouver le meilleur modèle qui représente nos données et dans quelle mesure le modèle choisi fonctionnera à l'avenir.
Pour les algorithmes de régression, quatre mesures d'évaluation sont couramment utilisées :

R-Squared : C'est une mesure statistique qui représente la proportion de la variance d'une variable dépendante expliquée par une ou plusieurs variables indépendantes dans un modèle de régression. Alors que la corrélation explique la force de la relation entre une variable indépendante et dépendante, R-squared détermine dans quelle mesure la variance d'une variable explique la variance de la seconde variable. Donc, si la R-squared d'un modèle est 0,50, alors environ la moitié de la variation observée peut être expliquée par les entrées du modèle.

Mean Absolute Error (MAE) : Le MAE mesure l'ampleur moyenne des erreurs dans un ensemble de prédictions, sans tenir compte de leur direction. C'est la moyenne sur l'échantillon d'essai des différences absolues entre la prédiction et l'observation réelle où toutes les différences individuelles ont un poids égal.

Mean Squared Error (MSE) : MSE est une mesure de qualité de modèle. Il vaut mieux se rapprocher de zéro. La MSE mesure la moyenne des carrés des erreurs ou des écarts. MSE prend les distances entre les points et la ligne de régression (ces distances sont les "erreurs") et les place ensuite pour supprimer tout signe négatif. Le MSE incorpore à la fois la variance et le biais du prédicteur.

Root Mean Squared Error (RMSE) : C'est la racine carrée de la moyenne des erreurs carrées. RMSE est une règle de notation quadratique qui mesure également l'ampleur moyenne de l'erreur. C'est la racine carrée de la moyenne des différences carrées entre la prévision et l'observation réelle. .

2.7 Conclusion

Dans ce chapitre, nous avons commencé par clarifier le contexte et les objectifs du projet qu'on pourrait résumer dans deux mots comme étant le comportement des conducteurs. Puis nous avons entamé la partie théorique où nous avons expliqué le déroulement du projet et nous avons éclaircis quelques notions.

Chapitre 3

Implémentation et résultats

3.1 Introduction

Après avoir fait l'étude théorique de ce projet , nous allons maintenant entamer la partie implémentation. Nous parlerons dans un premier temps des outils utilisés puis nous détaillerons les modèles utilisés et on finira par le déploiement de la solution.

3.2 Outils utilisés

Dans cette partie, l'environnement de travail est brièvement présenté en affichant le matériel et les outils logiciels ainsi que les différentes bibliothèques utilisées pour implémenter et valider la solution.

3.2.1 Outils Hardware

Le temps d'apprentissage des modèles de ML dépend de la puissance de calcul, de la mémoire disponible et du temps de l'unité de traitement centrale. Les matériaux qui ont été utilisés pour développer et valider la fonctionnalité de solution appartiennent à SAGEMCOM. La société d'accueil nous fournit l'ordinateur nécessaire pour réaliser le développement et la validation de la solution. Les caractéristiques de cet ordinateur sont :

CPU : Intel(R) Core (TM) i3.

OS : Windows 10

Mémoire : 8 GB

Disque dur : 1 TB

.

3.2.2 Outils Software

Pour développer notre solution, plusieurs logiciels et technologies ont été utilisés.

3.2.2.1 Les outils liés aux modèles de ML

Les modèles de ML utilisés dans notre étude sont écrits avec le langage Python qui est un langage de programmation interprété de haut niveau, open-source, multi-paradigme et multi-plateformes.



FIGURE 3.1 – Logo de Python

Pour l'environnement de travail, nous avons choisi de travailler avec Jupyter Notebook.
Les notebooks Jupyter sont des cahiers électroniques qui, dans le même document, peuvent rassembler du texte, des images, des formules mathématiques et du code informatique exécutable. Ils sont manipulables interactivement dans un navigateur web.
Initialement développés pour les langages de programmation Julia, Python et R (d'où le nom Jupyter), les notebooks Jupyter supportent près de 40 langages différents.
La cellule est l'élément de base d'un notebook Jupyter. Elle peut contenir du texte formaté au format Markdown ou du code informatique qui pourra être exécuté.



FIGURE 3.2 – Logo de Jupyter

Pour réaliser notre travail, nous avons utilisé les librairies disponibles sur Python. On peut citer par exemple :

- ***Scikit-learn :*** C'est une librairie de Machine Learning. Elle comporte divers algorithmes de classification, de régression et de clustering et est conçu pour interagir avec les bibliothèques numériques et scientifiques Python. C'est un outil simple et efficace pour l'exploration et l'analyse des données.
- ***Matplotlib :*** C'est une librairie de traçage Python 2D qui produit des figures de qualité de publication dans divers formats papier et environnements interactifs à travers les plates-formes. Matplotlib peut être utilisé dans les scripts Python, les shell Python et IPython, le bloc-notes Jupyter, les serveurs d'applications web et quatre boîtes à outils d'interface utilisateur graphique.
- ***Numpy :*** NumPy (diminutif de Numerical Python) fournit une interface pour stocker et effectuer des opérations sur les données. D'une certaine manière, les tableaux Numpy sont comme les listes en Python, mais Numpy permet de rendre les opérations beaucoup plus efficaces, surtout sur les tableaux de large taille. Les tableaux Numpy sont au cœur de presque tout l'écosystème de data science en Python.
- ***Pandas :*** Pandas est une librairie ouverte offrant des structures de données et des outils d'analyse de données très performants et faciles à utiliser pour le langage de programmation Python. Python a longtemps été très utile pour la manipulation et la préparation des données, mais moins pour l'analyse et la modélisation des données. Pandas vous aide à combler cette lacune, vous permettant d'effectuer l'intégralité de votre flux de travail d'analyse de données en Python.

3.2.2.2 Outils logiciels

Un logiciel a été principalement utilisé dans la phase déploiement du projet.

- ***Visual Studio Code :*** C'est un éditeur de code redéfini et optimisé pour la création et le débogage d'applications web et cloud modernes.



FIGURE 3.3 – Logo de Visual Studio Code

3.2.2.3 Technologies et Frameworks

- ***Angular 8 :*** Angular est un framework côté client open source basé sur TypeScript dirigée par l'équipe du projet Angular à Google et par une communauté de particuliers et de sociétés. Angular est une réécriture complète de AngularJS, cadriciel construit par la même équipe.



FIGURE 3.4 – Logo de Angular

- ***Flask :*** C'est un framework open-source de développement web en Python. Son but principal est d'être léger, afin de garder la souplesse de la programmation Python, associé à un système de templates.



FIGURE 3.5 – Logo de Flask

3.3 Développement des modèles de Machine Learning

Cette partie est dédiée à la description de la mise en oeuvre de quelques modèles de Machine Learning qui vont servir à prédire le kilométrage réalisé par un conducteur. Nous avons déjà mentionné dans le chapitre précédent les étapes par lesquelles nous devons passer pour créer notre modèle et prédire notre sortie. Nous allons tout d'abord commencer par décrire notre jeu de données.

3.3.1 Dataset

Durant ce projet, nous avons eu l'occasion de travailler avec deux types de dataset.

- Le premier jeu de données est une base de données de type JSON fournie par SAGEMCOM, qui travaille en collaboration avec Renault. Cette base de données contient bien évidemment des informations des voitures de la marque Renault. On trouve dans ce fichier 16 attributs. Nous avons divisé l'attribut date en 5 attributs qui sont l'année, le mois , le jour , l'heure et la minute et cette division va servir dans la visualisation des données. La figure 3.6 nous renseigne sur le nom des attributs :

```
df.columns
```

```
Index(['vehicleUuid', 'vin', 'averageSpeed', 'consumedFuel', 'distance',
       'duration', 'endDate', 'endLatitude', 'endLongitude', 'fleetId',
       'startDate', 'startLatitude', 'startLongitude', 'timestamp', 'date',
       'year', 'month', 'day', 'hour', 'minute'],
      dtype='object')
```

FIGURE 3.6 – Les attributs du dataset de Renault

L'attribut qu'on doit prédire est la distance. Notre base de données contient des informations sur 289 observations comme l'illustre la figure ci-dessous :

```
df.shape
```

```
(289, 20)
```

FIGURE 3.7 – La taille du dataset de Renault

Notre jeu de données ne contient ni des valeurs nulles , ni des valeurs manquantes donc nous pouvons zapper l'étape de nettoyage de données.

```
df.isna().sum()
```

```
vehicleUuid       0
vin               0
averageSpeed      0
consumedFuel      0
distance          0
duration          0
endDate           0
endLatitude       0
endLongitude      0
fleetId           0
startDate         0
startLatitude     0
startLongitude    0
timestamp         0
date              0
year              0
month             0
day               0
hour              0
minute            0
dtype: int64
```

FIGURE 3.8 – Vérification des valeurs manquantes

Remarque : Nous avons transformé le fichier JSON en dataframe pour qu'on puisse appliquer les méthodes de Python.

- Le deuxième jeu de données est un un fichier csv que nous avons trouvé sur le net. Ce fichier contient des informations sur 388 observations et contient 13 attributs : distance , FuelEconomy , averageSpeed , temp_inside , temp_outside , specials,gas_type , AC , rain , sun , refill liters et refill gas, comme l'indique la figure 3.8 :

```
df.columns
```

```
Index(['distance', 'FuelEconomy', 'averageSpeed', 'temp_inside',
       'temp_outside', 'specials', 'gas_type', 'AC', 'rain', 'sun',
       'refill liters', 'refill gas', 'Fuelconsumption'],
      dtype='object')
```

FIGURE 3.9 – La taille du dataset du net

Dans tout ce qui suit , les étapes du développement du modèle seront réalisées sur les deux datasets.

3.3.2 Visualisation des données

Commençons par le dataset fourni par Renault. La figure ci-dessous illustre le nombre de voiture par vin.

```
df.vin.value_counts().plot(kind="barh")
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x1d99e645390>
```

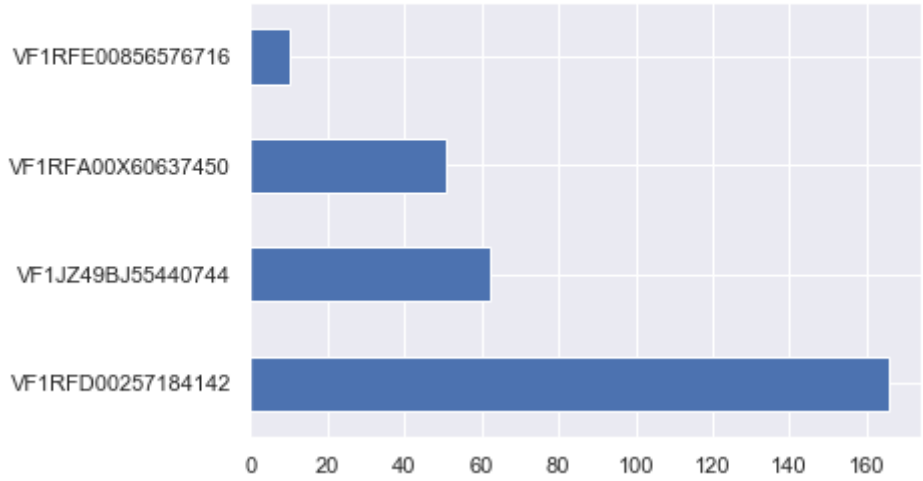


FIGURE 3.10 – Nombre de voitures par VIN

Vu la répartition des données, nous allons travailler avec le dernier VIN **VF1RFD00257184142** vu que c'est la série qui contient ue nombre important de voitures.
Nous allons maintenant illuster le comportement de l'attribut distance.

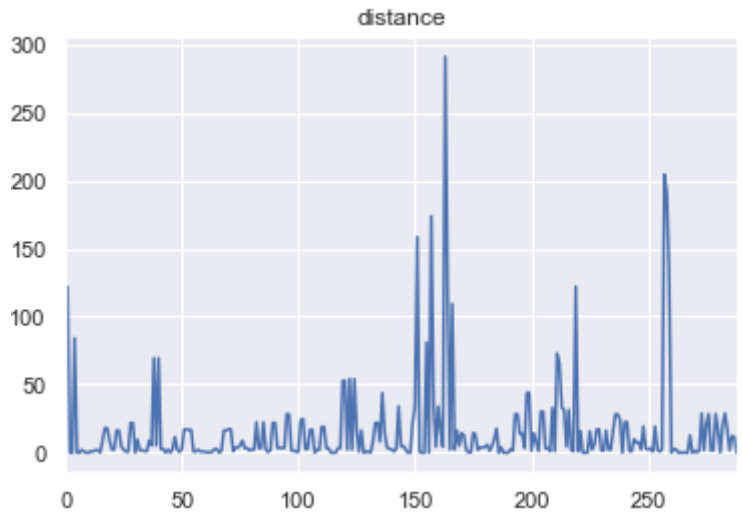


FIGURE 3.11 – La variation de la distance

Passons maintenant à la visualisation du dataset trouvé sur le net. Après avoir effectué quelques transformation, voici une petite description de notre jeu de données :

```
df.describe()
```

	distance	FuelEconomy	averageSpeed	temp_inside	temp_outside	AC	rain	sun	refill liters	Fuelconsumption
count	388.000000	388.000000	388.000000	376.000000	388.000000	388.000000	388.000000	388.000000	13.000000	388.000000
mean	19.652835	4.887887	41.927835	21.929521	11.358247	0.077320	0.123711	0.082474	37.115385	0.934883
std	22.667837	0.918730	13.598524	1.010455	6.991542	0.267443	0.329677	0.275441	8.587282	1.116249
min	1.300000	3.300000	14.000000	19.000000	-5.000000	0.000000	0.000000	0.000000	10.000000	0.084500
25%	11.800000	4.300000	32.750000	21.500000	7.000000	0.000000	0.000000	0.000000	37.600000	0.551650
50%	14.600000	4.700000	40.500000	22.000000	10.000000	0.000000	0.000000	0.000000	38.000000	0.680600
75%	19.000000	5.300000	50.000000	22.500000	16.000000	0.000000	0.000000	0.000000	39.000000	0.916500
max	216.100000	10.800000	90.000000	25.500000	31.000000	1.000000	1.000000	1.000000	45.000000	11.453300

FIGURE 3.12 – Informations sur le dataset du Net.

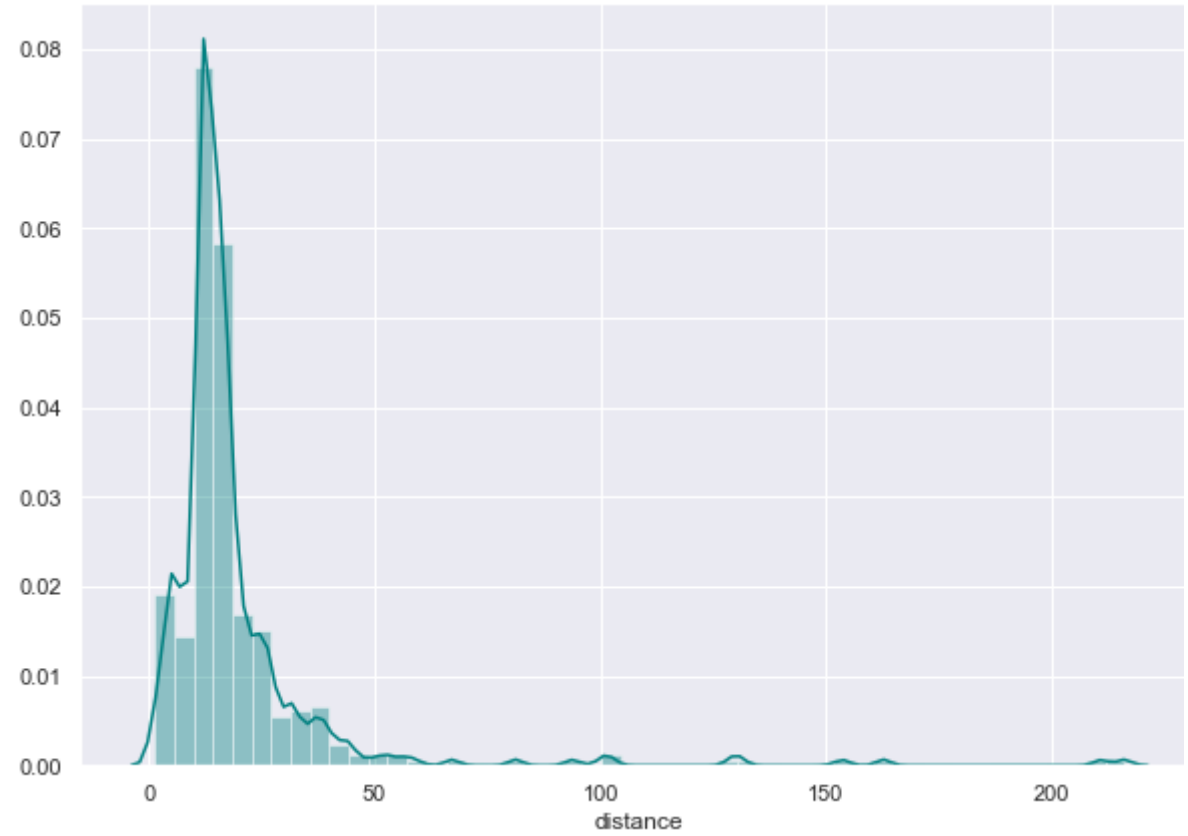


FIGURE 3.13 – Distribution de la distance dans le dataset du Net.

3.4 Features Selection

Nous abordons maintenant l'étape de sélection des attributs qui ont effet , positif ou négatif, sur la prédiction de la distance. Pour le premier dataset, la matrice de corrélation des attributs nous indique que seulement 3 attributs ont une influence sur la distance parcourue.

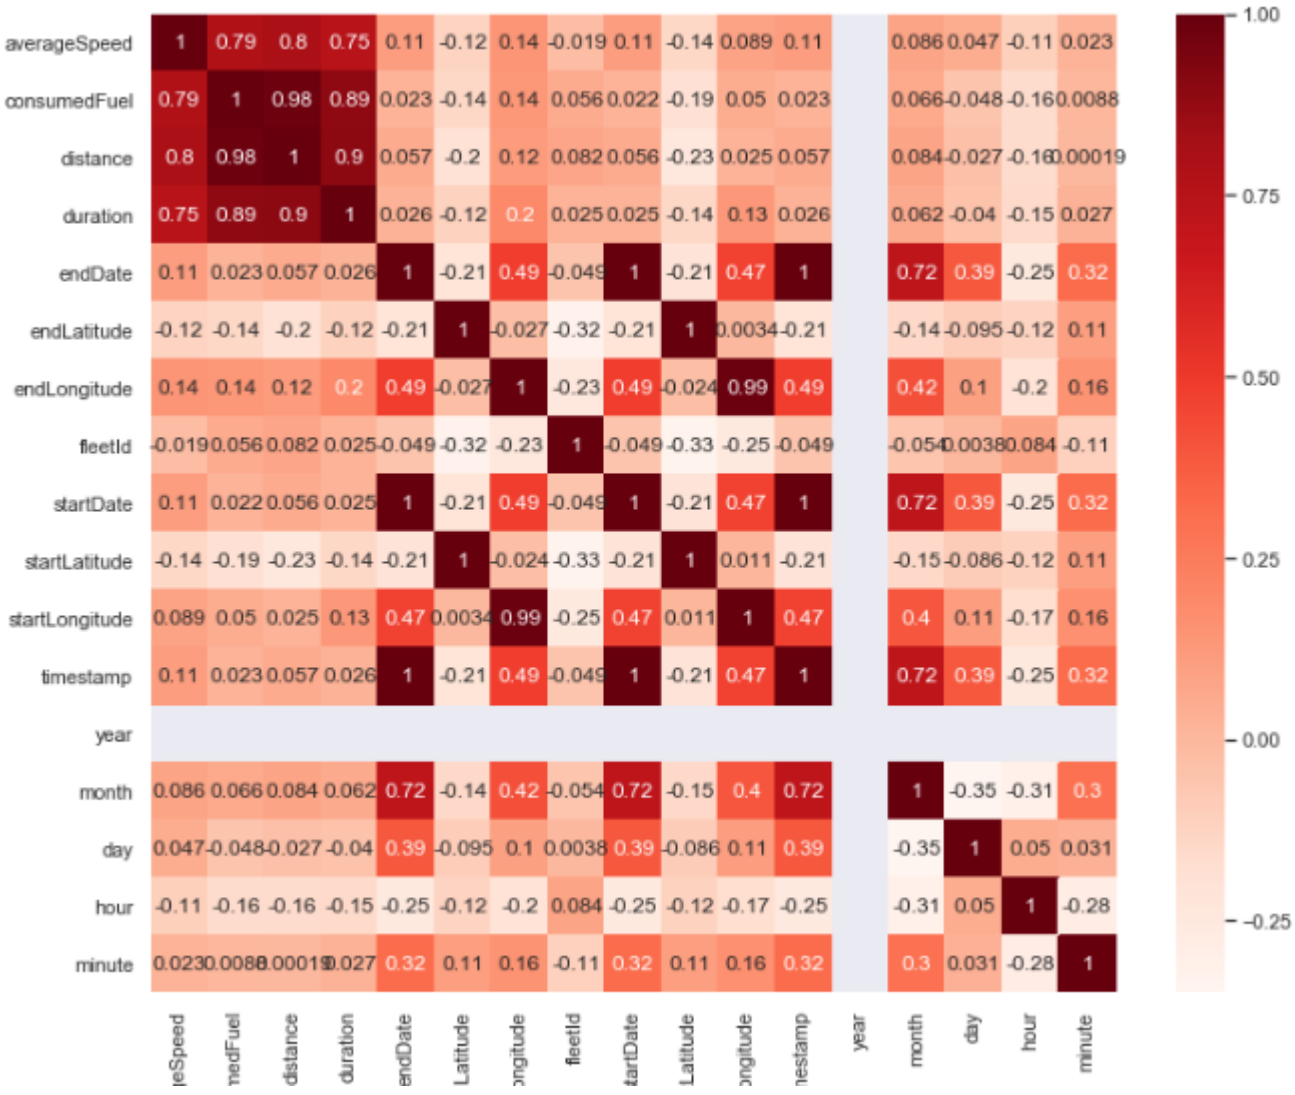


FIGURE 3.14 – La matrice de corrélation des attributs du dataset de Renault.

Les attributs retenus sont ceux qui ont une corrélation avec la distance supérieure à 0.5

```
#Corrélation avec la variable de sortie
cor_target = abs (cor ["distance"])
#Sélection des entités hautement corrélées
pertinence_features = cor_target [cor_target> 0.5]
pertinence_features
```

```
averageSpeed    0.800462
consumedFuel    0.980472
distance        1.000000
duration        0.895006
Name: distance, dtype: float64
```

FIGURE 3.15 – Les attributs retenus du dataset de Renault

Pour le dataset du Net, après avoir visualisé la matrice de corrélation avec la variable de sortie, on remarque que la distance dépend uniquement de 2 attributs qui sont la vitesse moyenne et la consommation du carburant.

```
#Corrélation avec la variable de sortie
cor_target = abs (cor ["distance"])
#Sélection des entités hautement corrélées
pertinence_features = cor_target [cor_target> 0.5]
pertinence_features
```

```
distance           1.000000
averageSpeed       0.562299
Fuelconsumption    0.992141
Name: distance, dtype: float64
```

FIGURE 3.16 – Les attributs retenus du dataset du Net

En plus de la matrice de corrélation , nous avons essayé d'extraire les attributs à travers XGBOOST Classifier, le résultat donné est comme suit :
Pour le dataset de Renault :

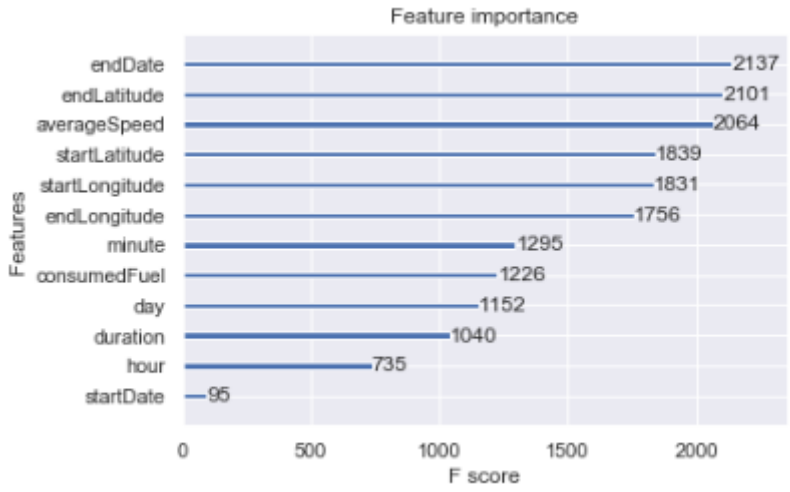


FIGURE 3.17 – Les attributs retenus par XGBOOST Classifier du dataset de Renault

Puisque StartLatitude , endLongitude , endLatitude et stratLongitude indiquent la distance du trajet on va les négliger .De plus , on remarque que la variable endDate est considerée comme étant une variable importante ce qui n'est pas le cas de StartDate . D'après les résultats de xgboost et de la corrélation entre les variables on peut dire que les variables qui agissent sur la distance sont : la consommation de carburant , la vitesse moyenne et la durée du trajet.
Pour le dataset du Net :

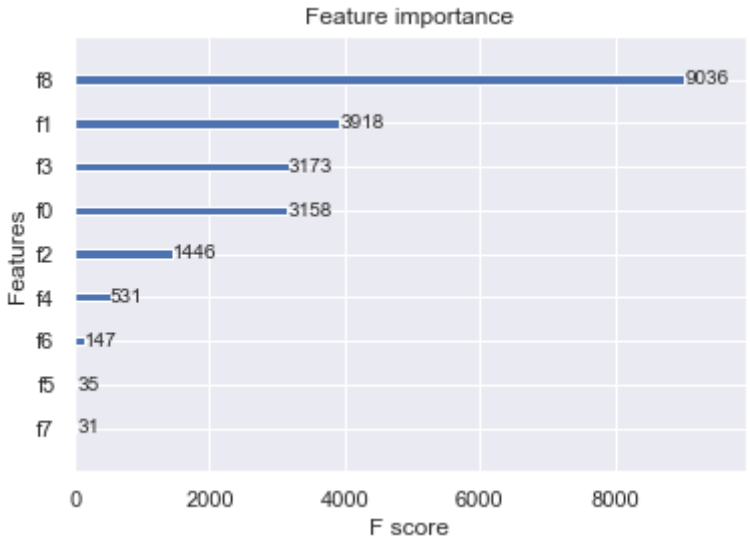


FIGURE 3.18 – Les attributs retenus par XGBOOST Classifier du dataset du Net

Ceci montre que les attributs qui sont d'une grande importance pour la distance sont la consommation de carburant , la vitesse moyenne et FuelEconomy. Suite à ces résultats on peut considérer dans ce dataset que les attributs qu'on va considérer sont la consommation de carburant et la vitesse moyenne.

3.5 Modélisation

Après avoir étudié les attributs et leur contribution dans la prédiction de la distance ou du kilométrage réalisé , on passe maintenant à la modélisation. On commence tout d'abord par diviser notre dataset en deux parties ; une pour l'apprentissage (75% des données) et l'autre pour tester nos modèles. Pour le choix du modèle, on a choisi de travailler avec quatre modèles et on choisira par la suite le meilleur en se basant sur quelques métriques d'évaluation.

- **XGBOOST :** XGBoost est l'une des implémentations les plus populaires et les plus efficaces de l'algorithme Gradient Boosted Trees, une méthode d'apprentissage supervisée basée sur l'approximation de fonction en optimisant des fonctions de perte spécifiques ainsi que l'application de plusieurs techniques de régularisation.
- **Random Forest Regressor (RFR) :** Une forêt aléatoire est une technique d'ensemble capable d'effectuer à la fois des tâches de régression et de classification à l'aide d'arbres de décision multiples et d'une technique appelée Bootstrap Aggregation, communément appelée baguage.
  C'est un type de modèle additif qui combine les décisions d'une séquence de modèles de base pour effectuer des prévisions.

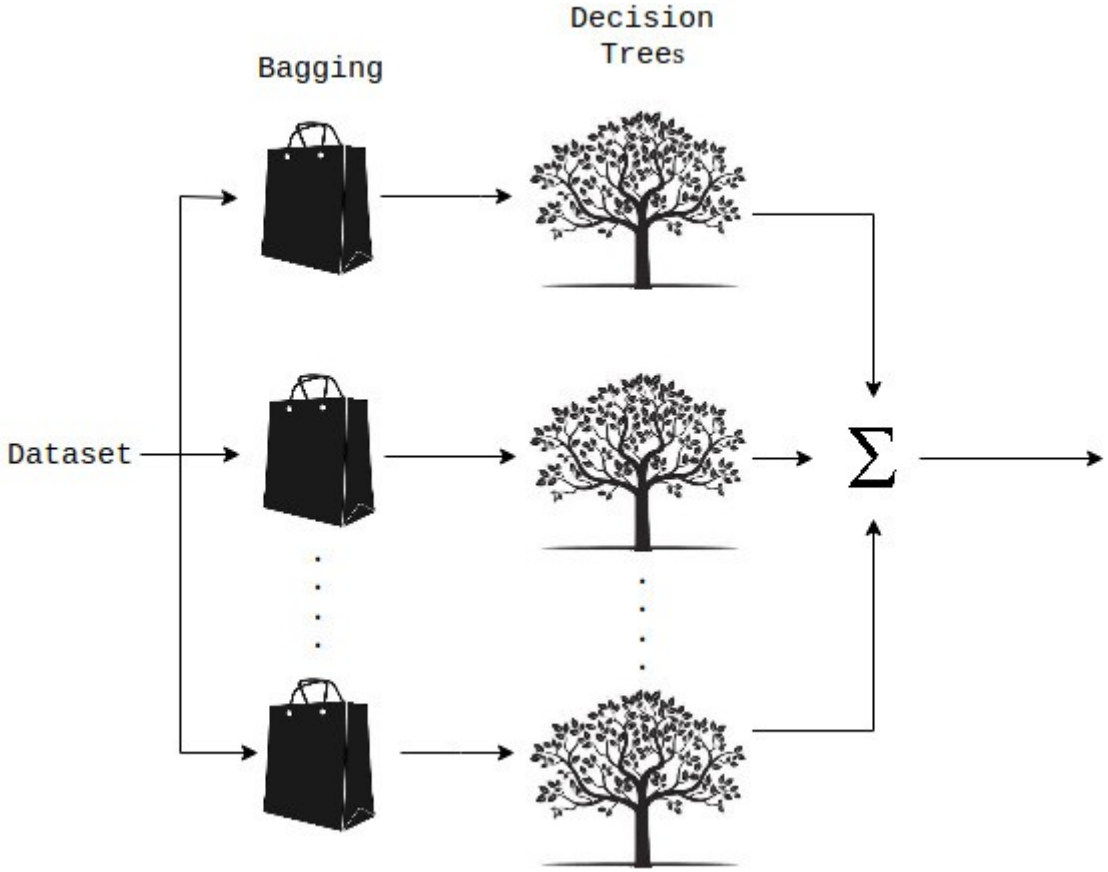


FIGURE 3.19 – Le process de Random Forest

L'idée de base derrière cela est de combiner plusieurs arbres de décision pour déterminer la sortie finale plutôt que de compter sur des arbres de décision individuels.

- Support Vector Machine (SVM) : Les machines vectorielles de support sont des classes d'algorithmes très spécifiques, caractérisées par l'utilisation de noyaux, l'absence de minima locaux, la rareté de la solution et le contrôle de la capacité obtenus en agissant sur la marge, ou sur le nombre de vecteurs de support, etc.
Support Vector Machine peut s'appliquer non seulement aux problèmes de classification mais aussi au cas de régression. Il contient néanmoins toutes les caractéristiques principales de l'algorithme de marge maximale : une fonction non linéaire est basée sur la cartographie linéaire de la machine d'apprentissage dans l'espace de fonctionnalités induit par le noyau à haute dimension. La capacité du système est contrôlée par des paramètres qui ne dépendent pas de la dimension de l'espace de fonction. Dans la régression SVM, les inputs sont d'abord mappés sur un espace de fonction en m-dimensionnel en utilisant une cartographie fixe (non linéaire), puis un modèle linéaire est construit dans cet espace de fonction. En utilisant la notation mathématique, le modèle linéaire (dans l'espace de fonction) f(x,w) est donné par :

$$f(\mathbf{x}, \boldsymbol{\omega}) = \sum_{j=1}^{m} \omega_j g_j(\mathbf{x}) + b$$

Où g(x) désigne un ensemble de transformations non linéaires, et b est le terme "biais". Souvent, les données sont supposées être de la moyenne zéro (cela peut être obtenu par

prétraitement), de sorte que le terme de biais est supprimé. L'un des avantages de Support Vector Machine, et de Support Vector Regression en tant que partie, est qu'il peut être utilisé pour éviter les difficultés d'utilisation des fonctions linéaires dans l'espace de fonction à haute dimension et le problème d'optimisation est transformé en programmes quadratiques à double convexe. Dans le cas de régression, la fonction de perte est utilisée pour pénaliser les erreurs qui sont supérieures au seuil. De telles fonctions de perte conduisent généralement à une représentation limitée de la règle de décision, ce qui confère des avantages algorithmiques et de représentation significative.

- **K Nearest Neighbors (KNN) :** Il s'agit d'un algorithme d'apprentissage supervisé. Il sert aussi bien pour la classification que la régression. L'algorithme utilise la "similarité des fonctionnalités" pour prédire les valeurs de tout nouveau point de données. Cela signifie que le nouveau point est assigné à une valeur en fonction de la façon dont il ressemble aux points du Dataset. La première étape consiste à calculer la distance entre le nouveau point et chaque point d'entraînement. Il existe diverses méthodes pour calculer cette distance, dont les méthodes les plus connues sont Euclidian, Manhattan (pour continu) et Hamming (pour catégorique). La deuxième étape consiste à sélectionner la valeur k. Cela détermine le nombre de voisins que nous examinons lorsque nous affectons une valeur à toute nouvelle observation.

Les résultats obtenus avec le dataset de Renault :

	ytest	ypred
25	2.13	0.197213
194	28.32	22.274761
117	3.38	1.513800
193	28.32	22.274761
31	9.54	4.625486

FIGURE 3.20 – La prédiction de XGBOOST Regressor pour le dataset de Renault

	averageSpeed	consumedFuel	duration	distance	prediction
25	18.257143	0.16	7	2.13	0.512128
194	27.384367	1.76	63	28.32	19.099486
117	21.806452	0.37	10	3.38	1.564263
193	27.384367	1.76	63	28.32	19.099486
31	39.295195	0.56	15	9.54	4.342180

FIGURE 3.21 – La prédiction de Random Forest Regressor pour le dataset de Renault

	averageSpeed	consumedFuel	duration	distance	prediction
25	18.257143	0.16	7	2.13	0.51
194	27.384367	1.76	63	28.32	30.06
117	21.806452	0.37	10	3.38	1.63
193	27.384367	1.76	63	28.32	30.06
31	39.295195	0.56	15	9.54	6.17

FIGURE 3.22 – La prédiction de K Neighbors Regressor pour le dataset de Renault

	averageSpeed	consumedFuel	duration	distance	prediction	distance
25	18.257143	0.16	7	2.13	-0.828927	2.13
194	27.384367	1.76	63	28.32	23.989334	28.32
117	21.806452	0.37	10	3.38	2.038153	3.38
193	27.384367	1.76	63	28.32	23.989334	28.32
31	39.295195	0.56	15	9.54	5.036828	9.54

FIGURE 3.23 – La prédiction de Support Vector Regressor pour le dataset de Renault

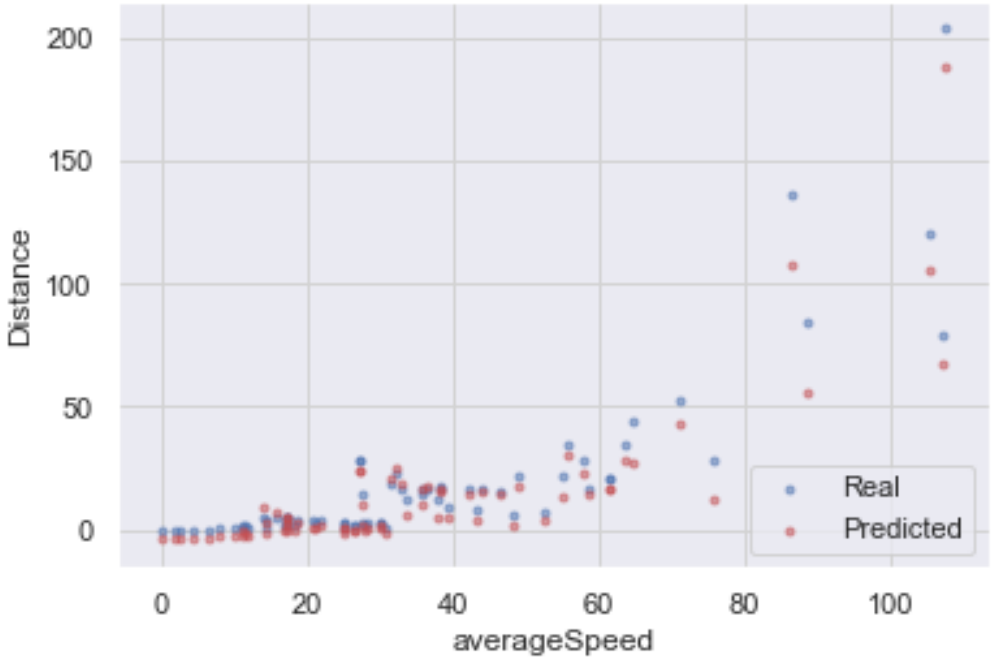


FIGURE 3.24 – Visualisation de la prédiction de SVR pour le dataset de Renault

Les résultats obtenus en appliquant les modèles sur le dataset du Net.

	averageSpeed	Fuelconsumption	distance	prediction
223	56	0.9920	24.8	15.933333
313	38	0.4859	11.3	5.900000
302	46	0.7304	16.6	13.300000
249	57	0.5375	12.5	11.066667
378	39	0.7128	16.2	11.800000

FIGURE 3.25 – La prédiction de KNR pour le dataset du Net

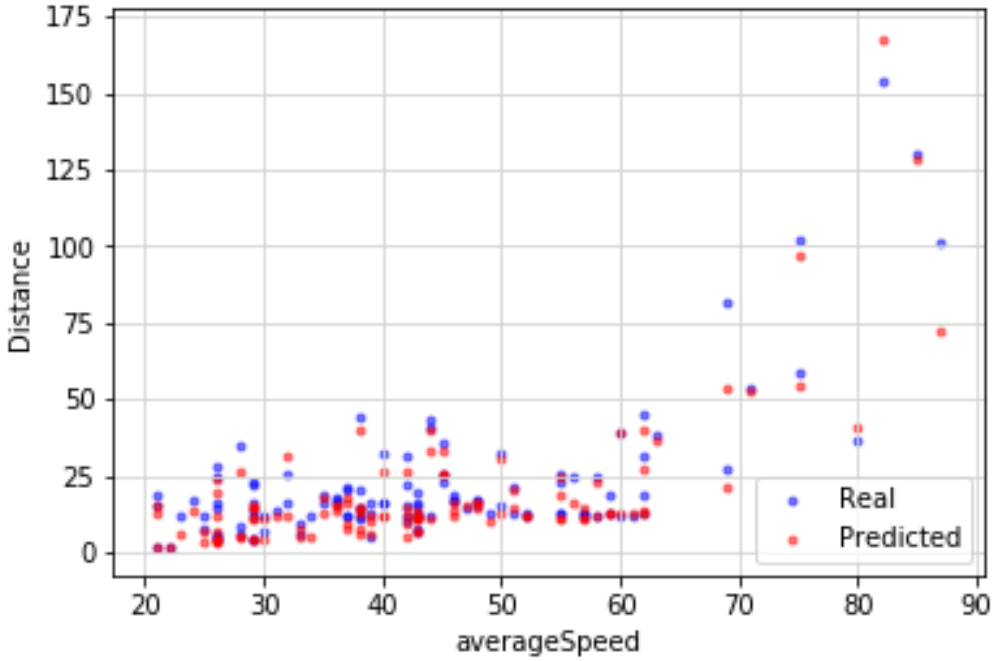


FIGURE 3.26 – Visualisation de la prédiction de KNR pour le dataset du Net

	averageSpeed	Fuelconsumption	distance	prediction
223	56	0.9920	24.8	18.345836
313	38	0.4859	11.3	7.155592
302	46	0.7304	16.6	12.507329
249	57	0.5375	12.5	9.636777
378	39	0.7128	16.2	11.620479

FIGURE 3.27 – La prédiction de SVR pour le dataset du Net

	averageSpeed	Fuelconsumption	distance	prediction
223	56	0.9920	24.8	17.956
313	38	0.4859	11.3	6.017
302	46	0.7304	16.6	12.157
249	57	0.5375	12.5	6.863
378	39	0.7128	16.2	11.806

FIGURE 3.28 – La prédiction de RFR pour le dataset du Net

	averageSpeed	Fuelconsumption	distance	prediction
223	56	0.9920	24.8	16.128849
313	38	0.4859	11.3	6.027144
302	46	0.7304	16.6	13.552185
249	57	0.5375	12.5	7.794806
378	39	0.7128	16.2	11.329845

FIGURE 3.29 – La prédiction de XGBOOST Regressor pour le dataset du Net

On peut considérer le problème de cette prédiction comme une prédiction qui dépend aussi du temps , c'est-à-dire une série temporelle. Pour cela, on a testé le modèle ARIMA pour le dataset de Renault et voici le résultat :

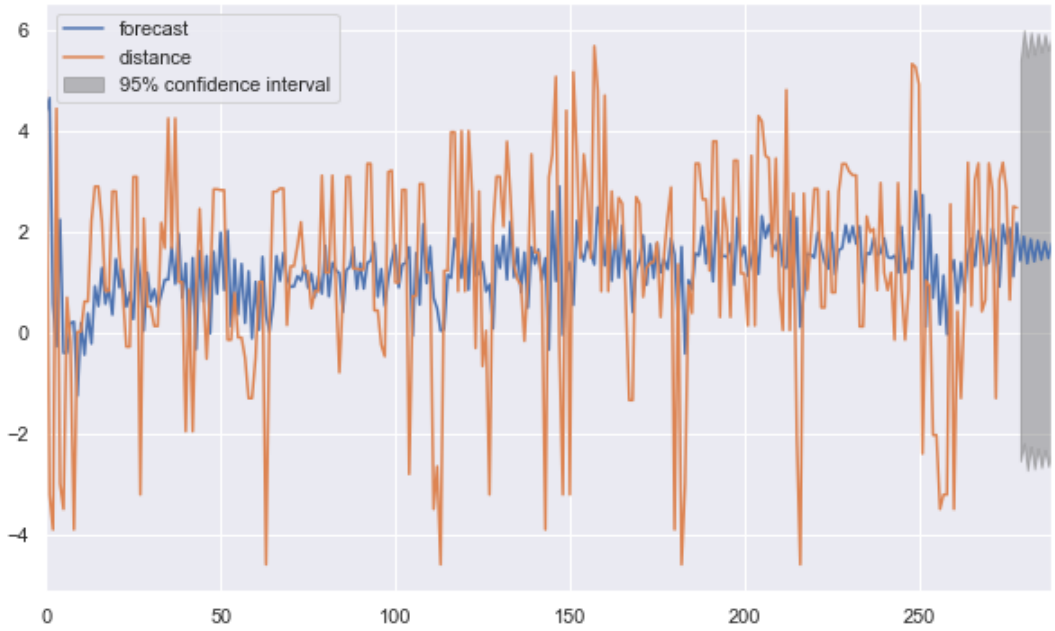


FIGURE 3.30 – La prédiction de ARIMA pour le dataset de Renault

3.6 Evaluation

En se basant sur les métriques que nous avons expliqué dans le chapitre précédent, nous allons choisir le meilleur modèle.
Pour le dataset de Renault :

	model	mse	rmse	mae	mape
0	Xgboost	37.895469	10.972167	3.276887	inf
1	RandomForest	37.645528	6.135595	3.511765	inf
2	SVR	47.812340	6.914647	4.409558	inf
3	Knn	35.263097	5.938274	3.299863	NaN

FIGURE 3.31 – Evaluation des modèles du dataset Renault

Le modèle choisi pour ce dataset est KNN.
Pour le dataset du Net :

	model	mse	rmse	mae	mape
0	Xgboost	77.646212	8.811709	4.789879	24.459238
1	RandomForest	19.560310	4.422704	3.398538	21.296253
2	SVR	18.694627	4.323728	3.621434	25.572912
3	Knn	28.119573	5.302789	3.421368	17.994363

FIGURE 3.32 – Evaluation des modèles du dataset du Net

Le modèle choisi pour ce dataset est SVR.

3.7 Déploiement

Le déploiement de la solution proposée est une étape très importante pour mettre en valeur le travail effectué.
Nous avons développé un Dashboard pour contrôler le kilométrage.

- **Partie Front End :** Il s'agit d'une interface qui permet au conducteur d'interagir avec le système et assure l'affichage des résultats des prévisions du modèle de Machine Learning.

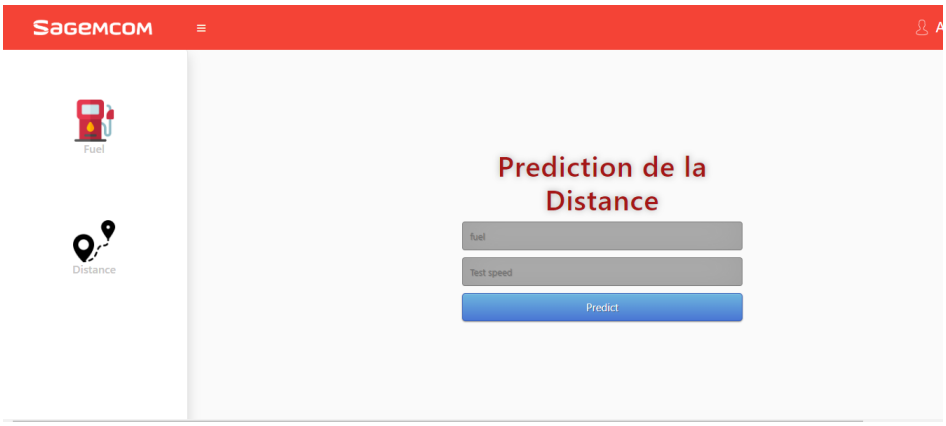


FIGURE 3.33 – L'interface de prédiction de la distance

- **Partie Back End :** Cette partie est développée avec le framework Flask de Python. Le back-end est le composant le plus important du système développé, il fournit des services et encapsule les fonctionnalités consommées par le client. Le serveur d'application utilisé est flask. Il permet de traiter les données en analysant le modèle ML

3.8 Conclusion

Ce chapitre est dédié à parler du travail effectué tout au long de la durée de stage.

Conclusion générale

L'intelligence artificielle a déjà commencé à transformer des choses qui nous étaient familières en des choses beaucoup plus intelligentes et rapides. Selon Deloitte, près de 98% des dirigeants d'assurances pensent que l'intelligence artificielle révolutionnera la manière dont les assureurs obtiennent des informations de leurs clients. Dans ce cadre , mon stage consiste à proposer une solution fournissant aux compagnies d'assurances des informations sur les habitudes de leurs clients et traitant la gestion des accidents en utilisant la technologie d'IA.
Pour ce faire, nous avons commencé par définir les termes de base du projet et par étudier certains algorithmes de Machine Learning utilisés dans cette solution. Ensuite, nous avons décrit la mise en œuvre et les résultats de chaque modèle proposé et le déploiement de la solution.

Bibiographie

- Sagemcom Software Technologies. https ://www.sagemcom.com/.
- What is Machine Learning ? https ://www.expertsystem.com/machine-learningdefinition/.
- Towards Data Science. https ://towardsdatascience.com/.
- Angular. https ://angular.io/.
- Machine Learning. https ://machinelearningmastery.com/.