SUP'COM

المدرسة العليا للمواصلات بتونس

ÉCOLE SUPÉRIEURE DES COMMUNICATIONS DE TUNIS

Cycle de formation des ingénieurs en Télécommunications

Option :

Networking, Cloud & Artificial Intelligence (NCA)

Rapport de Projet de fin d'études

Thème :

Système d'analyse automatique des e-mails

Réalisé par :

Nihel EL Abed

Encadrants :

M. Sami Tabbane

Mme. Arabya Ksouri

Travail proposé et réalisé en collaboration avec

CED

PROPERTY MOBILITY VITALITY

Année universitaire : 2019-2020

Ecole Supérieure des Communications de Tunis

SUP'COM

2083 Cité Technologique des Communications - Elghazala - Ariana - Tunisie

Tél. +216 70 240 900 – site web: www.supcom.mincom.tn

Signatures

Encadrant professionnel :
Mme. Arabya Ksouri

Encadrant académique :
M. Sami Tabbane

Dédicaces

“

Je dédie ce travail :

À mes parents bien-aimés ***Mohamed****,* ***Zoubaida El Abed****. Je ne serais jamais la personne que je suis aujourd'hui sans leurs sacrifices. Merci mama et papa de toujours croire en moi et de m'encourager pour réaliser mes rêves.*

À ma famille, qui m'a toujours soutenu, m'a donné espoir, amour et encouragement.

À mon oncle ***Mahmoud El Abed****, qui m'a inculqué l'amour d'apprendre dès le plus jeune âge.*

À tous ceux qui m'ont aidé, directement ou indirectement ; et ceux qui ont partagé avec moi les moments d'émotion lors de la réalisation de ce travail.

À vous tous, je dédie ce travail !

”

Nihel

Remerciement

Avant d'aborder le vif du sujet, nous tenons à remercier profondément :

Mon professeur, monsieur ***'Sami Tabbane'***, pour leurs conseils et leur supervision constante.

Madame ***'Arabya Ksouri'*** pour tout le soutien et l'encadrement qu'il nous a donné.

Le corps enseignant administratif de l'école supérieur des communications de Tunis ***'SUPCOM'***, pour avoir porté un vif intérêt à notre formation, et pour avoir prêté attention, et ce dans un cadre agréable de respect.

Nous tenons à remercier également tous ceux qui nous ont aidé de prés et de loin pour me permettre de mener à bien ce projet.

A tous ceux dont le soutien nous a été utile et nécessaire, nous disons :

Merci

Résumé

Ce rapport décrit le travail mené au sein de la société « CED Group » dans le cadre d'un projet de fin d'études. Mon objectif était de mettre en place un prototype d'application de type « Système d'extraction d'informations » basé sur le traitement du langage naturel, qui peut analyser de manière automatique les courriels entrants et en extraire, par la suite, les inforamtions pertinentes . Nous avons spécifiquement opté pour l'approche basée sur des règles. L'étude de l'état de l'art, l'analyse du besoin et la phase de développement, ont décelé les problématiques de l'analyse et de la compréhension du langage naturel par l'ordinateur, l'indexation et de l'extraction d'information des documents. Ce projet vise à apporter un soutien aux équipes back-office opérant au sein du « CED Group ».

Mots-clés : Analyse automatique des courriels, Traitement du langage naturel, indexation, Extraction d'informations basée sur des règles.

Abstract

This report describes the work carried out within the « CED Group » as part of a graduation project. My objective was to develop a « Information Extraction System »application prototype based on natural language processing, which can automatically analyze incoming emails and extract relevant information. We have specifically opted for the rules-based approach. The study of the state of the art, the analysis of the need and the development phase identified the problems of the analysis and the understanding of natural language by the computer, the indexing and the information extraction from documents. This project aim to support the back office teams operating within « CED Group ».

Keywords : Automatic email analysis, Natural language processing, indexing, Rules-based information extraction.

Avant-propos

Ce stage de fin d'études clôt pour moi une période de trois ans en école supérieure des communications de Tunis (SUP'COM) et m'ouvre une nouvelle période, celle de la vie professionnelle et c'est à « CED Group » que j'ai eu l'occasion d'effectuer mon stage de fin d'études.

Le sujet de stage s'est porté sur le projet de traitement du langage naturel. Ce projet me paraissait lié à un domaine qui a toujours attisé ma curiosité, la linguistique. J'étais également intéressé par le fait d'être impliqué dans les différentes étapes du cycle de vie d'un produit. Le traitement du langage naturel s'est révélé plus complexe que je l'imaginais, et les problématiques liées à la compréhension et au prétraitement des données se sont rapidement dévoilées.

Le but du stage est de concevoir un prototype d'application, basé sur le traitement du langage nature, pouvant analyser automatiquement des courriers électroniques. Cette application apportera de l'aide aux gestionnaires back office de « CED Group », qui traitent une centaines des emails quotidiennement.

Pour atteindre cet objectif, nous avons commencé par réaliser un état de l'art pour identifier différentes approches existantes ; une fois cette étape franchie nous avons rencontré l'équipe des opérations pour analyser le contexte et les différents besoins. Cela nous a permis d'élaborer un cahier des charges, et ce n'est qu'une fois ce dernier validé par le chef de département IT que nous avons réellement commencé à développer le prototype.

Table des matières

Introduction générale **12**

1 Contexte général du projet **14**

1.1 Présentation de l'organisme d'accueil 15

1.1.1 Carte d'identité 15

1.1.2 Structure organisationnelle du CED Group 16

1.1.3 Les différentes unités de CED Group 16

1.1.4 Les Services de CED Group 17

1.1.4.1 Propriété 17

1.1.4.2 Mobilité 17

1.1.4.3 Vitalité 18

1.2 Présentation du projet 18

1.2.1 Cadre du projet 18

1.2.2 Contexte du projet 18

1.2.3 Problématique 18

1.2.4 Solution proposée 19

1.2.4.1 Hypothèse de la solution 19

1.2.4.2 Introduction au IE 20

1.2.4.3 Implémentation proposée 20

1.3 Planification et conduite du projet 21

1.3.1 Processus de développement 21

1.3.2 Planning du projet 23

1.4 Conclusion 24

2 Etat de l'art 25
2.1 Introduction au TALN . . . 26
2.1.1 Les applications du TALN . . . 26
2.1.2 Les difficultés du TALN . . . 27
2.2 Approches pour l'extraction d'informations . . . 27
2.2.1 Approche basée sur des règles . . . 28
2.2.2 Approche Machine Learning traditionnelle . . . 29
2.2.3 Réseaux de neurones . . . 29
2.2.4 Analyse comparative des approches TALN . . . 29
2.3 Système IE proposé . . . 32
2.3.1 Pré-traitement linguistique . . . 32
2.3.1.1 Tokenisation . . . 32
2.3.1.2 Part-Of-Speech tagging POS . . . 33
2.3.2 Rule-Based Matching . . . 33
2.4 Conclusion . . . 33

3 Analyse et spécification des besoins 34
3.1 Spécification des besoins . . . 35
3.1.1 Besoins fonctionnels . . . 35
3.1.2 Besoins non-fonctionnels . . . 35
3.2 Analyse des besoins fonctionnels . . . 36
3.2.1 Identification des acteurs . . . 36
3.2.2 Diagramme des cas d'utilisation . . . 36
3.2.3 Conclusion . . . 42

4 Étude Conceptuel et architectural 43
4.1 Diagramme de classes . . . 44
4.2 Diagramme d'activité . . . 45
4.2.1 Diagramme d'activité de la solution . . . 45
4.2.2 Diagramme d'activité relatif à l'authentification . . . 48
4.3 Diagramme de séquence . . . 48

4.3.1 Diagramme de séquence de l'application 49
4.3.2 Diagramme de séquence « Analyse d'une nouvelle réclamation » . . 51
4.3.3 Diagramme de séquence « Suivi d'une ancienne réclamation » . . . 53
4.4 Architecture Logiciel du projet 54
4.5 Conclusion 56

5 Mise en oeuvre de la solution **57**
5.1 Introduction 58
5.2 Outils et technologies utilisées 58
5.2.1 Outil de modélisation UML 58
5.2.2 Outils de développement et de collaboration 58
5.3 Développement 60
5.3.1 Traitement textuel NLP 60
5.3.1.1 Conception des règles linguistiques 61
5.3.1.2 Évaluation des performances 63
5.3.2 Quelques interfaces de l'application 64
5.3.2.1 Page d'accueil 64
5.3.2.2 Page de Sign Up 65
5.3.2.3 Page de Login 66
5.3.2.4 Vue Administration 67
5.3.2.5 Menu d'administration 68
5.4 Conclusion 75

Conclusion générale **76**

Webographie **77**

Annexes **II**

A Implémentation **II**

Table des figures

1.1 Logo de CED 15
1.2 Filiales du groupe CED dans le monde 15
1.3 Structure organisationnelle du CED Group 16
1.4 Liste des solutions proposées par CED 17
1.5 Schéma illustratif de la solution proposé 20
1.6 Cycle de vie de la méthodologie scrum 22
1.7 Diagramme de gantt du projet 23

2.1 Différentes approches pour l'extraction d'informations 28
2.2 Système IE proposé 32

3.1 Diagramme des cas d'utilisation 37

4.1 Aperçu du diagramme de classes 44
4.2 Diagramme d'activité de l'application 47
4.3 Diagramme d'activité « Authentification » 48
4.4 Diagramme de séquence 50
4.5 Diagramme de séquence « Analyse d'une nouvelle réclamation » 52
4.6 Diagramme de séquence « Suivi d'une ancienne réclamation » 53
4.7 Architecture logiciel du projet 54
4.8 API REST 56

5.1 Document d'entrée 60
5.2 Arbre graphique de dépendance 61
5.3 Créations des patterns 62

5.4 Données de sortie du programme 63
5.5 La page d'accueil de l'application 65
5.6 La page du sign up de l'application 66
5.7 La page du login de l'application 67
5.8 La vue Administration 68
5.9 La vue configurer une adresse e-mail 69
5.10 La vue sélectionner une dresse e-mail 69
5.11 La vue Inbox 70
5.12 La vue Liste des réclamations 71
5.13 La vue Afficher Détails 72
5.14 La vue Informations Générales 72
5.15 La vue Informations des personnes 73
5.16 La vue informations des compagnies d'assurance 74
5.17 La vue Envoyer un e-mail 75

A.1 Développement des API FLASK RESTful II

Liste des sigles et acronymes

TALN	*Traitement Automatique de la Langue Naturelle*
ML	*Machine Learning*
NLP	*Natural Language Processing*
IE	*Information Extraction*
Regex	*Regular expressions*
CFG	*Context-free grammar*
POS	*Part-Of-Speech tagging*
RNN	*Réseaux Neuronaux Récurrents*
CNN	*Réseaux Neuronaux Convolutifs*
UI	*User Interface*
API	*Application Programming Interface*
REST	*REpresentational State Transfer*
HTTP	*HyperText Transfer Protocol*
POP	*Post Office Protocol*
SMTP	*Simple Mail Transfer Protocol*

Introduction générale

Les progrès technologiques nous ont permis d'accéder à de grandes quantités d'informations textuelles, soit sur Internet, soit dans des collections spécialisées. Cependant, les gens ne peuvent pas lire et digérer ces informations plus rapidement qu'auparavant. Afin de le rendre utile, il est souvent nécessaire de mettre ces informations dans une sorte de format structuré, par exemple dans une base de données relationnelle. Dans ce contexte, nous parlons de l'extraction automatique d'informations. Cette arène a pris beaucoup d'importance ces dernières années parce que nous sommes explosés avec divers types d'informations du monde réel. L'importance croissante de la récupération des données intelligentes est aujourd'hui l'objectif principal de toute entreprise.

La technologie d'extraction d'informations (IE) concerne la structuration des informations pertinentes à partir d'un texte d'un domaine donné. En d'autres termes, le but d'un système IE est de trouver et de lier les informations pertinentes tout en ignorant les informations superflues et non pertinentes. La plupart des approches d'extraction d'informations (IE) peuvent être regroupées dans l'une ou l'autre des catégories de technologies basées sur des règles, c'est-à-dire basées sur la connaissance ou sur l'apprentissage automatique (ML).

Nous nous sommes concentrés ici pour mettre en œuvre un système d'extraction d'informations à partir des courriers électroniques, à l'aide du traitement du langage naturel (NLP), notamment par l'utilisation de l'approche basé sur des règles. En effet, chez « CED Group », chaque bureau reçoit des centaines de courriels importants liés à son métier. Ces courriels abritent une énorme quantité d'informations considérables à extraire, cette tâche est exécutée par l'équipe opérationnelle back office. Notre objectif est alors d'accélérer son business et d'automatiser cette tâche.

Le présent rapport synthétise ainsi le déroulement de mon travail sur ce projet. Il est divisé en cinq chapitres :

Le premier chapitre présente brièvement l'organisation d'accueil « CED Group » et le cadre général du projet. Il décrit la problématique et met l'accent sur la solution proposée. À la fin de ce chapitre nous discutons la méthodologie appliquée pour assurer le bon déroulement de mon travail avec une planification de ce dernier.

Le deuxième chapitre sera dédié à la réalisation de l'état de l'art pour distinguer les différentes stratégies du traitement de langage naturel.

Le troisième et le quatrième chapitre présentent les phases d'analyse et de conception du projet. Dans ces chapitres nous détaillons les besoins fonctionnels et non fonctionnels et nous abordons l'analyse de ces besoins et puis mener l'étude technique, conceptuelle et architectural de la solution.

Le dernier chapitre introduit la phase de réalisation du projet. Il présente les différents outils et les techniques utilisés ainsi que les résultats de mise en œuvre de la solution.

En fin nous clôturons par une conclusion générale présentant une analyse du travail effectué au sein de « CED Group ». Cette partie met en évidence non seulement un résumé du travail réalisé, mais aussi des propositions et des différentes perspectives.

Chapitre 1

Contexte général du projet

> *Le but de ce chapitre est de situer le projet dans son environnement organisationnel et contextuel. La première partie présente l'organisation hôte, tandis que la deuxième partie traite des objectifs et des exigences de base de la solution « Système d'analyse automatique des e-mails ». La dernière partie est réservée aux méthodes et comportements adoptés pour pour la mise en œuvre du projet.*

1.1 Présentation de l'organisme d'accueil

1.1.1 Carte d'identité

FIGURE 1.1 – Logo de CED

CED Group dont le logo est présenté dans la figure 1.1 est un prestataire de services européen pour les entreprises du secteur de l'assurance, l'immobilier, logement, sociétés de leasing et domaine de soins et de santé, etc... [1]

CED est un fournisseur de services qui dispose d'une vaste gamme axée sur la protection et la préservation de la valeur.

Ses activités consistent à protéger et restaurer les citoyens et tous leurs biens. Elle est répartie dans 14 pays européens et son siège social se situe aux Pays-Bas. Elle génère près de 170 millions d'euros de chiffre d'affaires annuel et couvre 1500 salariés travaillant dans ces différents bureaux [2].



FIGURE 1.2 – Filiales du groupe CED dans le monde

1.1.2 Structure organisationnelle du CED Group

La figure 1.3 illustre la structure organisationnelle du CED Group [3].

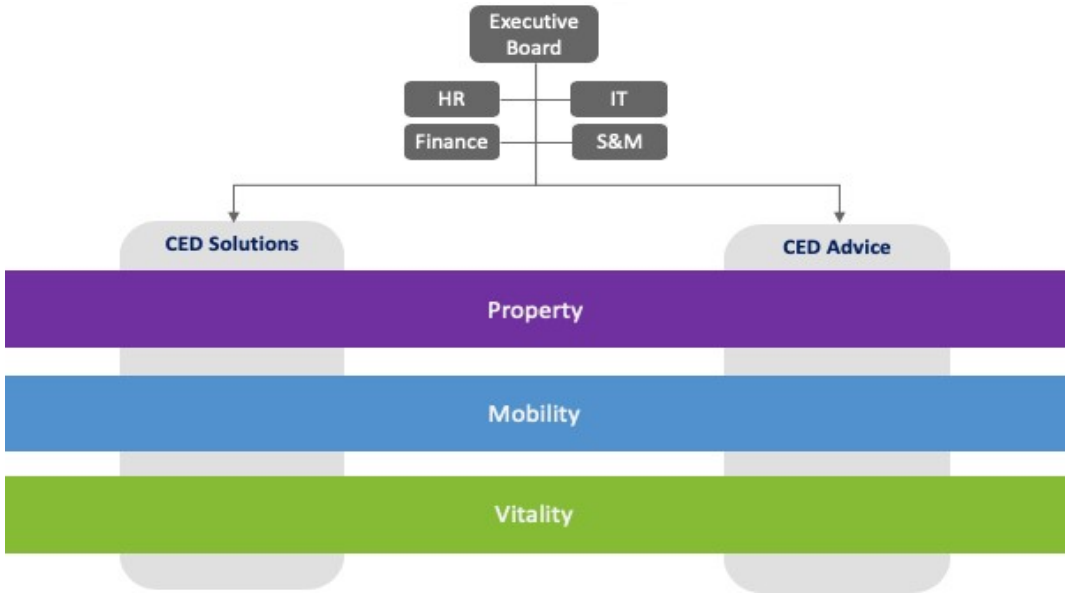


FIGURE 1.3 – Structure organisationnelle du CED Group

1.1.3 Les différentes unités de CED Group

CED souhaite offrir à ses cinq meilleurs clients par division une meilleure compréhension du service fournit. Cependant, Le groupe a lancé un programme bien ciblé afin de satisfaire les besoins de ses clients. La division Solutions est l'une des six divisions du groupe, et la division avec la plus grande base clientèle.

Au sein de la division Solutions, le Groupe CED possède 3 unités nécessaires (voir Figure 1.4) [4].

— **SOS International** : Est le propre centre d'urgence interne de CED. Les personnels du centre sont disponibles 24 heures sur 24, 7 jours sur 7 pour fournir une assistance immédiate.

— **Réclamations** : CED possède la plateforme de gestion des réclamations la plus avancée pour un processus simplifié de la notification à la réparation.

— **Réparation** : CED offre le plus grand réseau néerlandais d'entreprises de réparation et d'entretien professionnels.



FIGURE 1.4 – Liste des solutions proposées par CED

1.1.4 Les Services de CED Group

Nous discutons dans cette section l'unité « Réclamations » de « CED Group ». Dans cette unité opère l'équipe opérationnelle back office qui prend en charge le traitement des réclamations provenants via les courriers électroniques. L'organisation de cette équipe repose sur le maillage de trois divisions : l'equipe back office Propriété (Property), l'equipe back office Mobilité (Mobility) et l'equipe back office vitalité (Vitality).

1.1.4.1 Propriété

Tout le monde a des possessions, petites et grandes et ces possessions ont souvent une signification particulière. Par exemple : une maison qui ressemble à une vraie maison, une machine essentielle à la continuité des affaires, une bague héritée de quelqu'un qui vous est cher. Cette division s'interesse à la gestion des réclamations liées aux propriétés [5].

1.1.4.2 Mobilité

La mobilité vous donne la liberté de vous déplacer quand et où vous le souhaitez. La mobilité est une nécessité absolue pour beaucoup ; certaines entreprises ne pourraient pas survivre sans le transport de marchandises et de nombreuses personnes doivent avoir des voitures pour se rendre ou faire leur travail. Pour d'autres, la mobilité signifie la liberté offerte par un bateau ou une caravane. La division « Mobilité » prend en charge les réclamations liées aux mobilités [6].

1.1.4.3 Vitalité

La vitalité est notre bien le plus précieux. Se sentir en forme et en bonne santé dans son esprit et son corps, plein d'énergie au travail, à la maison et en famille et entre amis. Quiconque est plein de vitalité et qui se sent à l'aise dans sa peau se sent beaucoup plus énergique et heureux. Le dernier groupe de l'équipe back office traite les réclamations liées à la vitalité [7].

Le présent projet s'adresse à la division « Mobilité » qui sera prochainement définit de la même manière pour les autres divisions, afin d'avoir une vision claire des données et aider les gestionnaires back office à mieux gérer les réclamations des clients.

1.2 Présentation du projet

1.2.1 Cadre du projet

Notre projet intitulé « Sytème d'analyse automatique des emails » a été proposé dans le cadre de l'élaboration d'un stage de fin d'études au sien de la société « CED Group » en vue de l'obtention du diplôme nationale d'ingénieur en télécommunications, qui est accordé par **L'ÉCOLE SUPÉRIEURE DES COMMUNICATIONS DE TUNIS (SUP'COM)**.

1.2.2 Contexte du projet

Après avoir présenté l'organisme d'accueil et ses services, il est temps de mettre en évidence le contexte du projet.

Durant le stage, nous avons intégré l'équipe IT au sein de « CED » basé en Tunisie et encadré par les managers qui travaillent aux Pays-Bas.
Notre tâche est de mettre en place un système pour analyser et extraire automatiquement des informations à partir des courriels. Ce sytème servira d'aide à la saisie pour l'équipe opérationnelle plus précisément, celle qui gère les réclamations de type « Mobilité ».

1.2.3 Problématique

Les gestionnaires back office chez « CED Group » traitent quotidiennement des centaines des emails référant à des réclamations des clients. Ces emails contiennent des informations reliées aux détails d'un incident.

L'équipe passe un temps non négligeable dans la lecture et l'analyse des emails pour

identifier et extraire ces informations utiles qui sont éparpillés dans le corps du courriel et les pièces jointes. Tous les courriels ne sont pas des nouvelles réclamations (peuvent mettre à jour des informations ou bien confirmer un payment...) Elle s'est affrontée donc à la situation à laquelle une énorme base de données des réclamations étaient enregistrées.

Ainsi pour réduire le temps de saisie et accélérer le processus de traitement des réclamations des clients, CED veut adopter une stratégie d'extraction automatique de ces détails, et qui devra être très performante parce que les conséquences d'une information erronée à propos d'une réclamation peuvent être importantes.

Les différents champs pertinents à identifier en analysant un courrier électronique se récapitulent sous trois catégories :

Détails du sinistre :

- ⋆ Date et pays du sinistre
- ⋆ Les montants de dommages
- ⋆ Description du sinistre

Coordonnées des compagnies d'assurance :

- ⋆ Identité de l'assurance cliente
- ⋆ Numéro de police
- ⋆ Numéro de réclamation
- ⋆ Nom de la compagnie adversaire
- ⋆ Adresse de la compagnie adversaire

Détails des personnes touchées par l'incident :

- ⋆ Nom de l'assuré
- ⋆ Numéro de registration du véhicule
- ⋆ Type de vehicule de l'assuré
- ⋆ Nom de tiers
- ⋆ Adresse de tiers

1.2.4 Solution proposée

1.2.4.1 Hypothèse de la solution

La solution proposée consiste à mettre en place une application web qui regroupe toutes les opérations d'analyse, de gestion, d'exploitation et de maintenance des réclamations.

Une telle application permettra ainsi de :

- Faciliter la tâche de compréhension et d'analyse des e-mails.
- Accélérer le suivi des réclamations.
- Améliorer le business de l'entreprise.

1.2.4.2 Introduction au IE

La recherche et le développement dans IE ont été principalement motivés par « the Message Understanding Conferences (MUC1 [1]) ». Ces conférences offrent une décennie d'expérience dans la définition, la conception et l'évaluation de cette tâche.

Selon la communauté MUC, le système IE générique est un pipeline de composants, allant des modules de prétraitement et des filtres, aux composants linguistiques pour l'analyse syntaxique et sémantique, et aux modules de post-traitement qui construisent une réponse finale. Ces systèmes traitent chaque phrase du texte et tentent de proposer une représentation syntaxique, sémantique et pragmatique à grande échelle. De toute évidence, ils ont de sérieuses limitations de portabilité, car leur construction nécessite beaucoup d'ingénierie artisanale pour construire les grammaires et les bases de connaissances requises.

1.2.4.3 Implémentation proposée

La solution d'extraction automatique des informations qu'on propose dans notre projet consiste à récupérer les courriels, appliquer un traitement NLP pour identifier les champs cités précédemment, pour enfin gérer les informations structurées et ensuite les stocker vers une base de données (voir la figure 1.5).

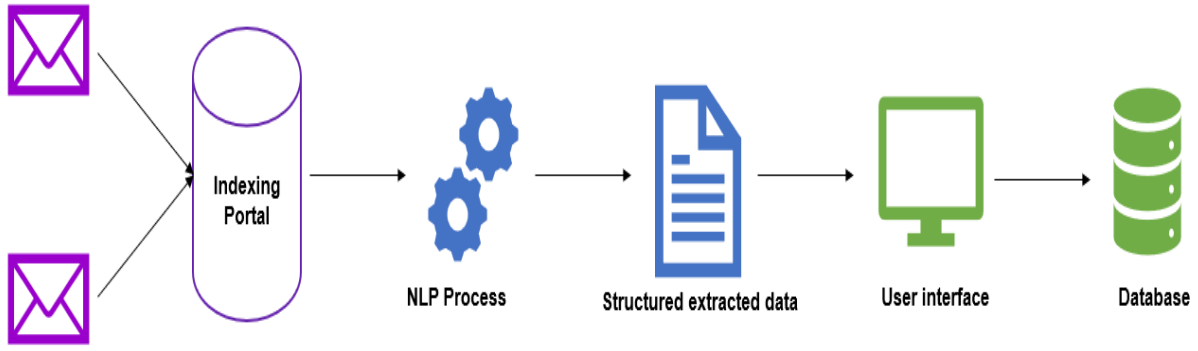


FIGURE 1.5 – Schéma illustratif de la solution proposé

1. https://en.wikipedia.org/wiki/Message_Understanding_Conference

Ainsi nous pouvant résumer le fonctionnement d'un tel système en trois étapes principales :

1. *Indexer les données*
   - Recueillir des données à partir de la boite email.
   - Reconnaître la revendication pertinente que devra être intégrée dans le portail d'indexation.
2. *Traiter les données*
   - Suggérer quel type de document a été inclus (par exemple, rapport de police / reçus).
   - Reconnaître s'il s'agit d'une nouvelle réclamation.
   - Analyser l'email (le message et les fichiers attachés).
3. *Visualiser les données*
   - Vérifier les informations extraites.
   - Enregistrer les informations dans la base de données.

Alors, nos objectifs à travers se projet consiste à centraliser les accès aux données, structurer les informations nécessaires et de fournir des interfaces de visualisation automatisées de maintien et de consommation de données.

1.3 Planification et conduite du projet

1.3.1 Processus de développement

Compte tenu de la nature du projet et de sa forte dépendance vis-à-vis des acteurs du domaine, nous nous sommes inspirés de l'esprit des méthodes agiles, et plus précisément SCRUM, pour nous organiser en prenant le temps de répartir les tâches et en effectuant une évaluation systématique des points bloquants et des objectifs atteints.

Le principe de la méthodologie SCRUM est de développer progressivement un logiciel tout en gardant la liste des changements ou des corrections à effectuer (backlog) totalement transparente.

Avec des livraisons très fréquentes, généralement toutes les 4 semaines, le client reçoit le logiciel à chaque itération. Plus nous avançons dans le projet, plus le logiciel est achevé et dispose de plus en plus de fonctionnalités.

Pour cela, la méthode est basée sur des développements itératifs à une récurrence constante de 2 à 4 semaines (2 semaines dans notre cas) comme le montre la figure 1.6 :

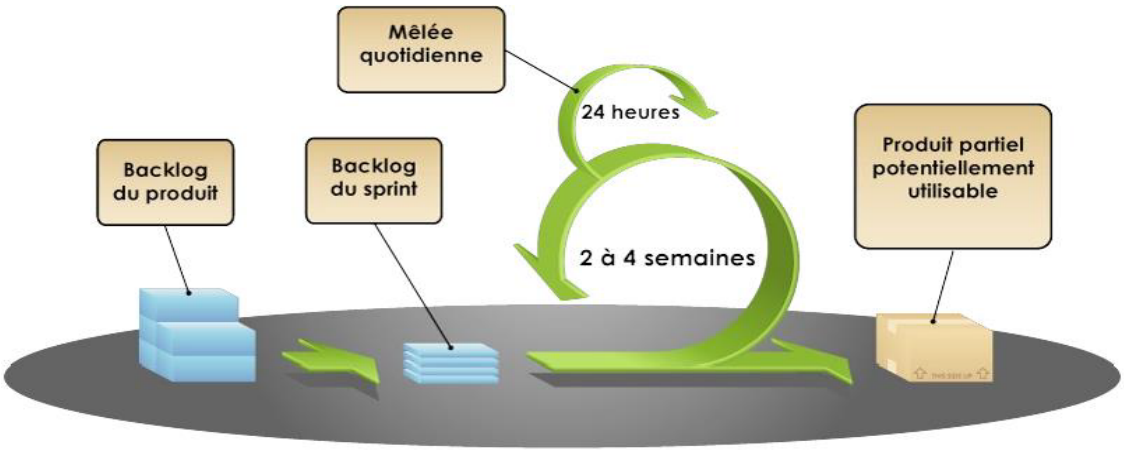


FIGURE 1.6 – Cycle de vie de la méthodologie scrum

Le schéma illustre un exemple de planification en Scrum : les itérations (sprints) durent entre 2 et 4 semaines en pratique, et possède chacune un objectif. L'objectif de chaque sprint est une liste d'items du backlog de produit ou de fonctionnalités à atteindre.L'équipe décompose ces items en tâches élémentaires de quelques heures.

Comme nous pouvons le voir sur cette figure, pour mettre en place la méthode SCRUM, il faut d'abord déterminer les différentes fonctionnalités de l'application qui constituent le backlog du produit. Vient ensuite l'étape de planification du sprint pour dessiner le plan détaillé d'une itération.

Lors du sprint, les collaborateurs du projet se réunissent toujours tous les jours pour présenter l'avancement des différentes tâches en cours, les difficultés rencontrées et les tâches restantes à effectuer. Une fois le produit partiel prête, nous vérifierons la conformité de ce qui a été réalisé pendant le sprint, puis nous pourrons l'améliorer en procédant à l'étape de rétrospective.

La méthodologie SCRUM implique 3 rôles principaux :

- **Product Owner** : Dans la plupart des projets, le responsable produit (product owner) est le responsable de l'équipe projet client. C'est lui qui définira et déterminera la priorité de la liste des fonctionnalités du produit, et choisira la date et le contenu de chaque sprint en fonction des valeurs (charges) qui lui sont communiquées par l'équipe.
- **Scrum Master** : Il est le véritable promoteur du projet, en supprimant les obstacles et en protégeant l'équipe des interférences extérieures, en veillant à ce que chacun

puisse fonctionner au maximum. Il est généralement le chef de projet.

- **Équipe de dévelopement** : elle regroupe tous les rôles habituellement requis pour un projet, à savoir le concepteur, le développeur, le testeur, etc. L'équipe s'organise elle-même et reste inchangée pendant la durée d'un sprint.

1.3.2 Planning du projet

La planification du projet est une étape importante d'avant-projet. Elle consiste à prévoir le déroulement de ce dernier durant les différentes phases formant le cycle de développement.

Le diagramme de Gantt dans la figure 1.7 démontre le déroulement du stage au fil du temps :

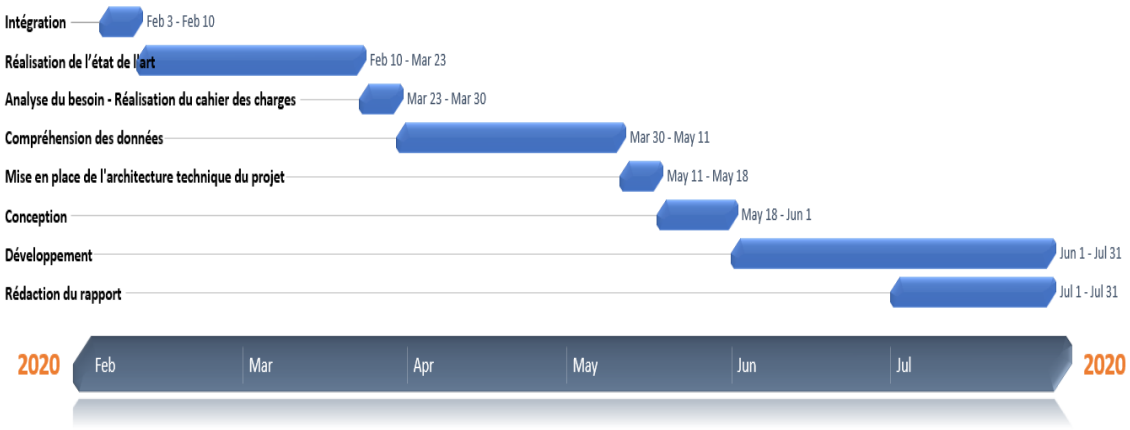


FIGURE 1.7 – Diagramme de gantt du projet

Comme la plupart des SSII (sociétés de services informatiques et d'ingénierie), « CED Group » est divisé en équipes de projet, chaque équipe travail sur un projet de manière quasi indépendante, le chef de projet remplit les fonctions RH quotidiennes et le Scrum Master prend en charge tout le cycle de vie logiciel.

Notre stage a commencé par une phase d'intégration. Cette phase comportait principalement des recherches sur les connaissance et les différents aspects et technologies adopté par l'entreprise.

Les formations programmées consistaient tout d'abord en quelques rappels concernant les bases du langage ASP.NET et des principes de développement mais aussi des technologies utilisées dans le projet.

Le plan d'intégration devait surtout faire une montée en compétence des collaborateurs sur des points critiques du projet, surtout en ce qui concerne les principes du clean code et aussi une introduction au principe de l'agilité adoptée dans les projets menés par « CED Group ».

Après la formation d'intégration, nous avons rejoint les équipes de développement pour enfin travailler sur le projet client.

Au début, nous avons été menés à une phase de montée en compétence dans le traitement du langage naturel, puisqu'il constitue le moteur principal utilisé dans le projet. Nous avons passé ensuite à la première itération qui concerne l'étude fonctionnelle ainsi que la capture et l'analyse des besoins fonctionnels, et ensuite le reste des itérations ou sprints de conception et l'implémentation du projet.

Les sprint étaient d'une durée de deux semaines pour chacune dans lesquels il y avait les processus de développement et de test de chaque fonctionnalité ajoutée et ainsi dans chaque deux à trois mois il y avait un processus de MEP (Mise en production) de la solution.

1.4 Conclusion

Dans ce chapitre introductif, nous avons présenté en premier lieu l'organisme « CED Group ». Dans un second lieu, nous avons déterminé le cadre du projet. Ensuite nous avons spécifié la problématique du projet. Et en dernier lieu, nous avons présenté la méthode de travail à adopter et illustré le déroulement du travail avec le planning suivi tout au long du projet.

Le chapitre qui suit couvre une étape principale pour le projet, qui est la réalisation de l'état de l'art.

Chapitre 2

Etat de l'art

> *Ce chapitre décrit l'état de l'art réalisé sur le traitement du langage naturel. Il a pour but de cerner avec clarté notre sujet et de découvrir les approches et les methodes possibles pouvant traiter notre problématique.*

2.1 Introduction au TALN

Le Traitement Automatique du Langage Naturel (TALN) vise à appliquer des méthodes informatiques pour exploiter des ressources exprimées en langue naturelle. C'est une discipline à l'interface entre la linguistique, l'informatique et l'intelligence artificielle.

Le TALN a donc pour objectif de développer des programmes informatiques capables de traiter de façon automatique des données linguistiques. Toute la complexité de cette tâche repose sur le fait qu'un langage naturel utilise un vocabulaire non exhaustivement défini, avec une sémantique ambigüe et des règles syntaxiques nombreuses à la complexité variable.

Pour traiter automatiquement des données linguistiques, il convient donc d'abord d'identifier les règles pertinentes de la langue puis de les représenter dans des formalismes opératoires et calculables et enfin de les implémenter à l'aide de programmes informatiques [8].

Mais pourquoi donc s'intéresser au Traitement Automatique du Langage ?

2.1.1 Les applications du TALN

A l'ère de l'Intelligence Artificielle et des données en masse, le TALN trouve, en dehors de son intérêt académique évident, une multitude d'applications pratiques dans :

- Le traitement de la parole
- La traduction automatique
- La compréhension automatique des textes
- La génération automatique de textes
- La gestion électronique de l'information et des documents existants (GEIDE)

Dans le cadre de notre projet, il s'agit de la compréhension automatique des textes. Le système va devoir comprendre et analyser les courriels saisies en langage naturel, pour pouvoir en extraire les informations pertinentes. Une telle tâche est dite : L'extraction automatique d'informations (IE).

Néanmoins, si le TALN permet effectivement d'exploiter des ressources linguistiques massives et complexes pour résoudre les ambiguïtés du langage écrit, ce n'est pas sans peine.

2.1.2 Les difficultés du TALN

1. *L'ambiguïté :*

   La première difficulté est l'ambiguïté du langage naturel. Elle se manifeste à plusieurs niveaux.

   - Au niveau phonétique : les homophones sont des mots distincts qui se prononcent de la même façon (par exemple "laid" et "lait").
   - Au niveau lexical : on trouve des ambiguïtés lexicales polysémiques (par exemple : "Antoine sent la rose" peut être paraphrasé en "Antoine hume la rose" ou "Antoine a l'odeur d'une rose") et des ambiguïtés lexicales homonymiques (par exemple dans la phrase "Cet ours a mangé un avocat," la forme avocat correspond à deux termes distincts, l'un désignant un fruit, l'autre une personne).
   - Au niveau grammatical : certaines phrases admettent plusieurs structures syntaxiques (par exemple la phrase "Julien a vu un homme avec un télescope" peut être paraphrasée en "Julien a vu un homme grâce à un télescope" ou "Julien a vu un homme qui avait un télescope").

2. *L'implicité :*

   La seconde difficulté majeure est la quantité d'implicite présente dans presque tout énoncé naturel. La compréhension d'un énoncé en langue naturelle est effectuée chez l'humain par des processus cognitifs impliquant des connaissances extérieures à celles comprises dans l'énoncé.

   Par exemple, de l'énoncé "L'appartement est en face de l'autoroute," un être humain déduit automatiquement que l'appartement en question se situe dans un environnement bruyant.

Pour surmonter ces difficultés, il faut adopter une approche pratique pour traiter notre tâche et effectuer un traitement linguistique complexe, en plusieurs étapes essentielles.

2.2 Approches pour l'extraction d'informations

Avant d'aller de l'avant, examinons les différentes approches de l'extraction d'informations. Nous pouvons globalement diviser l'extraction d'informations en deux branches : l'extraction d'information traditionnelle (Traditional Information Extraction) et l'extraction d'informations ouvertes (Open Information Extraction), comme indiqué dans la figure 2.1 ci-dessous.

Dans ***l'extraction d'information traditionnelle***, les relations à extraire sont prédéfinies.

Dans ***l'extraction d'informations ouvertes***, les relations ne sont pas prédéfinies. Le système est libre d'extraire les relations qu'il rencontre en parcourant les données textuelles.

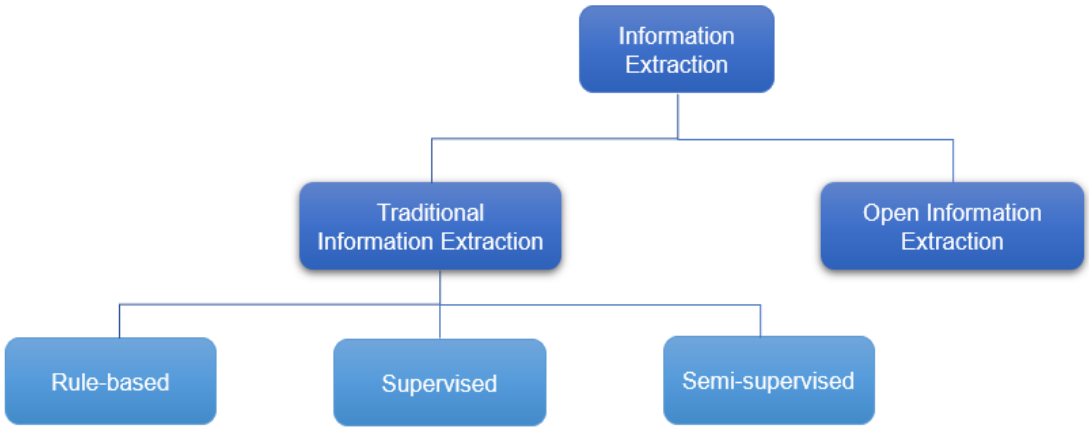


FIGURE 2.1 – Différentes approches pour l'extraction d'informations

Nous couvrirons uniquement les 3 méthodes principaux d'approches pour résoudre notre tâche d'extraction d'informations : approche basée sur des règles (Rule-based approach), approche supervisée et approche semi-supervisée [9].
Comprenons-les un par un .

2.2.1 Approche basée sur des règles

Le plus ancienne approche de TALN. Nous définissons un ensemble de règles pour la syntaxe et d'autres propriétés grammaticales d'un langage naturel, puis utilisons ces règles pour extraire des informations du texte.

Ces approches sont encore utilisés. C'est parce qu'ils ont fait leurs preuves et qu'ils fonctionnent bien. Les règles appliquées au texte peuvent offrir beaucoup d'informations. « Regular expression (Regex) » et « Context-free grammar (CFG) » sont des exemples classiques d'approches de TALN basées sur des règles.

Approches basées sur des règles :

- ont tendance à se concentrer sur la correspondance de modèles (pattern-matching) ou l'analyse (parsing).
- peuvent souvent être considérées comme une méthode de « fill in the blanks ».
- sont de faible rappel et de précision élevée, ce qui signifie qu'ils peuvent avoir des performances élevées dans des cas d'utilisation spécifiques, mais souffrent souvent d'une dégradation des performances lorsqu'ils sont généralisés.

2.2.2 Approche Machine Learning traditionnelle

Les approches d'apprentissage automatique « traditionnelles » comprennent la modélisation probabiliste, la maximisation de la vraisemblance et les classificateurs linéaires. Notamment, ce ne sont pas des modèles de réseaux neuronaux (voir ceux ci-dessous).

Les approches traditionnelles d'apprentissage automatique se caractérisent par :

- données d'apprentissage, dans ce cas, un corpus avec balisage.
- feature engineering - word type, mots environnants, majuscules, pluriel, etc...
- apprentissage d'un modèle sur des paramètres, suivi d'un ajustement sur des données de test (typique des systèmes d'apprentissage automatique en général).
- inférence (application du modèle aux données de test) caractérisée par la recherche des mots les plus probables, du mot suivant, de la meilleure catégorie, etc...

2.2.3 Réseaux de neurones

Cette approche est similaire à l'apprentissage automatique « traditionnel », mais avec quelques différences :

- feature engineering est généralement ignorée, car les réseaux « apprendront » des fonctionnalités importantes (c'est généralement l'un des grands avantages revendiqués de l'utilisation des réseaux neuronaux pour le TALN).
- au lieu de cela, des flux de paramètres bruts (« mots » - en fait des représentations vectorielles des mots) sans fonctionnalités techniques, sont introduits dans les réseaux de neurones.
- très grand corpus d'apprentissage.
- Les réseaux neuronaux spécifiques d'utilisation en TALN comprennent les réseaux neuronaux récurrents (RNN) et les réseaux neuronaux convolutifs (CNN).

2.2.4 Analyse comparative des approches TALN

Afin de bien choisir l'approche appropriée que nous utiliserons pour notre système, nous procédons à une analyse comparative des approches TALN pour le problème d'extraction d'informations.

Outre les paramètres d'évaluation standard des systèmes IE tels que la précision et le rappel, les techniques peuvent également être jugées au moyen de la mise en œuvre. Alors que l'apprentissage automatique statistique est largement utilisé comme technologie

de boîte noire concernant la transparence de la traçabilité des décisions, les approches basées sur des règles suivent une approche principalement déclarative menant à des modèles hautement transparents et expressifs.

D'autres avantages de ces langages de règles incluent la lisibilité et la maintenabilité et surtout la possibilité de transférer directement la connaissance du domaine en règles. Le potentiel d'inclure directement les connaissances d'un expert du domaine dans le processus d'IE plutôt que de choisir les données de formation, les hyper-paramètres ou les poids les plus prometteurs, incorporant ainsi indirectement les connaissances du domaine, est un avantage majeur par rapport aux autres approches d'IE.

Cependant, les approches basées sur des règles et le ML ne doivent pas être utilisées exclusivement, mais peuvent très bien se compléter. Comme l'apprentissage supervisé nécessite toujours une (grande) quantité de données de formation, l'une des premières étapes consiste à échantillonner et à créer des ensembles de données de formation. Dans les domaines où les échantillons pré-étiquetés sont rares ou inexistants, cette étape est une tâche qui prend le plus de temps.

Même si les systèmes IE basés sur des règles nécessitent la mise en œuvre manuelle de règles, le travail manuel impliqué se traduit directement par la qualité des règles, tandis que les techniques de ML nécessitent des connaissances théoriques et une expérimentation très approfondies pour maximiser leur efficacité. Cela est également dû à la similitude syntaxique et sémantique de la règle avec les expressions régulières, ce qui les rend plus faciles à apprendre et donc plus faciles à entretenir par des équipes ayant des compétences différentes.

Bien que l'IE basé sur des règles présente de nombreux avantages, les langages de règles de pointe actuels présentent également plusieurs inconvénients. Le tableau 2.1 ci-dessous résume les avantages et inconvénients des approches TALN.

Approche	Avantages	Inconvénients
Approche basée sur des règles	• Approche flexible, Déclarative • Facile à déboguer et à maintenir • Facile à intégrer la connaissance du domaine • Ne nécessite pas un corpus de formation massif • Compréhension du phénomène linguistique • Haute précision	• Heuristique • Nécessite des développeurs et des linguistes qualifiés • Nécessite un travail manuel fastidieux • Développement de l'analyseur lent • Rappel modéré (couverture)
Approche Machine learning	• Entraînable • Adaptable • Réduisez l'effort manuel • Facile à mettre à l'échelle • « Apprentissage » sans être explicitement programmé • Développement rapide (si les ensembles de données sont disponibles) • Rappel élevé (couverture)	• Nécessite un corpus de formation avec annotation • Difficile à déboguer • Pas de compréhension du phénomène du langage • Nécessite un recyclage pour l'adaptation du domaine • Nécessite une expertise en ML pour utiliser ou maintenir • opaque

TABLE 2.1 – Analyse comparative des approches de TALN

2.3 Système IE proposé

En passant par une phase de compréhension des données, nous avons constaté que l'approche fondée sur des règles est la plus appropriée à notre problème, notamment que nous avons besoin d'une haute précision d'une part et nous ne disposons pas de suffisamment de données étiquetées pour appliquer l'approche ML d'autre part.

La figure 2.2 illustre l'architecture globale du système avec des modules spécifiques décrits plus en détail dans les sections suivantes.

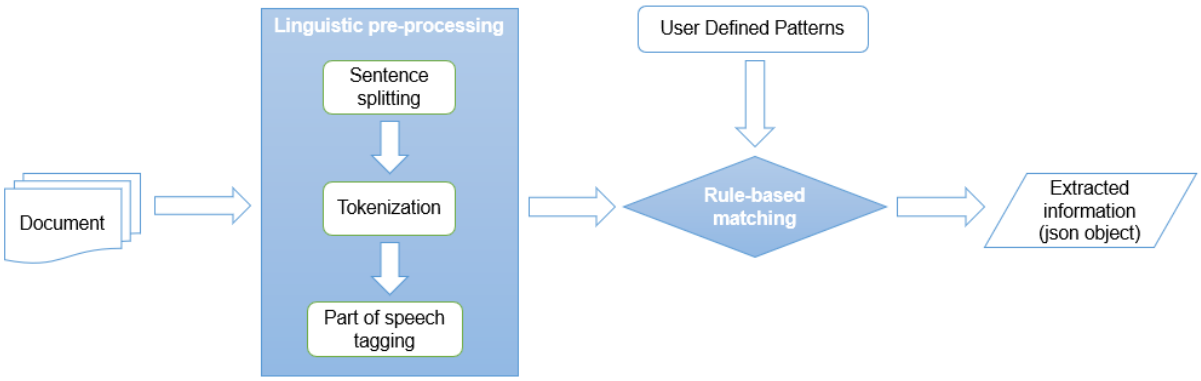


FIGURE 2.2 – Système IE proposé

2.3.1 Pré-traitement linguistique

Le prétraitement de texte est l'une des tâches les plus importantes du traitement du langage naturel (NLP). Les principales étapes de la phase de pré-traitement linguistique sont :

2.3.1.1 Tokenisation

Avant toute analyse automatique de texte, il est d'abord essentiel de le segmenter en unités linguistiques. La segmentation de plus bas niveau s'intéresse aux mots, et il est également possible de tokeniser en clauses, phrases et paragraphes. Cette étape s'appelle la tokenisation.

La tokenisation en mots est essentiellement basée sur l'espace, marqueur de séparation privilégié à l'écrit, mais il faut néanmoins rester vigilant et ne pas oublier certaines exceptions, tels que les noms composés dont le lien est explicite (e.g bateau-mouche, aujourd'hui), ou bien les noms composés détachés (e.g. pomme de terre). La gestion de ces

derniers relève d'une tokenisation avancée, et s'appuie généralement sur des ressources linguistiques externes.

2.3.1.2 Part-Of-Speech tagging POS

Après avoir segmenté le texte en unités lexicales, une première analyse avancée des données consiste à étiqueter chaque 'token' avec des informations grammaticales : c'est *l'étiquetage syntaxique*.

Cette étape permet d'attribuer une classe grammaticale (eg. nom, verbe, adjectif) à chaque token. Si des informations relatives au genre et au nombre apparaissent également, on parle d'étiquetage morphosyntaxique. L'étiquetage permet d'effectuer une première désambiguïsation entre un nom et un verbe conjugué homonymes par exemple (« une lance » ou « il lance »).

2.3.2 Rule-Based Matching

« Matching » c'est de faire la correspondance entre les « patterns » définis et qui forment les règles linguistiques et le text d'entrée. Le « matcher » recherche ces « patterns » que nous encodons sous forme de liste de dictionnaires. Il fonctionne jeton par jeton, c'est-à-dire mot pour mot, à l'exception de la ponctuation et des nombres où un seul symbole peut être un jeton.

2.4 Conclusion

En conclusion de cet état de l'art préliminaire, il apparaît que la méthode basée sur des règles est la plus adéquate à mettre en œuvre pour notre projet. Cependant, cette méthode demande des efforts en terme de connaissances lignuistiques. L'utilisation des méthodes d'apprentissage automatique (ML) dans les applications IE est principalement axée sur l'acquisition automatique des modèles d'extraction.

De nombreux outils sont disponibles pour implémenter ces méthodes. Ces méthodes sont donc susceptibles d'être améliorées en fonction des outils utilisés, mais le choix de la méthode à adopter dépend des données cibles, et donc du besoin du client.

Dans le chapitre qui suit, nous allons entamer la phase d'analyse fonctionnelle et non fonctionnelle de notre projet ainsi que la conception détaillée, phase dans laquelle, on a défini les spécifications dans le but d'élaborer l'architecture globale du projet.

Chapitre 3

Analyse et spécification des besoins

> *Dans ce chapitre, nous allons aborder les phases d'analyse et de spécification des besoins du projet, dans le but d'avoir une vision globale claire du comportement du projet ainsi que les attentes des utilisateurs.*

3.1 Spécification des besoins

3.1.1 Besoins fonctionnels

La capture des besoins fonctionnels est une étape importante du projet. Cette étape produit le dossier des spécifications fonctionnelles, et au cours duquel les fonctionnalités attendues sont formalisées ainsi que l'ensemble des règles de gestion en vigueur. Les besoins fonctionnels identifiés sont résumés dans les points suivants :

1. **Identification de la langue du courriel :**
   Les courriels réçus sont en plusieurs langues. La plate-forme doit permettre de savoir la langue du courriel, avant d'entamer le processus d'extraction. Le TALN dans ce projet se limite sur les réclamations écrites en anglais.
2. **Extraction des informations :**
   La fonctionnalité la plus importante dans le projet. La platforme doit reconnaître les champs considérables sur les parties concernés par l'incident en garantissant une bonne performance.
3. **Classification des fichiers :**
   Les documents attachés au courriel ne sont pas structurés et son de plusieurs types, projet doit permettre de les classifier et de suggérer quel type de document a été inclus (par exemple : rapport de police / reçus) avec un étiquetage et classement appropriés dans le système.
4. **Vérification :**
   Un système d'extraction d'informations ne peut pas garantir une performance totale. Or avoir des informations erronée ne peut pas être toléré. Par conséquent, le projet doit permettre de vérifier les détails extraits.
5. **Détermination de la bonne tâche de suivi :**
   En classant l'e-mail, la plate-forme doit permettre de suggérez la bonne tâche de suivi (par exemple, demande de mise à jour / accord de paiement) et lui attribuez une urgence.

3.1.2 Besoins non-fonctionnels

Outre que les besoins fonctionnels, notre solution doit respecter aussi les besoins non fonctionnels cités ci-dessous :

- **Fiabilité :** Les informations extraites par le système doivent être fiables et correctes.

- **Ergonomie :** L'interface graphique de l'application doit être compréhensible, intuitive, ergonomique et adapté aux utilisateurs.
- **Extensibilité :** Le système doit permettre l'intégration de nouvelles fonctionnalités.
- **Flexibilité :** Le système devra être flexible pour s'adapter au changement des exigences au fil du temps
- **Maintenabilité :** Le système doit être facile à maintenir et ouvert à toute nouvelle modification

3.2 Analyse des besoins fonctionnels

L'analyse des besoins est une étape très importante dans le processus de l'étude et le développement des systèmes d'informations. Cette partie identifie l'ensemble des acteurs qui interagissent avec le système et définit l'ensemble des cas d'utilisation de ce dernier en se basant sur les diagrammes UML.

3.2.1 Identification des acteurs

Un acteur est une personne, un matériel ou un logiciel qui interagit avec le système. L'analyse du présent projet commence par une identification des acteurs agissants sur les différentes parties du système. Les acteurs sont les employés back office du CED Group, qui sont les utilisateurs de l'application.

3.2.2 Diagramme des cas d'utilisation

Cette partie présente l'ensemble des cas d'utilisation de la solution « Système d'analyse Automatique des e-mails » en se basant sur le diagramme des cas d'utilisation du système et des tableaux qui décrivent les scénarios nominaux. Chaque cas d'utilisation schématise une exigence fonctionnelle. La figure 3.1 ci-dessous décrit les fonctionnalités énoncées auparavant :

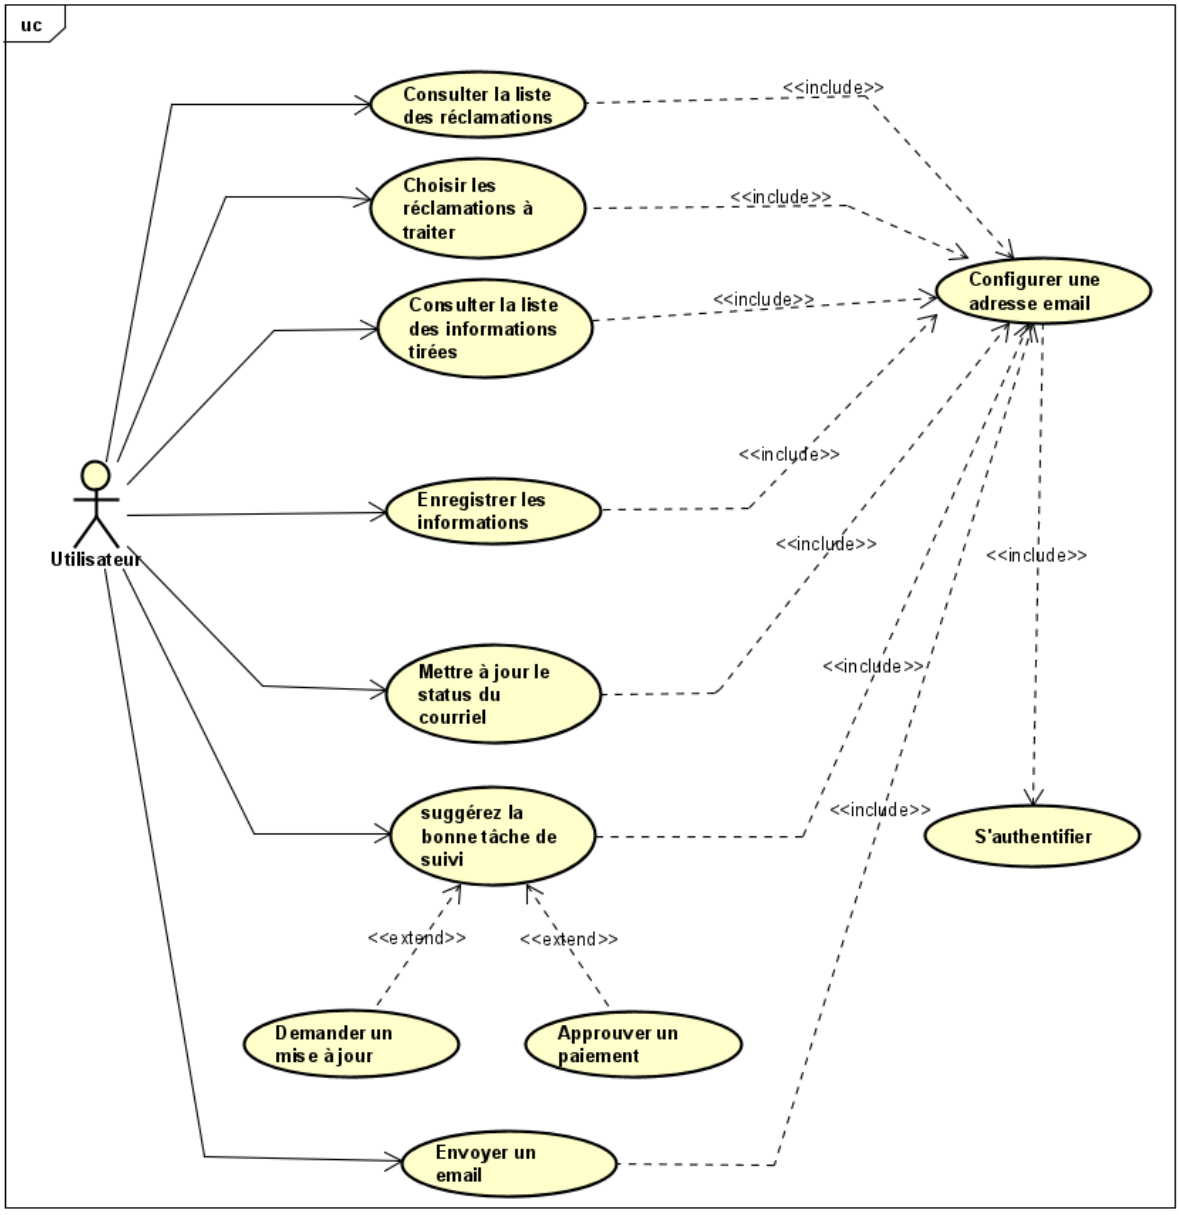


FIGURE 3.1 – Diagramme des cas d'utilisation

- **Cas d'utilisation S'authentifier :** permet aux utilisateurs de se connecter au système avec leurs logins et mots de passe afin de sécuriser la platforme.
  - ***Objectif :*** Cette fonctionnalité permet aux différents acteurs de se connecter.
  - ***Acteur :*** Tous les acteurs
  - ***Pré-condition :*** L'acteur se connecte au système.
  - ***Scénario nominal :***
    1. L'acteur saisit son login et son mot de passe.
    2. Le système vérifie les informations saisies.
    3. Le système trouve que les informations saisies sont valides.
    4. Le système connecte l'acteur.
  - ***Scénario d'erreur :***
    1. L'acteur saisit son login et son mot de passe.
    2. Le système vérifie les informations saisies.
    3. Le système trouve que les informations saisies sont invalides.
    4. Le système demande à l'acteur de vérifier les informations saisies.

- **Cas d'utilisation Configurer une adresse email :** Pour que le système puisse accéder au boite mail contenant les réclamations des clients, l'acteur est demandé de saisie l'adresse email convenable.
  - ***Objectif :*** Cette fonctionnalité permet à l'utilisateur d'entrer l'adresse email nécessaire.
  - ***Acteur :*** Tous les acteurs
  - ***Pré-condition :*** L'acteur se connecte au système.
  - ***Scénarios nominaux :***
    1. L'acteur saisie l'adresse email.
    2. L'acteur confirme l'adresse email.

- **Cas d'utilisation Choisir les réclamations à traiter :** Les courriels tirés à patir du boite mail ne sont pas tous nécessaires, il faut alors reconnaître la revendication pertinente référencée et la suggérer lors de l'indexation.
  - ***Objectif :*** Cette fonctionnalité permet à l'utilisateur de sélectionner les emails à traiter.
  - ***Acteur :*** Tous les acteurs
  - ***Pré-condition :***
    1. L'acteur se connecte au système.

2. L'acteur saisie l'adresse email.

— ***Scénarios nominaux :***

1. L'acteur affiche la liste des réclamations disponibles.
2. L'acteur choisit la réclamation à intégrer dans le portail d'indexation.
3. Le système confirme à l'acteur l'enregistrement du courriel.
4. Le système affiche la liste des réclamations enregistrées.

- **Cas d'utilisation Consulter la liste des réclamations :** La liste des réclamations est un ensemble des messages et des fichiers provenant par email.

— ***Objectif :*** Cette fonctionnalité permet à l'utilisateur d'avoir une idée sur la réclamation à savoir le nombre de fichiers attachés au courriel, la date de lancement de la réclamation...
— ***Acteur :*** Tous les acteurs
— ***Pré-condition :***

1. L'acteur se connecte au système.
2. L'acteur saisie l'adresse email.

— ***Scénarios nominaux :***

1. L'acteur affiche la liste des réclamations.
2. L'acteur sélectionne une réclamation.
3. Le système affiche les informations concernant la réclamation sélectionnée.

- **Cas d'utilisation Consulter la liste des informations tirées :** Avant l'enregistrement dans la base de données, il faut, intuitivement, visualiser les données extraites pour savoir la performance du sytème.

— ***Objectif :*** Cette fonctionnalité permet à l'utilisateur de consulter la liste des détails tirées.
— ***Acteur :*** Tous les acteurs
— ***Pré-condition :***

1. L'acteur se connecte au système.
2. L'acteur saisie l'adresse email.

— ***Scénarios nominaux :***

1. L'acteur affiche l'ensemble des informations extraites par le système.
2. L'acteur valide les informations.

- ⋆ Le système permet à l'acteur de prévisualiser le message de l'email et les fichiers attachés.
- ⋆ L'acteur peut éditer toute information erronée ou manquée.
- ⋆ L'acteur peut ajouter une information manquante.
- ⋆ L'acteur confirme au système la vérification.

- **Cas d'utilisation Enregistrer les informations :**
  - ***Objectif :*** Cette fonctionnalité permet à l'utilisateur de stocker les informations dégagées du courriel dans la base de données.
  - ***Acteur :*** Tous les acteurs
  - ***Pré-condition :***
    1. L'acteur se connecte au système.
    2. L'acteur saisie l'adresse email.
  - ***Scénarios nominaux :***
    1. L'acteur accède à la réclamation concernée.
    2. L'acteur click sur le buton « save ».

- **Cas d'utilisation Mettre à jour le status du courriel :** Le portail d'indexation constitue une sorte de conteneur global des emails. Il est divisé en deux version « Treated (traité) » et « Not Treated (non traitée) » pour distinguer les données en cours de traitement des données traitées.
  Le présent cas d'utilisation permet la synchronisation entre ces deux versions et l'indexation des objets de ce portail.
  - ***Objectif :*** Cette fonctionnalité permet à l'utilisateur d'attribuer un badge pour toute réclamation permettant de distinguer entre eux.
  - ***Acteur :*** Tous les acteurs
  - ***Pré-condition :***
    1. L'acteur se connecte au système.
    2. L'acteur saisie l'adresse email.
  - ***Scénarios nominaux :***
    1. L'acteur click sur le bouton « Edit ».
    2. L'acteur choisie l'option « Treated ».

- **Cas d'utilisation Suggérez la bonne tâche de suivi :** Après avoir traité le contenu de l'email et enregistré les détails dans la base de données, l'acteur est invité à définir la tâche de suivi convenable à l'état d'avancement du procedure de la réclamation.

  — ***Objectif :*** Cette fonctionnalité permet à l'utilisateur d'avancer les procedures d'une réclamation.
  — ***Acteur :*** Tous les acteurs
  — ***Pré-condition :***

  1. L'acteur se connecte au système.
  2. L'acteur saisie l'adresse email.

  — ***Scénarios nominaux :***

  1. L'acteur sélectionne la réclamation.
  2. L'acteur saisie la tâche de suivi convenable :
     ⋆ Demander un mise à jour.
     ⋆ Approuver un paiement.

- **Cas d'utilisation Envoyer un email :** Nous trouvons qu'un service de messagerie peut être utile, vu que les revendications peuvent manquer quelques détails nécessaires dans les procédures du traitement d'une réclamation.

  — ***Objectif :*** Cette fonctionnalité permet à l'utilisateur d'envoyer un courriel.
  — ***Acteur :*** Tous les acteurs
  — ***Pré-condition :***

  1. L'acteur se connecte au système.
  2. L'acteur saisie l'adresse email.

  — ***Scénarios nominaux :***

  1. L'acteur remplit les champs nécessaires :
     ⋆ L'acteur saisie l'adresse du destinataire.
     ⋆ L'acteur rédige l'email.
     ⋆ L'acteur peut attacher un fichier à l'email.
  2. L'acteur envoie l'email.
  3. Le système confirme à l'acteur l'envoie du courriel.

3.2.3 Conclusion

L'objectif de ce chapitre était de définir et d'analyser l'ensemble des besoins fonctionnels de notre solution. Cette étape est essentielle dans le développement d'un projet informatique car elle nous permet de définir le périmètre fonctionnel du projet, et de garantir la couverture de toutes les fonctionnalités recensées.

Chapitre 4

Étude Conceptuel et architectural

> *Dans ce chapitre nous allons nous nous concentrerons sur les aspects conceptuels et architecturaux de la solution à mettre en œuvre. Cette étude conceptuelle est basée sur l'élaboration et l'analyse des différents schémas et diagrammes.*

4.1 Diagramme de classes

c'est un diagramme qui montre une collection d'éléments statiques (classes), leur contenu et les relations entre eux, il fait abstraction des aspects dynamiques et temporels. Le diagramme de classes de la figure 4.1 représente ces différents classes et leurs relations :

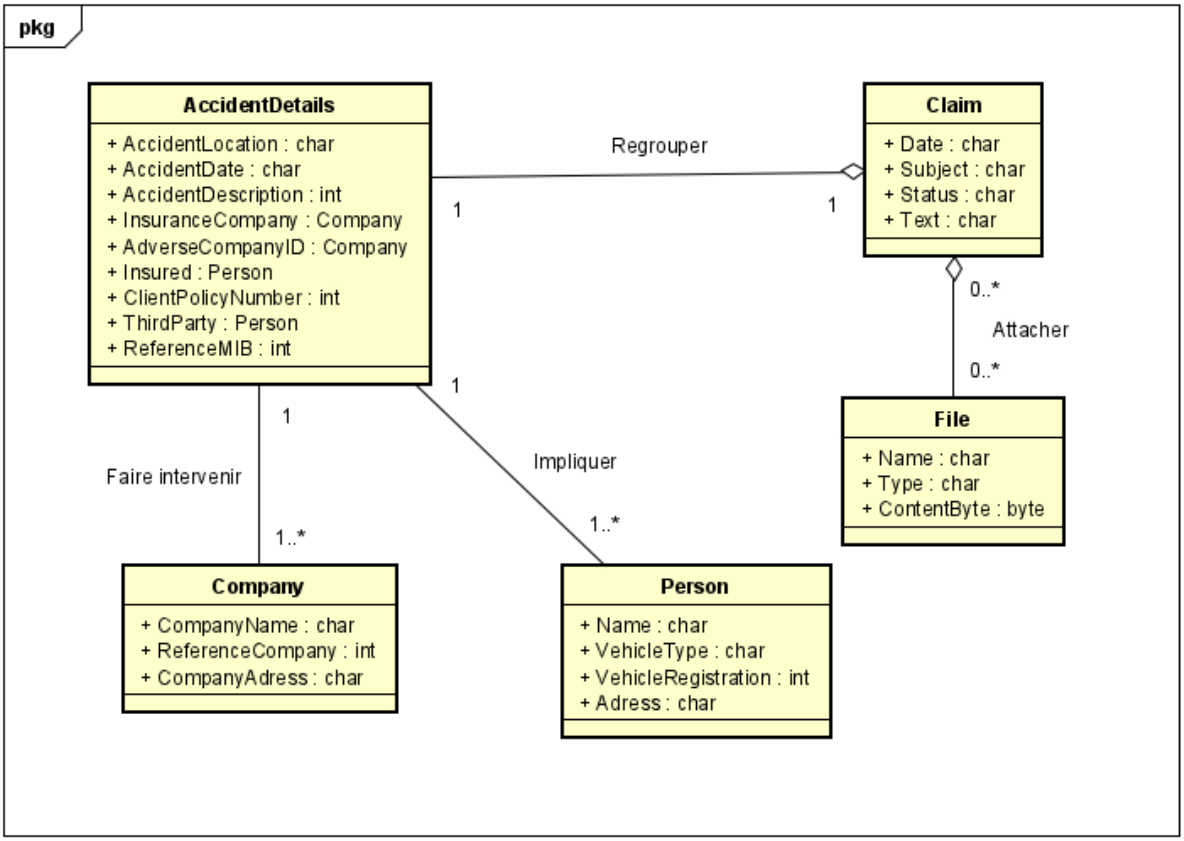


FIGURE 4.1 – Aperçu du diagramme de classes

Comme le montre la figure, les différentes entités présentées dans ce diagramme sont comme suit :

- **AccidentDetails :** représente les différents détails tirées à partir du message de l'email ainsi que les fichiers attachés. Cette classe est en relation « one-to-one » avec la classe « Claim », et une relation « one-to-many » avec la classe « Person » et la classe « Company ». En effet, un incident peut impliquer une ou plusieurs personnes, et fait intervenir par la suite une ou plusieurs sociétés d'assurances.
- **Person :** représente les différents attributs décrivant les personnes impliquées dans l'incident.

- **Company :** représente les différents attributs décrivant les sociétés d'assurance concernées par l'incident.
- **Claim :** représente les différents attributs décrivant le courriel sur lequel nous souhaitons lancer le processus du TALN. Cette classe établit une relation d'agrégation avec une cardinalité « one-to-one » avec la classe « AccidentDetails », et une relation d'agrégation avec une cardinalité « one-to-many » avec la classe « File ». En effet, une réclamation peut ne pas avoir de fichiers attachés, mais peut en avoir plusieurs. Egalement, une réclamation ne peut contenir qu'une seule liste de détails.
- **File :** représente les différents attributs décrivant les fichiers attachés au courriel. Un fichier peut être de type :
  1. **Police report** (extension pdf)
  2. **Accident photos** (extention png, jpg)
  3. **Injury report** (extension pdf)
  4. **Invoices** (extension pdf)

4.2 Diagramme d'activité

Le diagramme d'activité est le plus approprié pour modéliser la dynamique d'une tâche ou d'un processus métier. Ce diagramme est utilisé pour :

- Modéliser un « workflow » dans un cas d'utilisation ou entre plusieurs cas d'utilisation.
- Spécifier une opération et décrire sa logique

4.2.1 Diagramme d'activité de la solution

La figure 4.2 suivante présente le diagramme d'activité de l'application. Le processus de traitement du courriel commence par le lancement de l'application. Après avoir s'authentifié, l'utilisateur devra saisir l'adresse email qu'il souhaite traiter ses courriels. La plateforme accède au dossier « Inbox » de l'adresse saisie, et en récupère les courriels réçus. L'utilisateur peut ainsi consulter la liste de ces courriels. À cette étape, l'utilisateur est demandé de reconnaître les revendications pertinentes pour les introduire dans la base de données.

Avant de lancer le programme du TALN, il faut tout d'abord identifier le courriel à traiter. À ce niveau, nous distinguons deux cas de figure :

1. Un nouveau courriel décrivant une nouvelle réclamation : dans ce cas, l'utilisateur peut lancer le le programme du TALN pour l'analyse du courriel : message et fichiers. La plate-forme offre une interface pour visualiser les informations identifiées, sous forme d'un tableau. Après avoir consulté la liste, l'utilisateur peut vérifier son contenu.
   - Le programme d'extraction basé sur le TALN peut fournir des informations erronées. L'utilisateur doit donc rectifier l'analyse de la réclamation. Si la liste résultante manque certains détails nécessaire, il peut envoyer un email à l'expéditeur pour lui en demander.
   - Si le programme d'extraction basé sur le TALN a fourni des informations entièrement correctes, l'utilisateur confirme l'analyse de la réclamation.
2. Un nouveau courriel référant à une ancienne réclamation et mettant à jour certaines informations : dans ce cas de figure, les procedures de la réclamation ont avancé, l'utlisateur doit suggérer l'étape suivante :
   - Demande de mise à jour
   - Accord de paiement

Finalement, l'utilisateur de l'application change le type du courriel en « Treated » et enregistre la liste de détails dans la base de données.

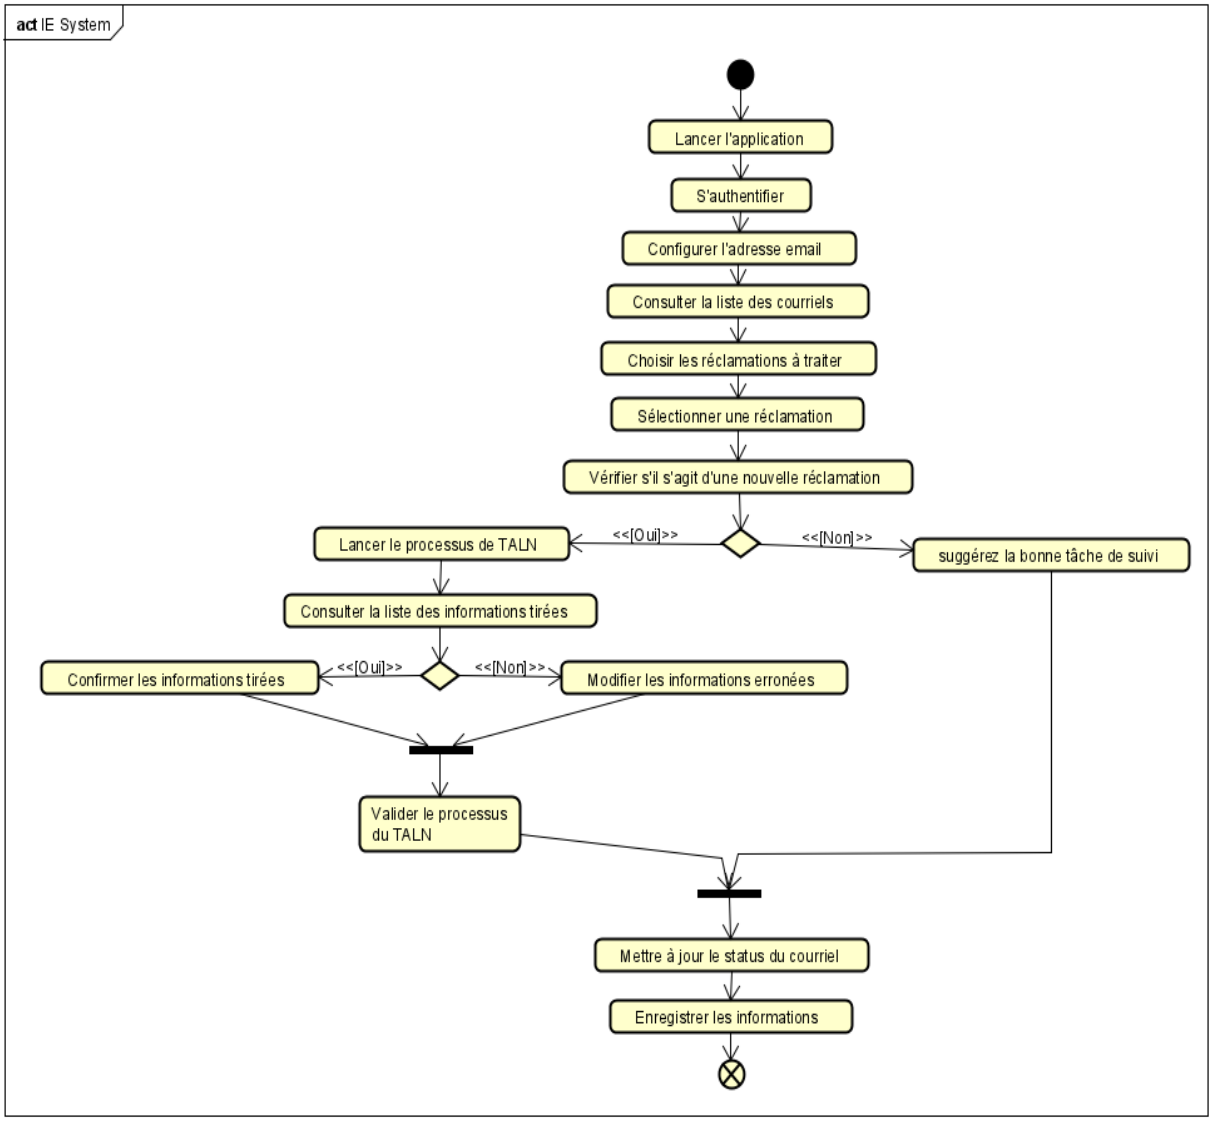


FIGURE 4.2 – Diagramme d'activité de l'application

4.2.2 Diagramme d'activité relatif à l'authentification

La figure 4.3 suivante représente le diagramme d'activité relatif à l'authentification. La première étape est de saisir le login puis le mot de passe. Il clique sur « Se connecter ». Le système vérifie le login et le mot de passe. Si les données sont correctes, la connexion au site s'établit et l'interface principale s'affiche de nouveau d'où la fin du processus d'authentification. Si les données ne sont pas correctes, l'utilisateur est appelé à saisir de nouveau le login et le mot de passe.

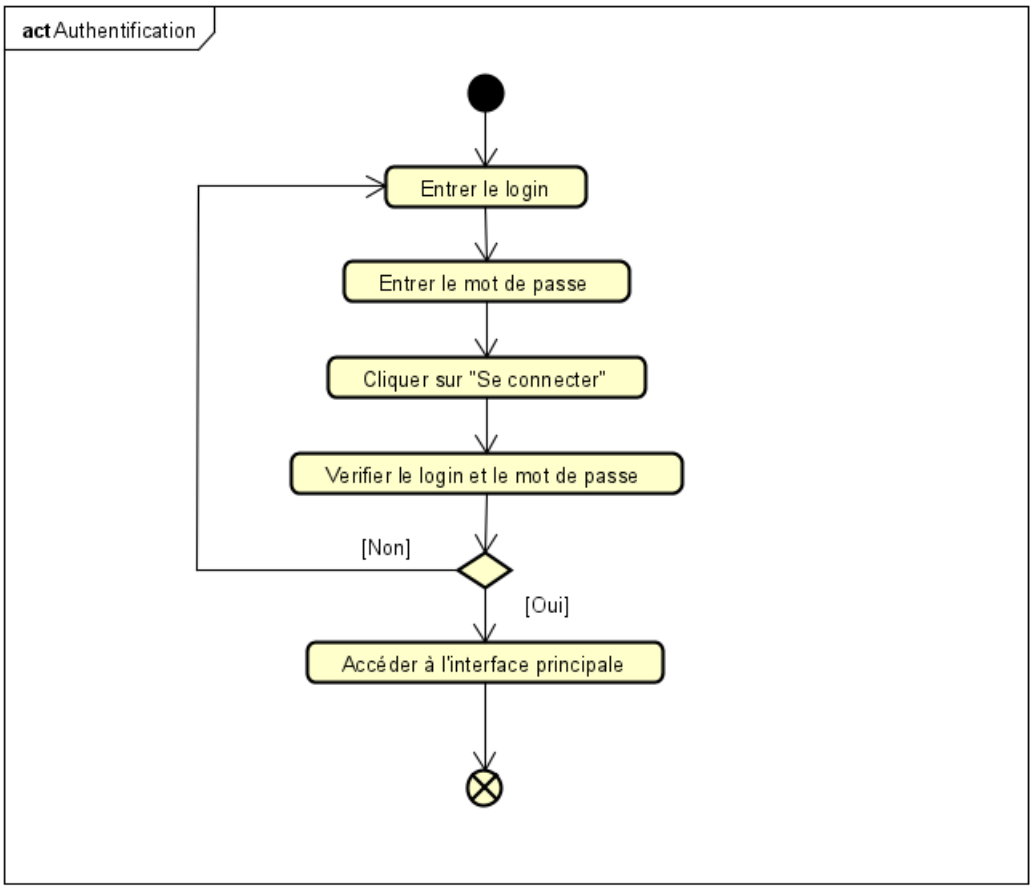


FIGURE 4.3 – Diagramme d'activité « Authentification »

4.3 Diagramme de séquence

Le diagramme de séquence décrit l'ordre d'interaction entre les objets composants le système. Ce diagramme se concentre sur la séquence des interactions d'un point de vue temporel.

4.3.1 Diagramme de séquence de l'application

Le Diagramme de séquence 4.4 suivant décrit globalement notre application « Système d'analyse automatique des e-mails ». Le processus commence par la création du compte, ensuite l'utilisateur est dirigé vers une page « Login ». Puis, à l'interface de l'application, l'utilisateur peut choisir l'action à effectuer.

La variable « Réclamation » peut prendre la valeur « nouvelle » s'il s'agit de la première fois que l'expéditeur a envoyé un courriel. Selon la valeur de la variable « Réclamation » nous faisons référence à l'un des deux diagrammes que nous présentons dans les deux paragraphes suivants.

Le processus de l'application se termine par la mise à jour de l'etat du courriel et la déconnexion.

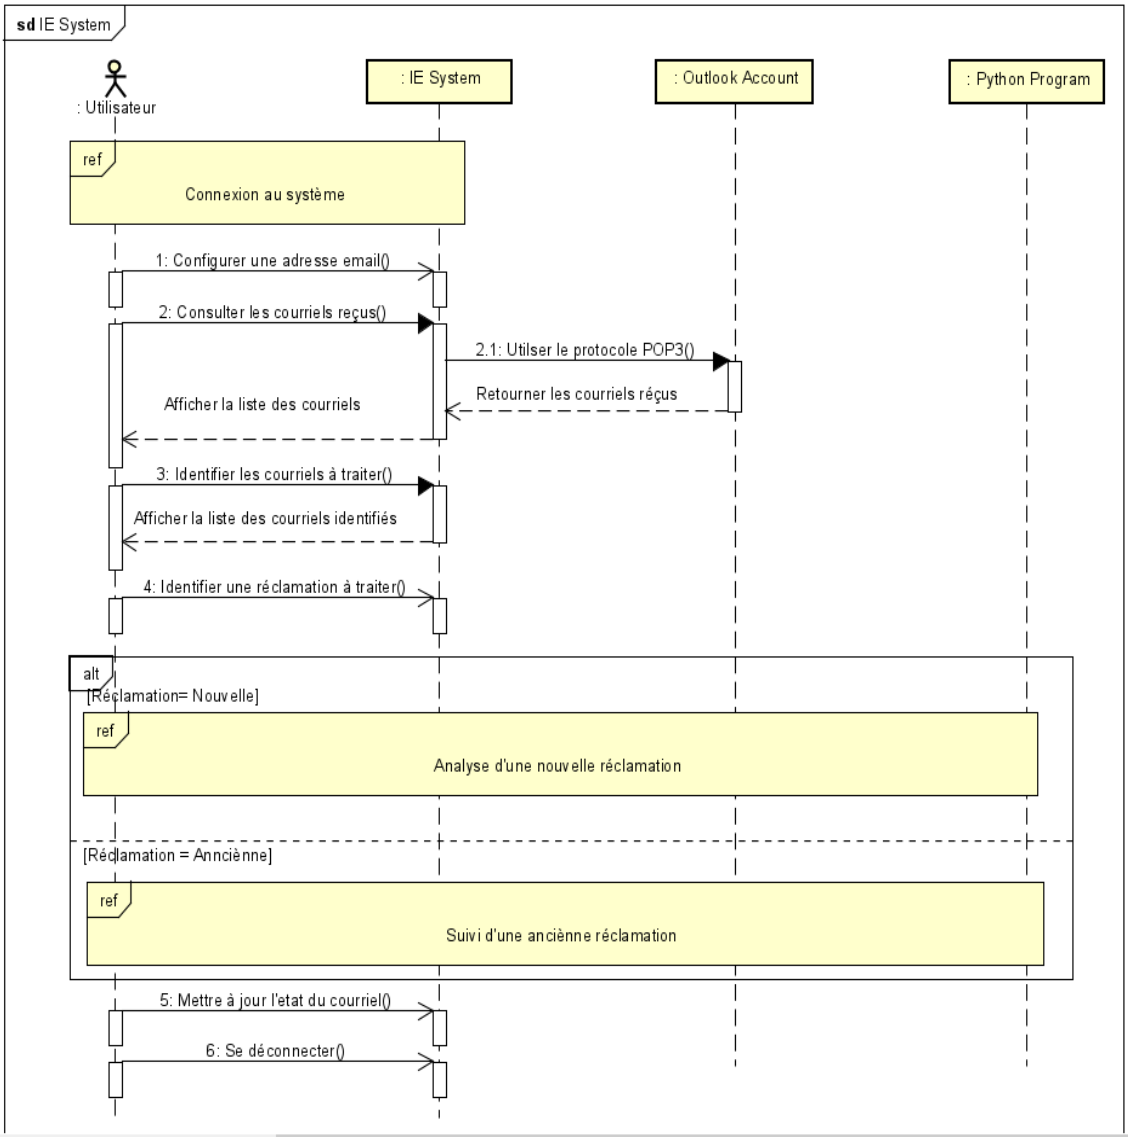


FIGURE 4.4 – Diagramme de séquence

4.3.2 Diagramme de séquence « Analyse d'une nouvelle réclamation »

Le diagramme 4.5 suivant représente le processus d'analyse d'une nouvelle réclamation reçue, qui est une référence du diagramme de séquence de l'application. La réclamation cochée par l'utilisateur et ajoutée dans la base de données, on l'attribue un statut « Not Treated ». Le programme d'extraction s'exécute.

En analysant la revendication, le programme renvoie les détails structurés de l'incident mentionnés dans le courriel, et qui seront affiché par l'application. L'utilisateur peut consulter le contenu du courriel pour vérifier les informations résultantes du processus d'extraction d'informations. Ensuite, il click sur le bouton « Save » pour enregistrer les informations dans la base de données, et modifie l'état de l'email en « Treated ».

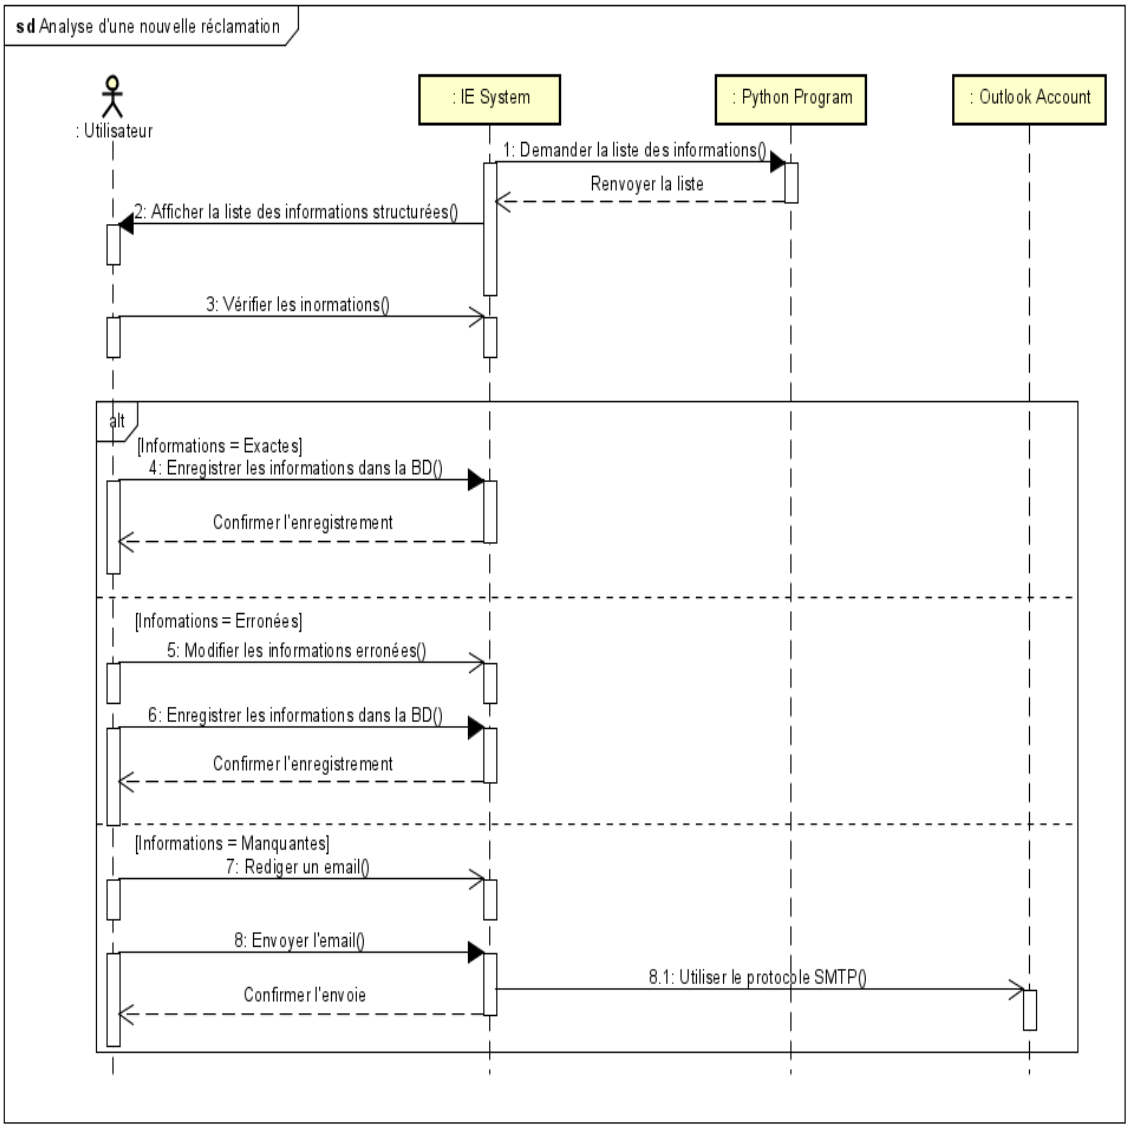


FIGURE 4.5 – Diagramme de séquence « Analyse d'une nouvelle réclamation »

4.3.3 Diagramme de séquence « Suivi d'une ancièn réclamation »

Le diagramme 4.6 suivant représente le processus d'analyse d'un courriel reçu qui poursuit les procédures d'une ancienne réclamation. Le diagramme est une référence du diagramme de séquence de l'application. L'utilisateur accède à l'onglet de recherche pour chercher la réclamation et ses détails. Il peut ainsi modifier les détails s'il s'agit d'un courriel de mise à jour des informations ou bien approuver un paiement.

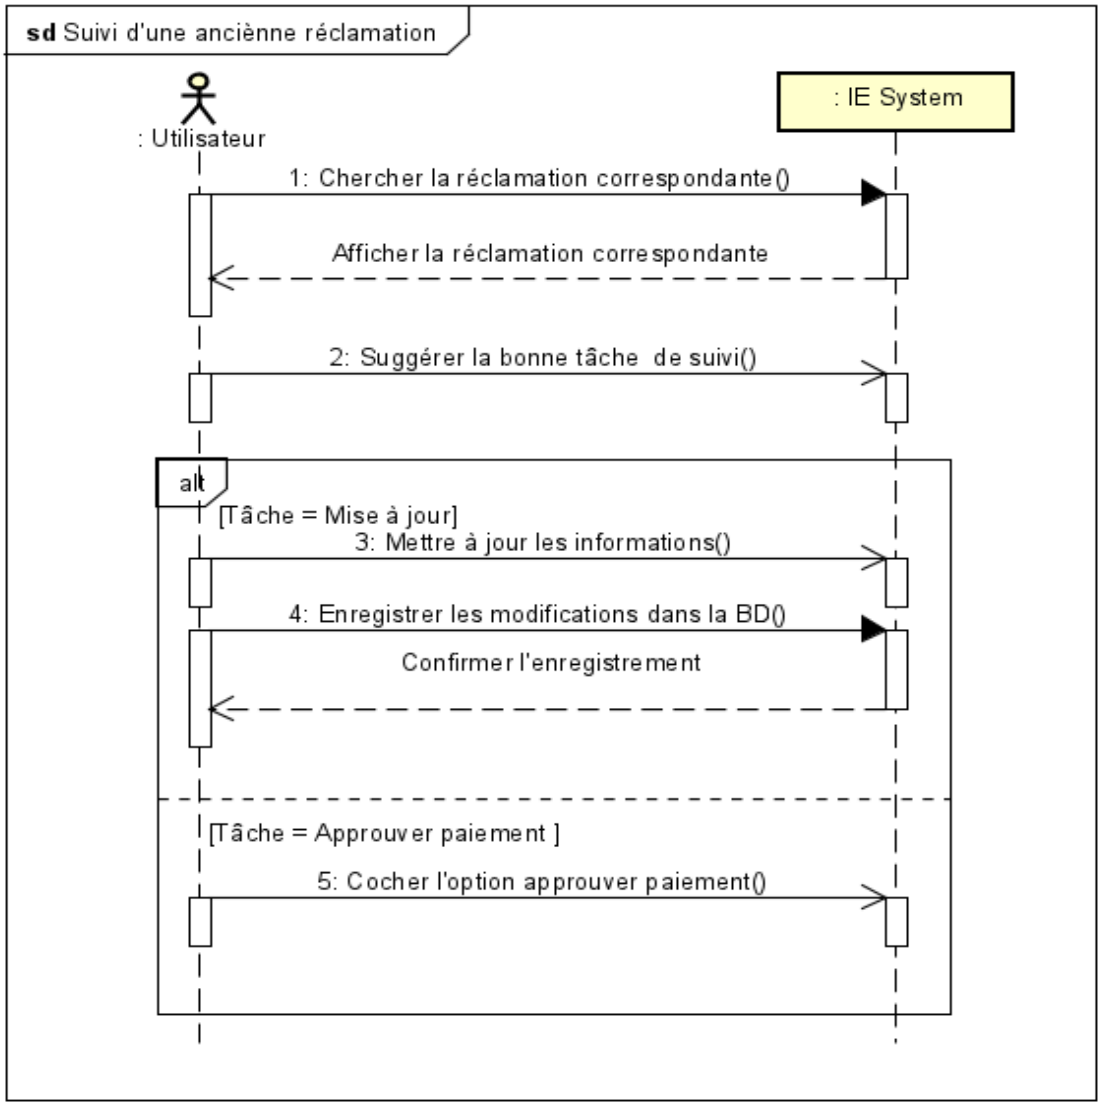


FIGURE 4.6 – Diagramme de séquence « Suivi d'une ancièn réclamation »

4.4 Architecture Logiciel du projet

Notre solution suit l'architecture logicielle présentée dans la figure 4.7 :

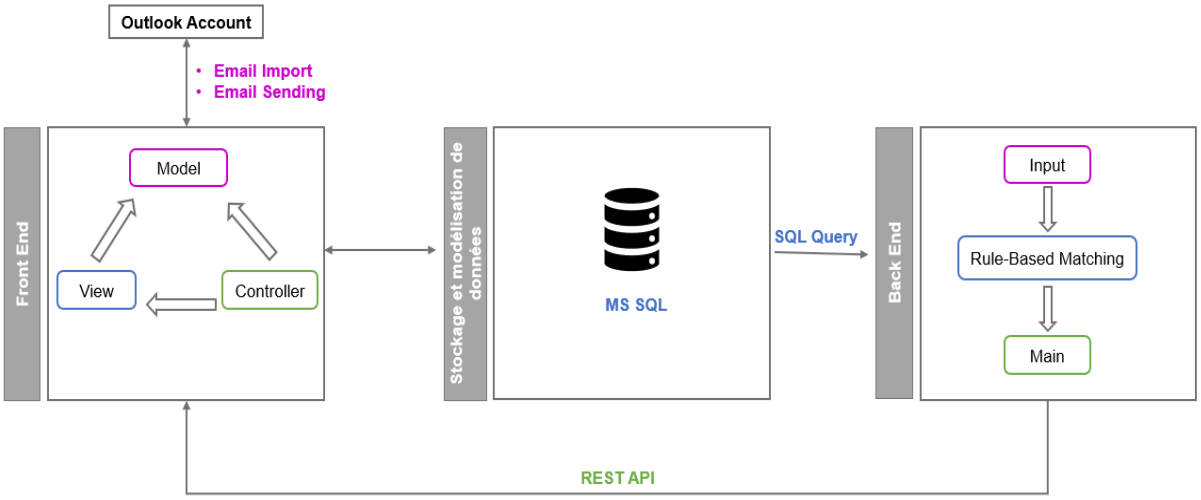


FIGURE 4.7 – Architecture logiciel du projet

Architecture Back End :

C'est le projet responsable du traitement d'une réclamation. Il s'appuie sur l'utlisation des règles pour générer un « output ». Ces règles, appliquées sur les données « Input », agissent comme la logique pour notre programme d'extraction d'informations.

Le projet est constitué principalement de trois fichiers :

- **Fichier « Input » :** Le fichier communiquant avec la base de données pour en importer les données à examiner.
- **Fichier « Rule-Based Matching » :** C'est au niveau de ce fichier que nous avons défini les règles à appliquer sur les données d'entrée, développer le programme de « matching » entre eux.
- **Fichier « Main » :** Ce fichier renvoie à la partie Front End les infomations extraites structurées sous une format JSON via des API REST.

Stockage et modélisation de données :

C'est la couche des données, qui servira à structurer, stocker et centraliser les données.

Architecture Front End :

Le projet Front End suit le modèle de conception MVC (Model-View-Controller). Ce modèle a été utilisé dans de nombreuses technologies différentes. Voici quelques caractéristiques importantes du modèle MVC :

- C'est un moyen puissant et élégant de séparer les préoccupations au sein d'une application (par exemple, la séparation de la logique d'accès aux données de la logique d'affichage) et s'applique très bien aux applications Web.
- Sa séparation explicite des préoccupations ajoute une petite complexité supplémentaire à la conception d'une application, mais les bénéfices extraordinaires l'emportent sur l'effort supplémentaire.

Le modèle architectural MVC sépare l'interface utilisateur (UI) d'une application en trois parties principales.

1. **Le contrôleur :** Un ensemble de classes qui gère la communication de l'utilisateur, le flux d'application global et la logique spécifique à l'application.
2. **Le modèle :** Un ensemble de classes qui décrit les données avec lesquelles vous travaillez ainsi que la logique métier.
3. **The View :** Définit comment l'interface utilisateur de l'application sera affichée. C'est un HTML pur, qui décide comment l'UI ressemble.

L'idée est que nous avons un composant appelé la vue, qui est le seul responsable du rendu de cette interface , qu'il s'agisse de HTML ou s'il s'agit réellement d'objets d'interface sur une application. La vue parle d'un modèle, et ce modèle contient toutes les données que la vue doit afficher.

Le contrôleur qui organise est tout. Lorsqu'une demande HTTP arrive pour une application MVC, cette requête est acheminée vers un contrôleur, et il appartient au contrôleur de parler à la base de données, au système de fichiers ou au modèle [10].

API RESTful :

Un API (interface de programme d'application) est un ensemble de règles permettant à différents programmes de communiquer entre eux. Il décrit la manière appropriée pour un développeur de logiciels de composer un programme sur un serveur qui communique avec diverses applications clientes. Il y a de multiples types d'API et c'est à nous de choisir celle qui s'adapte le mieux à nos besoins [11].
Nous avons opté pour une architecture « restful ».

REST (REpresentational State Transfer) est un style architectural et une méthodologie fréquemment utilisés dans le développement de services Internet, tels que les systèmes hypermédias distribués. Lorsqu'une API REST est appelée, le serveur transférer a représentation des ressources demandées Etat au client. Cette représentation de l'état peut être au format JSON, XML ou HTML.

Une API REST utilise les requêtes suivantes :

- Créer (create) => POST
- Afficher (read) => GET
- Mettre à jour (update) => PUT
- Supprimer (delete) => DELETE

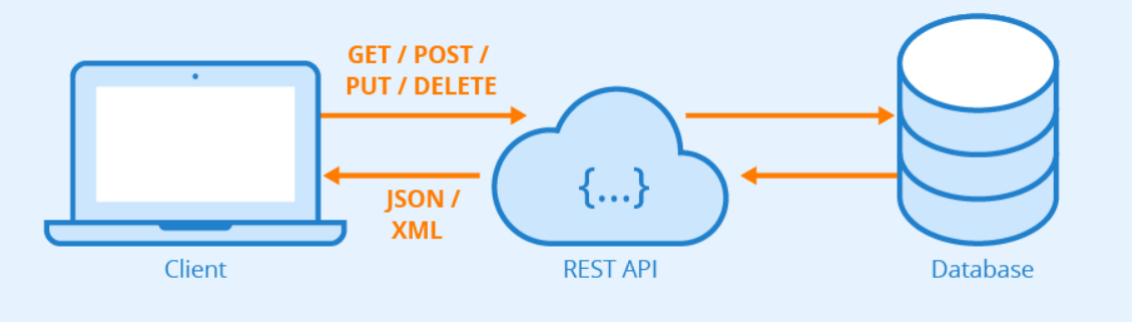


FIGURE 4.8 – API REST

4.5 Conclusion

Ce chapitre présente une vue conceptuelle de la solution à mettre en place. Il expose les différents diagrammes UML pour mieux comprendre les fonctionnalités offertes et pour mieux représenter la communication entre les différents objets du projet. Le chapitre suivant, présente la partie mise en œuvre de l'application.

Chapitre 5

Mise en oeuvre de la solution

Dans ce chapitre, on va présenter les outils utilisés pour la mise en oeuvre de la solution Système d'analyse automatique des e-mails ainsi qu'un aperçu des différentes vues et interfaces de cette solution.

5.1 Introduction

Une des étapes de la vie d'un projet, aussi importante que la conception, est l'implémentation. Cette étape représente la phase d'achèvement et d'aboutissement du projet. Pour accomplir cette tâche avec succès il est nécessaire de savoir utiliser les outils appropriés. Ce choix d'outils peut influencer la qualité du produit obtenu et donc nécessite une attention particulière et doit se baser sur les besoins du projet et le résultat attendu.

Ce chapitre présente l'environnement technique de travail ainsi que le choix effectué en termes d'environnement logiciel.

5.2 Outils et technologies utilisées

5.2.1 Outil de modélisation UML

- **Astah** [1] **:**
  - Pour la modélisation UML nous avons choisi le logiciel « Astah » qui est un outil de modélisation UML ayant une distribution gratuite. Il est facile à manipuler et il supporte les systèmes Windows.

5.2.2 Outils de développement et de collaboration

- **Visual Studio 2019** [2] **:**
  - Un environnement de développement permettant de générer des applications et services Web, des applications bureautiques et des applications mobiles.
- **Visual Studio Code** [3] **:**
  - Visual Studio Code est un éditeur de code extensible développé par Microsoft pour Windows, Linux et macOS.
  - Les fonctionnalités incluent la prise en charge du débogage, la mise en évidence de la syntaxe, la complétion intelligente du code, les snippets, la refactorisation du code et Git intégré.
- **Python** [4] **:**

1. https://astah.net/products/astah-community/
2. https://visualstudio.microsoft.com/fr/
3. https://code.visualstudio.com
4. https://www.python.org

— Un langage de programmation interprété, multi-paradigme et multiplateformes.

— Il favorise la programmation impérative structurée, fonctionnelle et orientée objet. Il est doté d'un typage dynamique fort, d'une gestion automatique de la mémoire par ramasse-miettes et d'un système de gestion d'exceptions.

- **Spacy** [5] **:**
  - — Une bibliothèque open source gratuite pour le traitement avancé du langage naturel (NLP) en Python.
  - — spécialement conçu pour une utilisation en production et aide à créer des applications qui traitent et «comprennent» de grands volumes de texte. Cette bibliothèque peut être utilisée pour créer des systèmes d'extraction d'informations ou de compréhension du langage naturel, ou pour pré-traiter du texte pour un apprentissage en profondeur.
- **Flask** [6] **:**
  - — Un framework open-source de développement web en Python.
  - — Nous avons développé des API Flask pour communiquer les données output, résultantes du programme d'extraction d'informations écrit en Python, à la partie Front End développé en .NET
- **.Net** [7] **:**
  - — Une plate-forme de développement avec des outils et des bibliothèques pour créer tout type d'application, y compris le Web, le mobile, le bureau, les jeux, l'IoT, le cloud et les microservices.
- **Protocoles de messagerie :**
  - — **POP3 :** est un protocole qui permet de récupérer les courriers électroniques situés sur un serveur de messagerie électronique. En dehors d'un paramétrage spécifique, POP se connecte au serveur de messagerie, s'authentifie, récupère le courrier, « peut » effacer le courrier sur le serveur, et se déconnecte [12].
  - — **SMTP :** est le protocole standard permettant de transférer le courrier d'un serveur à un autre en connexion dite « point à point » [13].
- **Microsoft SQL Server 2019** [8] **:**
  - — Il s'agit d'un système de gestion de base de données SQL que nous allons utiliser dans notre projet.

5. https://spacy.io
6. https://flask.palletsprojects.com/en/1.1.x/
7. https://dotnet.microsoft.com
8. https://www.microsoft.com/en-us/sql-server/sql-server-2019

— Il est conçu pour prendre en charge diverses applications de traitement des transactions, d'entreposage de données. Microsoft SQL Server 2019 possède une interface SQL Server Management Studio (SSMS) qui permet de gérer tous les objets de SQL Server.

5.3 Développement

Nous avons divisé le développement en deux phases. Une première phase sert au traitement textuel NLP et le developpement des API REST en flask. Une deuxième phase pour le développement de l'application. Ces deux phases seront détaillées dans les deux paragraphes suivants.

5.3.1 Traitement textuel NLP

Nous étudierons, dans cette section, un exemple de document textuel, présenté dans la figure 5.1. Les entités colorées indiquent les informations pertinentes à extraire.

Your reference : **RTA107880.001**
Our reference : **UK-19-22631-10-6956 /GS**
Policy No : **04E112702260**

Dear sir / Madam,

The accident, dated **26.10.2019**, took place in the **UNITED KINGDOM, A45**.
Our insured's name is **David MCCARTHY** and his vehicle registration number is **PB7254TC**. Your insured's name is **Mr Radatky Trukaz**. The Third party vehicle registration number **7P33634**.

We refer to the above dated incident and ask you to note our interest on behalf of our insured.
We understand that you are the insurers of Mr Radatky Trukaz Dummy Address who was involved in an incident on the above date with our insured. The circumstances of this incident as reported to us are that **your HGV moved from the left lane to the middle and hit the insured's near side rear**.

In the view of the circumstances we must hold your insured responsible. Full details of our outlay and supporting documentation will follow when available. In the meantime, please confirm your interest and that liability is not in dispute.
We can confirm that our cover is Comprehensive with **£150** excess.

Please note that our claim is independent to that of any uninsured loss being pursued by our policyholder.
If you have any queries please contact us on the above telephone number. To enable us to respond to your enquiry more quickly, please quote our reference as above.

Yours faithfully

FIGURE 5.1 – Document d'entrée

5.3.1.1 Conception des règles linguistiques

Tout d'abord, nous devons comprendre la structure des phrases et les relations entre les différents mots.

Matching de sous-arborescence

Nous devons être extrêmement créatifs pour proposer des règles capturant les différents « patterns ». Il est difficile de créer des « patterns » qui se généralisent bien entre différentes phrases. Pour améliorer les méthodes basées sur des règles pour l'extraction de relations/informations, nous devrions essayer de comprendre la structure de dépendance des phrases à portée de main. Prenons notre exemple de texte et construisons un arbre graphique de dépendances d'une des phrases (figure 5.2).

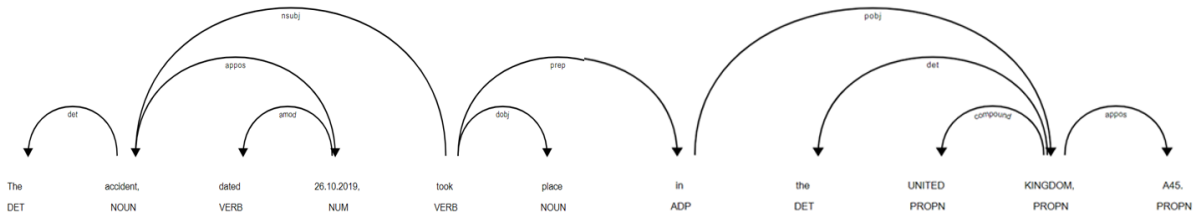


FIGURE 5.2 – Arbre graphique de dépendance

Nous allons simplement considérer les chemins de dépendance communs et extraire les entités et la relation entre elles. Par conséquent, les relations extraites de ces phrases sont :

- The accident date 26.10.2019.
- The accident place in the UNITED KINGDOM A45.

Nous allons parcourir cette arbre de dépendances. Examinons les balises de dépendance et les balises POS des mots de la phrase :

The –> det –> DET
accident –> nsubj –> NOUN
, –> punct –> PUNCT
dated –> amod –> VERB
26.10.2019 –> appos –> NUM
, –> punct –> PUNCT
took –> ROOT –> VERB
place –> dobj –> NOUN
in –> prep –> ADP
the –> det –> DET

UNITED –> compound –> PROPN
KINGDOM –> pobj –> PROPN
, –> punct –> PUNCT
A45 –> appos –> PROPN

Alors, par cette méthde, nous comprenons les structures de tous les phrases construisant notre texte. Nous pouvons, ainsi, Créer les modèles requis à l'aide des balises de dépendance et des balises POS (exemple de patterns crées : figure 5.3). Après, il suffit de faire la mise en correspondance entre ces modèles et notre texte pour rechercher les entités souhaitées. Pour ce faire, nous avons utilisé la bibliothèque spaCy qui dispose d'un « rule-matching engine », le **Matcher**, qui fonctionne sur des jetons, similaire aux expressions régulières.

Patterns definition

Entrée [76]:

```
Reference_pattern = [{'POS': 'PROPN'}, {'POS': 'PUNCT'}, {'POS': 'NUM'}, {'POS': 'PUNCT'}, {'POS': 'NUM'}, {'POS': 'PUNCT'},

Reference_pattern2 = [{'POS': 'NOUN'}]

PolicyNo_pattern = [{'POS': 'NOUN'}]

Date_pattern = [{'POS': 'NUM'}]

Place_pattern = [{'POS': 'PROPN'}, {'POS': 'PROPN'}, {'IS_PUNCT': True}, {'POS': 'PROPN'}]

Persons_pattern = [{'POS': 'PROPN'}, {'POS': 'PROPN'}]

Vehicle_pattern = [{'POS': 'PROPN'}]

Vehicle_pattern2 = [{'POS': 'NUM'}]

AccidentCircumstances_pattern = [{'POS': 'PROPN'}, {'POS': 'VERB'}, {'POS': 'ADP'}, {'POS': 'DET'}, {'POS': 'ADJ'}, {'POS':

Amount_pattern = [{'POS': 'PROPN'}, {'POS': 'NUM'}]
```

FIGURE 5.3 – Créations des patterns

Données de sortie du programme :

Nous avons récupéré les données identifiées dans le texte dans les variables JSON afin d'être utilisées plus tard dans nos API. Les détails obligatoires non fournis dans notre exemple seront marqués comme des informations manquantes (voir figure 5.4).

```
Entrée [131]: 1 print("General Information Provided :", body_Gen_results)

General Information Provided : [{'Date': '26.10.2019', 'Accident_Location': 'UNITED KINGDOM, A45', 'Reserve_amount': '£150', 'A
ccident_Circumstances': "your HGV moved from the left lane to the middle and hit the insured's near side rear."}]

Entrée [132]: 1 print("Individual Information provided Provided :", body_Person_results)

Individual Information provided Provided : [{'Insured': 'David MCCARTHY', 'Third_Party': 'Mr Radatky Trukaz', 'Insured_Vehicle_
registration': 'PB7254TC', 'TP_Vehicle_registration': '7P33634', 'Vehicle_Type': 'missed information !'}]

Entrée [133]: 1 print("Company Information Provided :", body_Company_results)

Company Information Provided : [{'Client': 'missed information !', 'Client_Policy_Number': '04E112702260', 'Client_Claim_ref':
'UK-19-22631-10-6956 /GS', 'Adverse_Company': 'missed information !', 'Adverse_Company_Adress': 'missed information !', 'Refere
nce_Adverse_Company': 'RTA107880.001'}]
```

FIGURE 5.4 – Données de sortie du programme

5.3.1.2 Évaluation des performances

Chaque système, algorithme ou théorie doit être évalué, c'est-à-dire que sa sortie doit être comparée à l'étalon-or (i.e la sortie idéale). La précision et le rappel sont des concepts très clés.

- **Rappel :** Mesure de la quantité d'informations pertinentes extraites par le système (couverture du système).
  - Si aucune réponse correcte possible :

$$Rappel = 1$$

  - Sinon :

$$Rappel = \frac{RC}{RCP}$$

    Avec :
    - ⋆ RC = Le nombre de réponses correctes données par le système.
    - ⋆ RCP = Le nombre total de réponses correcte possibles dans le texte.

- **Précision :** Mesure de l'exactitude des informations renvoyées par le système.
  - Si aucune réponse donnée par le système :

$$Precision = 1$$

  - Sinon :

$$Precision = \frac{RC}{R}$$

    Avec :
    - ⋆ RC = Le nombre de réponses correctes données par le système.
    - ⋆ R = Le nombre de réponses données par le système.

En appliquant ces deux formules, il ressort que le programme a un rappel et une précision maximales. Ceci s'explique par le fait que nos patterns correspondent bien aux informations recherchées.

En effet, les performances du programme reflètent la qualité des patterns déclarés, le problème de cette méthode est la généralisation des règles sur un grand nombre de corpus de données.

Nous avons découvert l'extraction d'informations, le concept de relations et de triplets, et nous avons évalué l'efficacité de notre programme. L'étape suivante consiste à consommer les infomations identifiées dans une applications web. Pour ce faire, nous avons développé des API FLASK RESTful (voir Annexe figure A.1) pour transporter les données.

5.3.2 Quelques interfaces de l'application

Nous présenterons, dans cette section, les différentes interfaces de l'application. Nous avons suivre un sénario dans lequel le courriel correspond à une nouvelle réclamation.

5.3.2.1 Page d'accueil

La figure 5.5 représente la page d'accueil de l'application. Cette page est composée des éléments suivants :

1. Sign up
2. Sign in
3. Des informations sur l'application

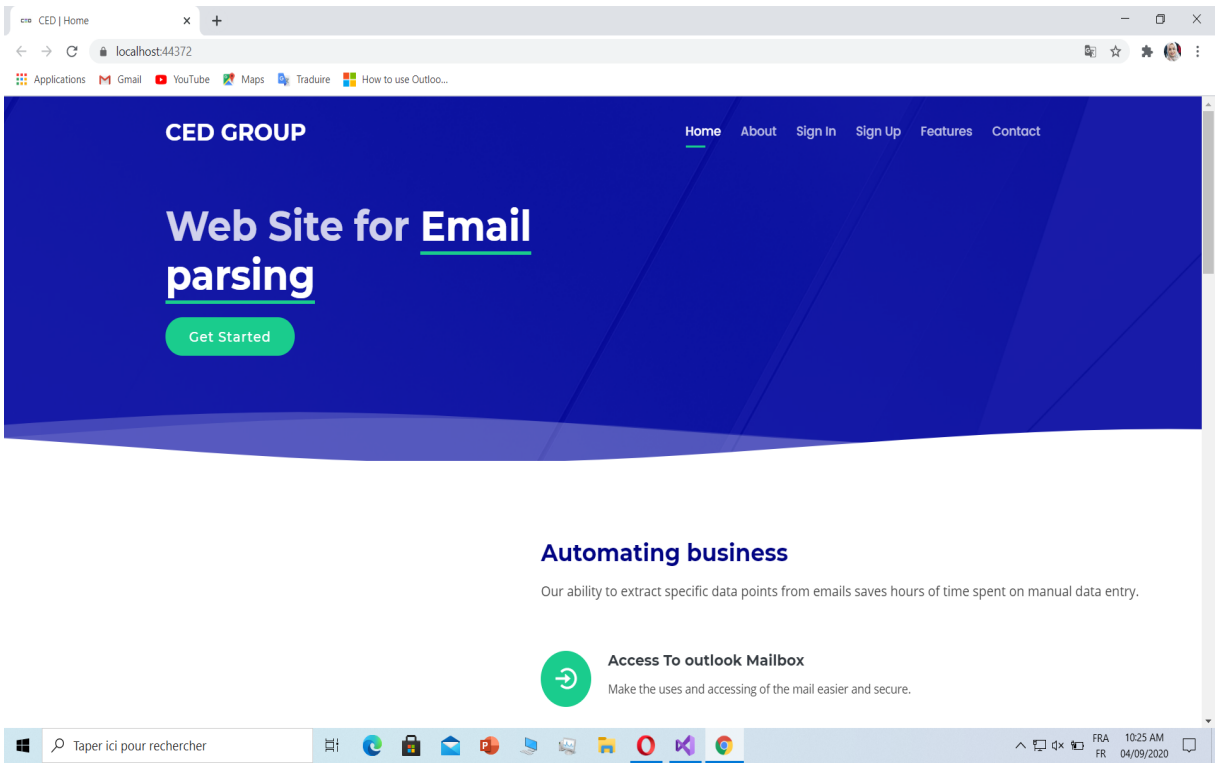


FIGURE 5.5 – La page d'accueil de l'application

5.3.2.2 Page de Sign Up

La figure 5.6 représente la page de création du compte utilisateur. Cette page est composée des éléments suivants :

1. Logo
2. Formulaire de création du compte, dans laquel les champs : Nom, adresse email, et mot de passe sont **requises**
3. Redirection vers la page de login

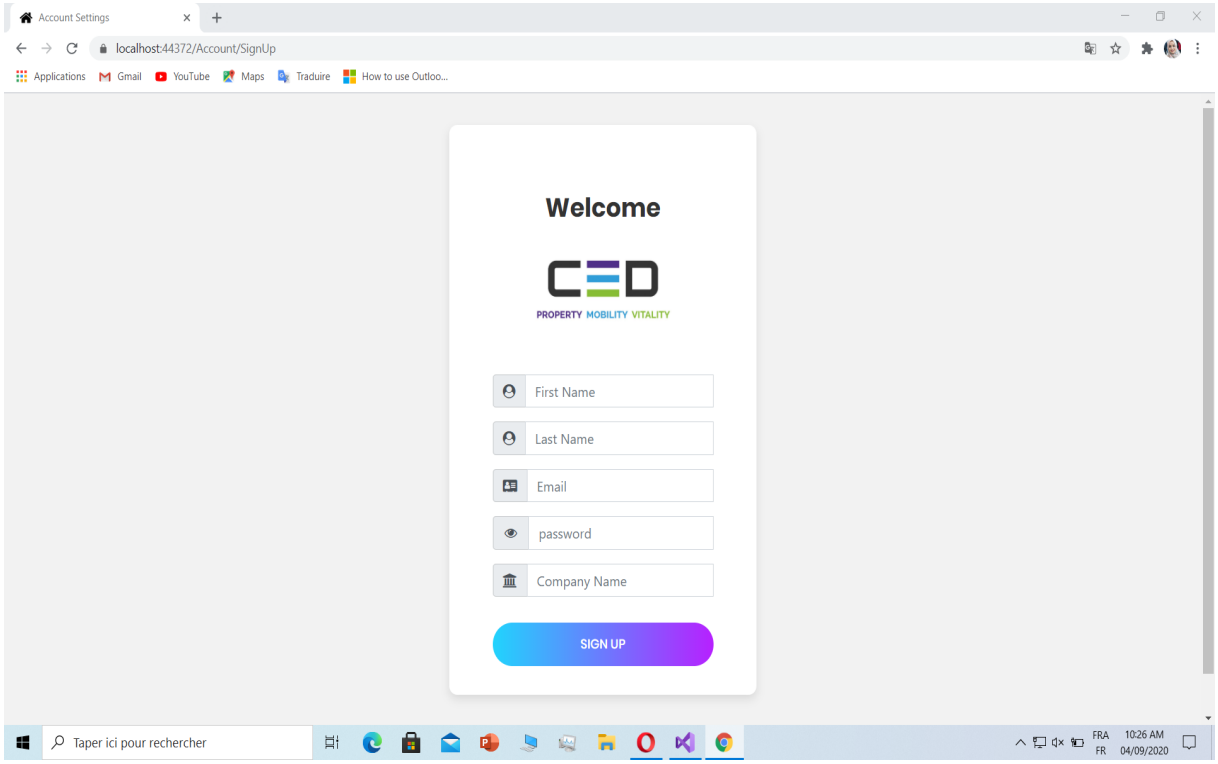


FIGURE 5.6 – La page du sign up de l'application

5.3.2.3 Page de Login

La figure 5.7 représente la page de login des utilisateurs. Cette page est composée des éléments suivants :

1. Logo
2. Formulaire d'authentification
3. Réinitialisation de mot de passe dans le cas d'oublie

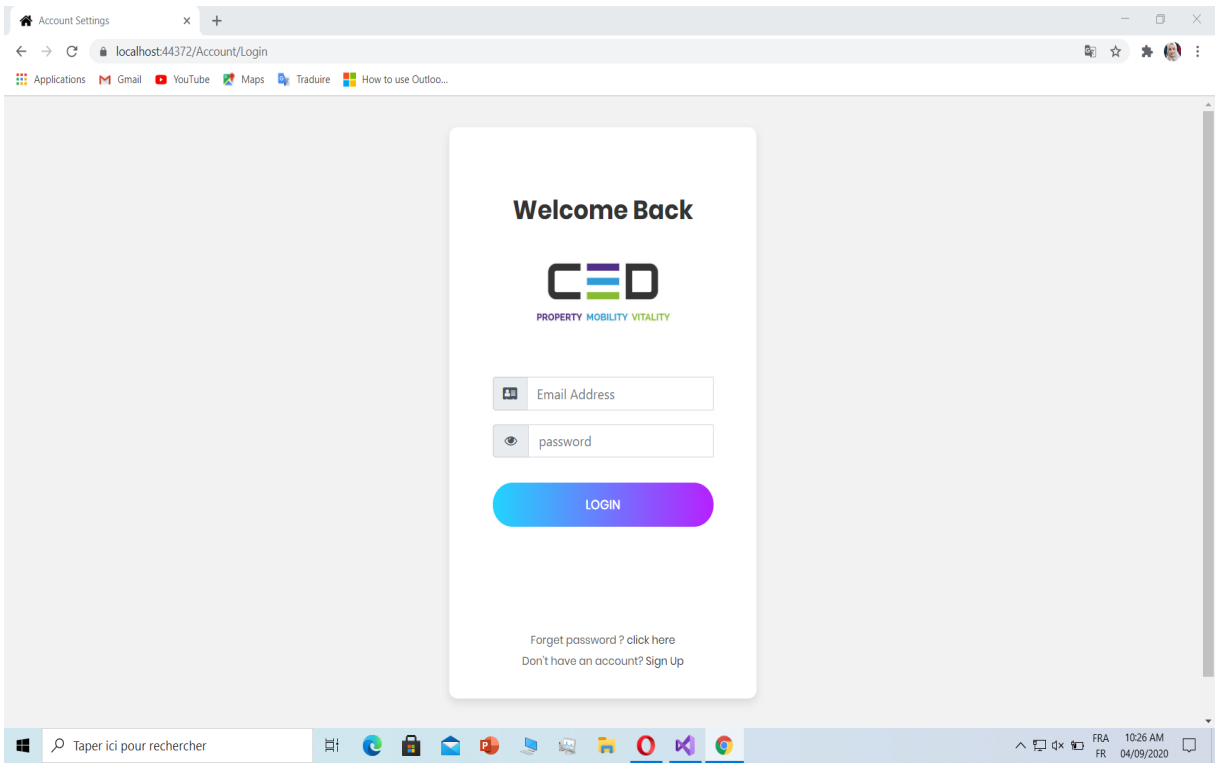


FIGURE 5.7 – La page du login de l'application

5.3.2.4 Vue Administration

La vue Administration regroupe toutes les opérations de gestion des réclamations. Cette vue, présentée dans la figure 5.8, est composé des éléments suivants :

1. Le menu d'administration qui regroupe les élément administrable dans le site sous forme d'arbres.

2. Le composant de recherche dans la liste des réclamations/courriels.

3. Les icônes de déconnexion et de profile.

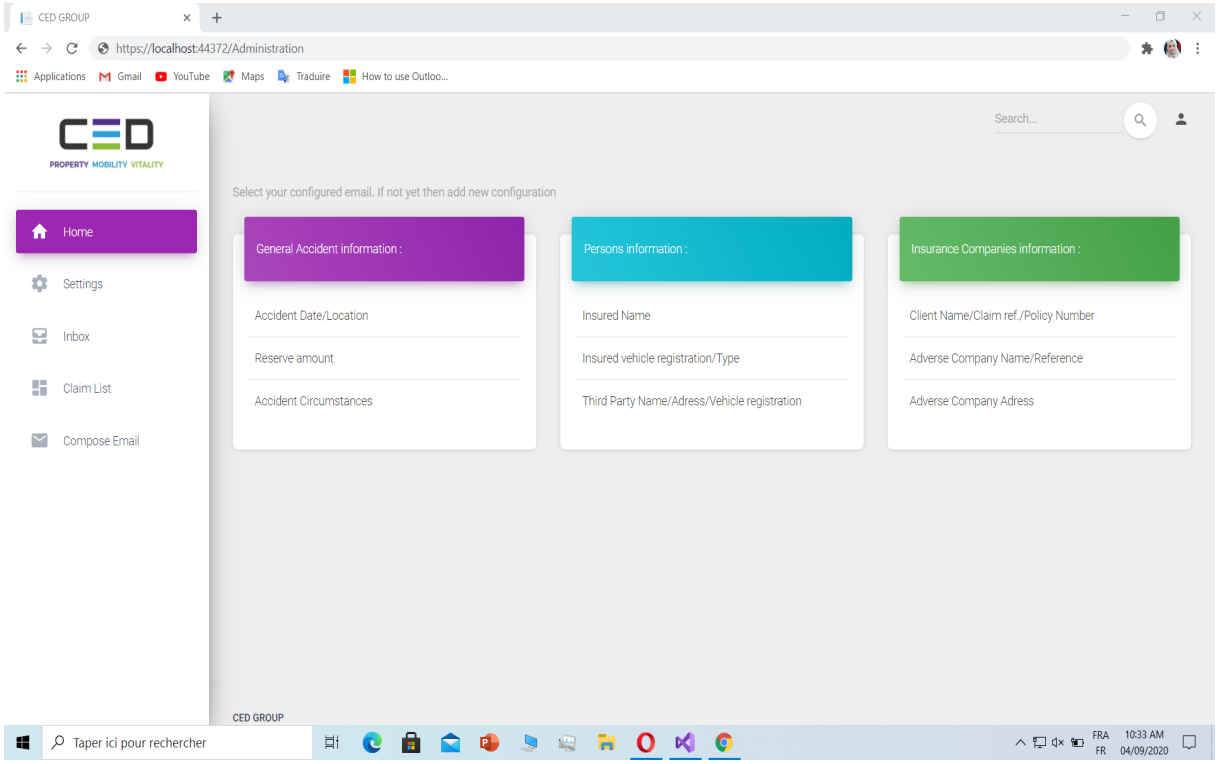


FIGURE 5.8 – La vue Administration

5.3.2.5 Menu d'administration

1. Paramètres :

   La vue Paramètres permet de saisir l'adresse email à laquelle l'utilisateur souhaite accéder à son dossier « Inbox ». Elle se compose de deux perspectives :

   (a) Ajouter une adresse e-mail : Tout d'abord Il faut configurer une adresse e-mail avec son mot de passe, ceci permet au protocole POP3 de se connecter à cet adresse et en récupérer les courriels disponibles.

   (b) Sélectionner une dresse e-mail : Si l'adresse email était configurée, l'utilisateur choisie la perspective « Select E-mail Adress ».

   Ces deux perspectives sont présentées dans les deux figures 5.10 5.9 :

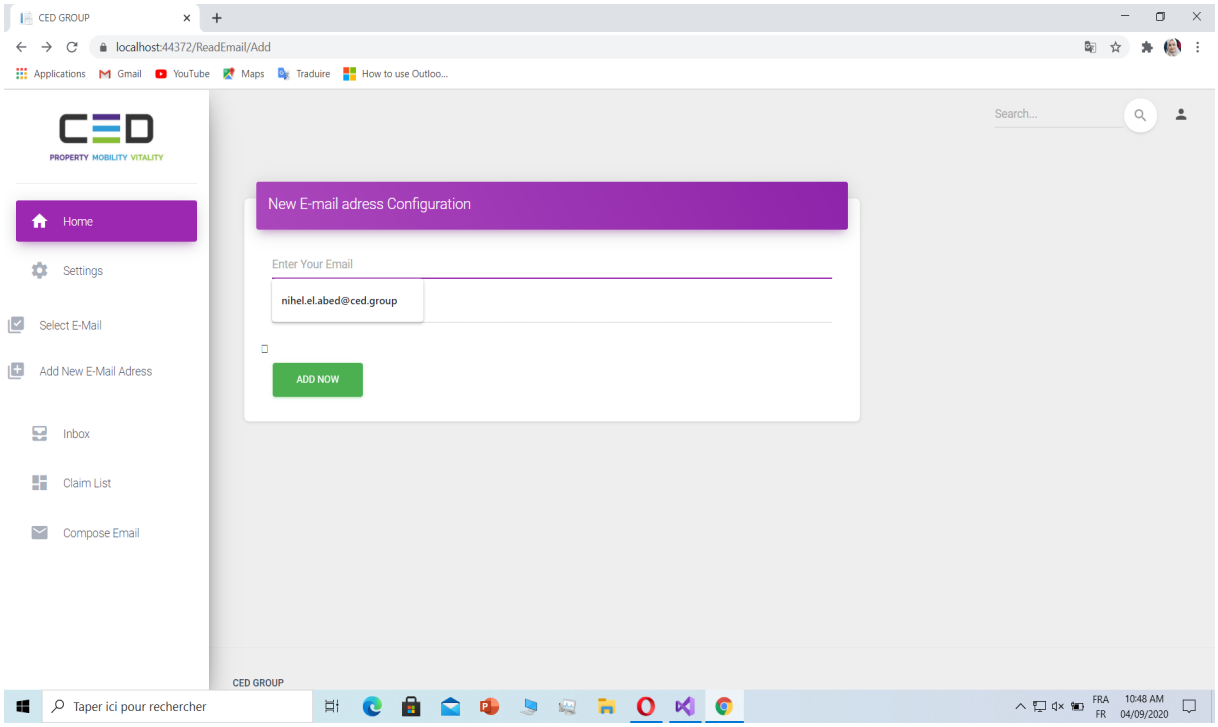


FIGURE 5.9 – La vue configurer une adresse e-mail

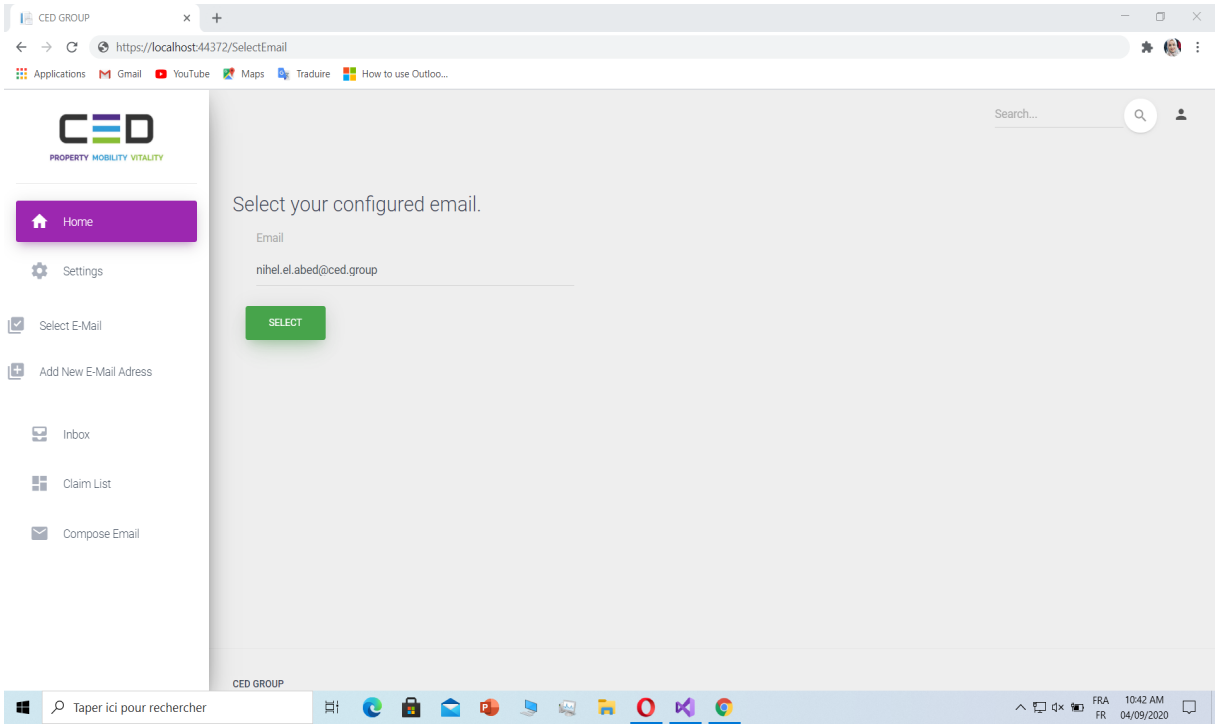


FIGURE 5.10 – La vue sélectionner une dresse e-mail

2. Inbox :

Cette vue affiche 5.11 les courriels réçus dans la boîte de réception de l'adresse e-mail saisie. La vue permet de :

- Cocher les courriels considérables.
- Attribuer une état au courriel.
- Enregistrer les courriels sélectionnés dans la base de données.

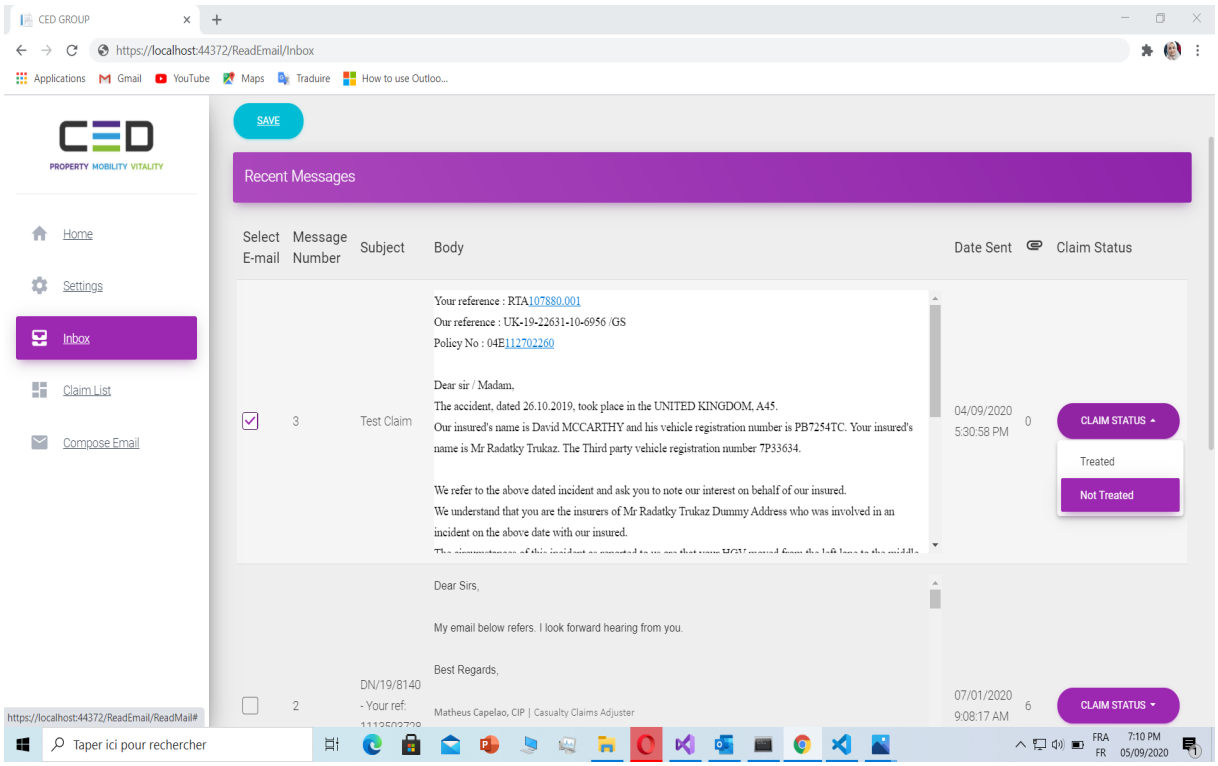


FIGURE 5.11 – La vue Inbox

3. Liste des réclamations :

Cette vue, présentée dans la figure 5.12, permet d'afficher l'ensemble des réclamations pertinentes reconnues par l'utilisateur et enregistrées dans la base de données.

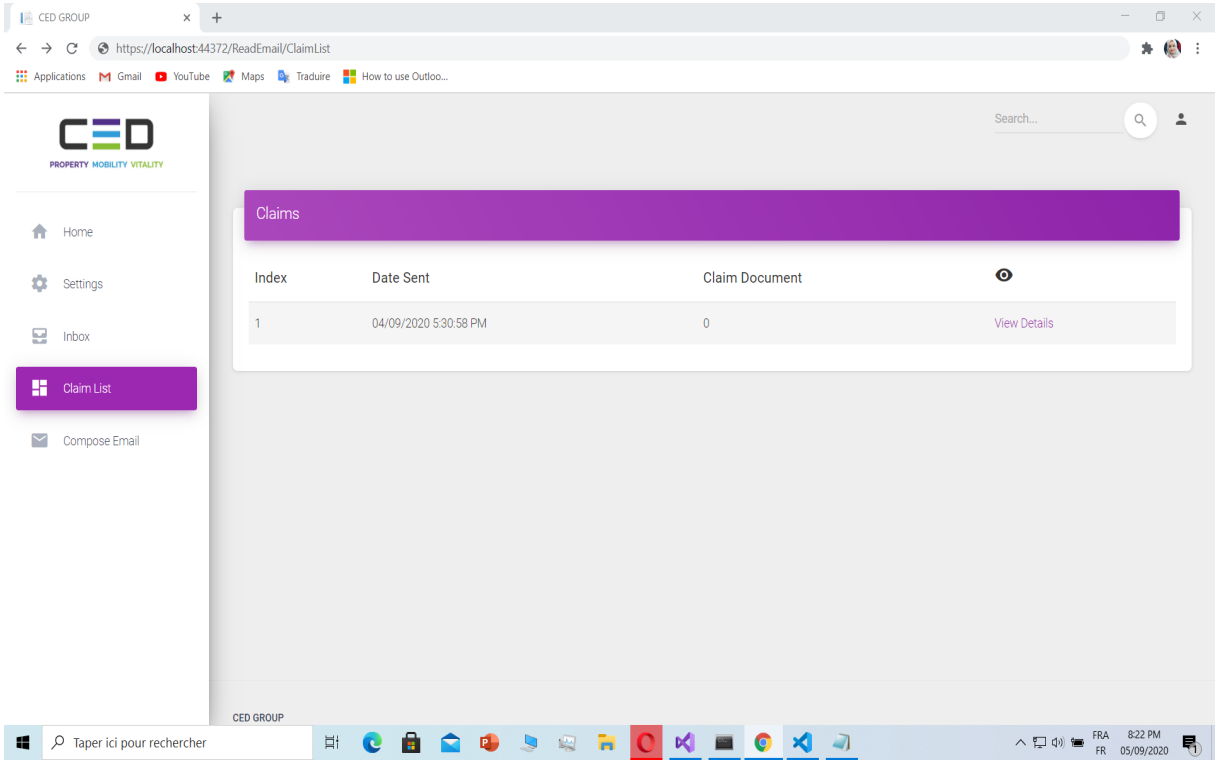


FIGURE 5.12 – La vue Liste des réclamations

En cliquant sur « View Details », L'utilisateur sera dirigé vers la vue présentée dans la figure 5.13. C'est une perspective permettant de :

- Afficher les résultats de l'analyse d'une réclamation sélectionner, avec des actions d'édition, de suppression et de sauvegarde :
  - Les informations générales sur l'incident(date, localisation, description.., voir figure 5.14).
  - Les informations sur les personnes impliquées dans l'incident(Nom, Numéro d'immatriculation du véhicule, Type de véhicule.., voir figure 5.15).
  - Les informations sur les companies d'assurances concernées par l'incident(Nom, référence, adresse, .., voir figure 5.16).
- Afficher un aperçu du message de réclamation.

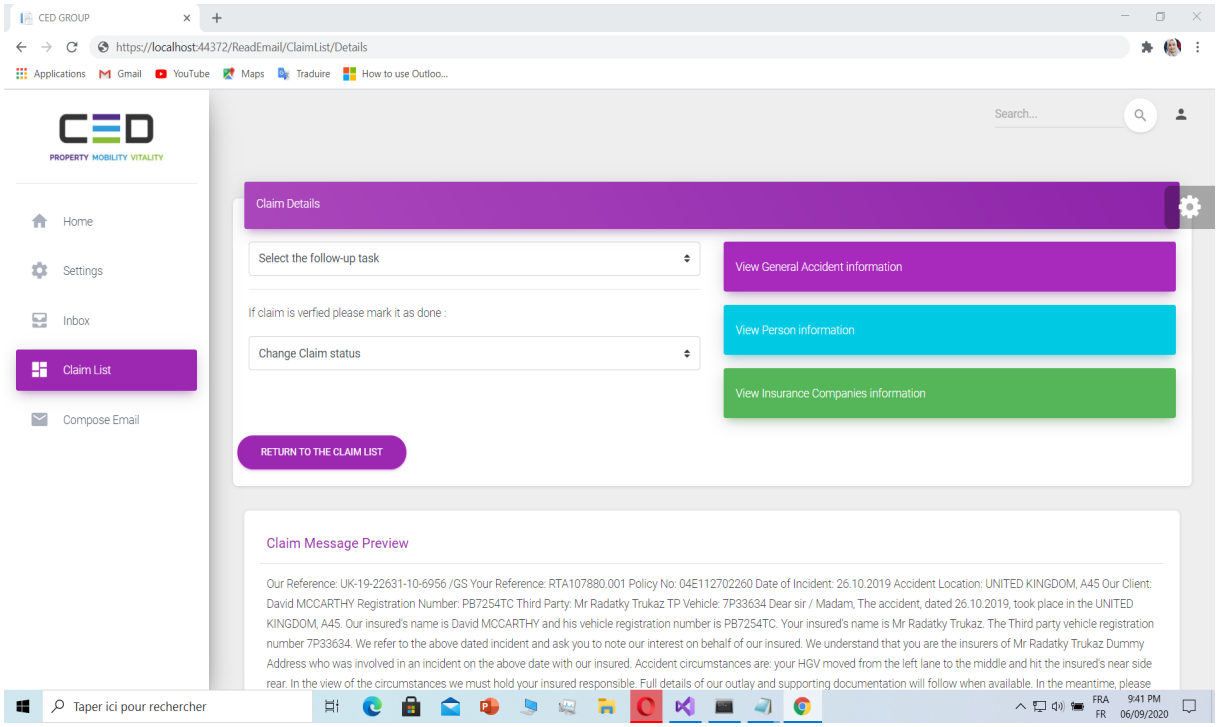


FIGURE 5.13 – La vue Afficher Détails

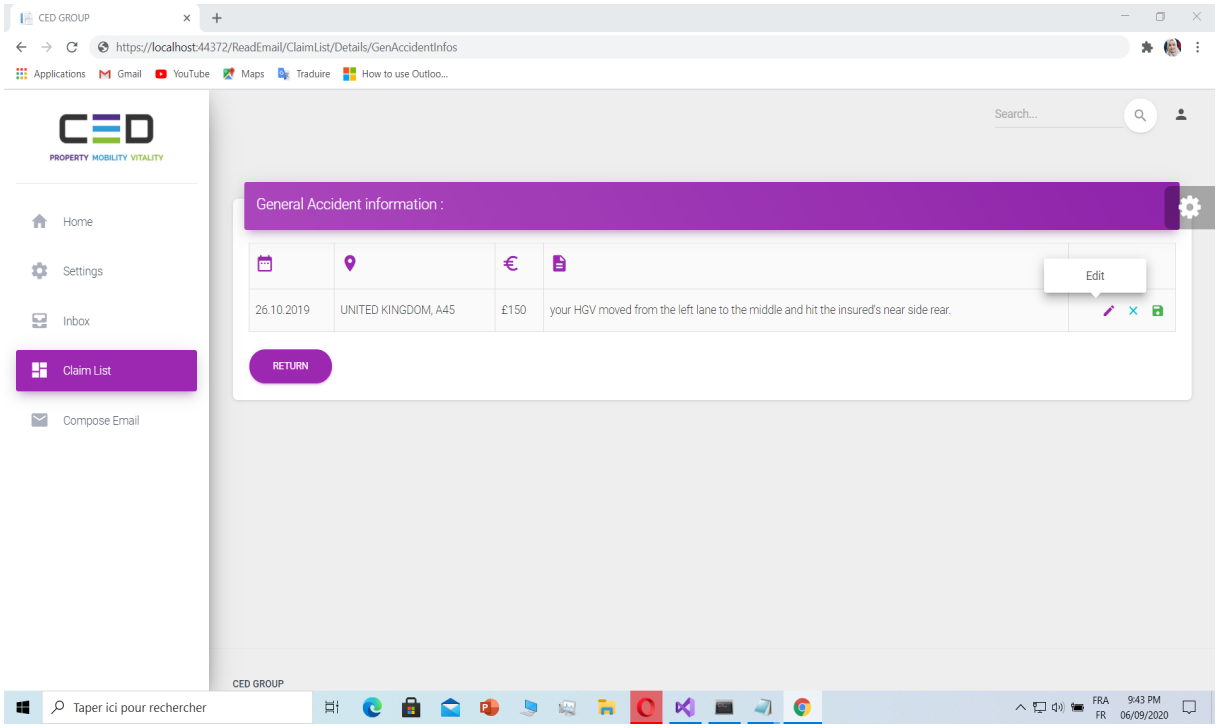


FIGURE 5.14 – La vue Informations Générales

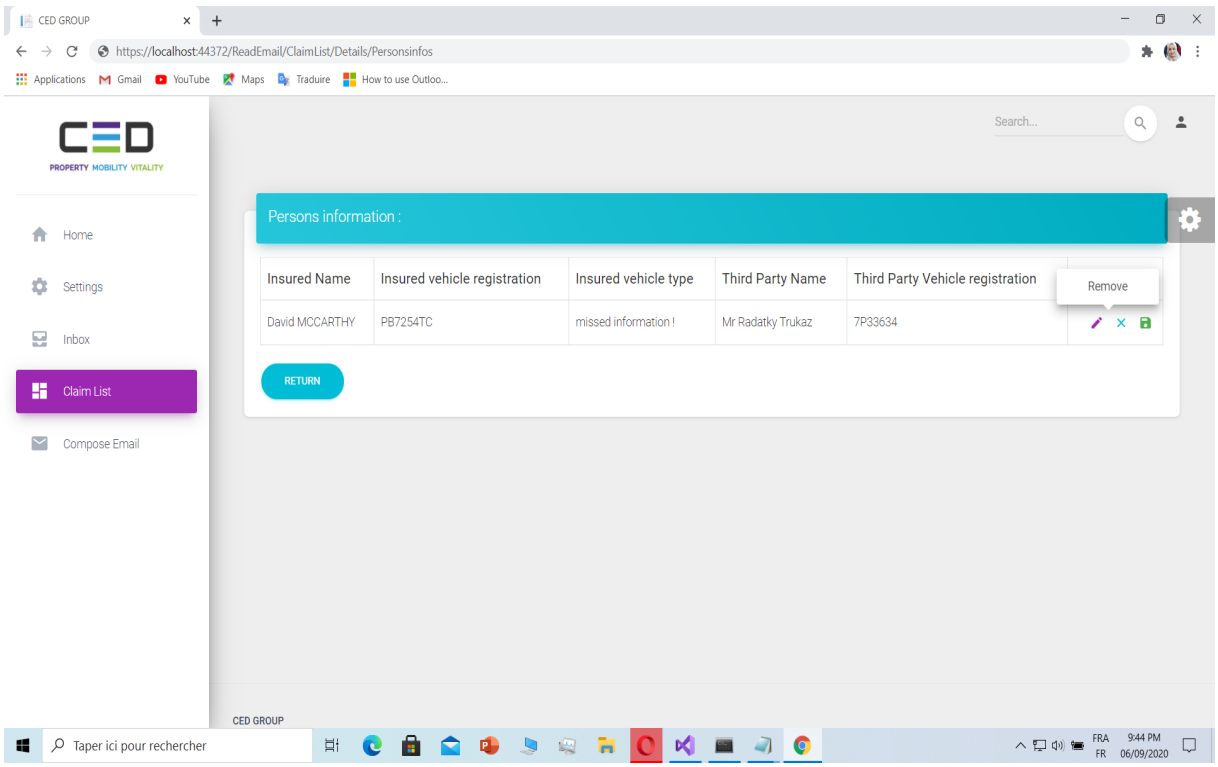


FIGURE 5.15 – La vue Informations des personnes

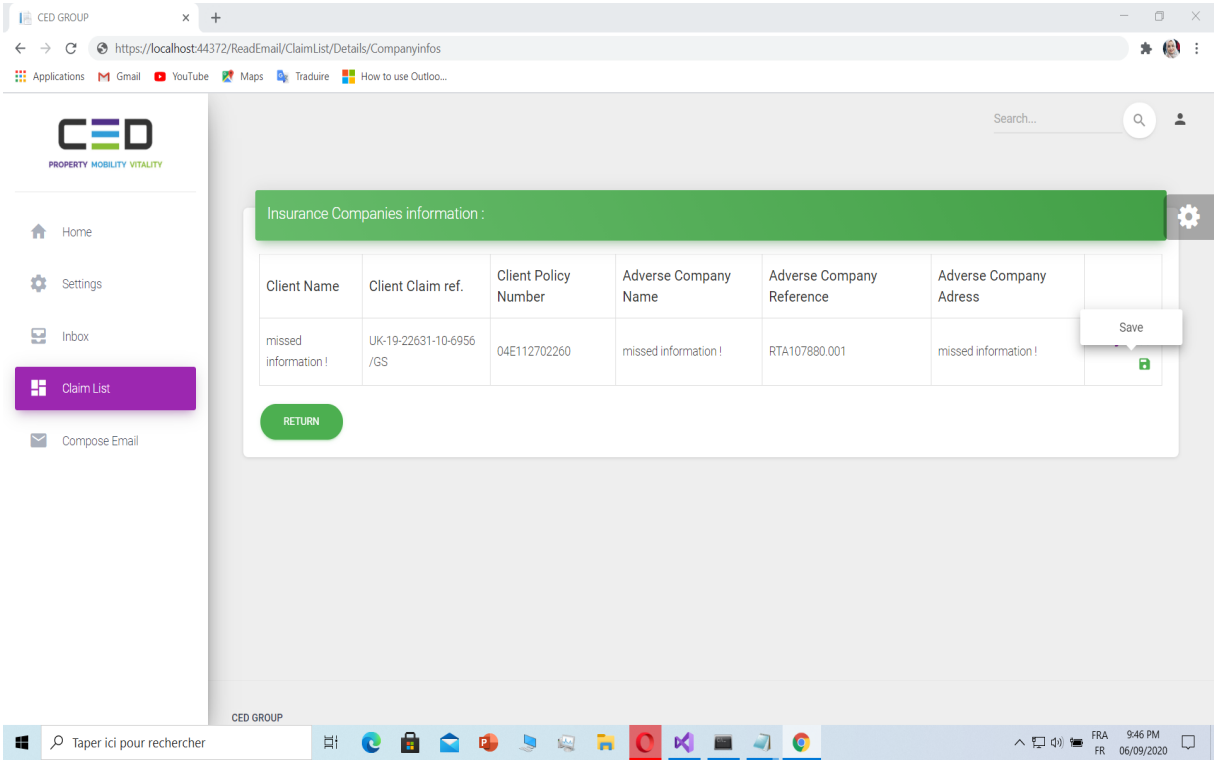


FIGURE 5.16 – La vue informations des compagnies d'assurance

4. Envoyer un e-mail :

   La vue Envoyer un e-mail, présentée dans la figure 5.17, permet d'envoyer un courriel.

   Elle se compose des éléments suivants :

   - À, Cc, Cci : Les destinataires d'e-mails.
   - Object et Corps de l'e-mail.
   - Choisir une fichier : L'utilisateur peut attacher des fichiers à son courriel.

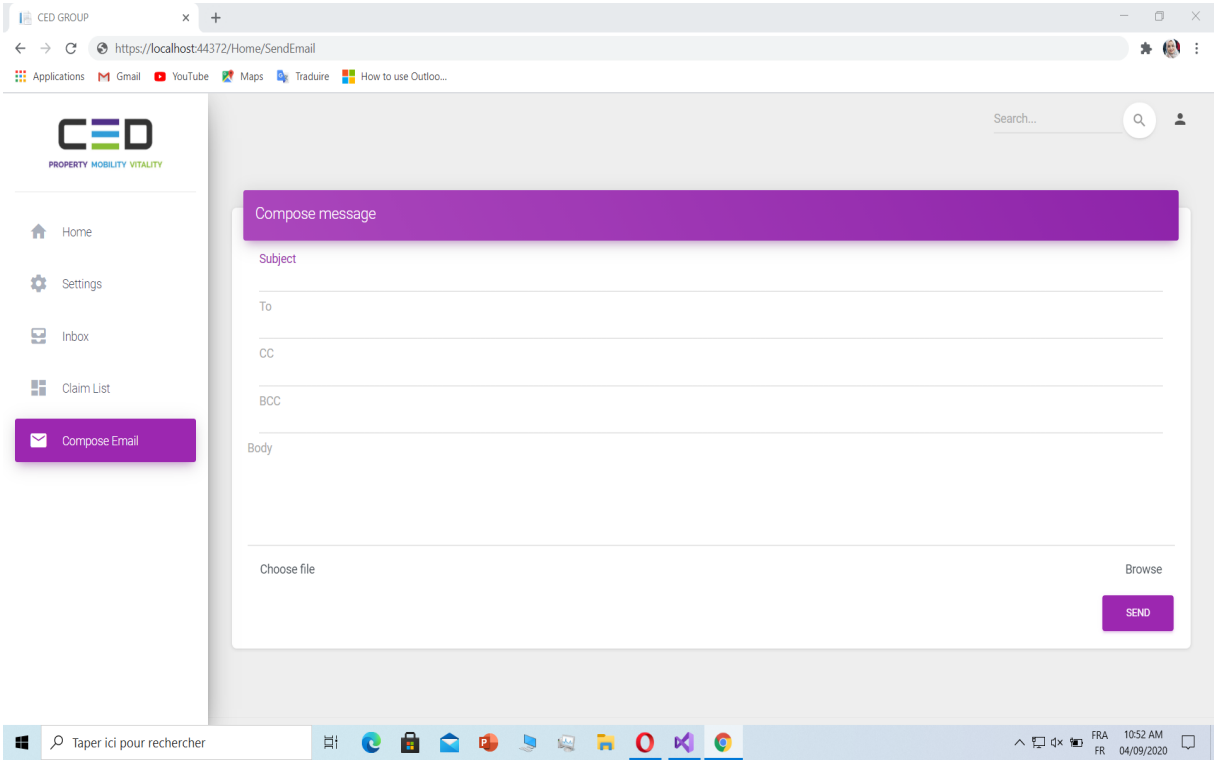


FIGURE 5.17 – La vue Envoyer un e-mail

5.4 Conclusion

Ce dernier chapitre a présenté le travail que nous avons effectué, l'environnement de développement, les outils et technologies utilisés dans le projet ainsi qu'une description détaillée des différentes phases d'implémentation du projet.

Conclusion générale

Ce stage au sein de CED Group a très bien répondu à mes attentes, puisqu'il m'a permis de travailler sur de nombreuses étapes du développement d'un produit : état de l'art, étude du besoin, établissement du cahier des charges et de sa solution.

Il m'a apporté également d'autre valeurs ajoutés. D'une part, j'ai appris a mieux gérer mon temps, mieux communiquer et collaborer avec les autres membres de l'équipe de développement. D'autre part, il m'a permis d'acquérir des compétences extrêmement importantes telle que le maintien et l'optimisation de mon code, l'intégration des bonnes pratiques, l'autonomie ainsi qu'une grande capacité de modélisation.

Le traitement du langage naturel s'est avéré être un domaine plus complexe que je ne l'imaginais ; derrière cette problèmatique se cache un enjeu majeur qui fascine la communauté informatique : rendre la machine capable de comprendre les humains. Des innovations dans ce domaine apparaissent de jour en jour et il est nécessaire de mener un travail de veille et d'adaptation pour rester à la pointe de l'innovation.

Mon projet de fin d'études consistait en la mise en œuvre d'une solution « Système d'analyse automatique des courriels » en faveur de l'équipe des gestionnaires back office de la division Mobilité à base de TALN. L'objectif de la solution était de minimiser le temps passé par cette équipe à lire et traiter les e-mails et les pièces jointes. Son rôle se réduit donc à une tâche de vérification et de correction.

La première itération du projet consistait en la définition du périmètre du projet. Les itérations qui suivaient ont été consacrées à la réalisation de plusieurs modules métiers de base. Lors de chaque itération, une étude fonctionnelle a été effectuée suivie d'une conception détaillée permettant par la suite d'enchaîner la phase de réalisation et de développement des modules en question.

En terme de perspectives, le projet dans sa version actuelle n'est pas encore achevé, on est actuellement en cours d'améliorer la performance du système et de personnaliser une solution similaire pour les divisions « Property » et « Vitality » pour faciliter encore plus leurs missions.

Webographie

[1] CED-Group, "Logo de ced group." https://www.ced.group, 2020. [Consulté le 3 juillet 2020].

[2] CED-Group, "Implantation de ced group dans le monde." https://www.ced.group/about-ced, 2020. [Consulté le 3 juillet 2020].

[3] CED-Group, "Structure de ced group." https://www.ced.group/services, 2020. [Consulté le 3 juillet 2020].

[4] CED-Group, "Unités de ced group." https://www.emn.nl, 2020. [Consulté le 3 juillet 2020].

[5] CED-Group, "Property." https://www.ced.group/property, 2020. [Consulté le 4 juillet 2020].

[6] CED-Group, "Mobility." https://www.ced.group/mobility, 2020. [Consulté le 4 juillet 2020].

[7] CED-Group, "Vitality." https://www.ced.group/vitality, 2020. [Consulté le 4 juillet 2020].

[8] Actu-IA, "Taln." https://www.actuia.com/contribution/sarah-marchand/le-taln-applique-aux-chatbots/, 2020. [Consulté le 5 juillet 2020].

[9] kdnuggets, "Principales approches traitement du langage naturel." https://www.kdnuggets.com/2018/10/main-approaches-natural-language-processing-tasks.html, 2020. [Consulté le 5 juillet 2020].

[10] Ahmed-Oumezzine, "Le modele mvc asp.net." http://ahmedoumezzine.blogspot.com/2017/07/modele-mvc-aspnet-mvc.html, 2019. [Consulté le 20 juillet 2020].

[11] Astera, "Définition restful api." https://www.astera.com/fr/type/Blog/reste-api-définition/, 2019. [Consulté le 20 juillet 2020].

[12] Wikipedia, "Définition pop3." https://fr.wikipedia.org/wiki/Post_Office_Protocol, 2019. [Consulté le 20 juillet 2020].

[13] CommentCaMarche, "Définition smtp." https://www.commentcamarche.net/contents/536-pop3-smtp-imap-protocoles-de-messagerie, 2019. [Consulté le 20 juillet 2020].

Annexes

Annexe A

Implémentation

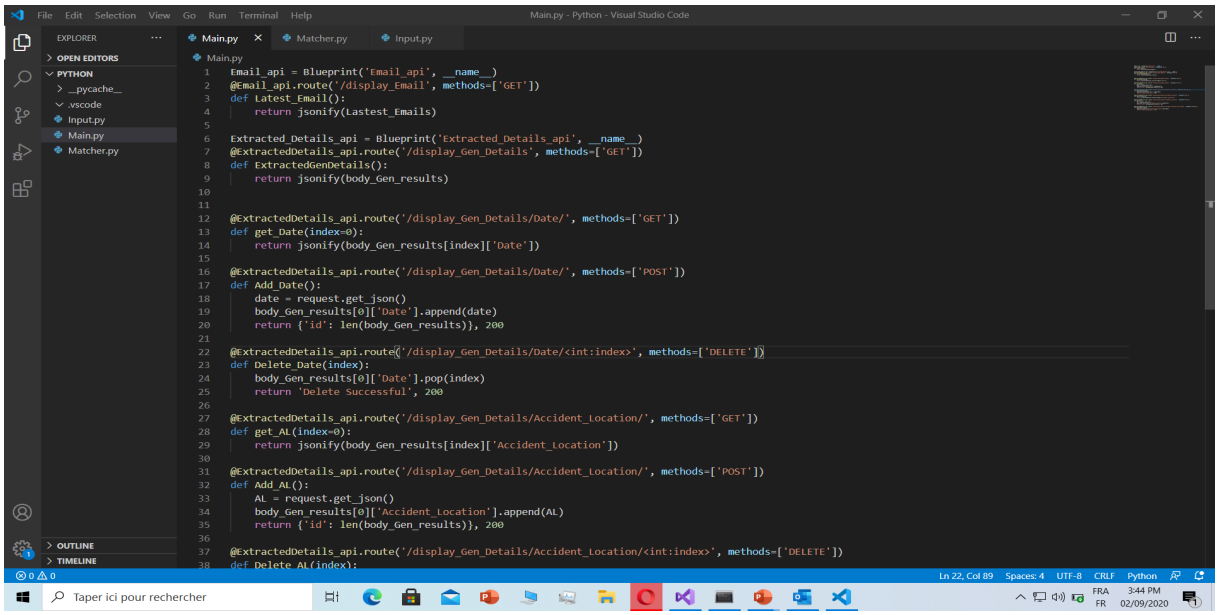


FIGURE A.1 – Développement des API FLASK RESTful