SUP'COM

المـــدرســـة العليـــا للمـــواصـــلات بتونـــس
ÉCOLE SUPÉRIEURE DES COMMUNICATIONS DE TUNIS

Cycle de formation des ingénieurs en Télécommunications

Option : AIM

Rapport de projet de fin d'études

Développement d'une Plateforme de Recrutement Intelligente

Auteur :
Saad Eddine SAAD

Encadrants Professionnels : Mme. Soumaya BESSAIDI &
M. Ghassen HADDAD
Encadrant Académique : M. Amine BEN SALEM

Travail proposé et réalisé en collaboration avec :

Audis Services

Année universitaire :2019/2020

مدينة تكنولوجيا المواصلات - طريق رواد كلم 3.5 - 2083 الغزالة أريانة - الهاتف : 000 857 71 216+ - الفاكس : 829 856 71 216+
Cité Technologique des Communications - Route de Raoued Km 3,5 - 2083 El Ghazala Ariana
Tél : +216 71 857 000 - Fax : +216 71 856 829 - E-mail : contact@supcom.tn - Web : www.supcom.tn

Dédicace

A mon cher père Ali, pour tous les moments de soutien et d'encouragement qu'il m'a donnés toute ma vie.

À ma chère mère Najia, pour sa gentillesse, son affection et pour les sacrifices qu'elle avait fait pour moi.

Ma mère, mon père, merci pour tous vos sacrifices, votre temps, votre soutien, et pour être toujours avec moi.
Aucune dédicace ne saurait exprimer mes gratitudes envers vous,

À mes chers frère et soeurs, Wajdi & Ismehen & Zouhour,

Votre pur amour et profonde tendresse sont la source de mon inspiration.
Je vous souhaite une vie pleine de bonheur et de succès.

À mes chers Amis et mes collègues

Je dédie ce travail à tous ceux qui ont cru en moi, comme témoignage de mon affection & ma gratitude infinie.

Remerciements

C'est avec un grand plaisir que je réserve cette page en signe de gratitude et de profonde reconnaissance à tous ceux qui m'ont aidé à la réalisation de ce travail.

Je tiens à remercier le directeur de l'entreprise Audis Services M. Kaïs Chaabouni, pour m'avoir donné sa confiance et sa contribution à la réalisation du projet.
Je tiens à remercier également mes encadrants professionnels Mme Soumaya BESSAIDI et M Ghassen HADDAD pour leurs aide et soutien et aussi pour leurs conseils et la qualité de la supervision dont j'ai bénéficié tout au long de ce projet ainsi que toute l'équipe du société pour l'encouragement continu.

Mon immense gratitude s'étend vers mon encadrant académique M. Amine BEN SALEM pour ses instructions, ses critiques les plus constructives, son aide et ses conseils inestimables qui m'ont été très bénéfiques en la livraison de ce projet.

J'exprime, en plus, ma vive reconnaissance à tous les enseignants de SUP'COM pour leurs conseils et soutien permanents.

Enfin, mes vifs remerciements vont de même aux membres du jury pour m'avoir honoré en acceptant d'évaluer ce travail et j'espère qu'ils y trouveront les qualités de clarté et de motivation qu'ils attendent.

Résumé

Ce travail s'inscrit dans le cadre du Projet de Fin d'études afin d'obtenir le diplôme national d'ingénieur en télécommunications. Il a été réalisé au sein de "Audis Services" et nous avons essayé d'être fidèle aux exigences citées dans le cahier des charges. Ce projet consiste à développer une plateforme de recrutement intelligente qui permet non seulement la mise en relation entre les demandeurs d'emploi et les recruteurs mais aussi le 'matching' entre les offres publiées et les meilleurs profils adéquats, en se basant sur les algorithmes d'intelligence artificielle et les techniques d'extraction d'informations.

Mots clés : IA, traitement du langage naturel(NLP), E-recrutement, Analyse des CVs, Recommandation d'emploi, classement des CVs, appariement CV/offre d'emploi.

Abstract

This work is part of the End of Studies Project in order to obtain the national diploma of engineer in telecommunications, it was carried out within "Audis Services" and we tried to be faithful to the cited requirements in the specifications. This project consists of developing an intelligent recruitment platform that not only allows job seekers to connect with recruiters but also matches published offers and the best suitable profiles, based on the algorithms of artificial intelligence and information extraction techniques.

Key words : AI, natural language processing(NLP), E-recruitement, Resume parsing, Job recommandation, Resume ranking, Resume-Job matching.

Table des matières

Table des figures **viii**

Liste des tableaux **x**

Liste des abréviations **xi**

Introduction générale **1**

1 Cadre Général du Projet **3**

1.1 Introduction 3

1.2 Présentation de l'organisme d'accueil 3

1.3 Problématique et présentation du projet 4

1.4 Étude de l'existant 5

1.4.1 Systèmes d'embauche de première génération 5

1.4.2 Systèmes d'embauche de deuxième génération 5

1.4.3 Systèmes d'embauche de troisième génération 5

1.5 Critique de l'existant 6

1.6 La Solution Proposée 7

1.7 Méthodologies de travail 7

1.7.1 Présentation de la méthodologie CRISP 7

1.7.2 Les Phases de la méthodologie CRISP 8

1.8 Planification des tâches 9

1.9 Conclusion 10

2 Étude théorique **11**

2.1 Introduction . . . 11
2.2 Définitions et Notions . . . 11
2.2.1 L'intelligence Artificielle et recrutement . . . 11
2.2.2 L'apprentissage profond . . . 12
2.2.3 Extraction de l'information . . . 12
2.2.4 Le traitement du langage naturel (NLP) . . . 12
2.2.4.1 La tokenisation . . . 13
2.2.4.2 Stemming et Lemmatisation . . . 13
2.2.4.3 La reconnaissance d'entités nommées (NER) . . . 13
2.2.5 Word embeddings et étude comparative entre les différentes méthodes 14
2.2.6 Frequency based Embedding . . . 15
2.2.6.1 Count Vector . . . 15
2.2.6.2 Term Frequency–Inverse Document Frequency vectorization 16
2.2.6.3 Co-Occurrence Matrix . . . 17
2.2.7 Prediction based Embedding . . . 18
2.2.7.1 CBOW . . . 18
2.2.7.2 Skip-gram . . . 20
2.2.7.3 Word2Vec . . . 21
2.3 Métriques de similarité . . . 22
2.3.1 L'indice de Jaccard . . . 22
2.3.2 Distance euclidienne . . . 22
2.3.3 Cosine Similarity . . . 23
2.4 Conclusion . . . 24

3 Conception et implémentation du modèle de reconstruction des relations (sémantique ou syntaxique) entre les mots 25

3.1 Introduction . . . 25
3.2 Architecture de processus intelligente globale . . . 25
3.3 Analyse du CV et extraction des informations . . . 26
3.3.1 Extraction du CV . . . 26
3.3.2 Extraction et identification du Vecteur candidat . . . 27

3.3.2.1 Extraction de l'émail et du numéro de téléphone 27
3.3.2.2 Extraction du nom de candidat à partir du CV 28
3.3.2.3 Extraction et identification des sections du CV 28
3.3.2.4 Évaluation de l'extraction 29
3.4 Implémentation du modèle de matching CV/annonce de travail 30
3.4.1 La compréhension du problème métier 30
3.4.2 La compréhension des données 30
3.4.3 Préparation et pré-traitement des données 32
3.4.4 La modélisation 33
3.4.4.1 Architecture de Word2Vec 33
3.4.5 Les paramètres du modèle 34
3.4.6 L'évaluation 35
3.4.7 Le déploiement 37
3.5 L'algorithme de classement 37
3.6 Conclusion 38

4 Étude et Conception de la Plateforme 39
4.1 Introduction 39
4.2 Analyses des besoins 39
4.2.1 Identification des acteurs 39
4.2.2 Les besoins fonctionnels 40
4.2.3 Les besoins non fonctionnels 41
4.3 Architecture globale de la solution 42
4.4 Conception et modélisation UML 43
4.4.1 Diagramme des cas d'utilisation 43
4.4.2 Description textuelle des cas d'utilisation 45
4.4.2.1 Cas d'utilisation : Authentification 46
4.4.2.2 Cas d'utilisation : Ajouter une offre d'emploi 47
4.4.2.3 Cas d'utilisation : Scraper une offre d'emploi 48
4.4.3 Les diagrammes dynamiques 48
4.4.3.1 Diagramme d'activité : consulter les candidatures 49

4.4.3.2 Diagramme de séquence : classer les candidats(CVs) . . . 50
4.4.4 Diagramme de classes . . . 50
4.5 Environnement de travail . . . 52
4.5.1 Environnement matériel . . . 52
4.5.2 Environnement logiciel . . . 53
4.6 Conclusion . . . 55

5 Choix des technologies et résultats 56
5.1 Introduction . . . 56
5.2 Choix des technologies . . . 56
5.2.1 Le Système de gestion de base de données :SGBD . . . 56
5.2.2 Langage de programmation et framework . . . 57
5.3 Résultats : Présentation des interfaces de la plateforme . . . 59
5.3.1 Espace Candidat . . . 59
5.3.2 Espace Entreprise . . . 64
5.3.3 Espace Administrateur . . . 69
5.3.3.1 Web scraping . . . 69
5.4 Conclusion . . . 70

Conclusion générale 71

Bibliographie 73

Webographie 74

Annexe A Liste des labels 75

Table des figures

1.1 Logo de l'entreprise Audis 4
1.2 Cycle de vie de la méthodologie CRISP 8
1.3 Diagramme de Gantt 9

2.1 Matrice Count Vector 16
2.2 Exemple :TF-IDF 17
2.3 Architecture de l'approche CBOW 19
2.4 Architecture de l'approche Skip-gram 21
2.5 La similarité cosinus 23

3.1 Architecture globale de la solution intelligente 26
3.2 Extraction et analyse du CV 27
3.3 Fonction d'expression régulière 28
3.4 Résultat d'extraction des 4 sections à partir de 150 CV 29
3.5 Stack-exchange DataSet 31
3.6 Nombre des phrases par longueur 33
3.7 Architecture du modèle Word2Vec 34
3.8 Paramètres utilisés pour le modèle 35
3.9 Évaluation de modèle avec :most-similar 36
3.10 Évaluation du modèle avec :most-similar with positive 36
3.11 Classement des CVs 38

4.1 Architecture globale de la plateforme 42
4.2 Diagramme des cas d'utilisation global 44

4.3 Diagramme d'activité : consulter les candidatures 49
4.4 Diagramme de séquence : classer les CVs 50
4.5 Diagramme de classes 51

5.1 Logo de MySQL 57
5.2 Architecture MVT de Django 58
5.3 Interface d'accueil 59
5.4 Interface d'inscription pour un candidat 60
5.5 Interface pour importer un CV 61
5.6 Interface d'accueil de candidat 61
5.7 Interface de profil pour un candidat 62
5.8 Interface de suivie de l'historique des candidatures 62
5.9 Interface de recommandation des offres 63
5.10 Interface de modification des paramètres de connexion 63
5.11 Formulaire d'inscription pour l'entreprise 64
5.12 Interface d'accueil de l'entreprise 65
5.13 Interface de profil de l'entreprise 65
5.14 Interface de suivie des offres publiées 66
5.15 Interface :publier une offre d'emploi 67
5.16 Interface Smart Search 68
5.17 Interface de classement des candidats 68
5.18 Interface d'administration Django 69
5.19 Interface : Web Crawler 70

A.1 Liste des labels 75

Liste des tableaux

4.1 Description textuelle du Cas d'utilisation : s'authentifier 46
4.2 Description textuelle du Cas d'utilisation : Ajouter une offre d'emploi . . . 47
4.3 Description textuelle du Cas d'utilisation : Scraper une offre d'emploi . . . 48
4.4 Caractéristiques de la machine de développement de l'application 52
4.5 Caractéristiques de la machine d'implémentation du modèle. 52

Liste des abréviations

ATS *Applicant Tracking System*
CBOW *Continuous Bag of Words*
CRISP *Cross Industry Standard Process*
CV *Curriculum vitae*
DL *Deep Learning*
HTML *HyperText Markup Language*
IA *Intelligence Artificielle*
IE *Information Extraction*
IT *Information Technology*
ML *Machine Learning*
NER *Named-entity recognition*
NLP *Natural Language Processing*
NLTK *Natural Language ToolKit*
SGBD *Système de gestion de base de données*
SLM *Simple Language Modeling*
TF-IDF *Term Frequency–Inverse Document Frequency*
UML *Unified Modeling Langage*

Introduction générale

Selon une étude effectuée en 2015 sur le comportement de recherche d'emploi du Pew Research Center, 79% des demandeurs d'emploi ont utilisé les ressources en ligne pour leur dernier emploi (Aaron, 2015).[1]

Les résultats de l'étude suggèrent que les sites d'emploi en ligne deviennent le principal canal pour les candidats dans cette ère numérique. Cependant, un autre résultat de l'étude indique que la plupart des demandeurs d'emploi n'arrivent pas à faire correspondre leurs expériences avec les exigences de l'emploi et passent des heures sur le site d'emploi pour postuler, ce qui n'est pas jugé approprié (Aaron, 2015). [1]

Si l'Internet permet certainement d'atteindre un public plus large du point de vue des recruteurs et rend les candidatures plus pratiques du point de vue des candidats, deux problèmes se posent : d'un côté, il y a énormément d'offres d'emploi en ligne dans différents portails et catégories d'emplois. Cette situation rend la tâche du candidat de présélectionner des emplois fastidieuse et chronophage, souvent dérivée d'une présélection sous-optimale. D'un autre côté, certaines offres d'emploi peuvent attirer des centaines, voire des milliers de candidatures, ce qui rend la tâche du recruteur de filtrer toutes les candidatures très difficiles dans les délais des entreprises.

Pour résoudre ce problème, certains systèmes ont été conçus pour aider les recruteurs à filtrer les candidatures, mais ils ont tendance à négliger les défis liés au langage naturel. En fait, les applications de recrutement en ligne traditionnelles n'utilisent normalement que de simples opérations booléennes pour comparer les exigences de base des emplois proposés par les employeurs et les informations de qualification de base des demandeurs d'emploi afin de générer des résultats de correspondance. Cette technique présente plusieurs lacunes telles que l'ignorance des problèmes liés au langage naturel, y compris la sémantique et les synonymes. Par conséquent, il arrive assez souvent que des emplois non pertinents soient appariés ou que trop de « résultats » soient obtenus qui ne conviennent pas vraiment[2]. En outre, les demandeurs d'emploi doivent parcourir une longue liste d'offres d'emploi dans une requête donnée pour sélectionner et ils doivent également remplir des informations de

base massives basées sur des formulaires. Pour les questions auxquelles ils doivent répondre, les choix proposés peuvent parfois être trop larges ou imprécis et il leur est difficile de les déterminer, ce qui conduit à une saisie de données inexacte.
De plus, l'application de recrutement en ligne devrait non seulement fournir un emploi correspondant, mais également explorer et découvrir des emplois pertinents à recommander aux demandeurs d'emploi. Les demandeurs d'emploi aimeraient voir une gamme d'emplois adaptés qui correspondent à leurs profils de travail, leurs qualifications et leurs propres intérêts. Cependant, avec des exigences et des spécifications d'emploi différentes de celles des employeurs, il est toujours difficile de regrouper des emplois similaires.

Ce projet de fin d'étude, réalisé au sein de la société Audis Services, vise effectivement à résoudre ces problèmes. Notre objectif principal est d'implémenter des méthodes intelligentes pour accélérer la tâche des recruteurs et des candidats en reprenant le processus de mise en correspondance. Dans ce travail, nous présentons une approche d'apprentissage automatique pour créer un modèle de classement des candidats selon une offre choisie, mais qui peut également être utilisé pour aider les candidats à travers un système de recommandation d'emploi.

Le présent rapport comprend cinq chapitres ; Le premier introduit le contexte général du projet et une présentation de la société accueillante. Dans le deuxième chapitre, une étude théorique définissant les termes et les mots clés du projet est effectuée. Le troisième chapitre explore les détails de la solution intelligente et l'implémentation du modèle. Nous abordons dans le 4ème volet du rapport l'étude conceptuelle de la plateforme de recrutement et sa mise en œuvre. Dans le dernier et cinquième chapitre, nous présentons les choix technologiques du projet ainsi que les résultats obtenus en démontrant les différentes interfaces de la plateforme. Nous clôturons par une conclusion générale où nous avons invoqué le travail réalisé brièvement en proposant nos futures perspectives et améliorations.

Chapitre 1

Cadre Général du Projet

1.1 Introduction

Dans ce chapitre, nous présentons d'abord une vue générale sur le cadre d'élaboration de ce projet ainsi sur l'organisme d'accueil. Ensuite, nous décrivons la méthodologie adoptée lors de la réalisation de ce travail.

1.2 Présentation de l'organisme d'accueil

Audis Services[1] est une société de conseil, de services et d'ingénierie informatique experte dans le domaine des nouvelles technologies et de l'informatique. Sa mission est de concevoir et de mettre en œuvre des solutions et des services informatiques évolutifs adaptés aux besoins de ses clients.
Depuis sa création en 2013, Audis Services n'a cessé de développer une expertise métier. Disposant de collaborateurs hautement qualifiés, Audis Services conseille des clients dans une démarche globale de changements induits par l'évolution des solutions applicatives à l'aide d'une méthodologie fiable et éprouvée.

Orienté aux entreprises, Audis se spécialise dans les services IT et se positionne comme un des partenaires de confiance pour accompagner différentes structures françaises privées ou publiques dans leurs transformations.

Audis se présente sur cinq corps de métier :
- Consulting
- Infogérance
- Assistance technique
- NearShore
- Data Science



FIGURE 1.1 – Logo de l'entreprise Audis

1.3 Problématique et présentation du projet

Le recrutement est une étape primordiale et fondamentale pour tout organisme professionnel. En effet, c'est un processus qui se divise lui-même en deux sous-étapes essentielles : Il s'agit en premier lieu d'identifier le poste vacant au sein de l'entreprise. En second lieu, les ressources humaines se tâchent de la description et la détermination du profil recherché. Cela implique entre autres la planification d'une stratégie de mise en place des exigences, la recherche des candidats adéquats, l'analyse des CVs en fonction des exigences et l'évaluation des candidats. La recherche et la présélection des meilleurs profils parmi des centaines de candidatures envoyées sont parmi les tâches les plus fastidieuses dans le processus de recrutement ; elles sont coûteuses en termes de temps, d'énergie et d'argent.
Vu sous un autre angle, la tâche du chercheur d'emploi est compliquée aussi. Celui-ci doit parcourir les offres d'emploi un à un jusqu'à parvenir au poste qui l'intéresse et va mieux avec ses compétences. Ce processus est fastidieux, long et très souvent sans résultat.

Il s'avère donc que le développement d'un système d'appariement traitant les informations relatives aux recruteurs ainsi que leurs offres d'emploi d'une part et les profils des candidats et leurs compétences d'une autre part sera la meilleure solution pour les deux intervenants.

C'est dans ce cadre que s'instaure ce projet de fin d'études qui a pour but de développer une plateforme de recrutement intelligente. En se basant sur les algorithmes d'intelligence artificielle et des techniques d'extraction d'informations, elle permet d'une part de filtrer et sélectionner les meilleurs candidats, allégeant ainsi la tâche des gestions de ressources humaines, et d'autre part de proposer les meilleurs offres d'emploi correspondant le mieux aux compétences de chaque candidat.

1.4 Étude de l'existant

Les métiers des Ressources Humaines et les techniques de recrutement ont changé ces dernières années avec la montée des réseaux sociaux et du numérique. Après avoir fait une documentation détaillée sur les solutions existantes, ayant déjà traité le sujet de recrutement, nous avons conclu qu'il y a principalement trois générations des sites d'emploi, chacune d'eux a essayé d'améliorer l'antécédente en se profitant de l'avancement des technologies.

1.4.1 Systèmes d'embauche de première génération

Durant ce processus d'embauche traditionnel, l'équipe de recrutement publie ses annonces et invite les candidats. Les méthodes d'édition étaient les journaux, la télévision et la radio. Les candidats intéressés postuleraient alors en y envoyant des CVs. Ces curriculum vitae ont ensuite été reçus et triés par l'équipe de recrutement et les candidats pré-sélectionnés ont été convoqués pour d'autres séries d'entretiens. L'ensemble du processus prendrait beaucoup de temps et d'efforts humains pour trouver le bon candidat adapté à leur poste et vice-versa pour les candidats.

1.4.2 Systèmes d'embauche de deuxième génération

Au fur et à mesure que les industries se développaient, les besoins de recrutement se sont rapidement accrus. Pour répondre à ces besoins de recrutement, certains sites d'emploi ont vu le jour. Ils ont proposé une solution dans laquelle le candidat doit télécharger ses informations dans un format particulier et les soumettre sur le site. De l'autre côté, les entreprises doivent afficher leurs offres d'emploi afin que les candidats puissent postuler. Certains filtres sont utilisés pour faciliter cette tâche, tels que la recherche basée sur l'emplacement, le domaine d'emploi et le titre du poste, ainsi que certains mots clés à rechercher dans le CVs et vice versa.

1.4.3 Systèmes d'embauche de troisième génération

Vous avez probablement déjà entendu de l'IA dans le recrutement. En effet, l'intelligence artificielle est une notion très peu utilisée dans le monde du recrutement mais qui offre pourtant de nombreux avantages comme l'automatisation de certaines tâches, notamment sur le sourcing ou le traitement des candidatures. De plus, elle permet aussi de pouvoir mieux identifier les talents qui pourraient être en adéquation avec le poste à pourvoir et l'entreprise. Le système d'analyse se base sur des algorithmes qui utilisent le traitement

du langage naturel (NLP), sous-domaine de l'IA. Et c'est dans ce cadre que s'inscrit notre projet.

1.5 Critique de l'existant

Bien qu'il y ait eu des travaux antérieurs pour automatiser le processus de recrutement d'une autre manière et qu'il y ait eu des travaux pour rendre le processus moins ennuyeux et plus facile en même temps, il y a encore place à l'amélioration. De nombreuses techniques de traitement du langage naturel ou d'apprentissage automatique sont issues de l'analyse de la manière dont le cerveau interprète les données réelles.
Par exemple, si deux emplois ont «Administrateur de base de données» dans les champs "JobTitle", il est probable que les CVs des candidats appropriés pour les deux emplois aient «SQL server» ou «MySQL» dans l'un des champs de leurs CVs . Mais la plupart des solutions existantes utilisent une approche de vraisemblance de requête (likelyhood query), avec l'enregistrement de travail aplati comme requête et le résumé aplati comme documents. Nous appelons cette approche de modélisation de langage simple «SLM». On s'attendait à ce que ses performances soient faibles car il n'a aucun moyen de combler le fossé du vocabulaire entre les descriptions de poste et les CVs - par exemple, l'administrateur de base de données et l'exemple de serveur SQL ci-dessus.
De plus, étant donné que la plupart de ces méthodes d'appariement des emplois sont toujours basées sur l'approche de base et traditionnellement négligeant la signification contextuelle et sémantique des compétences, les informations sur la qualification professionnelle du demandeur d'emploi ne sont pas comparées efficacement aux exigences de base du poste fournies par l'employeur. Ainsi, lorsque le demandeur d'emploi utilise ces applications de recrutement en ligne traditionnelles qui n'utilisent normalement que de simples opérations booléennes pour comparer les informations, des emplois non pertinents seront appariés ou un certain nombre de descriptions de poste seront obtenues.

Les systèmes de suivi des candidats peuvent être utilisés pour faciliter un certain nombre de processus différents lors du recrutement et de nombreuses entreprises les mettent en œuvre pour aider le personnel des RH dans le processus d'évaluation des CVs. L'un des inconvénients des ATS est qu'ils peuvent parfois être inexacts et peu fiables. Par exemple, les ATS rejettent souvent les CVs pour des raisons non valides, telles que le scanner ne pouvant pas les lire correctement. Si un CV est un peu plus complexe que d'autres, cela peut également amener le système à le rejeter. Ce n'est pas seulement injuste pour les candidats, mais aussi improductif pour les entreprises[4].

ATS ont souvent une limite pour les informations du candidat. Cela signifie souvent que les organisations finissent par éliminer des candidats parfaitement adaptés, ce qui est très contre-productif.

1.6 La Solution Proposée

Notre projet consiste à développer une plateforme de recherche d'emploi permettant la mise en contact entre les candidats (espace candidat) et les recruteurs (espace entreprise). Mis à part les fonctionnalités de base qu'une telle plateforme peut offrir ; à savoir publier une offre d'emploi, consulter les candidatures, postuler pour les offres désirées, consulter la liste des candidats à travers des filtres de recherche. Nous l'avons enrichi avec un système intelligent de matching CV/offre d'emploi, ayant pour objectif de recommander au candidat les postes les plus appropriées à son profil après avoir analysé son CV, en utilisant des techniques du NLP.
D'autre part, notre site d'emploi offre aux entreprises une fonctionnalité très intéressante, c'est de classer les candidats selon un score que nous calculons en utilisant un modèle intelligent pour chaque annonce d'emploi. Ce qui facilite la tâche de sélection des candidatures, et minimise l'intervention humaine.

1.7 Méthodologies de travail

Une méthodologie de travail est un cadre utilisé pour structurer, planifier et contrôler le développement d'une application. Il s'agit de modéliser un système avant sa réalisation afin de bien comprendre son fonctionnement et d'en assurer la cohérence.
L'organisation du travail dans ce projet, pour la partie IA est basée sur la méthodologie CRISP (Cross Industry StandardProcess).

1.7.1 Présentation de la méthodologie CRISP

CRISP [5] (Cross Industry Standard Process) est une méthode efficace très utilisable aujourd'hui pour les projets basés sur l'intelligence artificielle. La méthode CRISP est agile et itérative, c'est-à-dire que chaque itération apporte de la connaissance métier supplémentaire qui permet de mieux aborder l'itération suivante.
Cette méthode se décompose en 6 étapes allant de la compréhension du besoin métier au déploiement et la mise en production du modèle comme l'indique la figure 1.2.

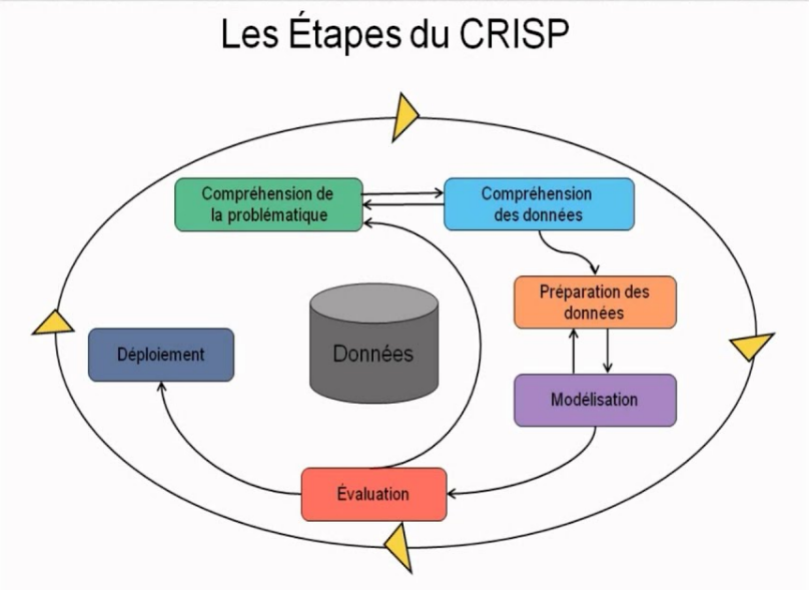


FIGURE 1.2 – Cycle de vie de la méthodologie CRISP

1.7.2 Les Phases de la méthodologie CRISP

1. **La compréhension du problème métier :**

   Cette phase consiste à identifier les objectifs et les exigences du projet .Il consiste en des réunions et en l'examen de documents pour définir un plan initial de projet pour atteindre les objectifs

2. **La compréhension des données :**

   Cette phase commence par une première collecte de données, puis d'autres activités pour se familiariser avec les données et en vérifier la qualité. Cette phase est liée à la phase précédente . En cas d'exploitation de données peu claire, nous pouvons prendre du recul pour comprendr et de voir comment elle bénéficie de ces données.

3. **Préparation et pré-traitement des données :**

   Cette étape comprend toutes les activités visant à préparer l'ensemble de données final à partir des données initiales. Les tâches de préparation des données peuvent être effectuées plusieurs fois et comprennent la sélection des attributs, le nettoyage des données et la transformation des données pour les rendre compatibles à la phase de modélisation.

4. **La modélisation :**

   Cette étape comprend le choix, le paramétrage et le test de différents algorithmes ainsi que leur enchaînement, qui constitue un modèle. Cette étape est la plus courte dans le temps, en fonction des résultats obtenus, nous pouvons prendre du recul et améliorer les données

5. **L'évaluation :**

   L'évaluation vise à vérifier les connaissances obtenues du modèle afin de s'assurer qu'ils répondent aux objectifs formulés au début du processus. Elle contribue aussi à la décision de déploiement du modèle ou à son amélioration si les résultats sont erronés, donc nous allons revenir à la première étape afin de surmonter nos erreurs. À ce stade, nous testons notamment la robustesse et la précision des modèles obtenus.

6. **Le déploiement :**

   Il s'agit de l'étape finale du processus. Elle consiste en une mise en production pour les utilisateurs finaux des modèles obtenus. Son objectif : mettre la connaissance obtenue par la modélisation, dans une forme adaptée.

1.8 Planification des tâches

Le diagramme de Gantt est un outil de planification des tâches nécessaires pour la réalisation d'un projet quelque soit le secteur d'activité. Il permet de visualiser l'avancement des tâches d'un projet de manière simple et concise, de planifier et suivre les besoins en ressources humaines et matérielles et donc de pouvoir suivre l'avancement du projet. Le diagramme de la figure 1.3 représente les principales tâches à réaliser dans notre projet.

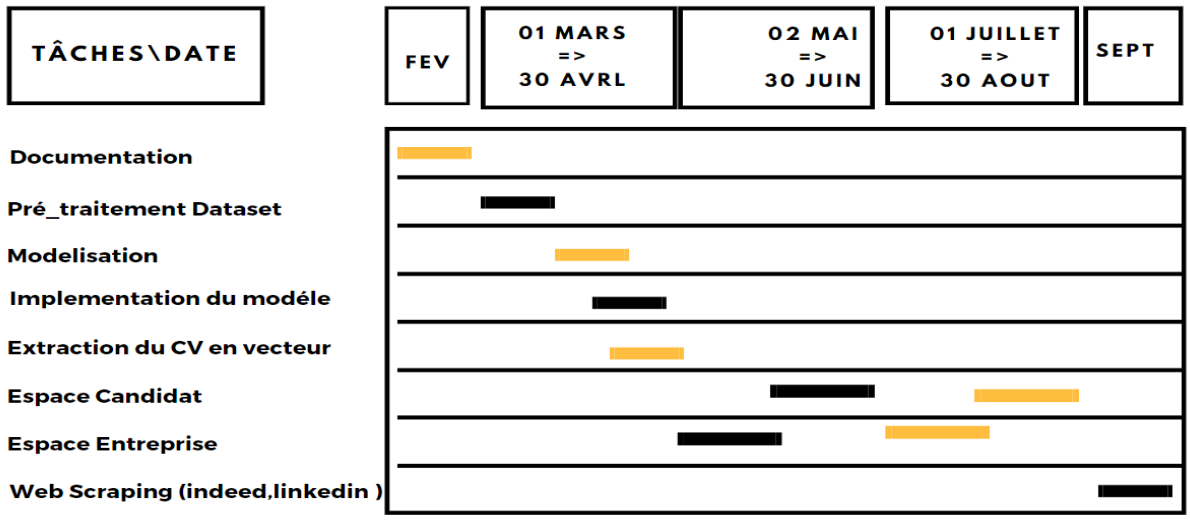


FIGURE 1.3 – Diagramme de Gantt

A l'aide de ce diagramme, nous avons pu organiser toutes les étapes de réalisation de notre projet et cela en les divisant sur toute la période de stage.

1.9 Conclusion

Ce chapitre constitue une partie introductive dans laquelle une présentation de l'organisme d'accueil ainsi que le contexte du projet a été élaborée en premier lieu.
En second lieu, nous avons étudié les problèmes de la situation courante et les solutions existantes sur le marché pour finir par proposer une solution à mettre en place. Enfin, nous avons justifié le choix de la méthodologie adoptée pour gérer ce projet et nous avons présenté la planification opté pour la réalisation de notre projet.

Chapitre 2

Étude théorique

2.1 Introduction

Avant de commencer ce projet, de nombreuses technologies disponibles et des travaux de recherche ont été étudiés et pris en considération. Cela nous a donné des connaissances et des informations qui ont clarifié la méthodologie adoptée afin d'obtenir le meilleur résultat possible.

Ce chapitre est une étude bibliographique des technologies existantes que nous allons utiliser plus tard dans notre projet.

2.2 Définitions et Notions

2.2.1 L'intelligence Artificielle et recrutement

Depuis l'ATS, les recruteurs ont mis à profit la technologie pour rendre leur travail plus facile, plus rapide et meilleur. Aujourd'hui, le thème dominant de la technologie RH est l'IA pour le recrutement. L'IA pour le recrutement est l'application de l'intelligence artificielle, comme l'apprentissage ou la résolution de problèmes qu'un ordinateur peut faire, à la fonction de recrutement.
Cette nouvelle technologie est conçue pour rationaliser ou automatiser une partie du flux de travail de recrutement, en particulier les tâches répétitives à volume élevé.
Par exemple, un logiciel qui applique l'apprentissage automatique aux CV pour filtrer automatiquement les candidats ou un logiciel qui effectue une analyse des sentiments sur les descriptions de poste pour identifier un langage potentiellement biaisé.

2.2.2 L'apprentissage profond

L'apprentissage en profondeur(DL) est une fonction d'IA qui imite le fonctionnement du cerveau humain dans le traitement des données à utiliser pour détecter des objets, reconnaître la parole, traduire des langues et prendre des décisions.Le DL est capable d'apprendre sans supervision humaine, en s'appuyant sur des données à la fois non structurées et non étiquetées. Grâce à DL, qui propose désormais une extraction améliorée et une identification plus intelligente des données de CV pour de meilleurs résultats de recherche. Grâce à une amélioration incroyable des champs de données, les taux d'erreur ont été considérablement réduits. La nouvelle pile technologique permet également de fournir une version plus rapide des langues. L'idée d'amener l'analyse à un niveau avancé grâce à la technologie de DL se transforme maintenant en réalité. Analysons la magie du DL, qui apporte une révolution dans le secteur des technologies RH. Il utilise des algorithmes pour traiter une grande quantité de données textuelles[3]. La capacité d'auto-apprentissage de cette technologie lui permet d'apprendre automatiquement la représentation de mots similaires. L'ajout de nouvelles connaissances est désormais un processus automatique. Auparavant, nous devions créer une liste de compétences manuellement. Mais avec l'adoption du NER, il est possible de prédire les entités et les valeurs directement à partir du texte.

2.2.3 Extraction de l'information

L'extraction d'informations (IE) déduit le processus de collecte automatique d'informations de manière structurée à partir de documents lisibles par machine non structurés et / ou semi-structurés. La tâche implique l'utilisation du traitement du langage naturel (NLP). L'objectif actuel d'IE se réfère à la quantité croissante d'informations disponibles sous une forme non structurée [1]. De nos jours, un volume énorme de documents se trouve en ligne et hors ligne. Extraire manuellement les informations de ces vastes volumes de données prend du temps. De plus, la création d'un certain modèle à partir des informations extraites a récemment été un nouveau défi et une préoccupation majeure de l'ère technologique moderne. Le recrutement est le processus de recherche et de sélection des meilleurs candidats pour pourvoir les postes vacants d'une organisation. Le processus de recrutement nécessite une planification, une stratégie de configuration des exigences, la recherche de candidats, la sélection des candidats selon les exigences et l'évaluation des candidats.

2.2.4 Le traitement du langage naturel (NLP)

Le traitement du langage naturel (NLP) est une branche de l'IA. C'est un processus d'analyse, de compréhension et de dérivation d'informations à partir des données textuelles d'une manière intelligente et efficace.

NLP concerne les interactions entre les ordinateurs et les humains via les langages naturels. Il comprend des défis tels que l'analyse syntaxique (analyse grammaticale) de la compréhension du langage naturel ou la génération du langage naturel.
En utilisant la NLP et ses composants, nous pouvons effectuer de nombreuses tâches automatisées et résoudre un large éventail de problèmes telles que la synthèse automatique, la traduction automatique, la reconnaissance d'entités nommées et l'analyse des documents. La capacité de comprendre un langage écrit non structuré et d'en extraire des informations importantes pour enseigner à la machine est exactement ce qui est nécessaire pour analyser des documents écrits tels que des CV, tout comme l'être humain.

2.2.4.1 La tokenisation

La tokenisation est le processus de division d'une chaîne, d'un texte en une liste de jetons. Nous pouvons considérer le jeton comme un mot dans une phrase, et une phrase est un jeton dans un paragraphe.
La tokenisation aide à interpréter la signification du texte en analysant la séquence des mots.

2.2.4.2 Stemming et Lemmatisation

La stemming et la lemmatisation sont des techniques de normalisation de texte (ou parfois appelées normalisation de mots) dans le domaine du NLP qui sont utilisées pour préparer du texte, des mots et des documents pour un traitement ultérieur. La stemming et la lemmatisation ont été étudiées, et des algorithmes ont été développés en informatique depuis les années 1960.
La Stemming est une technique utilisée pour extraire la forme de base des mots en supprimant les affixes. C'est comme couper les branches d'un arbre jusqu'à ses tiges. Par exemple, la racine des mots eating, eats, eaten is eat.
La technique de lemmatisation est comme la stemming. Le résultat que nous obtiendrons après la lemmatisation est appelé «lemme», qui est un mot racine plutôt que stem racine, le résultat de la racine. Après la lemmatisation, nous obtiendrons un mot valide qui signifie la même chose.

NLTK (Natural Language ToolKit)fournit la classe WordNetLemmatizer qui est un wrapper fin autour du corpus wordnet. Cette classe utilise la fonction morphy () dans la classe WordNet CorpusReader pour trouver un lemme.

2.2.4.3 La reconnaissance d'entités nommées (NER)

La reconnaissance d'entités nommées est probablement la première étape vers l'extraction d'informations qui cherche à localiser et à classer les entités nommées dans le texte

dans des catégories prédéfinies telles que les noms de personnes, d'organisations, de lieux, d'expressions de temps, de quantités, de valeurs monétaires, de pourcentages , etc.
Les bibliothèques Spacy et NLTK sont utilisées pour créer des outils de reconnaissance d'entités nommées.

2.2.5 Word embeddings et étude comparative entre les différentes méthodes

En termes très simplistes, Word Embeddings sont les textes convertis en nombres et il peut y avoir différentes représentations numériques du même texte. Mais avant de plonger dans les détails de Word Embeddings, la question suivante doit être posée - Pourquoi avons-nous besoin de Word Embeddings ?
Il s'avère que de nombreux algorithmes d'apprentissage automatique et presque toutes les architectures d'apprentissage profond sont incapables de traiter des chaînes ou du texte brut sous leur forme brute. Ils nécessitent des nombres en entrée pour effectuer tout type de travail, que ce soit la classification, la régression, etc. en termes généraux. Et avec l'énorme quantité de données présentes dans le format texte, il est impératif d'en extraire des connaissances et de créer des applications. Certaines applications du monde réel des applications de texte sont - l'analyse des sentiments, étude de similarité, détection de fraude.

Définissons maintenant formellement les Word Embeddings. Un format Word Embedding essaie généralement de mapper un mot à l'aide d'un dictionnaire sur un vecteur. Jetez un œil à cet exemple - phrase = "Word Embeddings are Word converted into numbers".
Un mot dans cette phrase peut être "Embeddings" ou "numbers", etc.
Un dictionnaire peut être la liste de tous les mots uniques de la phrase. Ainsi, un dictionnaire peut ressembler à - ["Word", "Embeddings", "are", "Converted", "into", "numbers"]
Une représentation vectorielle d'un mot peut être un vecteur codé à chaud(one-hot encoded vector) où 1 représente la position où le mot existe et 0 partout ailleurs. La représentation vectorielle du mot «numbers» dans ce format selon le dictionnaire ci-dessus est [0,0,0,0,0,1] et du mot «Converted» est [0,0,0,1,0,0].
C'est juste une méthode très simple pour représenter un mot sous forme vectorielle.
Examinons maintenant les différents types de "Word Embeddings" ou "Word Vectors" et leurs avantages et inconvénients. Les différents types de "word embeddings" peuvent être globalement classés en deux catégories :

- **Frequency based Embedding**
- **Prediction based Embedding**

2.2.6 Frequency based Embedding

Ces méthodes de word embeddings sont très basiques, faciles et rapides. Ceux-ci fonctionnent sur la base du décompte d'un mot dans chaque document.

2.2.6.1 Count Vector

Considérons un Corpus C de D documents d1, d2... ..dD et N mots uniques extraits du corpus C. Les N mots formeront notre dictionnaire et la taille de la matrice "Count vector" M sera donnée par D*N. Chaque ligne de la matrice M contient la fréquence des mots dans le document D(i). Comprenons cela à l'aide d'un exemple simple.
D1 :He is a lazy boy. She is also lazy.
D2 : Neeraj is a lazy person.
Le dictionnaire créé peut être une liste de jetons (mots) uniques dans le corpus = ['He','She','lazy','boy','Neeraj','person']. Ici, D = 2, N = 6.
Maintenant, une colonne peut également être comprise comme un vecteur de mot pour le mot correspondant dans la matrice M. Par exemple, le vecteur de mot pour 'lazy' dans la matrice ci-dessus est [2,1] et ainsi de suite. Ici, les lignes correspondent à les documents du corpus et les colonnes correspondent aux mots du dictionnaire. La deuxième ligne de la matrice ci-dessus peut être lue comme - D2 contient «lazy» : une fois, «Neeraj» : une fois et «person» une fois.

Maintenant, il peut y avoir un certain nombre de variations lors de la préparation de la matrice ci-dessus M.Les variations seront généralement en cours de préparation du dictionnaire.

La façon dont le dictionnaire est préparé :
Pourquoi ? Parce que dans les applications du monde réel, nous pourrions avoir un corpus contenant des millions de documents. Et avec des millions de documents, nous pouvons extraire des centaines de millions de mots uniques. Donc, fondamentalement, la matrice qui sera préparée comme ci-dessus sera très clairsemée et inefficace pour tout calcul. Donc, une alternative à l'utilisation de chaque mot unique comme élément de dictionnaire serait de choisir, disons, les 10 000 premiers mots en fonction de la fréquence, puis de préparer un dictionnaire.

La façon dont le compte est pris pour chaque mot :
On peut prendre la fréquence (nombre de fois qu'un mot est apparu dans le document) ou la présence (le mot est-il apparu dans le document) pour être l'entrée dans la matrice de comptage M. Mais généralement, la méthode de la fréquence est préférée à la dernière.

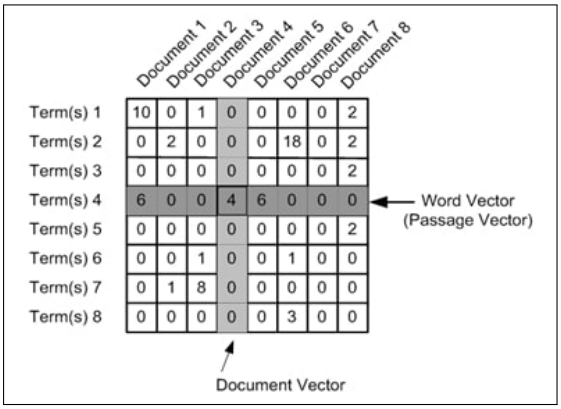


FIGURE 2.1 – Matrice Count Vector

2.2.6.2 Term Frequency–Inverse Document Frequency vectorization

C'est une autre méthode qui est basée sur la méthode des fréquences mais qui est différente de la méthode "Count Vector" en ce sens qu'elle prend en compte non seulement l'occurrence d'un mot dans un seul document mais dans l'ensemble du corpus. Alors, quelle est la raison derrière cela ? Essayons de comprendre en se basant sur l'exemple montré dans la figure 2.1.
Les mots courants tels que «est», «le», «un», etc. ont tendance à apparaître assez fréquemment par rapport aux mots qui sont importants pour un document. Par exemple, un document A sur Lionel Messi va contenir plus d'occurrences du mot «Messi» par rapport à d'autres documents. Mais des mots courants comme «le», etc. seront également présents à une fréquence plus élevée dans presque tous les documents.

Idéalement, ce que nous voudrions, c'est réduire le poids des mots courants présents dans presque tous les documents et donner plus d'importance aux mots qui apparaissent dans un sous-ensemble de documents.

TF-IDF fonctionne en pénalisant ces mots courants en leur attribuant des poids plus faibles tout en donnant de l'importance à des mots comme Messi dans un document particulier.

Alors, comment fonctionne exactement TF-IDF ? Considérez l'exemple de la figure 2.2 qui donne le nombre de termes (jetons / mots) dans deux documents.

Maintenant, définissons quelques termes liés à TF-IDF :

$$\text{tf-idf}_{t,d} = tf_{t,d} \cdot idf_t = tf_{t,d} \cdot \log \frac{N}{\text{df}_t} \tag{2.1}$$

- **TF** = (Nombre de fois que le terme t apparaît dans un document) / (Nombre de termes dans le document).Donc, TF ("This", Document 1) = 1/8, TF ("This",

Document 2) = 1/5
Cette methode indique la contribution du mot au document, c'est-à-dire que les mots pertinents pour le document doivent être fréquents. Par exemple : un document sur Messi doit contenir le mot «Messi» en grand nombre.

- **IDF** = log (N / n), où N est le nombre de documents et n le nombre de documents dans lesquels un terme t est apparu.Donc, IDF (This) = log (2/2) = 0.

Alors, comment expliquer le raisonnement derrière IDF ? Idéalement, si un mot est apparu dans tout le document, alors probablement ce mot n'est pas pertinent pour un document particulier. Mais s'il est apparu dans un sous-ensemble de documents, alors le mot a probablement une certaine pertinence pour les documents dans lesquels il est présent.Calculons IDF pour le mot «Messi». IDF (Messi) = log (2/1) = 0,301.
Maintenant, comparons le TF-IDF pour un mot commun «Ceci» et un mot «Messi» qui semble être pertinent pour le Document 1.
TF-IDF (This, Document1) = (1/8) * (0) = 0
TF-IDF (This, Document2) = (1/5) * (0) = 0
TF-IDF (Messi, Document1) = (4/8) * 0,301 = 0,15
Comme vous pouvez le voir pour Document1, la méthode TF-IDF pénalise fortement le mot «This» mais attribue un poids plus important à «Messi». Ainsi, cela peut être compris comme «Messi» est un mot important pour Document1 dans le contexte de l'ensemble du corpus.

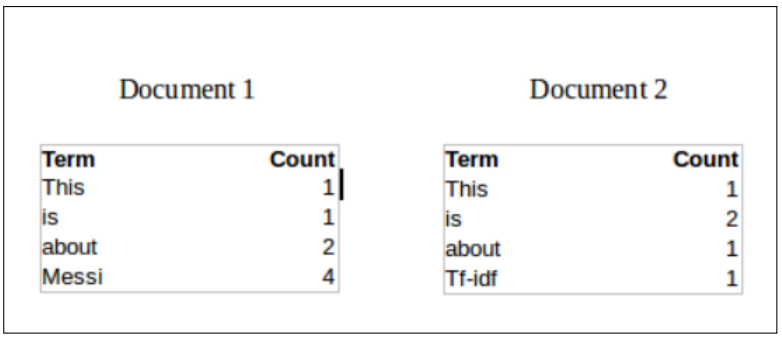


FIGURE 2.2 – Exemple :TF-IDF

2.2.6.3 Co-Occurrence Matrix

Co-occurrence - Pour un corpus donné, la co-occurrence d'une paire de mots, disons w1 et w2, est le nombre de fois qu'ils sont apparus ensemble dans une fenêtre contextuelle(Context Window).

Fenêtre contextuelle(Context Window)- La fenêtre contextuelle est spécifiée par un nombre et la direction.
Comment former la matrice de co-occurrence :

- La matrice A stocke les cooccurrences de mots.
- Dans cette méthode, nous comptons le nombre de fois où chaque mot apparaît dans une fenêtre d'une taille particulière autour du mot d'intérêt.
- Calculez ce nombre pour tous les mots du corpus

•Avantages de la matrice de co-occurrence :

Il préserve la relation sémantique entre les mots. c'est-à-dire que l'homme et la femme ont tendance à être plus proches que l'homme et la pomme.Il utilise SVD en son sein, qui produit des représentations vectorielles de mots plus précises que les méthodes existantes. Il utilise la factorisation qui est un problème bien défini et peut être résolu efficacement. être calculé une fois et peut être utilisé à tout moment une fois calculé. En ce sens, il est plus rapide par rapport aux autres.

•Inconvénients de la matrice de co-occurrence :

Il faut une énorme mémoire pour stocker la matrice de cooccurrence. Mais, ce problème peut être contourné en factorisant la matrice hors du système, par exemple dans des clusters Hadoop, etc. et peut être enregistré.

.

2.2.7 Prediction based Embedding

Jusqu'à présent, nous avons vu des méthodes déterministes pour déterminer les vecteurs de mots. Mais ces méthodes se sont avérées limitées dans leurs représentations de mots jusqu'à ce que Mitolov etc. el introduise word2vec à la communauté NLP. Ces méthodes étaient basées sur la prédiction en ce sens qu'elles fournissaient des probabilités aux mots et se révélaient être à la pointe de la technologie pour des tâches telles que les analogies de mots et les similitudes de mots. Ils ont également pu accomplir des tâches comme King -man + woman = Queen, ce qui était considéré comme un résultat presque magique. Regardons donc le modèle word2vec utilisé à ce jour pour générer des vecteurs de mots.Il y a deux approches prédicatives, qui sont CBOW(Continuous Bag of words) et Skip-gram. Ces deux réseaux sont des réseaux neuronaux peu profonds qui mappent le (s) mot (s) à la variable cible qui est également un ou des mots. Ces deux techniques apprennent des poids qui agissent comme des représentations vectorielles de mots. Discutons séparément de ces deux méthodes et acquérons de l'intuition dans leur fonctionnement.

2.2.7.1 CBOW

La fausse tâche dans CBOW est quelque peu similaire à Skip-gram, en ce sens que nous prenons toujours une paire de mots et enseignons au modèle qu'ils co-surviennent, mais au lieu d'ajouter les erreurs, nous ajoutons les mots d'entrée pour le même mot cible.

La dimension de notre couche cachée et de la couche de sortie restera la même. Seule la dimension de notre couche d'entrée et le calcul des activations de couche cachée changeront, si nous avons 4 mots de contexte pour un seul mot cible, nous aurons 4 vecteurs d'entrée 1xV. Chacun sera multiplié par la couche cachée VxE renvoyant des vecteurs 1xE. Les 4 vecteurs 1xE seront moyennés élément par élément pour obtenir l'activation finale qui sera ensuite introduite dans la couche softmax. l'architecture de l'approche CBOW est expliquée dans la figure 2.3

Avantages :

•Être probabiliste est la nature, elle est supposée être supérieure aux méthodes déterministes (en général).

•CBOW est plus rapide et représente mieux les mots fréquents.

•Il n'a pas besoin d'avoir d'énormes besoins en RAM comme celui de la matrice de cooccurrence où il doit stocker trois énormes matrices.

Inconvénients :

•CBOW prend la moyenne du contexte d'un mot.Par exemple, Apple peut être à la fois un fruit et une entreprise, mais CBOW prend une moyenne des deux contextes et la place entre un cluster pour les fruits et les entreprises.

•Entraîner un CBOW à partir de zéro peut prendre une éternité s'il n'est pas correctement optimisé.

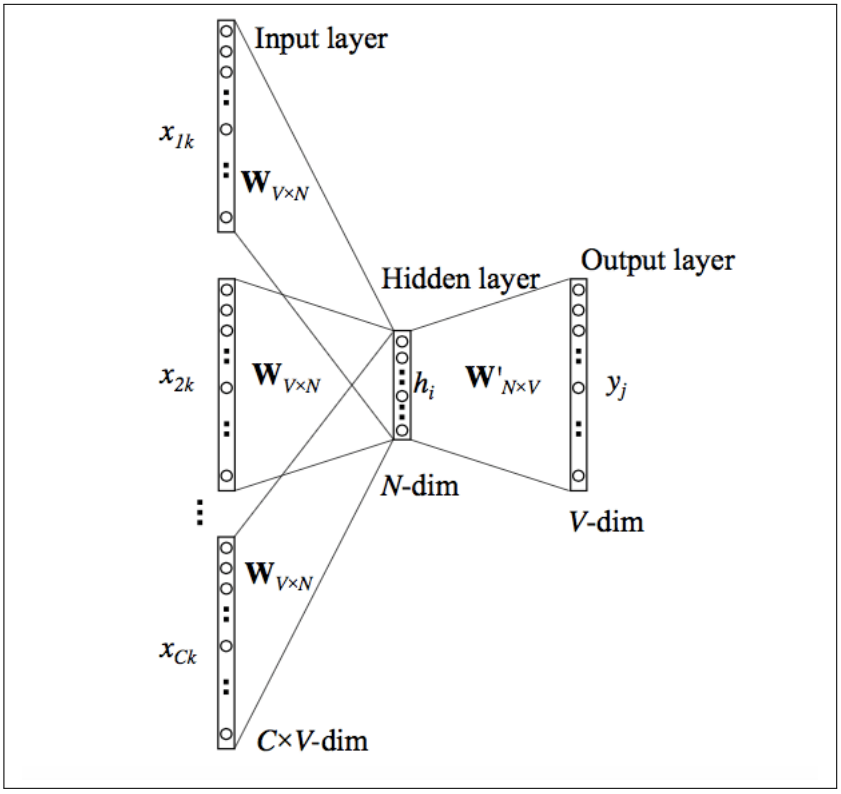


FIGURE 2.3 – Architecture de l'approche CBOW

2.2.7.2 Skip-gram

Skip - gram suit la même topologie que CBOW. Il renverse simplement l'architecture de CBOW. Le but de skip-gram est de prédire le contexte donné à un mot.
Par exemple, dans la phrase «I have a cute dog». Si l'entrée est «cute» alors la sortie est «I», «have», «a», «dog» en supposant une taille de fenêtre de 5.
Comme le montre la figure 2.4, la couche d'entrée a un vecteur de mot «one hot encoded» donné en entrée. La taille du calque(couche) masqué est égale à la taille de l'incorporation. Alors que la couche de sortie est un mot de contexte encodé à chaud. Les vecteurs sont «significatifs» en termes de description de la relation entre les mots. Le vecteur obtenu en soustrayant deux mots apparentés exprime parfois un concept significatif tel que le genre ou le temps du verbe.
Avantages :
•Le modèle Skip-gram peut capturer deux sémantiques pour un seul mot. c'est-à-dire qu'il aura deux représentations vectorielles d'Apple. Un pour l'entreprise et un autre pour le fruit..
•Le skip-gramme avec sous-échantillonnage négatif surpasse généralement toutes les autres méthodes.
•fonctionne bien avec une petite quantité de données d'entraînement, représente bien même des mots ou des phrases rares.
Inconvénients de Skip-gram :
•Pour cet algorithme la fonction Softmax est coûteuse en calcul..
•Le temps requis pour entraîner cet algorithme est élevé.

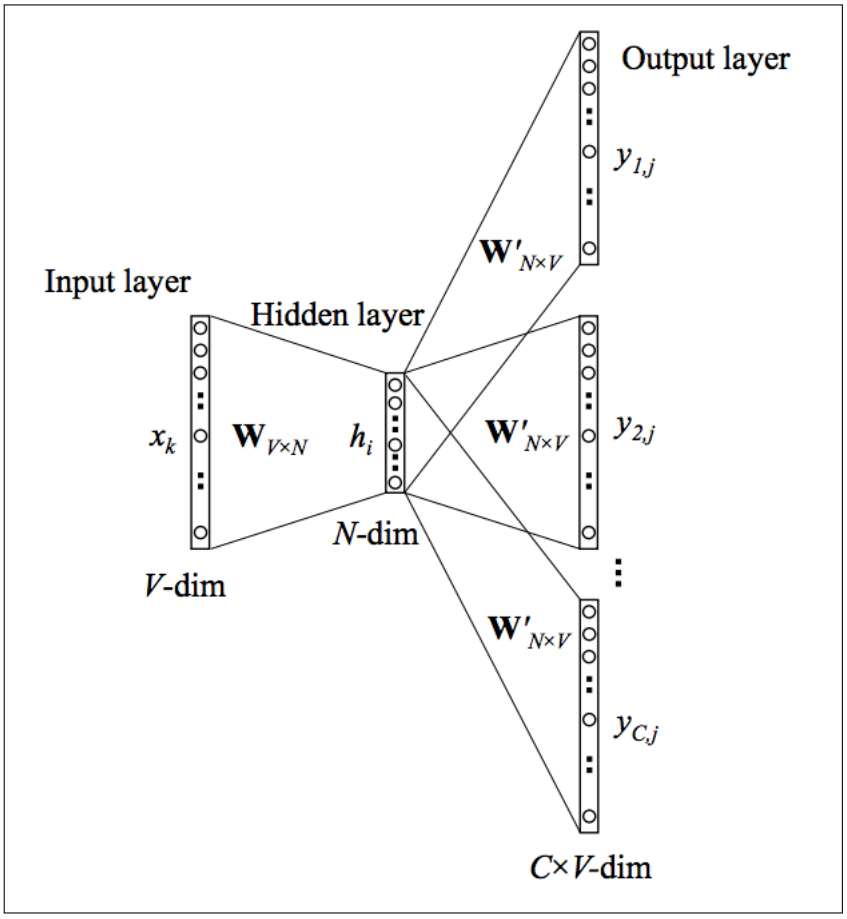


FIGURE 2.4 – Architecture de l'approche Skip-gram

2.2.7.3 Word2Vec

Word2vec est un groupe de modèles associés qui sont utilisés pour produire des embeddings de mots.Word2vec was created and published in 2013 by a team of researchers led by Tomas Mikolov at Google. Word2vec représente des mots dans une représentation d'espace vectoriel. Les mots sont représentés sous forme de vecteurs et le placement est fait de telle manière que des mots de sens similaire apparaissent ensemble et que des mots différents sont situés loin. Ceci est également appelé une relation sémantique. Les réseaux de neurones ne comprennent pas le texte mais ne comprennent que les nombres. L'incorporation de mots fournit un moyen de convertir du texte en vecteur numérique.[3] Word2vec reconstruit le contexte linguistique des mots. Avant d'aller plus loin, comprenons, qu'est-ce que le contexte linguistique ? Dans un scénario de vie général, lorsque nous parlons ou écrivons pour communiquer, d'autres personnes essaient de comprendre quel est l'objectif de la phrase. Par exemple, "Quelle est la température de l'Inde", ici le contexte est que l'utilisateur souhaite connaître la "température de l'Inde" qui est le contexte. En bref, l'objectif

principal d'une phrase est le contexte. Un mot ou une phrase entourant le langage parlé ou écrit (divulgation) aide à déterminer la signification du contexte. Word2vec apprend la représentation vectorielle des mots à travers les contextes.C'est un réseau neuronal à deux couches peu profond.Le réseau neuronal peu profond se compose de la seule couche cachée entre l'entrée et la sortie, tandis que le réseau neuronal profond contient plusieurs couches cachées entre l'entrée et la sortie. L'entrée est soumise à des nœuds tandis que la couche cachée, ainsi que la couche de sortie, contient des neurones.

2.3 Métriques de similarité

Le terme mesure de distance de similarité a une grande variété de définitions parmi les praticiens des mathématiques et de l'exploration de données. Cette similitude est un bloc de base d'apprentissage non supervisé comme la classification par clustering, etc. En NLP, nous voulons également trouver la similitude entre la phrase ou le document. L'état ou le fait d'être similaire ou de similarité mesure à quel point deux objets sont semblables. La mesure de similarité dans un contexte d'exploration de données est une distance dont les dimensions représentent les caractéristiques des objets. Si la distance est petite, deux objets sont très similaires où, comme si la distance était grande, nous observerons un faible degré de similitude.Nous passerons par 3 mesures de distance de base, qui sont :

- Jaccard Similarity
- Euclidean Distance
- Cosine Distance(similarity)

2.3.1 L'indice de Jaccard

L'indice de Jaccard, également connu sous le nom d'intersection sur l'Union et le coefficient de similitude de Jaccard, est une statistique utilisée pour évaluer la similitude et la diversité des ensembles d'échantillons. Le coefficient de Jaccard mesure la similitude entre des ensembles d'échantillons finis et est défini comme la taille de l'intersection divisée par la taille de l'union des ensembles d'échantillons.

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|} \tag{2.2}$$

2.3.2 Distance euclidienne

La distance euclidienne entre deux points dans le plan ou dans l'espace tridimensionnel mesure la longueur d'un segment reliant les deux points. C'est la manière la plus évidente de représenter la distance entre deux points.Le théorème de Pythagore peut être utilisé

pour calculer la distance entre deux points.

$$d\left(X,Y\right)=\sqrt{\sum_{i=1}^{n}\left(x_i-y_i\right)^2} \tag{2.3}$$

2.3.3 Cosine Similarity

La similarité cosinus est une métrique utilisée pour mesurer la similitude des documents, quelle que soit leur taille. Mathématiquement, il mesure le cosinus de l'angle entre deux vecteurs projetés dans un espace multidimensionnel. La similitude cosinus est avantageuse car même si les deux documents similaires sont éloignés de la distance euclidienne (en raison de la taille du document), il y a de fortes chances qu'ils soient encore orientés plus près l'un de l'autre. Plus l'angle est petit, plus la similitude cosinus est élevée comme c'est indiqué dans figure 2.5.
Cette métrique détermine l'angle entre deux objets est la méthode de calcul pour trouver la similitude. La plage de score est de 0 à 1.

$$\cos(\mathbf{A},\mathbf{B})=\frac{\mathbf{AB}}{\|\mathbf{A}\|\|\mathbf{B}\|}=\frac{\sum_{i=1}^{n}\mathbf{a}_i\mathbf{b}_i}{\sqrt{\sum_{i=1}^{n}\left(\mathbf{a}_i\right)^2}\sqrt{\sum_{i=1}^{n}\left(\mathbf{b}_i\right)^2}} \tag{2.4}$$

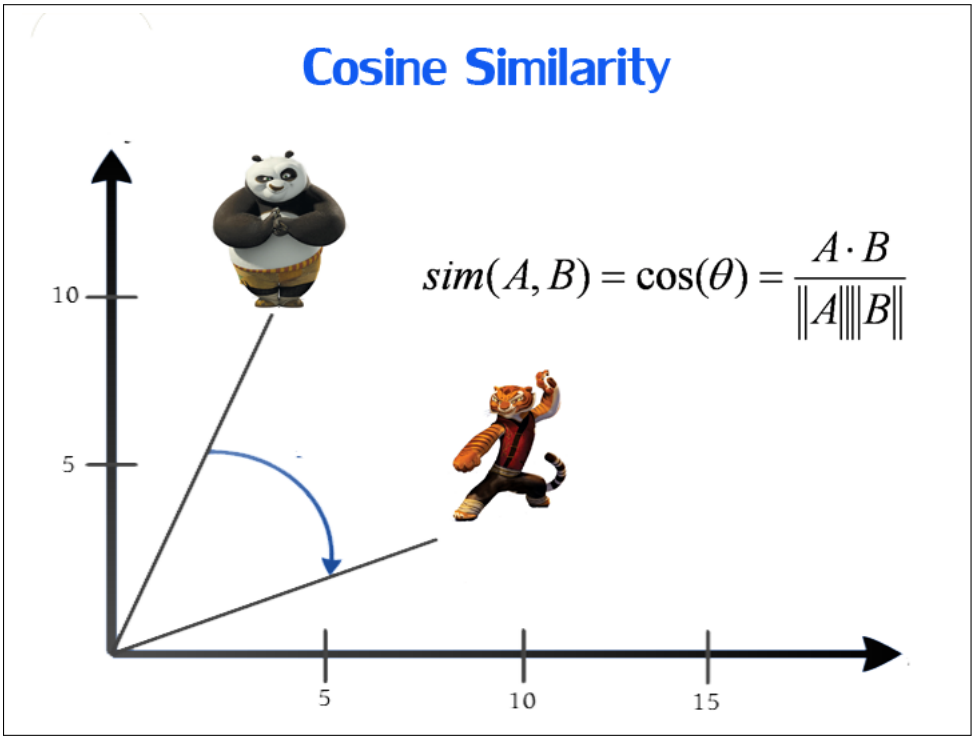


FIGURE 2.5 – La similarité cosinus

2.4 Conclusion

Dans ce chapitre, nous avons réalisé une étude théorique sur quelques parties du projet qui nécessitent des études préliminaires. Nous avons exposé brièvement quelques outils d'extraction d'informations suivis par des modèles de représentation des mots de texte . Toutes ces techniques vont nous servir à la réalisation d'un modèle linguistique .

Chapitre 3

Conception et implémentation du modèle de reconstruction des relations (sémantique ou syntaxique) entre les mots

3.1 Introduction

Cette partie présente le noyau de notre projet, nous allons développer un modèle linguistique capable de connaître et distinguer entre les différents mots techniques qui constituent un CV ou une annonce d'emploi et ce en suivant la méthodologie CRISP.

Mais avant d'entamer cette partie, il faut d'abord analyser le CV et extraire les informations nécessaires pour pouvoir faire le correspondance candidat/annonce d'emploi.

3.2 Architecture de processus intelligente globale

La figure 3.1 ci-dessous présente l'architecture globale de cette partie.Nous avons passé par toutes les étapes de la méthodologie CRISP, en utilisant 3 ensembles de données.Après l'évaluation, nous décidons quant au déploiement selon les performances obtenues.

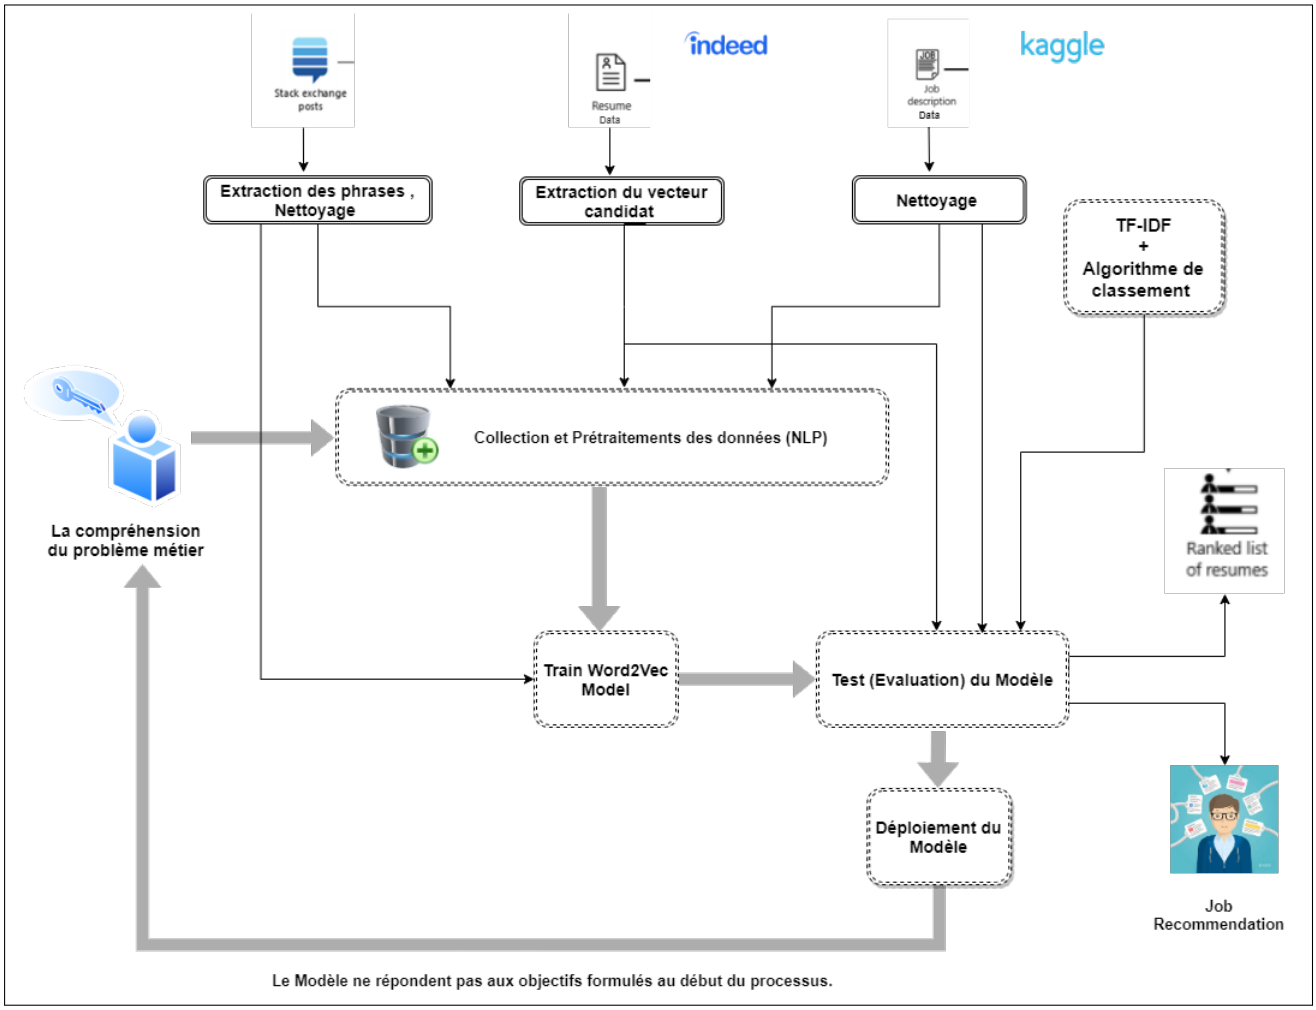


FIGURE 3.1 – Architecture globale de la solution intelligente

3.3 Analyse du CV et extraction des informations

L'objectif de cette partie est de transformer un CV ,en entrée, sous format PDF ou DOCX , en plein texte, puis d'extraire le vecteur candidat (7 champs) , en utilisant les différentes techniques du NLP.

3.3.1 Extraction du CV

Comme 1ère étape , nous allons convertir le CV sous format PDF ou DOCX en un fichier texte , contenant la totalité du contenu du CV. Nous utilisons la bibliothèque PDFMiner (nous pouvons utiliser PyPDF aussi mais PDFMiner a une plus grande précision dans l'extraction du texte, même s'il n'est pas encore parfait) pour traiter les documents PDF

et docx2txt (extraire également tout texte des tableaux ,les images...) pour les documents DOCX .

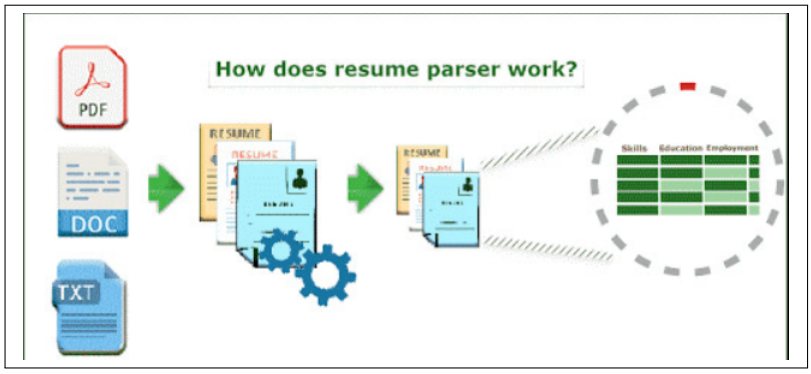


FIGURE 3.2 – Extraction et analyse du CV

3.3.2 Extraction et identification du Vecteur candidat

Chaque Candidat inscrit dans notre plateforme, sera présenté par un vecteur-candidat, qui contient 8 champs, dont 7 à extraire nous même, Pour ce faire, nous avons eu recours aux techniques d'extraction d'informations basées sur NLP à savoir la tokenisation, NER et les expressions régulières.

3.3.2.1 Extraction de l'émail et du numéro de téléphone

L'adresse électronique et le numéro de téléphone ont des "pattern" bien définis en eux-mêmes. Nous utiliserons donc des expressions régulières pour les extaire à partir des CV. Python a un package intégré appelé "re", nous a permis de manipuler les expressions régulières.

```
32
33 EMAIL_REGEX = r"[A-Z0-9._%+-]+@[A-Z0-9.-]+\.[A-Z]{2,4}"
34 PHONE_REGEX = r"([0-9]{2} )([0-9]{3} ){2}"
35 def term_match(string_to_search, term):
36
37     try:
38         regular_expression = re.compile(term, re.IGNORECASE)
39         result = re.findall(regular_expression, string_to_search)
40         if len(result) > 0:
41             return result[0]
42         else:
43             return None
44     except Exception:
45         logging.error('Error occurred during regex search')
46         return None
47
48 # ========================================================================
```

FIGURE 3.3 – Fonction d'expression régulière

3.3.2.2 Extraction du nom de candidat à partir du CV

Nous avons utilisés la bibliothèque SpaCy, précisément les tokens ayant comme label "PERSON" (voir en annexe A.1 la liste des labels disponibles dans cette bibliothèque) pour extraire le champ "nom" à partir du CV.
Nous avons pris les tokens qui ont comme label 'PERSON'. Ce label est donné à tous les noms propres dans le texte y inclus les noms de marques.S'ils sont plusieurs le premier est considéré comme l'identité du candidat.

3.3.2.3 Extraction et identification des sections du CV

Cette étape constitue une phase importante dans le processus d'extraction des informations à partir d'un CV puisqu'elle permet d'alimenter les quatre derniers champs du vecteur candidat.
Le contenu de chaque CV peut être divisé en 4 sections s , à savoir "Éducation", "Skills" , "Expérience" et "Extra".Pour la section "Extra" , elle regroupe les centres d'intérêt, les activités extra-curriculum etc .
Durant cette phase, nous avons utilisé la bibliothèque Spacy , "tokenization" , "stemming" ainsi que les fonctionnalités qui permettent de faire une étude de similarité (linguistique) entre les tokens.

L'approche utilisée pour identifier les 4 sections , passe par les étapes suivantes :
• Préparer, à priori, un dictionnaire contenant l'ensemble des mots les plus similaires et significatifs pour chaque section
• Itérer sur toutes les lignes de tous les CV, un par un.
• Pour chaque ligne, supprimer d'abord toutes les lignes vides ou les lignes contenant uniquement des symboles. Certains CV ont une ligne désignée par des astérisques ou des tirets.

• Ensuite, catégoriser chaque ligne dans l'une des quatre sections. Cela se fait en calculant sa similitude avec les mots existants. Si la similitude est supérieure au seuil (=06), nous mettons à jour la section et marquons ce point, en revanche, si la similitude est inférieure au seuil, nous continuons avec la section précédente.

3.3.2.4 Évaluation de l'extraction

Pour tester la performance des techniques d'extraction du vecteur candidat , nous avons appliqué ces bouts de codes sur un ensemble des CVs (150 candidat).
Concernant l'extraction des numéros de téléphones et des e-mails , nous avons arrivé à les extraire parfaitement .Pour le nom du candidat , nous avons réussi même à extraire des noms tunisiens (quoique "spacy model" ait un vocabulaire de base en anglais).
En ce qui concerne, le reste des champs , les 4 sections , nous avons obtenu des résultats acceptables pour un 1ère essai, surtout que cette tâche est encore le sujet de beaucoup de recherches récentes, et les chercheurs n'arrivent pas encore à trouver un algorithme performant permettant de délimiter parfaitement les sections d'un CV.

	.DS_Store	cv1	cv10	cv100	cv101	cv102	cv103	cv104	cv105	cv106	...	cv90
extra	□bud1□□□%...	mahboob alam \n software developer - dynamix i...	deepali chaudhari \n mumbai , maharashtra \n	ramakrishnan k \n cuddalore , tamil nadu \n mc...	jayaprakash andamuthu \n application developer...	rajeev gupta \n additional information \n * se...	alaguraj ramachandran \n android application d...	aiswarya chandrasekaran \n application develop...	ashay jain \n application developer \n bhopal ...	heena patel \n surat , gujarat \n contribute o...	...	karthikeyan p \n â□¢ link end datum tool end ....
exp		-PRON- want work progressive organization -PRO...	work experience \n team member(software develo...	-PRON- hard worker , enthusiastic , responsibl...	â□¢ with good knowledge develop application an...	* currently work cognizant technology solution...	work experience \n application application dev...	â□¢ good communication interpersonal skill eas...	â□¢ currently work application developer atos ...	work experience \n iphone application develope...	...	senior research analyst relationship science (...
skill		skill \n html5 (2 year) , css3 (2 year) , ...	be information technology \n nagpur university...	skill \n communication skills . \n fast learne...	b.sc computer technology \n diploma informatio...	application developer - cognizant technology s...	skill \n â□¢ operating system : windows 10 ubu...	â□¢ primary skill constitute cobol , jcl , db2...	â□¢ expertise java , groovy language related f...	to pursue growth experience field information ...	...	â□¢ validate information give island (factset...
edu		education \n pg - diploma advance software dev...	education \n	education \n be \n dhanalakshmi srinivasan col...	education \n kongu arts science college erode ...	education \n b.e. engineering \n bengal engine...	education \n b.e computer science engg \n vel ...	education \n bachelor of engineering electroni...			...	education \n bachelor engineering computer sci...

FIGURE 3.4 – Résultat d'extraction des 4 sections à partir de 150 CV

3.4 Implémentation du modèle de matching CV/annonce de travail

Cette partie présente le coeur de notre projet , elle consiste à implémenter un modèle intelligent capable en quelques sorte de remplacer l'être humain, pour arriver à trouver les profils les plus adéquats pour une offre , et de recommander aux candidats les opportunités de travail qui correspondent le plus avec eux . Pour ce faire, nous allons suivre les différentes phases de la méthodologie CRISP, détaillées dans les prochaines étapes.

3.4.1 La compréhension du problème métier

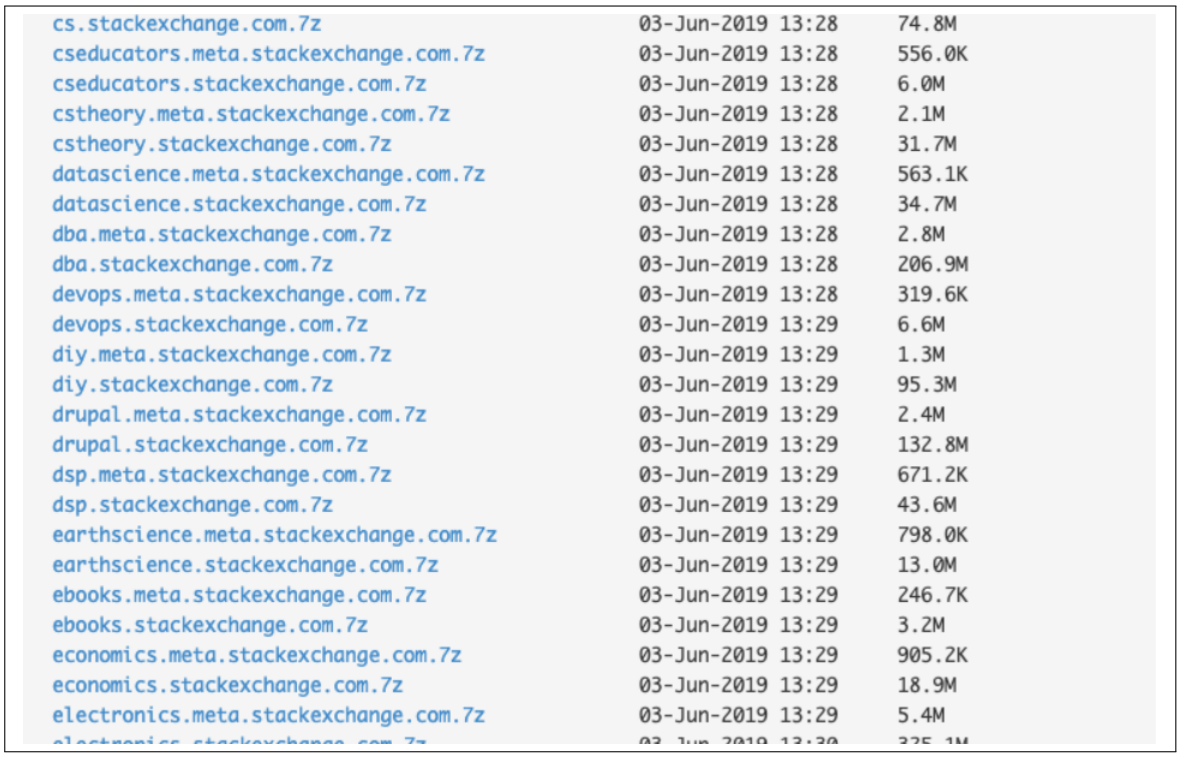
Durant cette phase, nous avons fixé les besoins et les objectifs du projet. Pour construire le modèle "words embeddings", il est vraiment important de disposer d'une grande quantité de données afin d'obtenir des résultats aussi précis que possible.
De plus , nous avons lu encore sur les cas d'utilisations du modèle word2vec pour mieux comprendre la nature des données à collecter dans la phase suivante . Donc l'objectif c'est d'implémenter un modèle capable de maintenir une relation sémantique pour le cas spécifique de classement les candidats et recommandation d'emplois .

3.4.2 La compréhension des données

Durant cette phase , nous avons besoin de 3 datasets pour pouvoir entraîner et tester notre modèle dans le deux sens (classement des CVs et job recommandation). En tous nous avons utilisé 3 ensembles de données .

1. **StackExchange Network Posts Data**
   Cet ensemble de données est nécessaire pour former le modèle word2vec.
   Il s'agit d'un corpus anonyme de tout le contenu fourni par les utilisateurs sur le réseau Stack Exchange.
   Chaque site est formaté comme une archive distincte composée de fichiers XML compressés via 7-zip à l'aide de la compression bzip2.
   Avec plus que 360 archives, chacune contient des informations et des publications dans le réseau Stack-exchange sur un domaine de compétences et d'expertise. On peut citer une archive pour "software engineering" ,une pour "data-science" , autre pour "electronics" etc.
   Une autre point fort de notre ensemble de données , qu'elle couvre différents axes :
   • archives des beaucoup de langues comme "spanish" ,"korean" etc.
   • archives des thèmes générales tels que "chess" , "astronomy" , "gaming" etc .

Chaque archive de site comprend : les publications, les utilisateurs, les votes, les commentaires, l'historique des messages et les liens postaux (tous dans le format .xml).
Nous allons nous intéresser seulement aux fichiers "Posts.xml" , puisqu'ils contiennent des Plain texts ou textes bruts, qui présente le corpus de notre modèle, surtout que chaque sous-domaine est séparé à part dans une archive.



cs.stackexchange.com.7z	03-Jun-2019 13:28	74.8M
cseducators.meta.stackexchange.com.7z	03-Jun-2019 13:28	556.0K
cseducators.stackexchange.com.7z	03-Jun-2019 13:28	6.0M
cstheory.meta.stackexchange.com.7z	03-Jun-2019 13:28	2.1M
cstheory.stackexchange.com.7z	03-Jun-2019 13:28	31.7M
datascience.meta.stackexchange.com.7z	03-Jun-2019 13:28	563.1K
datascience.stackexchange.com.7z	03-Jun-2019 13:28	34.7M
dba.meta.stackexchange.com.7z	03-Jun-2019 13:28	2.8M
dba.stackexchange.com.7z	03-Jun-2019 13:28	206.9M
devops.meta.stackexchange.com.7z	03-Jun-2019 13:28	319.6K
devops.stackexchange.com.7z	03-Jun-2019 13:29	6.6M
diy.meta.stackexchange.com.7z	03-Jun-2019 13:29	1.3M
diy.stackexchange.com.7z	03-Jun-2019 13:29	95.3M
drupal.meta.stackexchange.com.7z	03-Jun-2019 13:29	2.4M
drupal.stackexchange.com.7z	03-Jun-2019 13:29	132.8M
dsp.meta.stackexchange.com.7z	03-Jun-2019 13:29	671.2K
dsp.stackexchange.com.7z	03-Jun-2019 13:29	43.6M
earthscience.meta.stackexchange.com.7z	03-Jun-2019 13:29	798.0K
earthscience.stackexchange.com.7z	03-Jun-2019 13:29	13.0M
ebooks.meta.stackexchange.com.7z	03-Jun-2019 13:29	246.7K
ebooks.stackexchange.com.7z	03-Jun-2019 13:29	3.2M
economics.meta.stackexchange.com.7z	03-Jun-2019 13:29	905.2K
economics.stackexchange.com.7z	03-Jun-2019 13:29	18.9M
electronics.meta.stackexchange.com.7z	03-Jun-2019 13:29	5.4M

FIGURE 3.5 – Stack-exchange DataSet

2. **Ensemble de données des CVs**
   Cet ensemble de données permet de tester le modèle word2vec . Parmi ces CV, ceux les plus adéquats pour une offre d'emploi vont être sélectionnés et classés selon leur score.
   Ainsi, un script Python (collectCV.py) a été utilisé pour collecter environ 300 curriculum vitae de candidats ayant postulé à des postes de "Développeur logiciel" , "Data Scientist", "Développeur Web ", etc. Ces CVs sont scrappés à partir du site d'emploi indeed.com .
3. **Ensemble de données des annonces d'emploi**
   Cet ensemble de données permet lui aussi de tester le modèle word2vec . Ces annonces d'emploi constituent la base du filtrage et classement des CVs.
   C'est un ensemble de données de Kaggle contenant plus de 5000 offres d'emploi.C'est un fichier csv contenant 2 colonnes, "job-title" et "job description" .

3.4.3 Préparation et pré-traitement des données

Une fois toutes nos données sont prêtes, c'est primordiale maintenant de les pré-traiter et les rendre compatibles à notre cas d'utilisation en supprimant les informations inutiles .
• Concernant l'ensemble de données des CVs, pas de pré-traitement spéciale à faire vu que tous les CVs passeront par notre code d'extraction de CV (chapitre 3.2) pour extraire le vecteur candidat, là chaque CV subit les pré-traitements nécessaires déjà mentionnées (tokenization, lemmatization , suppression des stop-words...).
•En ce qui concerne les annonces d'emploi, importées du site web Kaggle, une communauté en ligne de scientifiques des données et de praticiens de l'apprentissage automatique, nous allons utiliser NLP (Spacy model, lemmatization, suppression des mots non significatifs pour filtrer les descriptions de poste liées à l'industrie informatique.

• La partie pertinente du pré-traitement, a été appliquée sur l'ensemble des données dédié pour entraîner le modèle. Surtout qu'il faut arriver à avoir une Dataset nettoyée ,de valeur, compréhensible et compatible avec le modèle. Dans une 1ère étape, nous avons nettoyé les fichiers "Posts.xml" de chaque archive, nous avons utilisé la méthode "parse" de la classe "ElementTree" de la bibliothèque "xml.etree" dédiée spécialement pour traiter les fichiers XML. Nous lisons ensuite le contenu de l'archive et l'analysons à l'aide d'un objet de la classe "BeautifulSoup". Stack-exchange stocke le contenu textuel de l'archive dans des balises "Body" contenu lui même dans "row/balise". Nous utilisons la fonction "findall" de l'objet "BeautifulSoup" pour récupérer tout le contenu des balises "Body". Dans une 2ème étape, nous convertissons tout le texte en minuscules, puis supprimons tous les chiffres, caractères spéciaux et espaces supplémentaires du texte. Après le pré-traitement, il ne nous reste plus que les mots. Le modèle Word2Vec est formé sur une collection de mots. Tout d'abord, nous devons convertir notre données en phrases.
Donc, Nous lisons ensuite le contenu de nos fichiers "paras.txt" et l'analysons à l'aide d'un objet de la classe "BeautifulSoup", divisons ces paragraphes sans balise en phrases appropriées en utilisant NLP (spacy). Comme dernière étape de pré-traitement, nous supprimons tous les mots vides du texte.

Finalement, nous nous sommes amusés avec les données pour extraire quelques informations et statistiques de notre corpus , tels que le nombre des mots totale , nombre des phrases , nombre des phrases pour chaque longueur comme le montre la figure 3.6 .

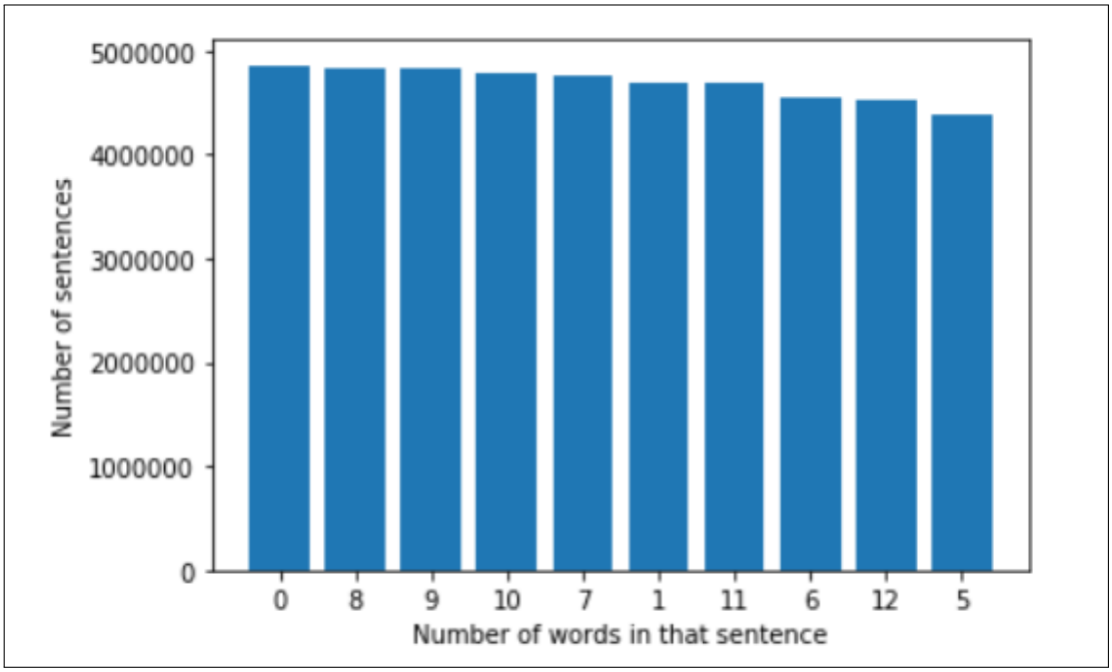


FIGURE 3.6 – Nombre des phrases par longueur

3.4.4 La modélisation

À la suite de l'étude préliminaire, le modèle choisi pour cette partie est Word2Vec, un algorithme qui prend un corpus comme entrée et le produit sous la forme de vecteurs.

3.4.4.1 Architecture de Word2Vec

Il existe deux architectures utilisées par word2vec :

- CBOW
- Skip-gram

Avant d'aller plus loin, expliquons pourquoi ces architectures ou modèles sont importants du point de vue de la représentation des mots.
L'apprentissage de la représentation des mots est essentiellement non supervisé, mais des cibles / étiquettes sont nécessaires pour entraîner le modèle. Skip-gram et CBOW convertissent la représentation non supervisée en forme supervisée pour la formation du modèle. En CBOW, les mots voisins sont fournis en entrée pour prédire la cible. En d'autres termes, un contexte est fourni comme entrée pour prédire la cible. Par contre, Skip-gram est opposé / inverse de CBOW, dans lequel un mot cible est fourni en entrée afin de prédire les mots contextuels / voisins.

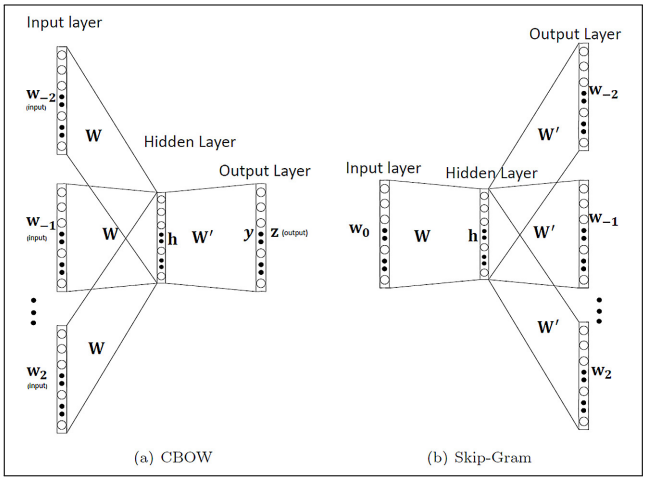


FIGURE 3.7 – Architecture du modèle Word2Vec

3.4.5 Les paramètres du modèle

Word2Vec accepte plusieurs paramètres qui affectent à la fois la vitesse et la qualité du "training".

- **sentences :**Les phrases itérables peuvent être simplement une liste de listes de jetons, mais pour les corpus plus grands, considérez un itérable qui diffuse les phrases directement à partir du disque / réseau.
- **size :** Dimensionnalité des vecteurs de mots.
- **window :** Distance maximale entre le mot actuel et le mot prédit dans une phrase.
- **min-count :** Ignore tous les mots dont la fréquence totale est inférieure à cela.
- **workers :** Utilisez ce nombre de threads de travail pour entraîner le modèle (= entraînement plus rapide avec des machines multicœurs).
- **sg(0,1) :** Algorithme du training : 1 pour skip-gram ; sinon CBOW, par défaut=0.
- **hs(0,1) :** Si 1, softmax hiérarchique sera utilisé pour la formation du modèle. Si 0 et négatif est différent de zéro, un échantillonnage négatif(negative sampling) sera utilisé.
- **negative :** Si> 0, un échantillonnage négatif sera utilisé, l'int pour négatif spécifie combien de «mots de bruit» doivent être dessinés (généralement entre 5 et 20). S'il est défini sur 0, aucun échantillonnage négatif n'est utilisé.
- **sample :** Le seuil pour configurer quels mots de fréquence plus élevée sont sous-échantillonnés aléatoirement, la plage utile est (0, 1e-5).
- **iter :** Nombre d'itérations (époques) sur le corpus.
- **hashfxn :** Fonction de hachage à utiliser pour initialiser aléatoirement les poids, pour une reproductibilité accrue de la formation.

```
In [7]:
# Set values for various parameters
#size = 300            # Word vector dimensionality
#min_count = 10        # Minimum word count
#workers = 4           # Number of threads to run in parallel
#window = 15          # Context window size
#sample = 1e-3         # Downsample setting for frequent words


model = gensim.models.Word2Vec(sentences,  workers=4, size=300, min_count = 1, window = 15, sample = 1e-3)
```

FIGURE 3.8 – Paramètres utilisés pour le modèle

Nous avons choisi la valeur de min-count 1 pour conserver la totalité des mots, vu que notre ensemble des données est bien spécifique, du coup tous les mots ont une relation directe ou indirecte avec le monde de compétences et mots techniques etc.
Dans les modèles utilisant de grands corpus et un nombre élevé de dimensions, le modèle skip-gram offre la précision globale la plus élevée et produit systématiquement la plus grande précision sur les relations sémantiques, ainsi que la précision syntaxique la plus élevée dans la plupart des cas. Cependant, le CBOW est moins coûteux en calcul et donne des résultats de précision similaires.

3.4.6 L'évaluation

L'entraînement du Word2Vec est une tâche non supervisée, il n'ya pas de bon moyen d'évaluer objectivement le résultat. L'évaluation dépend de notre cas d'utilisation. Donc pour évaluer notre modèle, nous avons testé différentes méthodes du classe Word2Vec de la bibliothèque gensim.models telles que "doesnt-match", "most-similar" et "similarity" autant des fois, en utilisant des vocabulaires dans le contexte de compétences et recrutement .Nous avons obtenu des bons résultats, notre modèle est capable même de différencier entre un langage et une framework, de connaître les mots qui pèsent le plus dans un CV selon le poste demandé.

- **model.similarity :** Calcule la similitude cosinus entre deux mots.
- **model.doesnt-match(liste) :**Quel mot de la liste donnée ne va pas avec les autres ?
- **model.most-similar(mot)[:N] :**Trouve les N mots les plus similaires à "mot". Dans la figure 3.9, nous affichons les 5 mots les plus similaires pour les deux mots "sql" et "hadoop".

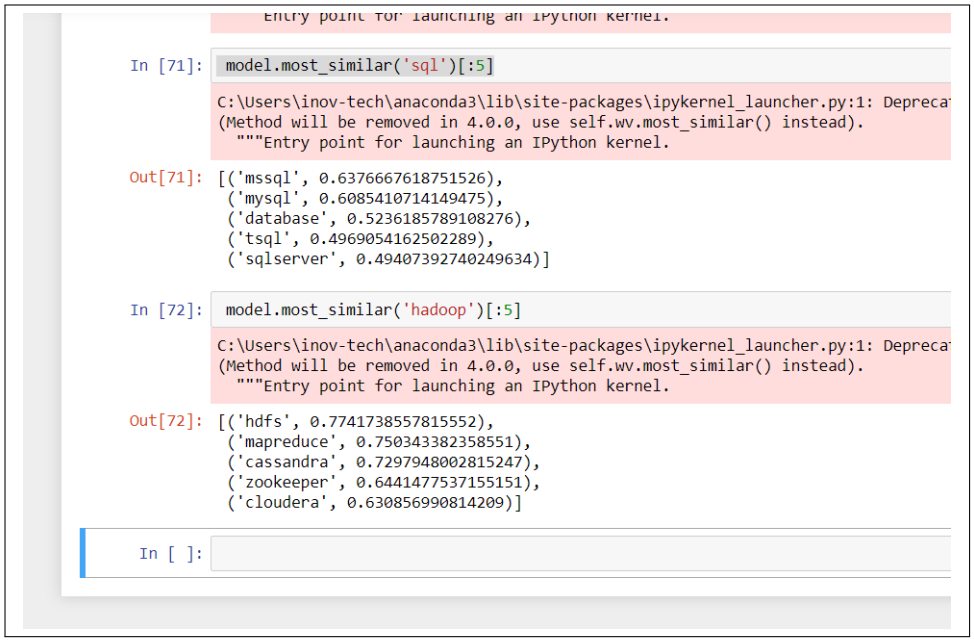


FIGURE 3.9 – Évaluation de modèle avec :most-similar

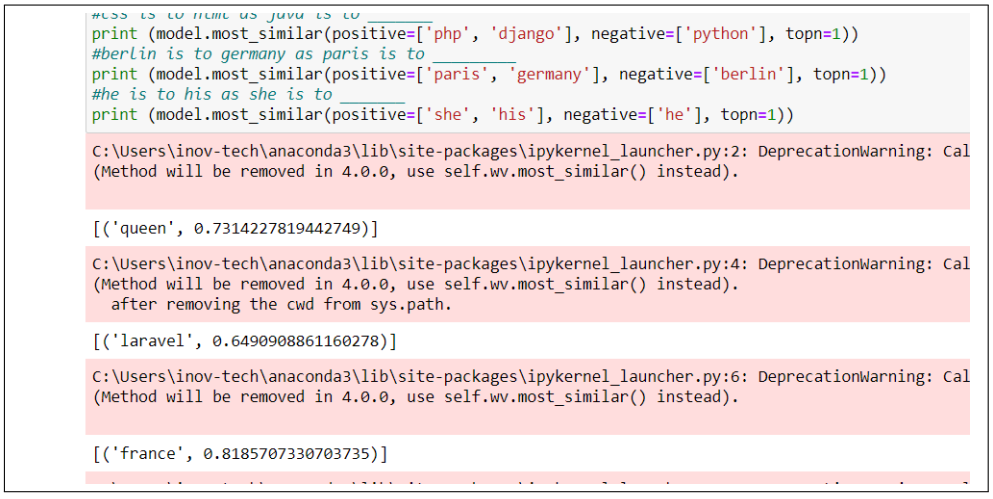


FIGURE 3.10 – Évaluation du modèle avec :most-similar with positive

Dans la figure 3.9, nous avons demandé à notre modèle quel sont les 5 mots les plus similaires aux mots "sql" et "hadoop". Le résultat est très acceptable, pour sql le modèle assume que les termes mssql, mysql, database, tsql et sql server sont les plus proches, et ça semble choquant ! nous arrivons à créer un modèle qui est capable d'identifier le sens des mots.Pour hadoop, le modèle répond par hdfs, mapreduce, cassandra, zookeeper et cloudera.
Pour la figure 3.10, la méthode utilisée va retourner les N mots les plus similaires. Les

mots positifs contribuent positivement à la similitude, les mots négatifs négativement.En lui donnant les mots "python", "django" et "php" le modèle nous retourne "laravel", donc ça nous donne : "Laravel pour PHP est comme django pour python". C'est extraordinaire, le modèle vient d'apprendre que "Laravel" est un framework php.

3.4.7 Le déploiement

Dans la phase de déploiement,nous allons intégrer ces deux moteurs intelligents dans notre application web.D'une part nous intégrons le système de classement des CVs dans l'espace entreprise pour offrir à l'entreprise la possibilité de classer des candidats selon une offre d'emploi précise.Donc ici le système prend en entrée l'offre de l'entreprise connectée et les CVs à partir du base de données après un premier filtrage.D'autre part,nous proposons dans l'espace candidat un système de recommandation d'emplois,basé aussi sur notre modèle Word2Vec et la technique TF-IDF, qui prend comme paramètres le vecteur-candidat du candidat connecté et des offres d'emploi filtrées à partir de la base de données.

3.5 L'algorithme de classement

Pour classer les CVs par rapport une annonce d'emploi, nous avons choisi d'utiliser la méthode TF-IDF.Comme déjà mentionné dans le chapitre 2, cette approche calcule l'importance d'un mot dans une collection des CVs. Les compétences demandées fréquents dans un CV mais pas dans tous les CVs ont tendance à avoir un score TF-IDF élevé.Donc ici,nous cherchons exactement les compétences qui font la différence entre les candidats et qui permettent d'avoir un score élevé. Notre algorithme de classement comprend principalement 4 étapes :

1. Pour une description d'emploi donnée, **supprimez tous les "stop words"** et effectuez une lemmatisation pour obtenir un corpus des mots sélectionnés.
2. Pour chaque mot-clé trouvé dans ce corpus (dans la description d'emploi), nous avons cherché **les 5 les plus mots similaires** et leur **similarité** correspondante en utilisant la méthode "most-similar".
3. Maintenant, trouver **TF-IDF** pour chaque mot, qui a été obtenu à l'étape 2.
4. Le score du CV est la somme des **TF-IDF *similarité** pour tous les mots générés à l'étape 2.

$$\text{tf-idf}_{t,d} = tf_{t,d} \cdot idf_t = tf_{t,d} \cdot \log \frac{N}{\text{df}_t} \tag{3.1}$$

•tf :term frequency of term t in the resume d
•N :total number of resumes

•df-t :number of resumes containing the term t

Prenons un exemple, supposons nous avons 10 CVs contenant tous le mot "Java", et que l'annonce d'emploi contient "Java" aussi comme compétence demandée. Donc ici **TF-IDF** du mot "java" vaut zéro (log(10/10)=log(1)=0). C'est logique, non ? Une compétence demandée mais qui existe chez tous les candidats ne pèse rien.

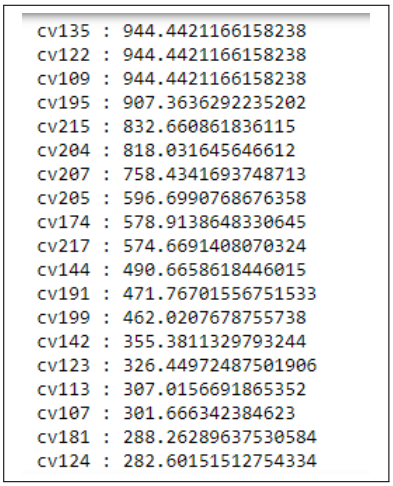


FIGURE 3.11 – Classement des CVs

3.6 Conclusion

Dans ce troisième chapitre, nous avons exposé de manière détaillée notre solution intelligente ; nous avons décrit comment extraires les informations pertinentes du CV, ainsi que le modèle et les différentes étapes de son implémentation. Finalement nous avons modélisé notre solution en présentant les résultats obtenus.

Chapitre 4

Étude et Conception de la Plateforme

4.1 Introduction

Ce chapitre mettra en évidence les différentes études et conceptions réalisées pour le développement de l'application Web pour synthétiser notre travail et arriver à développer un site d'emploi basé sur l'intelligence artificielle. Nous commençons alors par l'analyse des besoins suivie par l'étude de l'architecture globale de la plateforme pour enfin terminer par présenter la conception en diagrammes UML.

4.2 Analyses des besoins

La phase de spécification et d'analyse des besoins est une étape décisive dans la réalisation de notre projet. Dans cette section, nous commencerons par identifier les acteurs puis passerons à la spécification des besoins.

4.2.1 Identification des acteurs

Avant de passer à l'identification des besoins, il est essentiel dans le cycle de vie du développement logiciel de commencer par identifier les acteurs du système. Dans notre projet, nous avons trois acteurs :

- Le Candidat : C'est l'entité qui utilise notre application afin de chercher des offres de travail et postuler pour celles qui correspondent le mieux à son profil.
- L'entreprise : Elle publie les offres d'emploi pour recruter et chercher les meilleurs profils correspondants.
- L'administrateur : Son rôle est de gérer les paramètres de l'application et la gestion des comptes utilisateurs ainsi que la gestion de l'alimentation du site d'emploi par

les offres d'emploi et les profils à partir des autres sites d'emploi (Indeed , Linkedin , Monster ...).

4.2.2 Les besoins fonctionnels

L'application doit fournir un ensemble de fonctionnalités répondant aux besoins des utilisateurs. Dans ce qui suit, elles seront détaillées en fonction des différents utilisateurs .

Un candidat doit pouvoir :

- Créer un compte ,importer son CV (Pdf ou Docx), modifier et valider l'extraction .
- Modifier son vecteur candidat à tout moment (e-mail , numéro de téléphone , expériences professionnels, compétences...) ou modifier le CV en important un autre.
- Visualiser toutes les offres d'emploi disponibles, chercher des annonces en utilisant les filtres (job-title , localisation , nom de l'entreprise) .
- Chercher les meilleures offres adéquates à son profil à travers le système de recommandation.
- Postuler pour toute offre d'emploi disponible sur la plateforme .
- Suivre l'état de ses candidatures, c-à-d consulter la liste des offres auxquelles il a postulé.
- Modifier ses paramètres (nom d'utilisateur , mot de passe) tout en respectant les normes de sécurité .

Une entreprise doit être capable de :

- Créer un compte ainsi que publier, modifier et supprimer une offre d'emploi .
- Modifier ses coordonnées métier (numéro de téléphone ,localisation ,domaine d'expertise..).
- Visualiser et consulter tous les CVs disponibles, chercher des profils en utilisant les filtres (compétences , CV-field) .

- Suivre l'état de ses annonces publiées en consultant la liste des candidatures reçues pour chaque annonce.

- Chercher les meilleurs profils adéquats aux postes publiés à travers la solution de classement des candidats.

- Modifier ses paramètres (nom d'utilisateur, mot de passe) tout en respectant les normes de sécurité .

Un administrateur doit être en mesure de :

- Gérer les comptes d'utilisateurs , les CVs ainsi que les annonces publiées .

- Contrôler et effectuer le "web crawling" des offres d'emploi à partir des autres sites (Indeed , linkedin ...).

4.2.3 Les besoins non fonctionnels

Les besoins non fonctionnels concernent les contraintes à prendre en considération pour mettre en place une solution adéquate aux attentes des clients. Le système doit garantir les besoins opérationnels suivants :

- **Convivialité :** L'application doit être facile à utiliser. En effet, les interfaces utilisateurs doivent être conviviales c-à-d simples, ergonomiques et adaptées à l'utilisateur.

- **Compatibilité :** Application compatible avec différents navigateurs.

- **Maintenabilité :** La capacité de l'application à être maintenue, de manière cohérente et à moindre coût, en état de fonctionnement.

- **Rapidité :** Cela signifie que les opérations doivent avoir un temps minimal pour être exécutées et que les visualisations doivent également avoir un temps minimal pour rendre une vue dans le navigateur.

- **Extensibilité :** L'application doit permettre à tout moment l'ajout d'autres modules.

4.3 Architecture globale de la solution

La figure 4.1, présente l'architecture globale de notre plateforme. Nous présentons les différents systèmes de base, le système de recommandation, le système de classement des candidats ainsi que le système de scraping. Nous avons négligé ici les autres fonctionnalités de base telles que consulter les candidatures, postuler à une offre, modifier les champs du vecteur candidat, modifier une offre, etc.

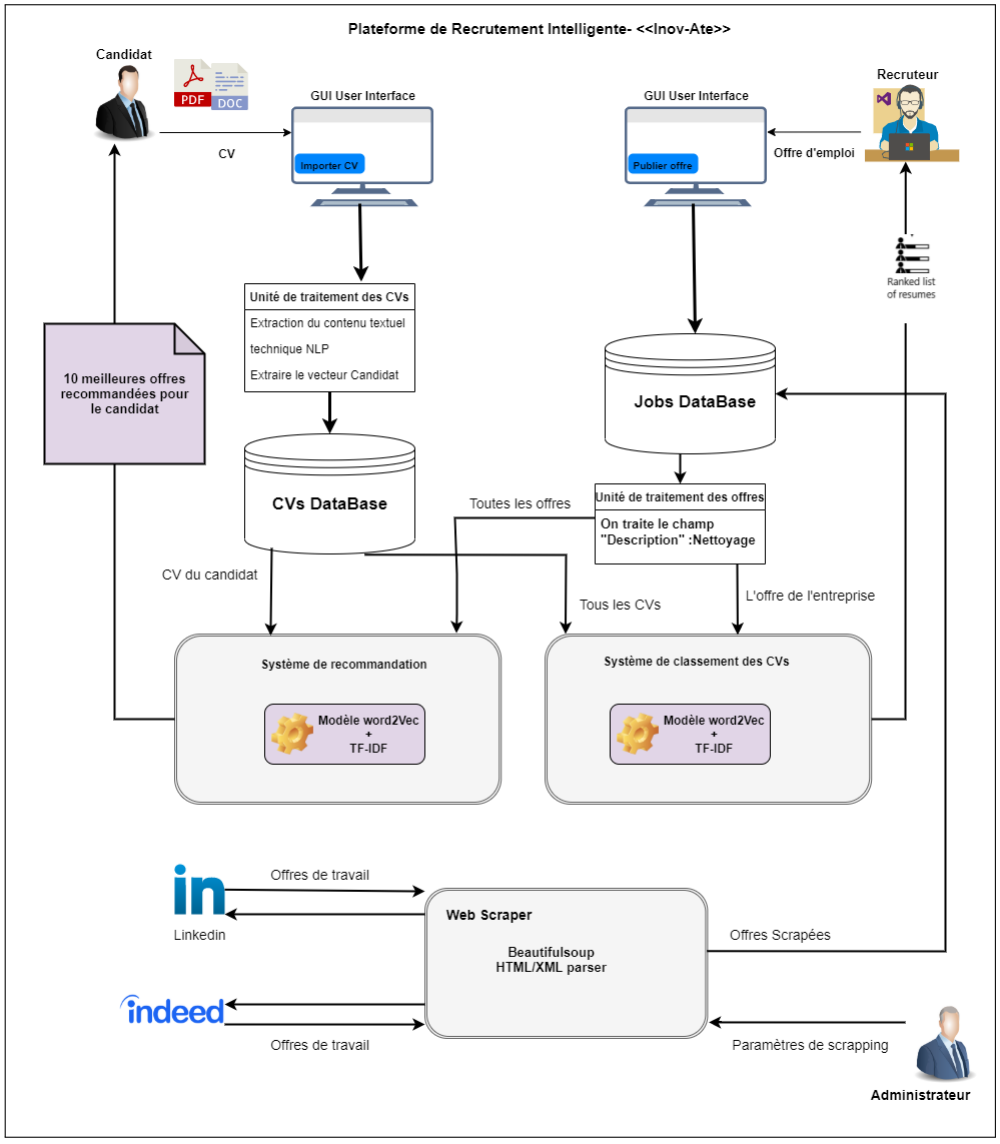


FIGURE 4.1 – Architecture globale de la plateforme

4.4 Conception et modélisation UML

En partant des analyses des besoins, cette section entame la phase de conception de notre application "Inov-Ate". L'objectif de cette phase est de concevoir le modèle de la solution.
La modélisation UML (Unified Modeling Langage) est utilisée pour spécifier, visualiser, modifier et construire les documents nécessaires au bon développement d'un logiciel orienté objet.

4.4.1 Diagramme des cas d'utilisation

Après la définition de nos acteurs et pour illustrer les fonctionnalités offertes par notre application, nous avons opté pour le diagramme de cas d'utilisation.
En langage UML, les diagrammes de cas d'utilisation décrivent les fonctions générales et la portée d'un système. Ces types de diagrammes sont des vues statiques qui présentent les fonctionnalités d'un système. Nous exprimons dans ces diagrammes les besoins des utilisateurs de l'application vis-à-vis de l'application.

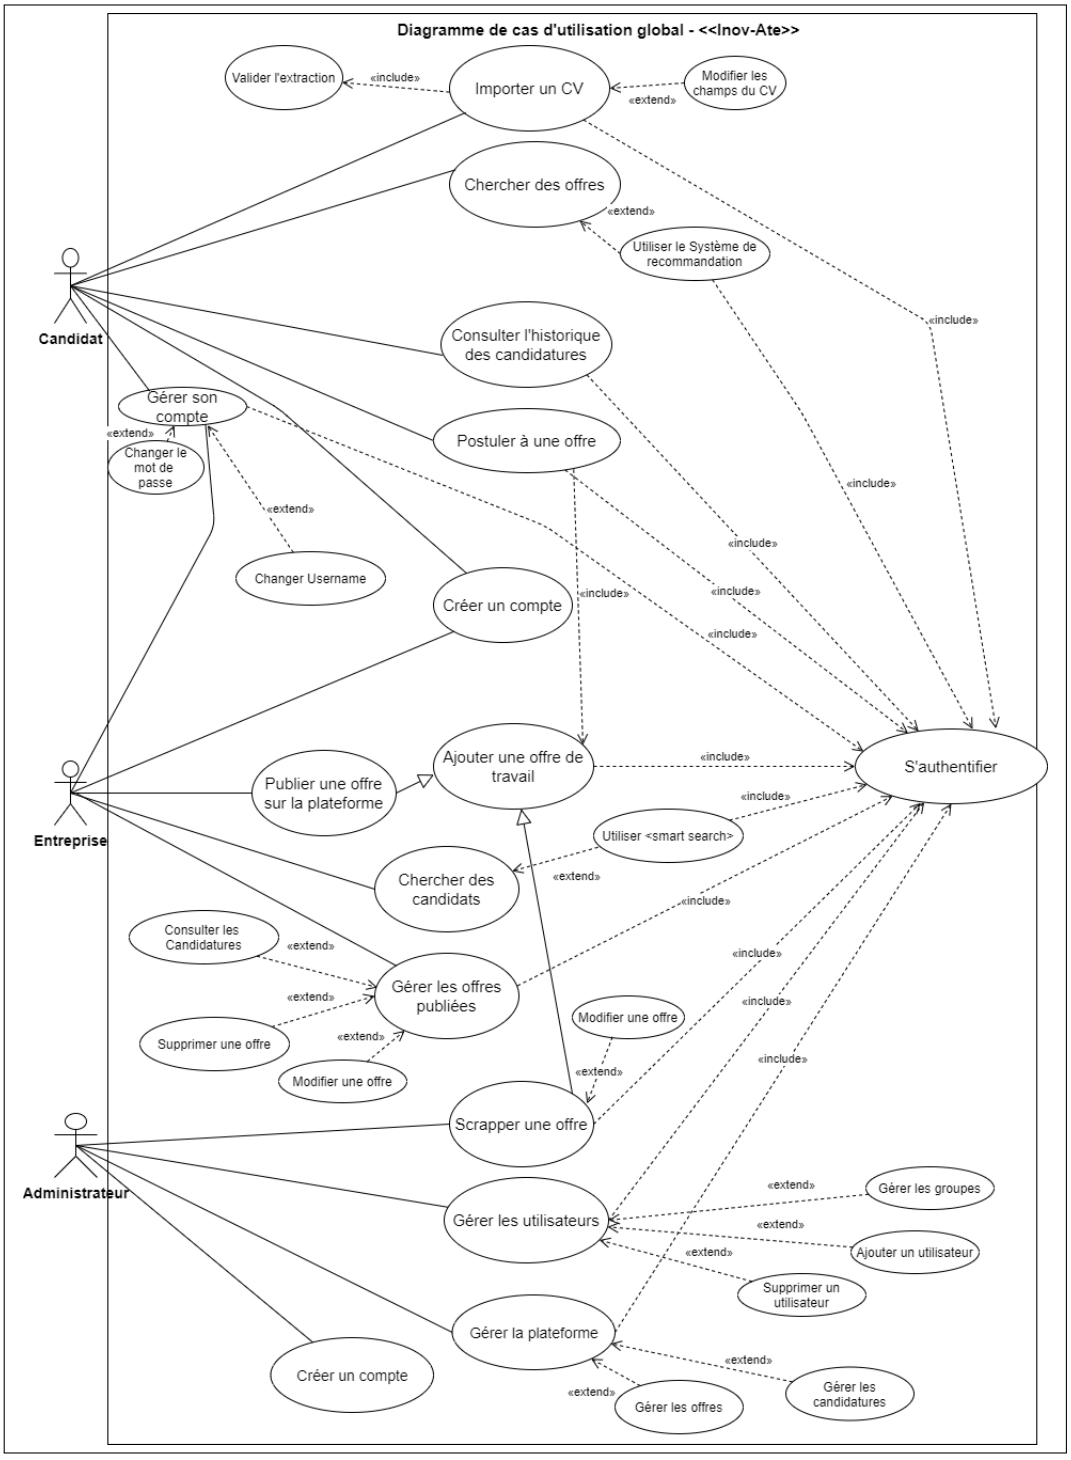


FIGURE 4.2 – Diagramme des cas d'utilisation global

La figure 4.2 montre tous les cas d'utilisations de notre plateforme .

- Pour assurer toutes ces fonctionnalités, il faut que l'utilisateur s'authentifie.
- L'ajout d'une offre (généralisation) se fait de deux manières ; soit une entreprise publie une offre (spécialisation) ou l'administrateur la scrape à partir d'autres sites (spécialisation).
- Pour qu'un CV soit importé sur la plateforme, le candidat doit valider l'extraction d'abord.
- L'administrateur peut gérer les candidatures, les CVs, les offres, les utilisateurs ainsi que les groupes et leurs permissions.
- Un candidat peut chercher des offres (à travers les filtres), comme il peut utiliser aussi le système de recommandation pour faciliter la recherche d'emplois.
- Une Entreprise peut chercher les candidats (à travers les filtres), comme elle peut aussi utiliser "smart search" pour trouver les meilleurs profils plus rapidement.

4.4.2 Description textuelle des cas d'utilisation

La description textuelle des cas d'utilisation permet de clarifier leurs déroulement et d'indiquer d'éventuelles contraintes. Dans ce qui suit, nous présentons les descriptions textuelles de quelques cas d'utilisation.

4.4.2.1 Cas d'utilisation : Authentification

Cas d'utilisation	S'authentifier
Acteur	Candidat
Pré-conditions	• Le candidat existe dans la base de données. • Le candidat remplit le formulaire d'inscription avec toutes les informations nécessaires.
Post-conditions	Le candidat est connecté avec succès.
Scénario nominal	1. Le candidat remplit les champs nom d'utilisateur et mot de passe. 2. Le candidat clique sur le bouton "Login". 3. Le système vérifie si le candidat existe ou non. 4. Le système renvoie un message de confirmation et redirige le candidat vers la page d'accueil.
Scénario alternatif	**A1.** Le candidat n'existe pas dans la base de données : **A1.4.** Le système renvoie un message de type "Le nom d'utilisateur ou Le mot de passe est incorrect".

TABLE 4.1 – Description textuelle du Cas d'utilisation : s'authentifier

4.4.2.2 Cas d'utilisation : Ajouter une offre d'emploi

Cas d'utilisation	Ajouter une offre d'emploi
Acteur	Entreprise
Pré-conditions	L'entreprise est connectée.
Post-conditions	• L'offre existe dans la base de données. • L'entreprise remplit le formulaire d'ajout d'une offre avec toutes les informations nécessaires.
Scénario nominal	1. L'entreprise clique sur le bouton "Post a Job". 2. L'entreprise remplit les champs "Job-title","Job-field","location" et "Description". 3. L'entreprise clique sur le bouton "Post". 4. Le système vérifie si l'entreprise a rempli les champs obligatoires. 5. Le système valide l'opération.
Scénario alternatif	**A1.** Un champ obligatoire qui manque : **A1.4.** Le système renvoie le message "Vous devez remplir les champs obligatoires" .

TABLE 4.2 – Description textuelle du Cas d'utilisation : Ajouter une offre d'emploi

4.4.2.3 Cas d'utilisation : Scraper une offre d'emploi

Cas d'utilisation	Scraper une offre d'emploi
Acteur	L'administrateur
Pré-conditions	• L'administrateur est connectée. • Aucune modification de la structure d'URL du site à partir duquel nous allons extraire.
Post-conditions	• L'offre existe dans la base de données. • L'administrateur vérifie bien que l'offre est collectée avec toutes les informations nécessaires.
Scénario nominal	1. L'administrateur clique sur le bouton "Scrape Jobs". 2. L'administrateur remplit les champs "Nombre de jobs à scraper","location" et "Keywords" . 3. L'administrateur clique sur le bouton "Scrape". 4. Le système vérifie si l'administrateur remplit les champs obligatoires. 5. L'administrateur vérifie les champs après le collecte en cas de doute.
Scénario alternatif	**A1.** L'administrateur remplit le champ "Keywords" par des mots incompréhensible par le site source : **A1.4.** Aucune offre trouvée et scrapée pour ces mots clés" .

TABLE 4.3 – Description textuelle du Cas d'utilisation : Scraper une offre d'emploi

4.4.3 Les diagrammes dynamiques

Les diagrammes dynamiques sont utilisés pour exprimer et modéliser le comportement du système dans le temps. Ils incluent la prise en charge des diagrammes d'activité, des diagrammes d'état, des diagrammes de séquence et des extensions, y compris la modélisation des processus métier.

4.4.3.1 Diagramme d'activité : consulter les candidatures

Un diagramme d'activité est un diagramme de comportement, c'est-à-dire qu'il décrit le comportement d'un système. Un diagramme d'activité représente le flux de contrôle d'un point de départ à un point d'arrivée montrant les différents chemins de décision qui existent pendant que l'activité est en cours d'exécution. Dans cette partie, nous présentons le diagramme d'activités de la cas d'utilisation consulter les candidatures , afin d'avoir une vue globale sur le comportement dynamique de notre système pendant cette fonctionnalité.

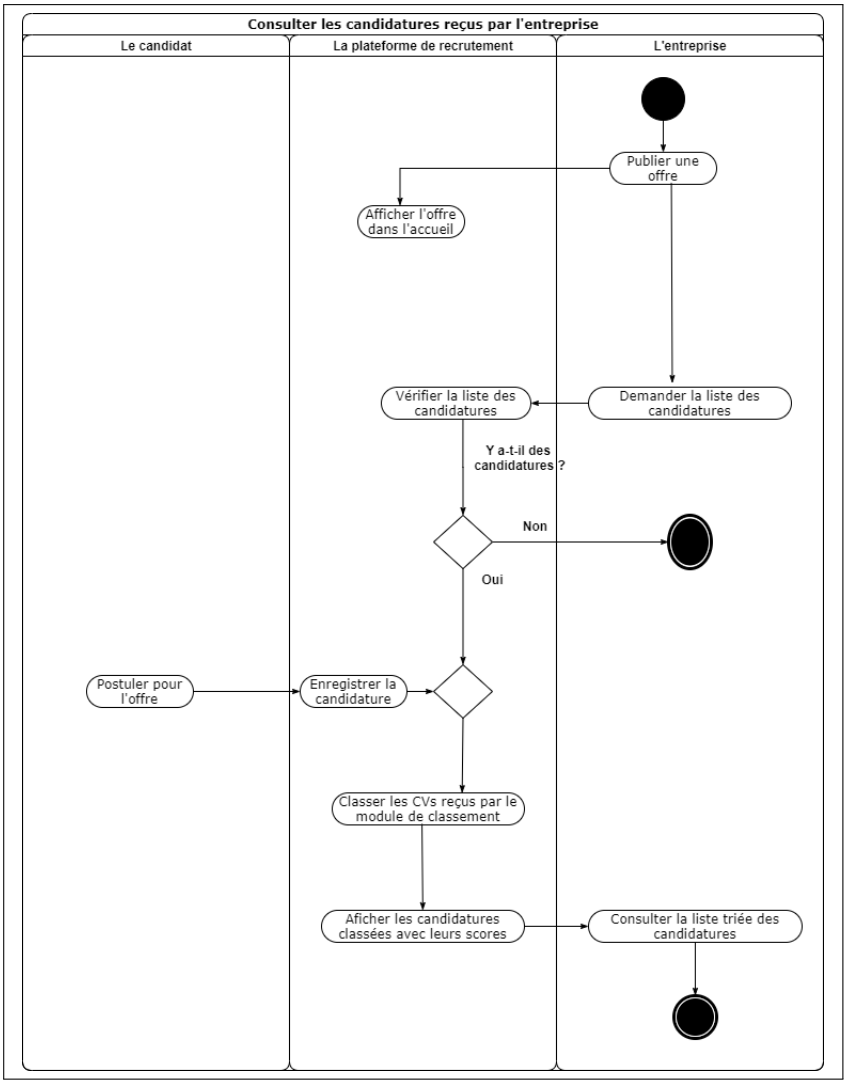


FIGURE 4.3 – Diagramme d'activité : consulter les candidatures

4.4.3.2 Diagramme de séquence : classer les candidats(CVs)

Un diagramme de séquence décrit simplement l'interaction entre les objets dans un ordre séquentiel, c'est-à-dire l'ordre dans lequel ces interactions ont lieu. Par exemple ici, l'entreprise choisit l'offre pour laquelle elle veut trouver les bons profils ,le systeme consulte la table "Candidat" pour filtrer les candidats à compter dans le classement.Le module de classement fait son calcul puis envoi la résultat dans l'interface "Ranking CV" .

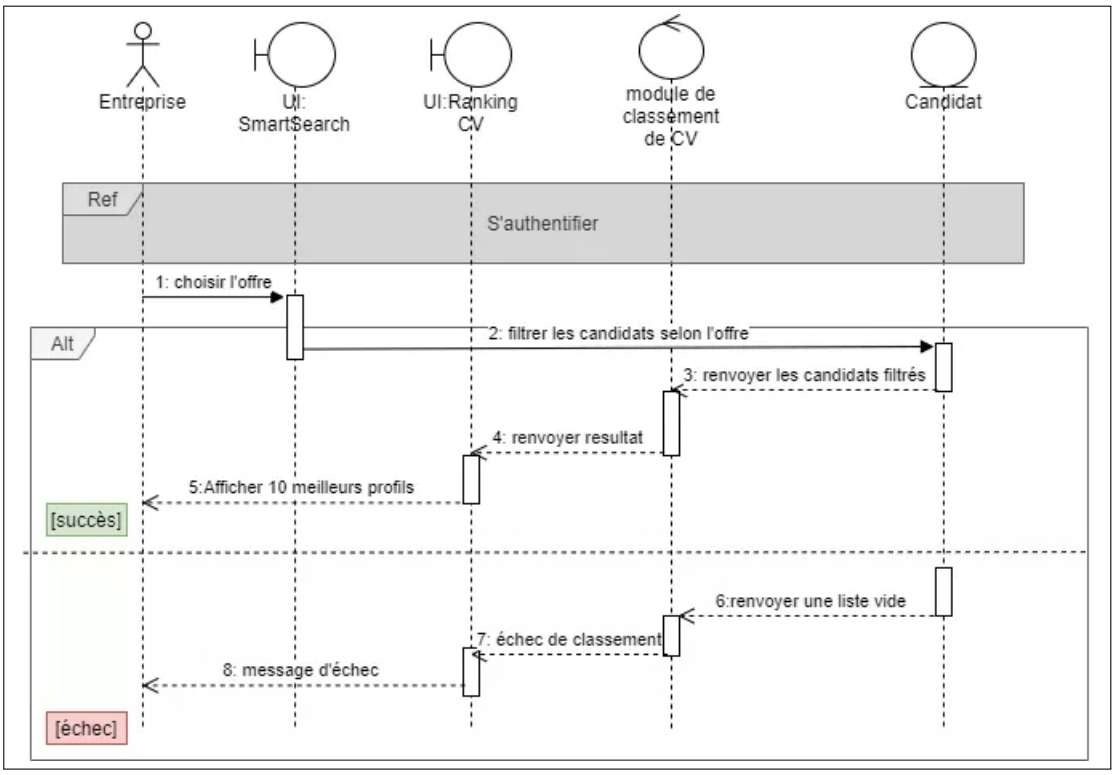


FIGURE 4.4 – Diagramme de séquence : classer les CVs

4.4.4 Diagramme de classes

Le diagramme de classes est la partie la plus importante dans la planification d'un projet car son rôle est la modélisation de la base de données et la définitions des associations qui relient toutes les classes du système. Il s'agit d'une vue statique, car nous ne tenons pas compte du facteur temporel dans le comportement du système

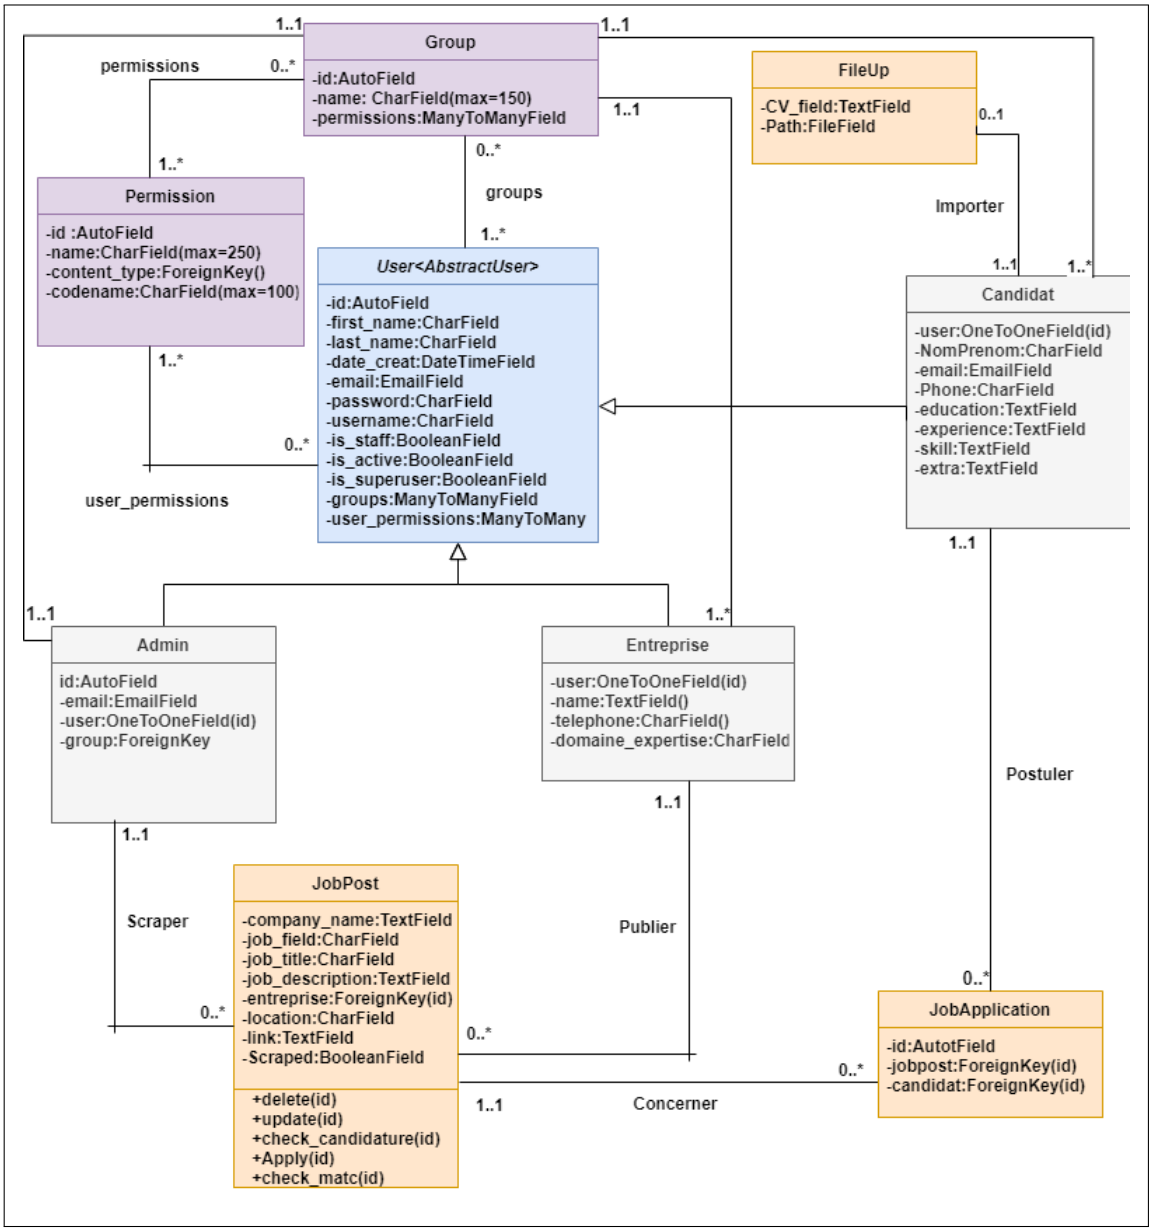


FIGURE 4.5 – Diagramme de classes

La figure 4.5 présente l'architecture conceptuelle de notre application .

- **La classe User** : c'est l'entité qui encapsule les données relatives à l'utilisateur de l'application, cet utilisateur peut être **un Candidat**, **une Entreprise** ou bien **un Administrateur**.
- **La classe Permission :** Django est livré avec un système d'autorisations intégré. Il fournit un moyen d'attribuer des autorisations à des utilisateurs et groupes d'utilisateurs spécifiques.

- **La classe Candidat :** Un Candidat peut importer au plus un CV (**FileUp**) et postuler pour plusieurs **JobPosts**.
- **La classe Entreprise :** Une Entreprise peut publier plusieurs **JobPosts**.
- **La classe JobApplication :** Une candidature est une relation qui met en contact un candidat avec une annonce d'emploi.
- **La classe JobPost :** Une offre d'emploi peut être soit publiée par une **Entreprise** soit scrapée par **l'Administrateur** à partir d'autres sites.
- **La classe Fileup** :Un CV est publié par un seul **Candidat**.

4.5 Environnement de travail

Dans cette section, nous présentons l'environnement matériel et technique relatif à la réalisation de l'application.

4.5.1 Environnement matériel

Les tableaux 4.4 et 4.5 montrent les détails des deux machines utilisées, la 2ème est utilisée pour le training et l'évaluation du modèle.

Type	Laptop Lenovo
Processeur	Intel(R) Core(TM) i5-4210U CPU @ 1.70GHz 2.40 GH
RAM	6 GB
Disque dur	1 TB SSD
Carte graphique	Nvidia GEFORCE 840
Système d'exploitation	Microsoft Windows 10 Pro

TABLE 4.4 – Caractéristiques de la machine de développement de l'application

Type	Laptop acer
Processeur	i7-7700HQ @ 2.80 GHz 2.40 GH
RAM	20 GB
Disque dur	1 TB SSD
Carte graphique	Nvidia GTX 1050
Système d'exploitation	Microsoft Windows 10 Pro

TABLE 4.5 – Caractéristiques de la machine d'implémentation du modèle.

4.5.2 Environnement logiciel

Dans cette partie, nous listons les différents logiciels que nous avons utilisés tout au long du projet.

- **Anaconda**
  Anaconda est une distribution gratuite et open source du langage de programmation Python, Elle vise à fournir des utilitaires de science des données avec plus de 100 packages Python et un propre gestionnaire de packages [9].

  La distribution comprend des packages compatibles avec tout système d'exploitation (Windows, Linux, macos).

  Elle est utilisé pour la science des données, l'apprentissage automatique, le traitement de données à grande échelle, l'analyse prédictive, etc.



Figure 4.6 : Logo d'Anaconda.

- **Spyder**
  The Scientific Python Development Environment, est un environnement scientifique puissant écrit en Python, pour Python, et conçu par et pour les scientifiques, les ingénieurs et les analystes de données. [9].

  Il offre une combinaison unique des fonctionnalités avancées d'édition, d'analyse, de débogage et de profilage d'un outil de développement complet avec l'exploration de données, l'exécution interactive, l'inspection approfondie et les superbes capacités de visualisation d'un progiciel scientifique [9].



Figure 4.7 : Logo de Spyder .

- **Jupyter Notebook**

  Jupyter Notebook est un environnement basé sur le Web qui crée des documents Jupyter Notebook dédié pour le calcul interactif .

  Il s'agit bien d'une application Web qui permet d'éditer tout ce qui en relation avec la science des données, l'apprentissage automatique, le nettoyage et la transformation des données, la visualisation des données, et bien plus encore . Nous l'avons utilisé pour faire les pré-traitements et nettoyage de nos données[9].



Figure 4.8 : Logo de Jupyter Notebook.

- **Git Bash**

  Git Bash est une application pour les environnements Microsoft Windows qui fournit une couche d'émulation pour une expérience de ligne de commande Git. Bash est un acronyme pour Bourne Again Shell. Un shell est une application de terminal utilisée pour s'interfacer avec un système d'exploitation via des commandes écrites[11].

  Bash est un shell par défaut populaire sur Linux et macOS. Git Bash est un package qui installe Bash, certains utilitaires bash courants et Git sur un système d'exploitation Windows.

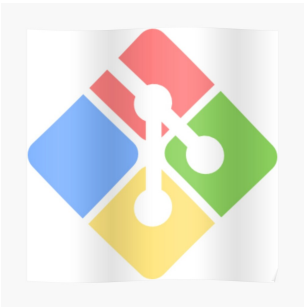


Figure 4.9 : Logo de Git Bash.

- **Jira**

  Jira Software fait partie d'une famille de produits conçus pour aider les équipes de tous types à gérer le travail.Aujourd'hui, Jira est devenu un puissant outil de gestion du travail pour tous les types de cas d'utilisation, de la gestion des exigences et des cas de test au développement logiciel agile[8].

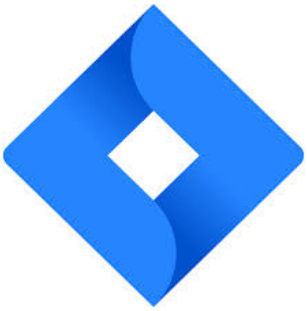


Figure 4.10 : Logo de Jira .

- **Bitbucket**

  Bitbucket est un service d'hébergement de référentiel de contrôle de version basé sur le Web appartenant à Atlassian, pour le code source et les projets de développement qui utilisent les systèmes de contrôle de révision Mercurial (du lancement jusqu'au 1er juillet 2020) ou Git (depuis octobre 2011)[8].

  Bitbucket appartient à la même famille de produits que Jira, c'est l'Atlassian .



Figure 4.11 : Logo de Bitbucket .

- **MySQL Workbench**

MySQL Workbench est un logiciel de gestion de base de données MySQL. Disponible sous Windows, Mac et Linux, il permet de gérer les tables de base de données (ajout, modification, suppression) à travers une interface graphique simple d'usage[10].



Figure 4.12 : Logo de MySQL Workbench .

4.6 Conclusion

Au cours de ce chapitre, nous avons capturé les besoins fonctionnels et non fonctionnels de notre application, tout en précisant les rôles des utilisateurs de notre projet.
Ensuite, nous avons présenté l'architecture globale de notre application ainsi que l'environnement de travail.
Ce chapitre contient également une section détaillant la conception de l'application.
Nous procédons, dans le prochain chapitre, à la présentation des travaux réalisées ainsi que le choix des technologies.

Chapitre 5

Choix des technologies et résultats

5.1 Introduction

Le présent chapitre constitue le dernier volet de notre projet dont l'objectif est d'exposer le travail réalisé. Dans un premier temps, nous présentons les différentes technologies utilisées pour réaliser ce projet. Dans un second temps, nous présentons quelques interfaces de notre plateforme .

5.2 Choix des technologies

À cause de la multitude des outils de développement web, , il s'avère être ardu de se fixer sur un qui s'adaptera à notre projet. Cette tâche réclame quelques efforts car elle déterminera la façon dont notre application sera mise en place, utilisée et maintenue.
À cet effet, il est obligatoire de clarifier nos options en se basant sur nos besoins et les particularités de notre projet tels que l'adaptation au web , la performance,l'adaptation à l'écosystème : outils et communauté.

5.2.1 Le Système de gestion de base de données :SGBD

Un système de gestion de base de données (SGBD) est un logiciel qui permet de stocker des informations dans une base de données. Un tel système permet de lire, écrire, modifier, trier, transformer voire imprimer les données contenues dans la base de données.
Pour notre projet , nous avons choisi de travailler avec **MySQL**. C'est un SGBD parmi les plus populaires au monde. Il est distribué sous une double licence, une licence publique

générale GNU et une licence propriétaire en fonction de votre utilisation. La première version de MySQL est apparue en 1995 et l'outil est régulièrement entretenu. Il s'agit d'un outil stable, fiable et puissant, doté de fonctionnalités avancées. En plus d'être gratuit, un autre aspect très attrayant de MySQL est sa nature open source [6] .. La base de données a été administrée depuis l'interface Admin fournie par Django ou à l'aide du logiciel MySQL Workbench (présenté dans le chapitre 4).



FIGURE 5.1 – Logo de MySQL

5.2.2 Langage de programmation et framework

Python est un langage open source, interprété de haut niveau et offre une excellente approche pour la programmation orientée objet. C'est l'un des meilleurs langages utilisés par les data scientistes pour divers projets/ applications de science des données. Python fournit une grande fonctionnalité pour gérer les mathématiques, les statistiques et la fonction scientifique.
C'est pour cela nous avons choisi python comme langage, surtout qu'il est le plus approprié pour le déploiement de la partie intelligente développée aussi en python en utilisant différentes bibliothèques (spacy , gensim , pandas , NumPy ,SciPy ,math...).

- **Le framework DJANGO :**
  Pour la partie développement, nous avons utilisé le fameux framework Django pour faciliter l'intégration de la partie IA dans notre site. C'est un framework Web Python de haut niveau qui encourage un développement rapide et une conception propre et pragmatique. Conçu par des développeurs expérimentés, il prend en charge une grande partie des soucis du développement Web, ce qui permet de se concentrer sur le développement de l'application. C'est gratuit, open source possède une communauté active ainsi qu'une riche documentation.[7]

Django offre également un Mapping d'objet-relationnel (ORM pour Object Relational Mapping) qui permet de manipuler les objets du modèle afin d'exploiter les quatre opérations CRUD (Create, Read, Update and Delete) sur les tables associées dans la base de données sans écrire des requêtes SQL.
Django permet de développer une application :

— Complète : Django comprend des dizaines d'extras pour gérer les tâches de développement Web courantes. Il prend en charge l'authentification des utilisateurs, l'administration du contenu, etc ...
— Sécurisée : Son système d'authentification des utilisateurs offre un moyen sécurisé de gérer les comptes d'utilisateurs et les mots de passe en évitant les erreurs classiques comme mettre des informations sur la session dans des cookies, où elles sont vulnérables (à la place les cookies contiennent seulement une clé, et les données sont stockées dans la base de données), ou directement stocker des mots de passe, au lieu du mot de passe hachés.
— Maintenable : Les principes de conception du code Django encouragent la création d'un code simple à maintenir et réutilisable. Il fait notamment appel à la philosophie DRY (Don't Repeat Yourself) afin de voir toute la duplication superflue, l'était la taille du code. Django promeut aussi le regroupement de fonctionnalités reliées entre elles en "applications" réutilisables.

Django utilise un modèle MVT (Modèle Vue Template). Ce modèle s'inspire du modèle MVC (Modèle Vue Contrôleur). Le MVC sépare le modèle (accès et mis à jour des données) de la vue (interface utilisateur) et du contrôleur (action des utilisateurs). La spécificité de Django c'est qu'il gère lui-même le contrôleur.
La figure 5.2 illustre l'architecture d'un projet dans Django et qui sera l'architecture logique de notre application Web.
Un template est un fichier HTML. Il sera récupéré par la vue et envoyé au visiteur ; cependant, avant d'être envoyé, il sera analysé et exécuté par le framework (Le contrôleur de Django). Django fournit un moteur de templates qui permet, dans le code HTML, d'afficher des variables, d'utiliser des structures conditionnelles ou encore des boucles.

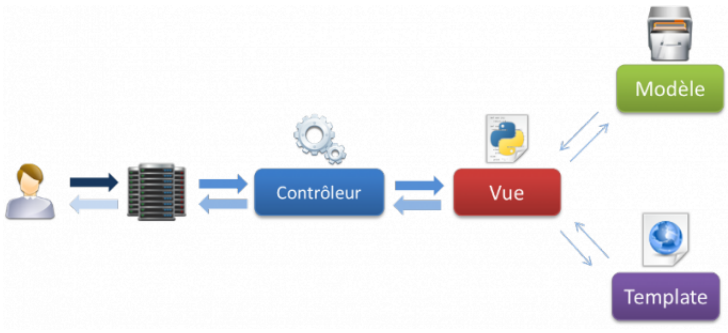


FIGURE 5.2 – Architecture MVT de Django

5.3 Résultats : Présentation des interfaces de la plateforme

Dans cette partie, nous allons présenter les interfaces de l'application, c'est un aperçu sur le travail accompli au cours de la période de développement d'une application Web qui va intégrer toutes les fonctionnalités déjà mentionnées dans la partie conception.
Avant de passer à la présentation des différentes interfaces spécifiques à chaque groupe (candidat, entreprise et administrateur), nous commençons par introduire la page d'accueil de notre plateforme "Inov-Ate", illustrée dans la figure 5.3, l'accès à cette page s'effectue sans authentification.

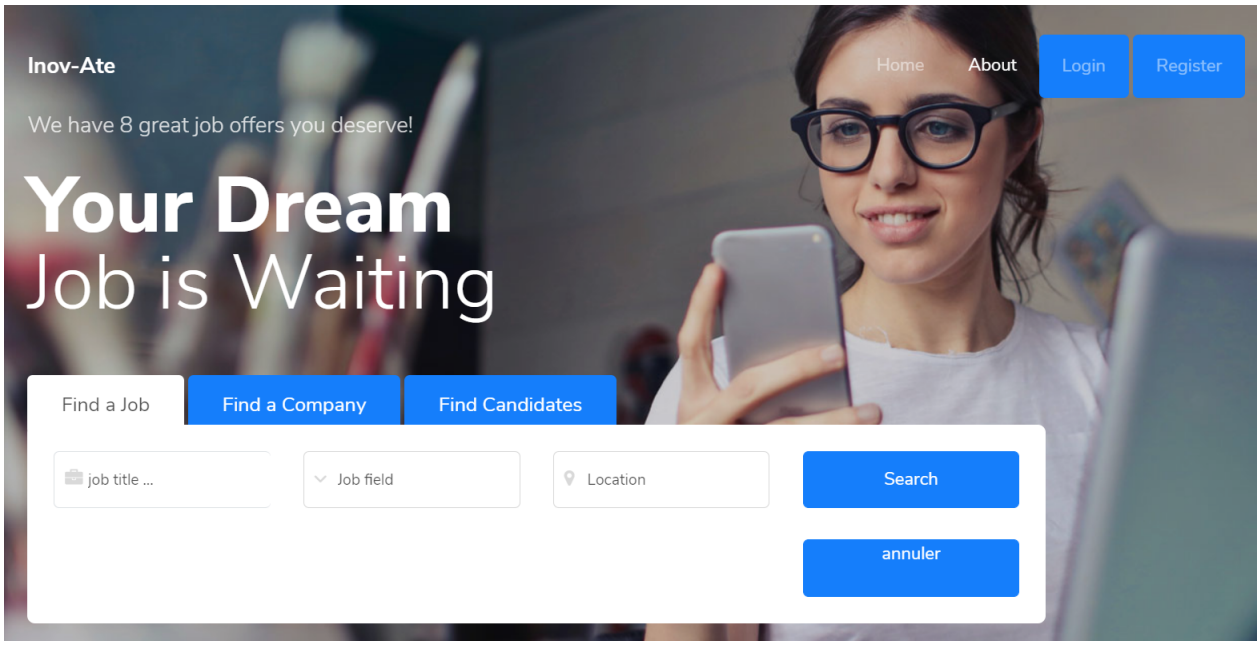


FIGURE 5.3 – Interface d'accueil

Un utilisateur, à travers cette interface, peut consulter la liste des offres d'emploi, la liste des candidats et la liste des entreprises inscrits sur la plateforme. Il peut également affiner les résultats de recherche en utilisant les filtres mis à sa disposition.

5.3.1 Espace Candidat

Le candidat peut naviguer entre six interfaces qui sont :

1. Accueil
2. About
3. Profile

4. Job Applications
5. Job recommendation
6. Settings

Un candidat doit être inscrit sur la plateforme pour accéder aux fonctionnalités avancées qu'elle offre. le candidat doit remplir un formulaire de trois champs : Email, mot de passe et confirmation de mot de passe. Dans le cas où l'utilisateur saisit un mot de passe incorrecte (pas de conformation entre le deux champs de mot de passe, mot de passe faible...) ou un nom d'utilisateur non valide, un message d'erreur s'affiche et demande de changer les informations saisies.
La sécurité de ce processus est assurée par par l'algorithme de hachage sécurisé SHA-256.)

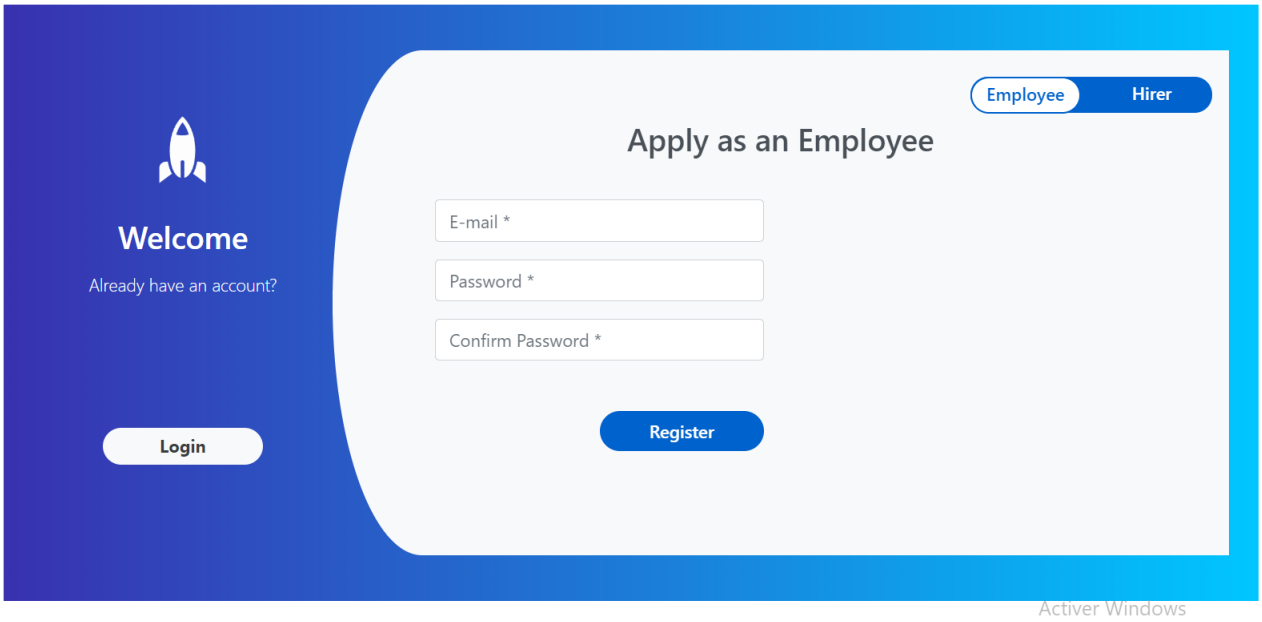


FIGURE 5.4 – Interface d'inscription pour un candidat

Après avoir rempli le formulaire de connexion (login), le candidat aura l'accès à six onglets, mais avant ça, nous lui demandons d'importer son CV (cette interface apparaît seulement lors de la 1ère connexion). Nous lui demandons de sélectionner aussi le domaine de compétences de son CV (IT, chimie, industrie, mécanique etc ...), qui va être ensuite utilisé pour filtrer et classer les CVs.

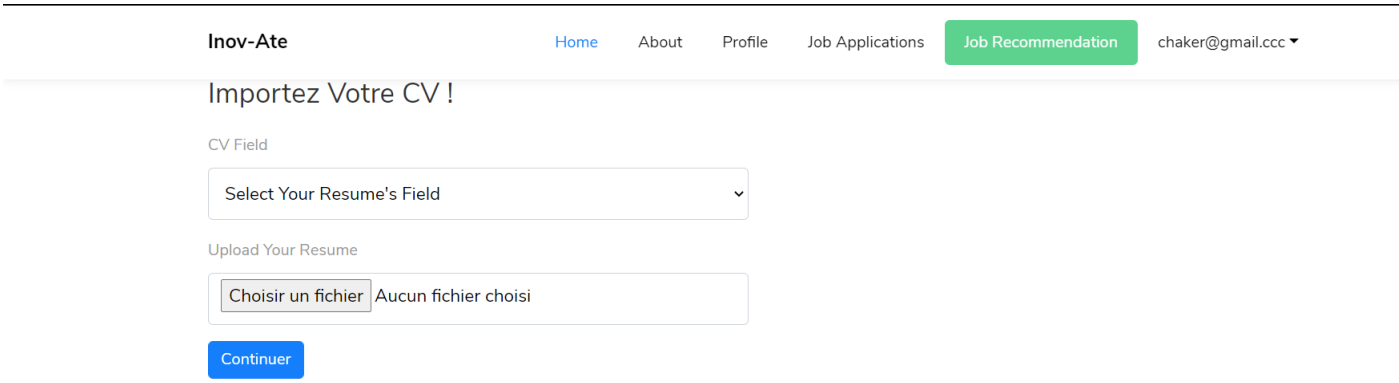


FIGURE 5.5 – Interface pour importer un CV

- **Home :** qui est le premier onglet du menu, représente la page d'accueil(cf. Figure 5.6) qui contient la liste des offres publiées. Ici, le candidat peut postuler à n'importe quelle offre qu'il juge adéquate et ce en cliquant sur le bouton "Apply". Un pop-up de validation s'affiche alors pour qu'il confirme son choix.

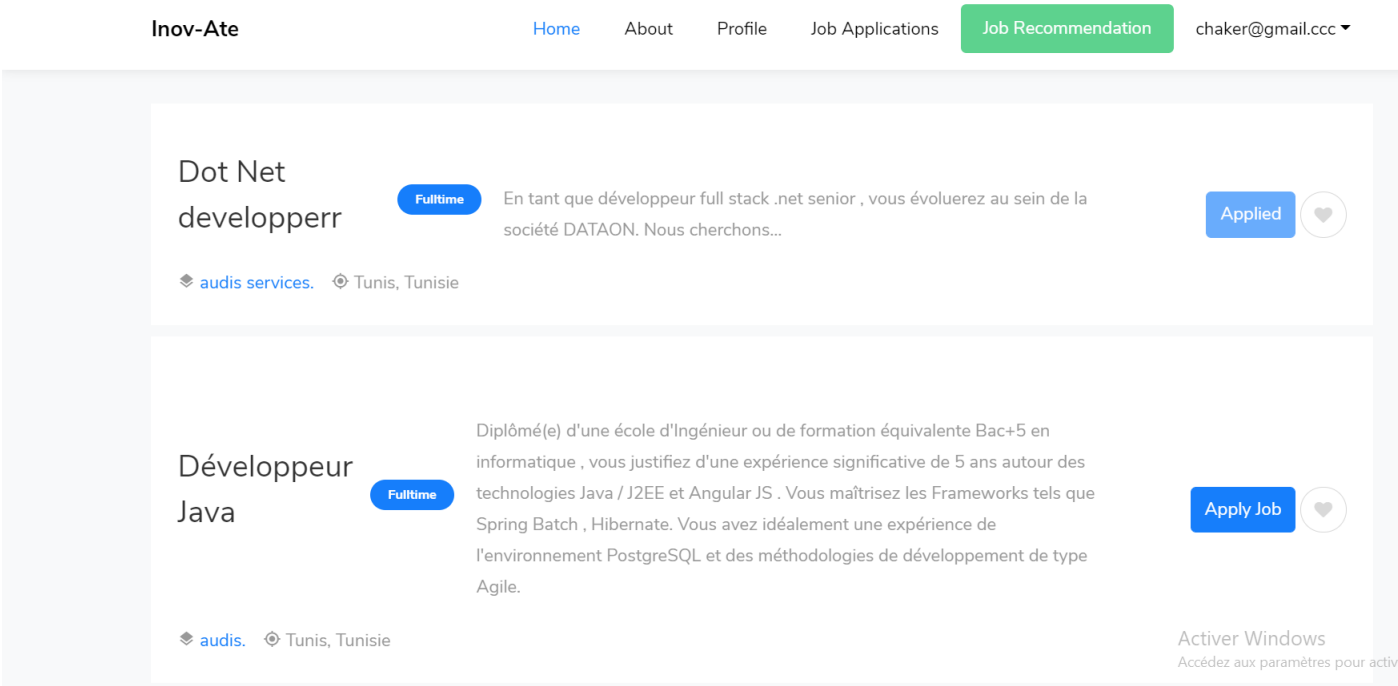


FIGURE 5.6 – Interface d'accueil de candidat

- **Profile :** Dans cette interface le candidat peut modifier l'un de champs de son vecteur-candidat, ajouter des informations, des compétences ou des projets dans

la section expérience ainsi que mettre à jour son CV en important un autre en appuyant sur la button "Update Resume".

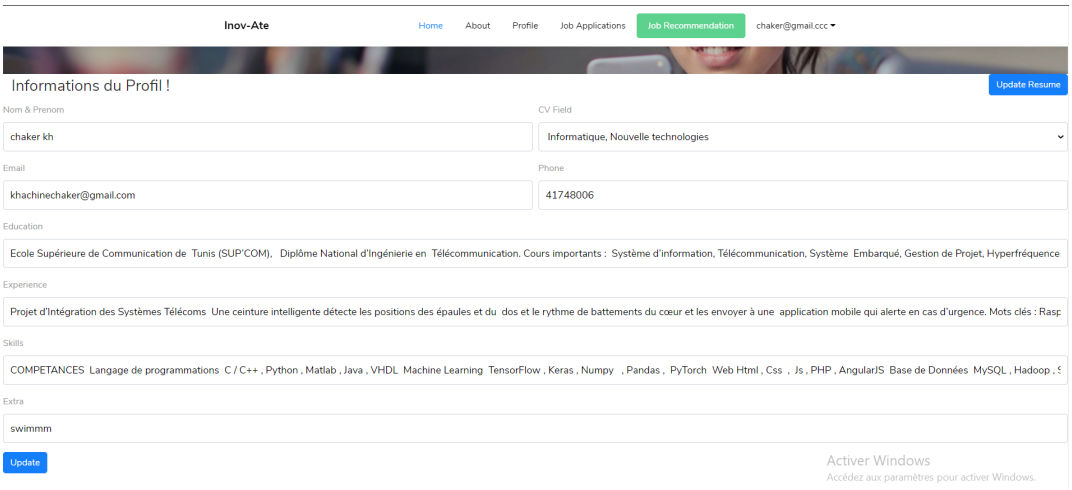


FIGURE 5.7 – Interface de profil pour un candidat

- **Job Applications :** En visitant cet onglet, ilustré dans la figure 5.8, le candidat peut trouver toutes les annonces de travail auxquelles il a postulé.

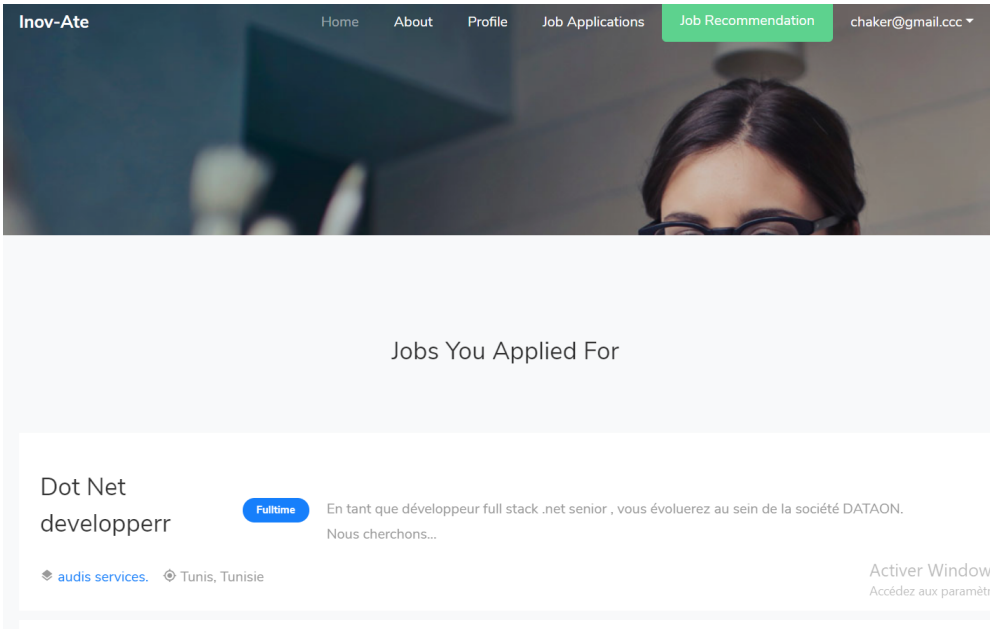


FIGURE 5.8 – Interface de suivie de l'historique des candidatures

- **Job Recommendation :** C'est dans cette interface (cf. figure 5.9) que nous proposons au candidat d'utiliser notre système de recommandation , en indiquant le lieu

et le domaine de travail, l'application va retourner au candidat les 10 offres d'emploi les plus adéquates à son profil dans le domaine sélectionné.

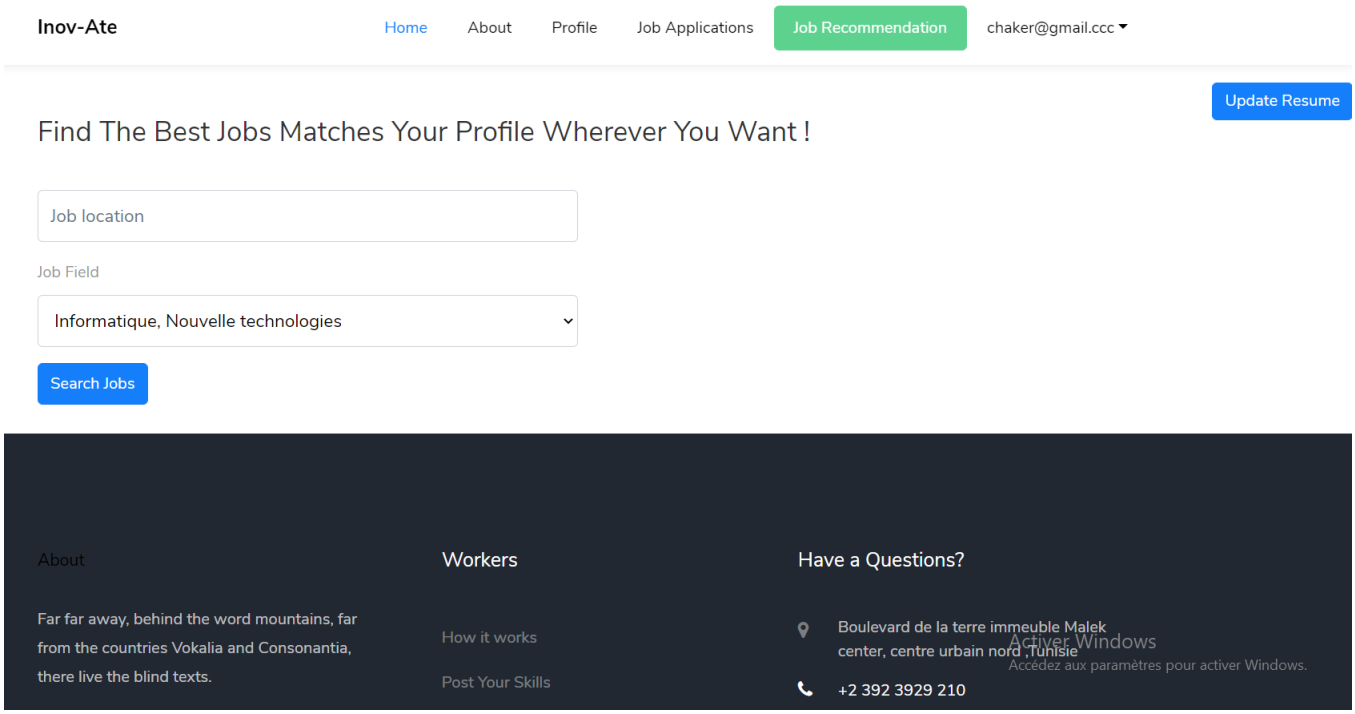


FIGURE 5.9 – Interface de recommandation des offres

- **Settings :** Parmi les fonctionnalités fournies par notre application, la possibilité de modifier à tout moment ses paramètres de connexion : nom d'utilisateur et mot de passe, comme le montre la figure 5.10. Cette fonctionnalité est valable pour tout type d'utilisateur.

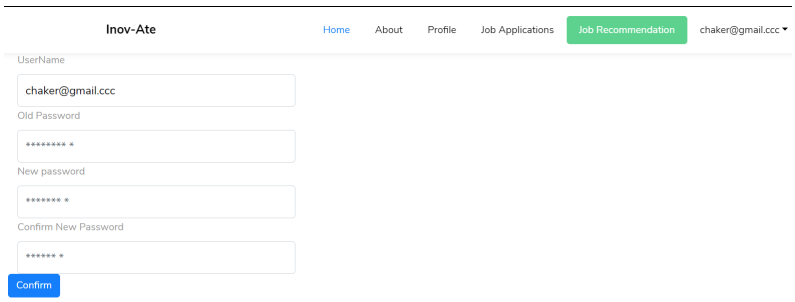


FIGURE 5.10 – Interface de modification des paramètres de connexion

5.3.2 Espace Entreprise

L'entreprise peut consulter les pages/interfaces :**"Home"**,**"About"**,**"Profile"**, **"Published Jobs"**,**"Post a Job"**,**"Smart Search"** et **"Settings"**.
Comme pour le candidat, l'entreprise doit tout d'abord avoir un compte, sur la plateforme donc elle passe le formulaire d'inscription (cf. Figure 5.11) qui contient contient les champs : Nom de l'entreprise, l'émail, le numéro de téléphone, le domaine d'expertise ainsi que le mot de passe.

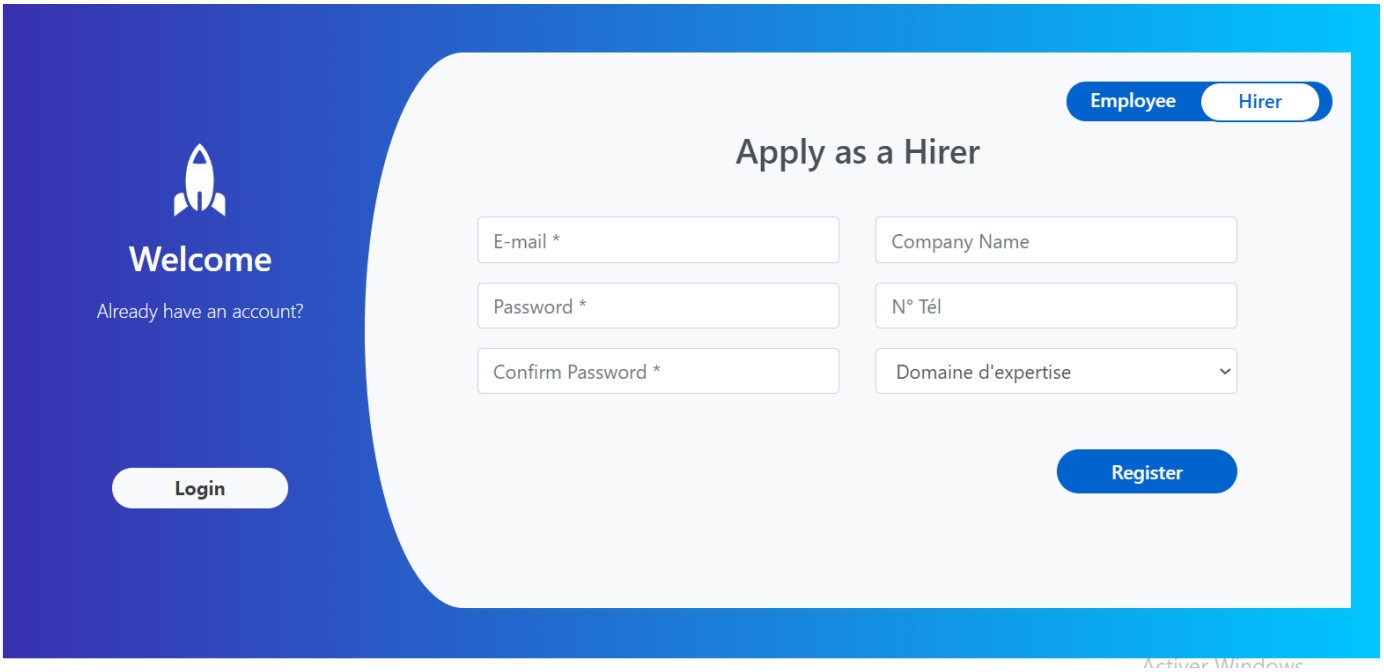


FIGURE 5.11 – Formulaire d'inscription pour l'entreprise

- **Home :** le premier onglet du menu, permet de visualiser la liste des candidats. L'utilisateur peut également affiner les résultats de recherche en utilisant les filtres mis à sa disposition : recherche par compétences, par mot clés et même par métier (cf. figure5.12).

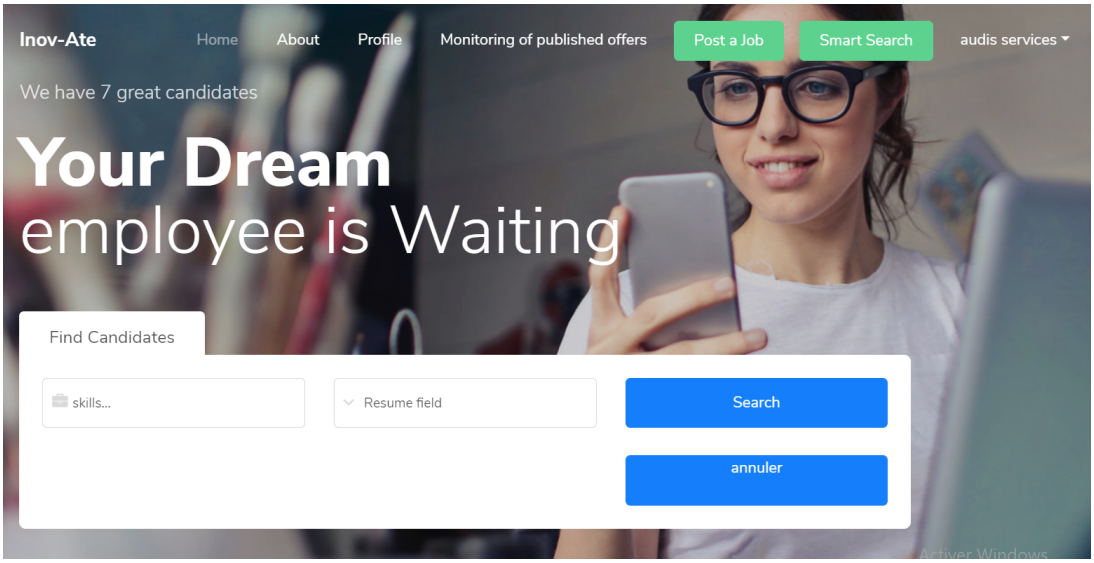


FIGURE 5.12 – Interface d'accueil de l'entreprise

- **Profile :** Cette interface, comme le montre la figure 5.13, permet à l'entreprise de modifier ses coordonnées.

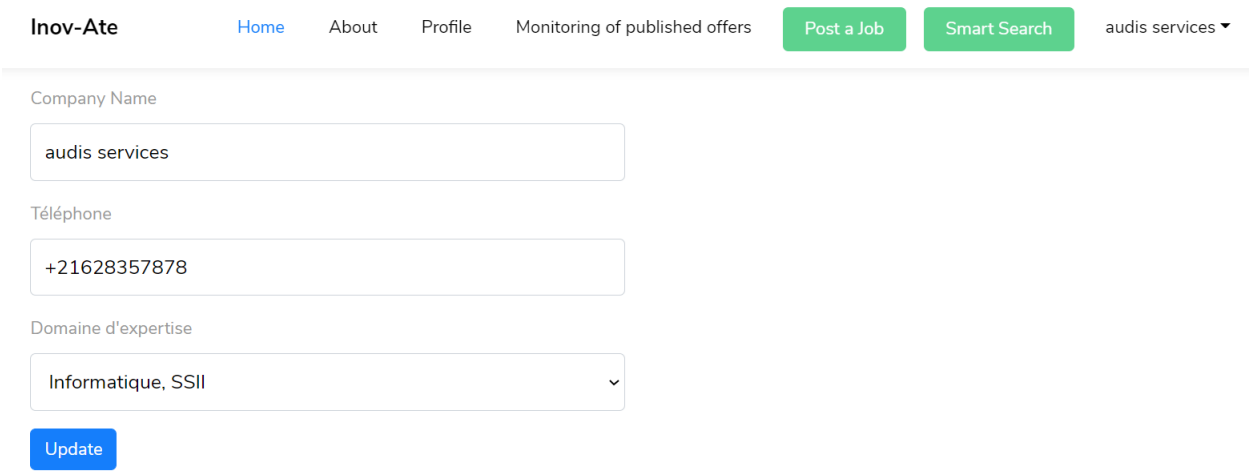


FIGURE 5.13 – Interface de profil de l'entreprise

- **Published offers :** Dans cet espace, l'entreprise peut modifier ou supprimer les offres qu'elle a publiées. Elle a aussi un accès aux listes des candidats ayant postulé aux annonces publiées.

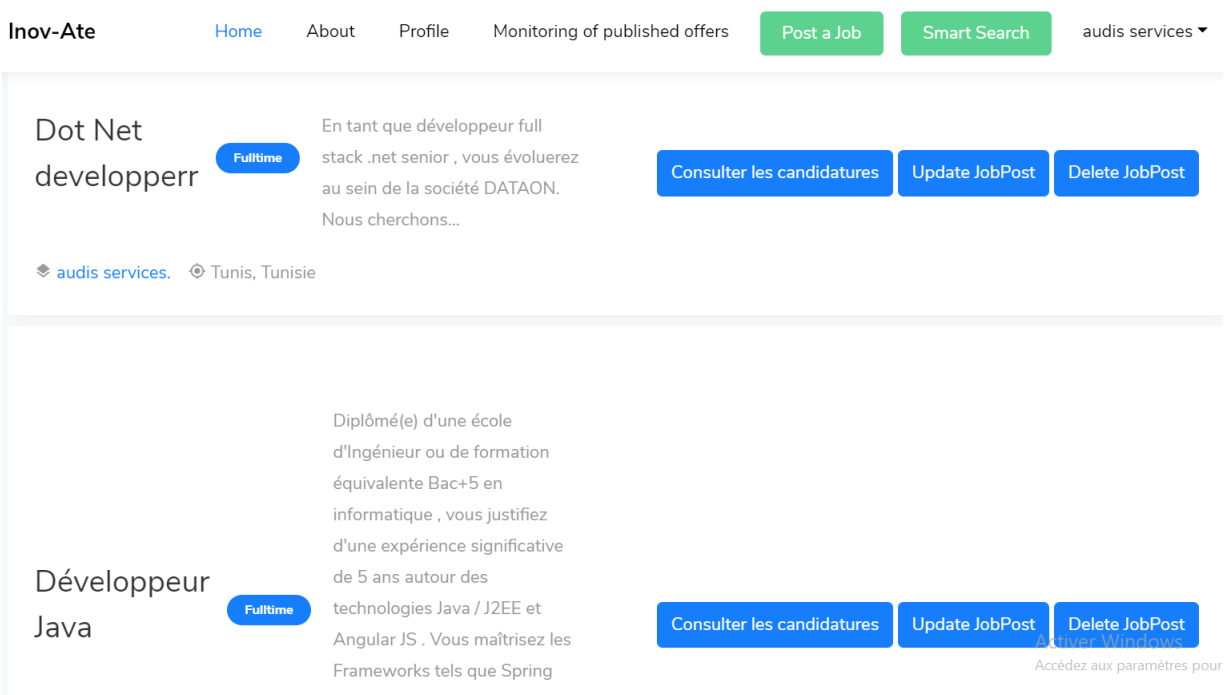


FIGURE 5.14 – Interface de suivie des offres publiées

- **Post a Job :** C'est à travers cette interface que l'entreprise publie des offres de travail. Le formulaire contient cinq champs .

  1. Le nom de l'entreprise
  2. Le domaine de l'offre (IT,Chimie ,Électrique ...)
  3. Le titre du poste
  4. La localisation de l'offre
  5. La description et détails de l'offre

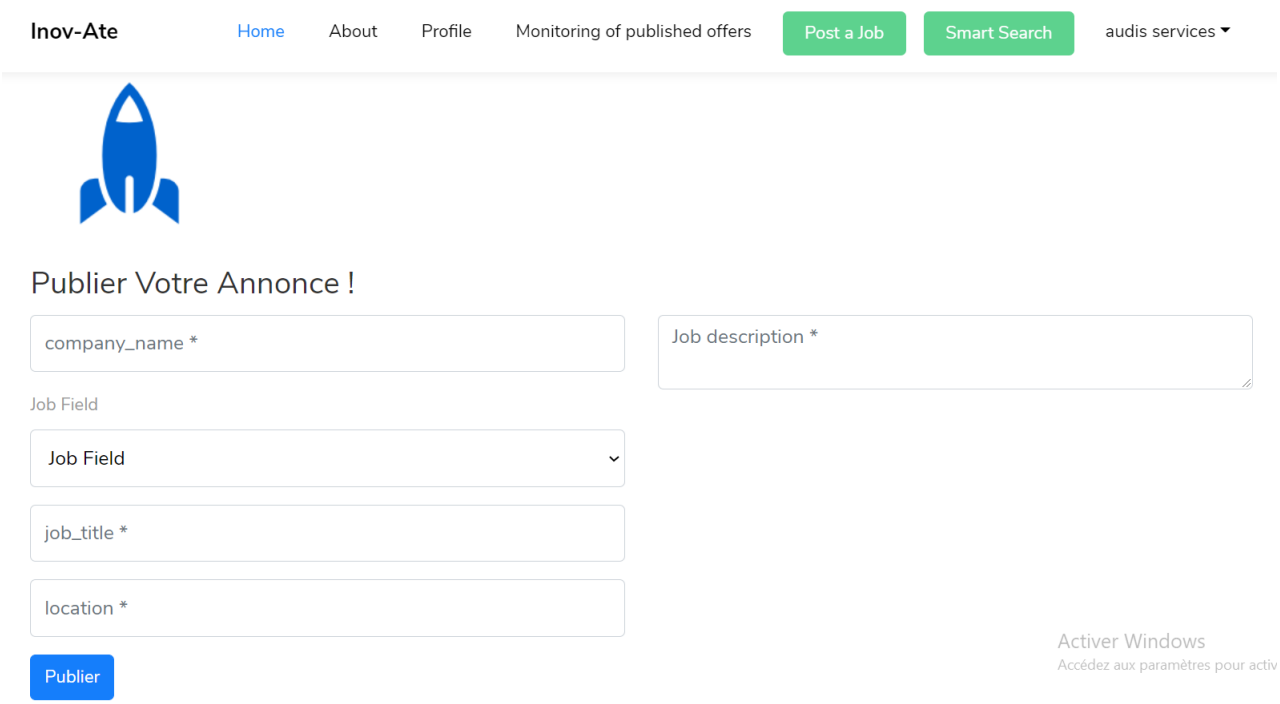


FIGURE 5.15 – Interface :publier une offre d'emploi

- **Smart search :** A travers cette interface, nous proposons à l'entreprise la liste des dix meilleurs profils adéquats aux postes publiés, classées par ordre décroissant de leur score.
  La logique de classement prend en considération le métier du CV ; nous nous intéressons qu'aux profils/ CVs appartenant au même domaine de compétences que l'offre publiée.

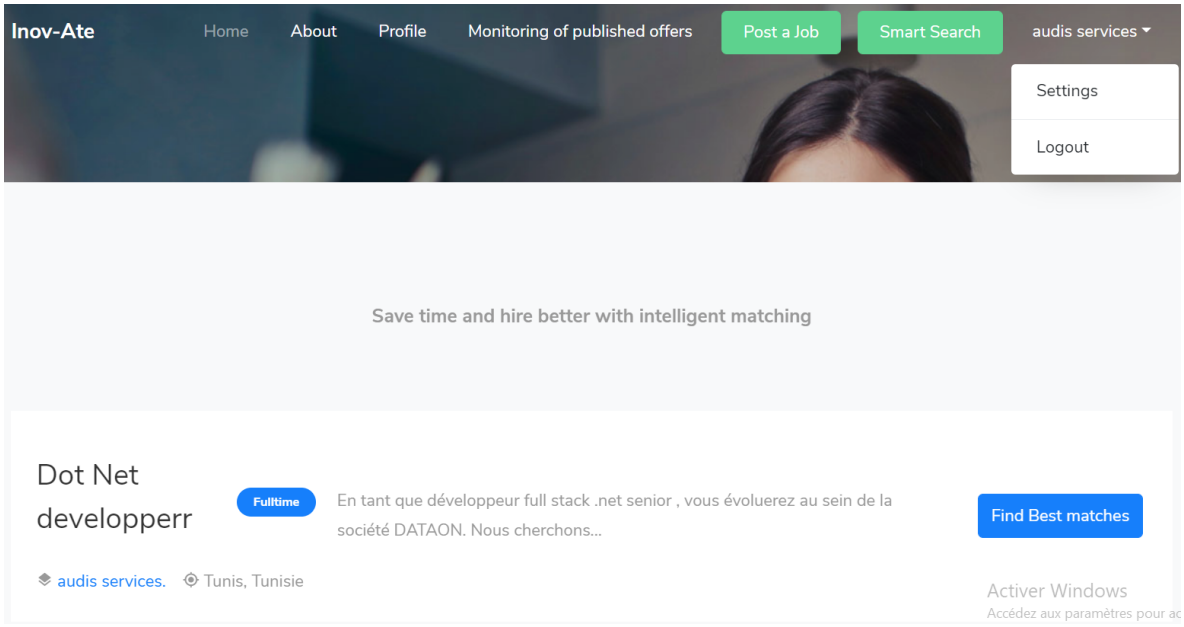


FIGURE 5.16 – Interface Smart Search

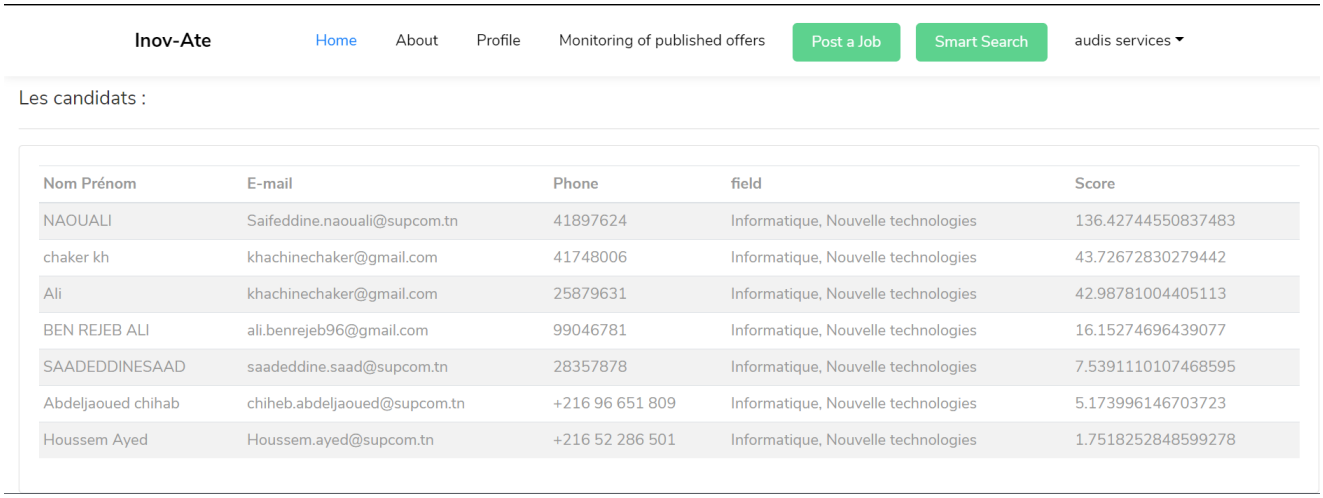


FIGURE 5.17 – Interface de classement des candidats

5.3.3 Espace Administrateur

L'une des avantages de Django, c'est qu'il fournit une interface prête à l'emploi pour les activités administratives comme la gestion des utilisateurs. Dans notre projet nous avons accordé à l'administrateur (cf. figure 5.18) le droit de gérer les utilisateurs et les groupes d'utilisateurs(Candidats et Entreprises), d'accorder les permissions des utilisateurs, de gérer les candidatures, les CVs ainsi que les offres, c'est un **superuser**.

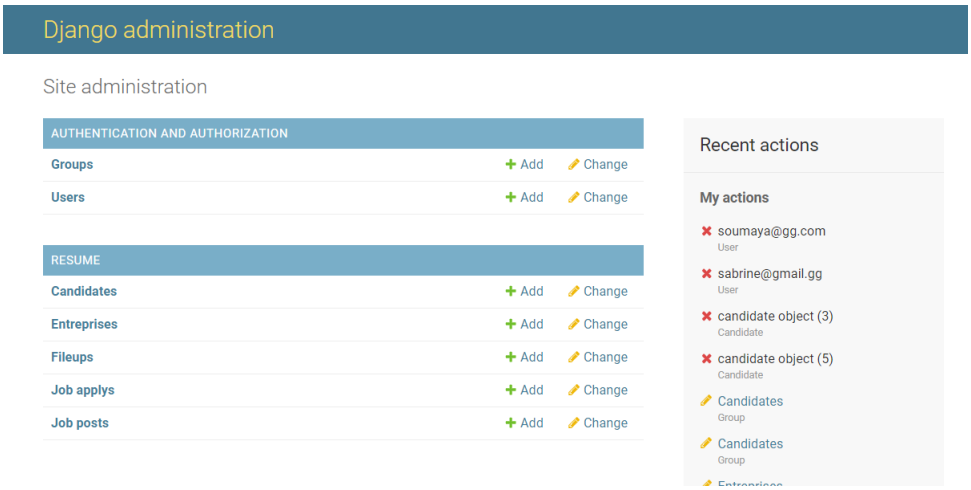


FIGURE 5.18 – Interface d'administration Django

5.3.3.1 Web scraping

Parmi les tâches que nous avons assigné à l'administrateur ,c'est de "scraper" des offres d'emploi à partir d'autres plateformes de recrutement. C'est pour ça que nous avons développé l'interface "Web Crawler", illustrée dans la figure 5.19, qui permet de réaliser cette tâche.
L'administrateur choisit dans un premier lieu le site à partir du quel il va collecter les annonces, puis dans un second lieu, il remplit le reste des champs du formulaire de scraping", à savoir le nombre des offres à scraper ,le titre de l'annonce (ingénieur java ,data scientiste ...) ainsi que l'adresse/ le pays (France , Allemagne ,Espagne...).

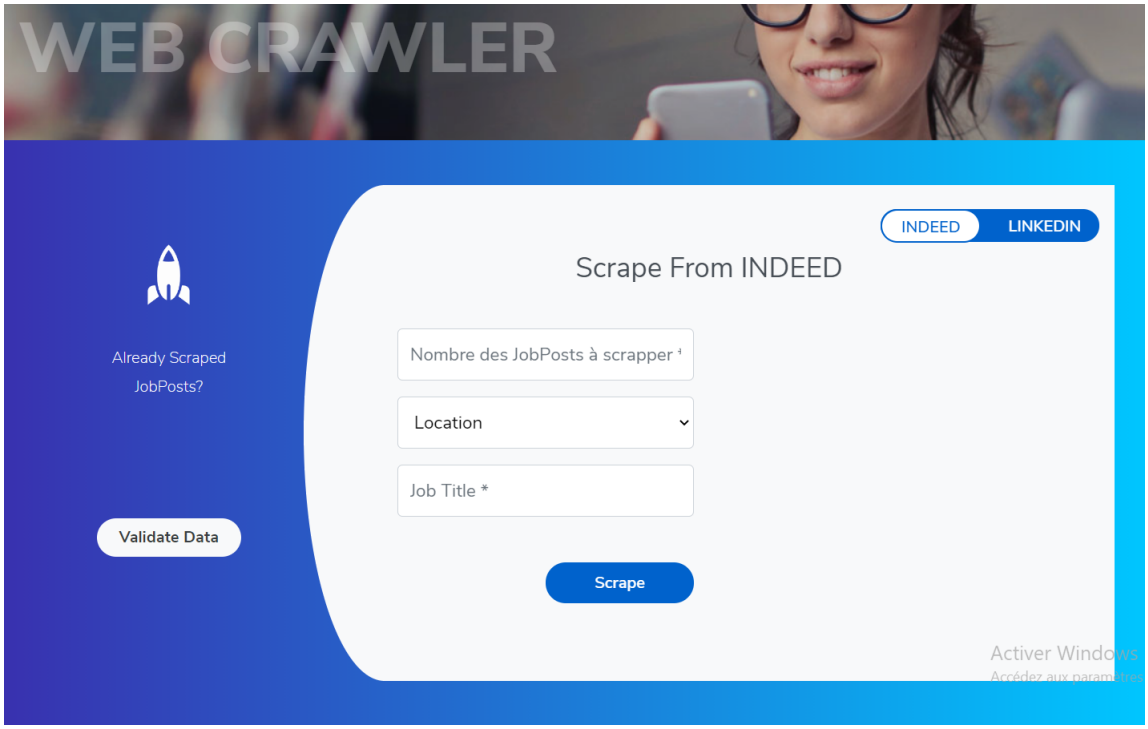


FIGURE 5.19 – Interface : Web Crawler

5.4 Conclusion

À la fin de ce chapitre, nous avons réussi à produire un livrable répondant aux besoins du client qui consiste au développement d'une plateforme de recrutement intelligente en se basant sur les algorithmes d'IA et des techniques d'extraction d'informations permettant la sélection des meilleurs candidats et offres d'emploi. Nous clôturons ce rapport par une conclusion générale.

Conclusion générale

De nos jours, la recherche d'emploi par le biais de moteurs d'appariement en ligne est très importante et bénéfique tant pour les demandeurs d'emploi que pour les employeurs. Mais les solutions des moteurs traditionnels omettant les significations sémantiques des différents CVs n'ont pas suivi le rythme des changements incroyables des techniques de ML et des capacités de calcul. Ces solutions sont généralement régies par des règles manuelles et des pondérations prédéfinies de mots-clés qui conduisent à une expérience de recherche inefficace et frustrante.

La gestion des compétences a récemment été reconnue comme l'un des facteurs clés pour faire face à la compétitivité croissante des différentes entreprises. Donc, l'adoption d'une approche efficace d'appariement serait d'une grande ampleur sur le marché du travail. En fait, une représentation appropriée des connaissances et un 'matching' des aptitudes et d'autres compétences dans le poste et des profils individuels - s'ils sont correctement choisis - pourraient soutenir l'automatisation de la gestion des ressources humaines grâce à des services de filtrage et de classement adéquats.

C'est ainsi,et dans le cadre de ce projet de fin d'études, que nous avons développé une plateforme de recrutement intelligente basée sur l'appariement entre candidats et offres d'emploi développée afin de rendre le processus de recrutement simple, efficace et automatisé. Pour atteindre cet objectif, nous avons commencé par une étude bibliographique sur les modèles et les technologies existantes qui vont assurer la faisabilité de notre projet. Ensuite, nous avons implémenté un modèle Word2Vec capable d'extraire les relations sémantiques et syntaxiques entre les compétences et les mots clés après être arrivé à extraire le vecteur candidat à partir d'un CV en utilisant les techniques du NLP.
A fin de mettre notre modèle en usage par les recruteurs ainsi que les chercheurs d'emploi, nous avons fait la conception détaillée d'une application web pour bien définir les spécifications et les besoins et partant de ces spécifications, nous avons réussi à implémenter une plateforme appelé Inov-Ate qui mettra en contact les employeurs avec les candidats.

Néanmoins, nous tenons à souligner quelques limites dans notre solution ; entre autres l'extraction des sections du CV parfaitement ainsi que l'extraction des informations plus détaillées telles que le nombre d'années d'expérience pour expérience dans le CV, le calibre des sociétés dans lequel le candidat a fait une expérience, etc .

Grâce au caractère évolutif et à la modularité de notre application Inov-Ate, elle pourra être améliorée en ajoutant quelques fonctionnalités comme :

- Les employés peuvent donner des avis sur l'entreprise qu'ils travaillent dans.
- Ajout d'un ChatBot qui discute avec les candidats.
- Essayer une autre technique sauf TF-IDF pour le système de recommandation.
- Implémenter un web-crawler pour scraper aussi des profils Linkedin et des CVs.

Le travail dans le cadre de ce PFE, était d'une importance considérable dans la mesure où il nous a servi comme portail vers le monde professionnel et la vie d'entreprise. De point de vue technique, il nous a permis de mettre en œuvre les acquis théoriques que nous avons appris tout au long de notre cursus universitaire et de les enrichir et approfondir des connaissances dans le domaine de gestion de ressources humaines. Outre, ce projet était aussi enrichissant quant aux bonnes pratiques de la gestion de projet vu que nous avons eu l'opportunité d'organiser son déroulement dès le début.

Bibliographie

[1] Aaron, Smith. *Searching for Work in the Digital Era*, Pew Research Center 2015.

[2] Smyth, B., Bradley, K. & Rafter, R., 2002. Personalization Techniques for Online Recruitment Services. Communications of the ACM, 45(5), pp.39-40.

[3] Plagianakos, V.P., Tasoulis, D.K. & Vrahatis,M.N.,2005.Computational intelligence techniques for acute leukemia gene expression data classification. In Neural Networks, 2005. IJCNN '05. Proceedings. 2005 IEEE International Joint Conference on. Montreal, Que., 2005.

Webographie

[1] Site web de Audis Services, https://www.inov-tech.fr/ [Accès le 6-Août-2020]

[2] Evolution de recrutement, https://www.enaco.fr/evolution-techniques-de-recrutement/ [Accès le 15-Juin-2020]

[3] Word Embedding, https://www.analyticsvidhya.com/blog/2017/06/word-embeddings-count-word2veec/ [Accès le 15-Juin-2020]

[4] , https://www.thehrbooth.co.uk/blog/hr-software/the-benefits-and-drawbacks-of-using-applicant-tracking-systems-for-recruitment/ [Accès le 15-Juin-2020]

[5] Methodologie CRISP, https://smartvision-me.com/the-crisp-dm-data-mining-methodology/ [Accès le 15-Juin-2020]

[6] , http://www.databasequest.com/index.php/product-service/mysql-dbquest [Accès le 15-Juin-2020]

[7] Django documentation, https://docs.djangoproject.com/en/3.1/https ://docs.djangoproject.com/e [Accès le 15-Juin-2020]

[8] Bitbucket, https://bitbucket.org/product [Accès le 15-Juin-2020]

[9] Anaconda, https://www.anaconda.com/ [Accès le 15-Juin-2020]

[10] MySQL Workbench, https://sql.sh/logiciel/mysql-workbench [Accès le 15-Juin-2020]

[11] Git, https://www.atlassian.com/git/tutorials/git-bash [Accès le 15-Juin-2020]

Annexe A

Liste des labels

TYPE	LA DESCRIPTION
PERSON	Les gens, y compris fictifs.
NORP	Nationalités ou groupes religieux ou politiques.
FAC	Bâtiments, aéroports, autoroutes, ponts, etc.
ORG	Entreprises, agences, institutions, etc.
GPE	Pays, villes, états.
LOC	Sites non-GPE, chaînes de montagnes, plans d'eau.
PRODUCT	Objets, véhicules, aliments, etc. (pas de services.)
EVENT	Nommés ouragans, batailles, guerres, événements sportifs, etc.
WORK_OF_ART	Titres de livres, chansons, etc.
LAW	Documents nommés transformés en lois.
LANGUAGE	Toute langue nommée.
DATE	Dates ou périodes absolues ou relatives.
TIME	Temps inférieur à un jour.
PERCENT	Pourcentage, y compris «%».
MONEY	Valeurs monétaires, y compris l'unité.
QUANTITY	Mesures, en poids ou en distance.
ORDINAL	«Premier», «deuxième», etc.
CARDINAL	Chiffres qui ne relèvent pas d'un autre type.

FIGURE A.1 – Liste des labels